

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Florian Martin

licencié.e ès lettres

diplômé.e de master

**Pour une nouvelle approche des
données patrimoniales dans un
système de gestion des collections**

**Skinsoft - *Natural Language Processing* et
indexation semi-automatisée pour des
archives cinématographiques**

Sous la direction de **Ségolène Albouy**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : NLP ; *Computer Vision* ; Gestion des collections, Intelligence Artificielle ; *UX-Design* ; Système de gestion des collections.

Informations bibliographiques : Florian Martin, *Pour une nouvelle approche de la gestion des collections et données patrimoniales : mobilisations d'outils IA dans un système de gestion de collections. Skinsoft - Projet IA pour des archives cinématographiques*, mémoire de master « Technologies numériques appliquées à l'histoire », dir. [Ségolène Albouy], École nationale des chartes, 2026.

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie exhaustive

- « (PDF) Descriptive Standards and Collection Management Software for Documentary Heritage Management : Attitudes and Experiences of Information Professionals », *ResearchGate* (, 15 juill. 2026), DOI : 10.1108/GKMC-08-2020-0129.
- « (PDF) Digital for Heritage and Museums : Design-Driven Changes and Challenges », dans *ResearchGate*, DOI : 10.21606/iasdr.2023.397.
- (PDF) *Perceived Usefulness, Perceived Ease of Use, and User Acceptance of Information Technology*, URL : https://www.researchgate.net/publication/200085965_Perceived_Usefulness_Perceived_Ease_of_Use_and_User_Acceptance_of_Information_Technology (visité le 25/05/2026).
- 37 / 2021 - *Les collections patrimoniales ont-elles un avenir ?*, Culture & Musées, 19 déc. 2019, URL : <https://journals.openedition.org/culturemusees/3434> (visité le 07/07/2026).
- ADAMOPOULOU (Eleni) et MOUSSIADES (Lefteris), « Chatbots : History, Technology, and Applications », *Machine Learning with Applications*, 2 (15 déc. 2020), p. 100006, DOI : 10.1016/j.mlwa.2020.100006.
- AI & ChatGPT Statistics for 2026 (Usage & Adoption Data)*, Instant Press, URL : <https://www.instantpress.co/ai-statistics> (visité le 25/08/2026).
- AI4HUMAN, *NLI / Natural Language Inferencing*, Medium, 21 avr. 2024, URL : <https://medium.com/@aiforhuman/nli-natural-language-inferencing-8f231f23800e> (visité le 22/05/2026).
- AMERSHI (Saleema), INKPEN (Kori), TEEVAN (Jaime), KIKIN-GIL (Ruth), HORVITZ (Eric), WELD (Dan), VORVOREANU (Mihaela), FOURNEY (Adam), NUSHI (Besmira), COLLISSON (Penny), *et al.*, *Guidelines for Human-AI Interaction*, 2019, p. 13, DOI : 10.1145/3290605.3300233.
- AN (Siyu), LU (Junru), DONG (Junnan), WANG (Qiufeng), LI (Yinghui), FEI (Weizhi), YU (Zichao), YUAN (Zheng), LIU (Biao), WANG (Haopeng), *et al.*, *Toward Native Multimodal Modeling : A Roadmap*, 25 mai 2026, DOI : 10.48550/arXiv.2605.25343, arXiv : 2605.25343 [cs.CV].

- Archipanon pour le Ciné-Journal suisse*, URL : <https://www.bar.admin.ch/fr/archipanon-pour-le-cine-journal-suisse> (visité le 10/08/2026).
- Archives & Museum Informatics : Publishing : Archives : Functional Requirements for Collections Management Systems : Table of Contents*, URL : https://www.archimuse.com/publishing/bearman_col_mgmt_sys.html (visité le 18/07/2026).
- ARCHIVES DE FRANCE (Direction des), *Note d'information DITN/RES/2007/008*, Notes d'informations DITN/RES/2007/008, Paris, Ministère de la Culture et de la Communication — Direction des Archives de France (DITN), 2007, URL : https://francearchives.gouv.fr/file/0f68a1bf4a28b3d3788377df873c992542ee5545/Note_DITN_RES_2007_008.pdf.
- ARCHIVIA, *l'IA au service de la culture*, BFM, 9 janv. 2025, URL : https://www.bfmtv.com/paris/paris-pratique/archivia-l-ia-au-service-de-la-culture_AB-202501090768.html (visité le 11/05/2026).
- AWAD (George), BUTT (Asad A), FISCUS (Jonathan), LEE (Yooyoung), GODARD (Eliot), DIDUCH (Lukas), LIU (Jeffrey), GRAHAM (Yvette), QUENOT (Georges) et QUENOT (Georges), « An Overview on the Evaluated Video Retrieval Tasks at TRECVID 2022 » ().
- « TRECVID 2024 - Evaluating Video Search, Captioning, and Activity Recognition » ().
- « TRECVID 2019 : An Evaluation Campaign to Benchmark Video Activity Detection, Video Captioning and Matching, and Video Search & Retrieval », dans *TREC Video Retrieval Evaluation : TRECVID*, Gaithersburg, United States, 2019, URL : <https://hal.science/hal-03100554> (visité le 07/05/2026).
- Axle AI - AI Powered MAM*, URL : <https://www.axle.ai/> (visité le 13/05/2026).
- BADDA (Atmane), « Technology Acceptance Model (TAM) : Literature Review », *International Journal of Accounting, Finance, Auditing, Management and Economics*, 6–11 (oct. 2025), p. 459-492, DOI : 10.5281/zenodo.17450768.
- BASTIEN (Christian) et SCAPIN (Dominique), « Ergonomic Criteria for the Evaluation of Human-Computer Interfaces » ().
- BELCIC (Ivan), *Qu'est-ce que la génération augmentée par récupération (RAG) ?* / IBM, 3 oct. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/retrieval-augmented-generation> (visité le 23/08/2026).
- BÉQUET (Gaëlle) et CÉDELLE (Laure), « Numérisation et Patrimoine Documentaire », *Politique de Conservation*, n°4 (2000), p. 67-72.
- BERGEOT (Patrick) et ESTAVOYER (Morgane), *Le jumeau numérique dans le patrimoine : fantasme ou réalité ?*, Livre Blanc, Paris, Centre des monuments Nationaux, 2025, 193p.

- URL : https://www.monuments-nationaux.fr/content/download/9908945/file/Livre%20blanc%203D_web_compressed.pdf.
- BOSCO (Allesandra), BULEGATO (Fiorella) et CALOGERO (Lucilla), « Data-Driven Design for the Design Heritage », dans Budapest, 2024, p. 765-783, DOI : 10.63442/JEJH1802.
- BOULLIER (Dominique) et LOHARD (Audrey), *Opinion mining et Sentiment analysis : Méthodes et outils*, Marseille, 2012 (Sciences Po médialab), URL : <https://books.openedition.org/oep/198> (visité le 23/08/2026).
- BOWES (Stuart), « From Digital Transition to Low-Impact Museums : A Strategic Planning Framework for Sustainable Museum Transformation », *Heritage*, 9 (), p. 205-231.
- BREDIN (Hervé), « Pyannote.Audio 2.1 Speaker Diarization Pipeline : Principle, Benchmark, and Recipe », dans 2023, p. 1983, DOI : 10.21437/Interspeech.2023-105.
- BRISSAUD (Olivia), « L'élaboration du principe d'inaliénabilité pour les collections muséales et les biens du domaine public mobilier sous la Révolution française », *Livraisons de l'histoire de l'architecture*-26 (2013/déc./10), p. 141-156, DOI : 10.4000/1ha.343.
- BSIR (Besma), HAMED (Kaouthar), LAIBIDI (Oumaima) et WAHADA (Abir BEN), « Artificial intelligence for the enhancement of television archives Case study : The heritage of Tunisian television », *Journal of Information Sciences*, 24-1 (11 juill. 2025), p. 1-20, DOI : 10.34874/IMIST.PRSM/jis-v24i1.54261.
- CAZZARO (Mirco) et SILVELLO (Gianmaria), « Querying LLMs as If They Were Digital Libraries » ().
- Charte Sur La Conservation Du Patrimoine Numérique - UNESCO Digital Library*, URL : https://unesdoc.unesco.org/ark:/48223/pf0000179529_fre (visité le 09/07/2026).
- CHU (Yunfei), XU (Jin), ZHOU (Xiaohuan), YANG (Qian), ZHANG (Shiliang), YAN (Zhijie), ZHOU (Chang) et ZHOU (Jingren), *Qwen-Audio : Advancing Universal Audio Understanding via Unified Large-Scale Audio-Language Models*, 21 déc. 2023, DOI : 10.48550/arXiv.2311.07919, arXiv : 2311.07919 [eess.AS].
- Collections Management as Critical Museum Practice*, 2024, DOI : 10.14324/111.9781800087040.
- Comment intégrer des bases de données à des outils de traitement du langage naturel ?*, URL : <https://fr.linkedin.com/advice/0/how-can-you-integrate-databases-natural-language-hwjef?lang=fr> (visité le 22/05/2026).
- Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL / Blog Google Cloud*, Blog Google Cloud, URL : <https://cloud.google.com/blog/fr/products/bases-de-donnees/comment-obtenir-du-code-sql-de-qualite-avec-lia-decryptage-des-techniques-de-text-to-sql> (visité le 06/05/2026).

- COMPUTER VISION / NLP, URL : https://www.academia.edu/145648073/COMPUTER_VISION_NLP?sm=b&rhid=39780437368 (visit  le 05/05/2026).
- Concevoir et G rer Une Collection Audiovisuelle / Images En Biblioth ques, URL : <https://imagesenbibliotheques.fr/formations/stages-sur-mesure/concevoir-et-gerer-une-collection-audiovisuelle> (visit  le 09/03/2026).
- Dominique Coq ( d.), *Apprendre   g rer des collections patrimoniales en biblioth que*, Villeurbanne, 2012, DOI : 10.4000/books.pressesenssib.643.
- C T -LAPOINTE (Simon), « Les documents audiovisuels num riques d'archives », *Documentation et biblioth ques*, 65-3 (2019), p. 39-57, DOI : 10.7202/1064748ar.
- CST, *L'intelligence artificielle dans l'exploitation et la distribution cin matographique :  tat des lieux, usages, outils et perspectives*, CST, 19 sept. 2025, URL : <https://cst.fr/cinema-exploitation-ia/> (visit  le 26/02/2026).
- CULTURE (Minist re de la), *Guide de Gestion Des Documents Patrimoniaux*, Paris, Minist re de la Culture, 2021, URL : <https://www.culture.gouv.fr/content/download/272461/3169783?version=13>.
- DE JANTI (Villeneuve), « Mus ologie et Informatique : L' uvre d'art   l' poque de Sa Reproduction Num rique », dans 2018.
- DENO L (Charlotte), « L'apport de L opold Delisle   la catalographie : de l' laboration des Instructions pour la r daction d'un catalogue de manuscrits (1884)   l'interop rabilit  des m tadonn es num riques », *Bulletin du bibliophile-2* (2019), p. 342-353, DOI : 10.3917/bubib.370.0140.
- « Development of NASA-TLX (Task Load Index) : Results of Empirical and Theoretical Research », dans *Advances in Psychology*, 1988, t. 52, p. 139-183, DOI : 10.1016/S0166-4115(08)62386-9.
- DEVLIN (Jacob), CHANG (Ming-Wei), LEE (Kenton) et TOUTANOVA (Kristina), *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, 24 mai 2019, DOI : 10.48550/arXiv.1810.04805, arXiv : 1810.04805 [cs].
- EDMONDSON (Ray), « PHILOSOPHY AND PRINCIPLES » ().
- EPPLER (Martin) et MENGIS (Jeanne), « The Concept of Information Overload : A Review of Literature from Organization Science, Accounting, Marketing, MIS, and Related Disciplines », *The Information Society*, 20 (1 r nov. 2004), p. 325-344, DOI : 10.1080/01972240490507974.
- Europeana Enriches Its Data with the AAT, Europeana PRO, URL : <https://pro.europeana.eu/page/europeana-aat> (visit  le 15/05/2026).

- EYZAGUIRE (Cristobal), WU (Jiajun) et NIEBLES (Juan Carlos), *Linear Scaling Video VLMs for Long Video Understanding*, 29 mai 2026, DOI : 10.48550/arXiv.2605.31598, arXiv : 2605.31598 [cs.CV].
- FAIRBAIRN (Natasha), PIMPINELLI (Maria Assunta), ROSS (Thelma) et THILL (Viviane), « Le Manuel de catalogage des images animées de la FIAF » ().
- FARZINDAR (Atefeh) et ROCHE (Mathieu), « Les Défis de l'analyse Des Réseaux Sociaux Pour Le Traitement Automatique Des Langues », *Revue TAL : traitement automatique des langues*, 54-3 (2013), p. 7-16, URL : <https://hal-lirmm.ccsd.cnrs.fr/lirmm-01184552> (visité le 06/05/2026).
- FLAMENT (Alexandre), *Google SGE (AI Overviews) : définition, fonctionnement et impact SEO en France*, deux.io, 2 juill. 2025, URL : <https://deux.io/definition-google-sge/> (visité le 29/07/2026).
- FRIES (Juliette), *La valorisation et la médiation des patrimoines écrits et graphiques en cinémathèque : le corpus d'affiches de cinéma de la Cinémathèque royale de Belgique*, other, Cinémathèque royale de Belgique, 3 rue Ravenstein, 1000 Bruxelles, 2023, p. 138, URL : <https://dumas.ccsd.cnrs.fr/dumas-04563090> (visité le 26/02/2026).
- FUICA (Beatriz Tadeo), BUISSON (Olivier) et MUSSOU (Claude), « Watching Historical Films Through AI : Reflections on Image Retrieval from Heritage Collections », *Cinergie – Il Cinema e le altre Arti*-20 (20 déc. 2021), p. 97-112, DOI : 10.6092/issn.2280-9481/13082.
- GAINON DE FORSAN DE GABRIAC (Clara), *Deep Natural Language Processing for User Representation*, Theses, Sorbonne Université, 2021, URL : <https://theses.hal.science/tel-03545621> (visité le 05/05/2026).
- GAO (Yunfan), XIONG (Yun), GAO (Xinyu), JIA (Kangxiang), PAN (Jinliu), BI (Yuxi), DAI (Yi), SUN (Jiawei), WANG (Meng) et WANG (Haofen), *Retrieval-Augmented Generation for Large Language Models : A Survey*, 27 mars 2024, DOI : 10.48550/arXiv.2312.10997, arXiv : 2312.10997 [cs.CL].
- GARG (Sourav) et MILFORD (Michael), *SeqNet : Learning Descriptors for Sequence-based Hierarchical Place Recognition*, 24 févr. 2021, DOI : 10.48550/arXiv.2102.11603, arXiv : 2102.11603 [cs.CV].
- GESSESSEW (Genet), *Object Detection : Combining YOLO and SAM2 for Enhanced Video Segmentation*, Medium, 21 nov. 2024, URL : <https://medium.com/@genet.gessessew/supercharging-object-detection-combining-yolo-and-sam2-for-enhanced-video-segmentation-3a8c5e603430> (visité le 11/05/2026).
- GIVOIS (Ève), BOLKA-TABARY (Laure), KERGOSIEN (Eric), GANTIER (Samuel) et HAOUDI (Bouchra El), « Élaboration itérative d'un thésaurus pour indexer le cinéma documentaire

- à partir des procédés filmiques », *I2D - Information, données & documents*, 2-2 (2 déc. 2021), p. 122-150, DOI : 10.3917/i2d.212.0122.
- Google/Gemma-4-31B-it · Hugging Face, 20 août 2026, URL : <https://huggingface.co/google/gemma-4-31b-it> (visité le 28/08/2026).
- GRAY (Colin), KOU (Yubo), BATTLES (Bryan), HOGGATT (Joseph) et TOOMBS (Austin), *The Dark (Patterns) Side of UX Design*, 2018, DOI : 10.1145/3173574.3174108.
- GROUPE (WEBQAM), *L'UX Design : Définition, enjeux et mise en pratique - Webqam*, Site Webqam Groupe, 21 févr. 2022, URL : <https://www.webqam.fr/blog/ux-design-definition-enjeux-mise-en-pratique/> (visité le 22/05/2026).
- GUO (Tong) et GAO (Huilin), *Content Enhanced BERT-based Text-to-SQL Generation*, 22 avr. 2020, DOI : 10.48550/arXiv.1910.07179, arXiv : 1910.07179 [cs].
- HAAS (Lukas), SKRETA (Michal), ALBERTI (Silas) et FINN (Chelsea), *PIGEON : Predicting Image Geolocations*, arXiv.org, 11 juill. 2023, URL : <https://arxiv.org/abs/2307.05845v6> (visité le 15/05/2026).
- HAMADI (Abdelkader), *Utilisation Du Contexte Pour l'indexation Sémantique Des Images et Vidéos*, Theses, Université de Grenoble, 2014, URL : <https://theses.hal.science/tel-01551793> (visité le 07/05/2026).
- HEDRICK (Brandon P), HEBERLING (J Mason), MEINEKE (Emily K), TURNER (Kathryn G), GRASSA (Christopher J), PARK (Daniel S), KENNEDY (Jonathan), CLARKE (Julia A), COOK (Joseph A), BLACKBURN (David C), *et al.*, « Digitization and the Future of Natural History Collections », *BioScience*, 70-3 (1^{er} mars 2020), p. 243-251, DOI : 10.1093/biosci/biz163.
- HODENT (Celia), *L'UX, c'est quoi exactement ? Une approche bienveillante pour des expériences optimales*, 2022, DOI : 10.3917/dunod.hoden.2022.01.
- HOLDSWORTH (Cole Stryker Jim), *Qu'est-ce que le NLP (traitement automatique du langage naturel) ?* / IBM, 11 août 2024, URL : <https://www.ibm.com/fr-fr/think/topics/natural-language-processing> (visité le 05/05/2026).
- Home - PySceneDetect, URL : <https://www.scenesdetect.com/> (visité le 07/05/2026).
- HOURCADE (Jean-Charles), LALOË (Franck) et SPITZ (Erich), *Longévité de l'information numérique. Les données que nous voulons garder vont-elles s'effacer ?*, 2010, URL : <https://stm.cairn.info/longevite-de-l-information-numerique--9782759805099> (visité le 09/07/2026).
- HuggingFaceTB/SmolVLM2-2.2B-Instruct · Hugging Face, 6 mai 2024, URL : <https://huggingface.co/HuggingFaceTB/SmolVLM2-2.2B-Instruct> (visité le 01/09/2026).
- HUSSON (Pierre), *Indexation Iconographique et Intelligence Artificielle : Expérimentations Autour Du Répertoire Des Tableaux Italiens Dans Les Collections Publiques Françaises*

- (*RETIF*), mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 08/08/2026).
- IA métadonnées & recherche visuelle archives, bibliothèques & musées*, URL : <https://www.archipanion.com/fr/> (visité le 07/05/2026).
- Image Identification & Content Moderation*, Videntifier, URL : <https://videntifier.com/> (visité le 13/05/2026).
- IMPETT (Leonardo) et OFFERT (Fabian), *There Is a Digital Art History*, arXiv.org, 14 août 2023, URL : <https://arxiv.org/abs/2308.07464v1> (visité le 15/05/2026).
- Intelligence artificielle : définition et utilisation*, Thèmes | Parlement européen, 9 juill. 2020, URL : <https://www.europarl.europa.eu/topics/fr/article/20200827ST085804/intelligence-artificielle-definition-et-utilisation> (visité le 22/08/2026).
- Intelligence artificielle et collections de la BnF : l'exemple de l'HTR (Handwritten Text Recognition)*, BnF - Site institutionnel, URL : <https://www.bnf.fr/fr/intelligence-artificielle-et-collections-de-la-bnf-l'exemple-de-lhtr-handwritten-text-recognition> (visité le 23/08/2026).
- Intelligence artificielle, de quoi parle-t-on ?*, URL : <https://www.cnil.fr/fr/intelligence-artificielle/intelligence-artificielle-de-quoi-parle-t-on> (visité le 22/08/2026).
- Intfloat/Multilingual-E5-Base · Hugging Face*, 17 févr. 2025, URL : <https://huggingface.co/intfloat/multilingual-e5-base> (visité le 28/08/2026).
- Intfloat/Multilingual-E5-Small · Hugging Face*, URL : <https://huggingface.co/intfloat/multilingual-e5-small> (visité le 28/08/2026).
- ISO 9241-112 :2025*, ISO, URL : <https://www.iso.org/fr/standard/87518.html> (visité le 20/08/2026).
- JOANNA, *Stocker les données : la piste prometteuse de l'ADN*, Interstices, 13 janv. 2023, URL : <https://interstices.info/stocker-les-donnees-la-piste-prometteuse-de-ladn/> (visité le 09/07/2026).
- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2019, URL : <https://shs.cairn.info/le-vocabulaire-du-cinema--9782200625405> (visité le 09/03/2026).
- JVC (Juvénal), *Interrogez efficacement vos bases de données avec Elasticsearch*, Data Transition Numérique, 21 juin 2022, URL : <https://www.data-transitionnumerique.com/search-elasticsearch/> (visité le 25/07/2026).
- KAVLAKOGLU (Jacob Murel Ph D. Eda), *Qu'est-ce que la racinisation et la lemmatisation ? / IBM*, 18 févr. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/stemming-lemmatization> (visité le 23/08/2026).

- KEVERS (Laurent), « Indexation Semi-Automatique de Textes : Thésaurus et Transducteurs », dans *Sixième Conférence Francophone En Recherche d'Information et Applications (CORIA)*, Presqu'Île de Giens, France, 2009, URL : <https://hal.science/hal-02454216> (visité le 08/08/2026).
- KITTIVORAWONG (Chanwut), GE (Yongming), HELAL (Yousef) et CHEUNG (Alvin), « Spatialyze : A Geospatial Video Analytics System with Spatial-Aware Optimizations », *Proceedings of the VLDB Endowment*, 17–9 (mai 2024), p. 2136-2148, DOI : 10.14778/3665844.3665846, arXiv : 2308.03276 [cs.DB].
- KNYAZEVA (Elena), WISNIEWSKI (Guillaume) et YVON (François), « Les Méthodes “ Apprendre à Chercher ” En Traitement Automatique Des Langues : Un État de l'art », *Revue TAL : traitement automatique des langues*, 59–1 (2018), p. 39-63, URL : <https://hal.science/hal-02103318> (visité le 06/05/2026).
- KO (Byungsoo), KIM (Han-Gyu), HEO (Byeongho), YUN (Sangdoo), CHUN (Sanghyuk), GU (Geonmo) et KIM (Wonjae), *Group Generalized Mean Pooling for Vision Transformer*, arXiv.org, 8 déc. 2022, URL : <https://arxiv.org/abs/2212.04114v1> (visité le 15/05/2026).
- KOOLEN (Marijn), KAMPS (Jaap) et KEIJZER (Vincent), « Information Retrieval in Cultural Heritage », *Interdisciplinary Science Reviews*, 34 (18 juill. 2013), p. 268-284, DOI : 10.1179/174327909X441153.
- KOROLKOV (Vasilii) et YANCHENKO (Andrey), *Automatic Detection of Intro and Credits in Video Using CLIP and Multihead Attention*, 13 avr. 2025, DOI : 10.48550/arXiv.2504.09738, arXiv : 2504.09738 [cs.CV].
- L'abbé Grégoire (31 Aout 1794) - Assemblée Nationale*, URL : <https://www2.assemblee-nationale.fr/decouvrir-l-assemblee/histoire/grands-discours-parlementaires/l-abbe-gregoire-31-aout-1794> (visité le 08/07/2026).
- L'archivage numérique intelligent pour votre entreprise*, Konfuzio, 29 avr. 2022, URL : <https://konfuzio.com/fr/archivage-numerique/> (visité le 26/02/2026).
- L'IA dans l'industrie cinématographique : le début d'une nouvelle ère*, URL : <https://www.autodesk.com/fr/design-make/articles/ai-in-the-film-industry> (visité le 26/02/2026).
- L'importance de l'UX Dans Une Application Métier*, URL : <https://usabilis.com/limportance-de-lux-dans-une-application-metier/> (visité le 22/05/2026).
- LA GUARDIA (Marcello), KOEVA (Mila) et LO BRUTTO (Mauro), « Digital Innovation for the Documentation, Management, and Fruition of Cultural Heritage », *Heritage*, 8–8 (août 2025), p. 292, DOI : 10.3390/heritage8080292.

- LALLEMAND (Carine), *Méthodes de Design UX. 30 Méthodes Fondamentales Pour Concevoir Des Expériences Optimales. (2e Edition)*, 2018.
- LANDRAGIN (Frédéric), « Anaphores et coréférences : analyse assistée par ordinateur » ().
- LAROUSSE (Éditions), *Larousse.fr : encyclopédie et dictionnaires gratuits en ligne*, URL : <https://www.larousse.fr/> (visité le 08/07/2026).
- LAROUZÉE (Justin), GUARNIERI (Franck) et BESNARD (Denis), « Le modèle de l'erreur humaine de James Reason » ().
- LE ROUZIC (Rose-Marie), « L'influence de la Révolution en France sur la notion de patrimoine et sur l'archéologie : rôle et pratiques (1790-1848) à travers quelques exemples », dans *Révolutions : L'archéologie face aux renouvellements des sociétés*, dir. Clara Filet, Svenja Höltekemeier, Capucine Perriot et Joëlle Rolland, Paris, 2017 (Archéo.doct), DOI : 10.4000/books.psorbonne.6831.
- Les plus grands défis en matière d'adoption de l'IA pour 2026 / IBM*, 26 mars 2025, URL : <https://www.ibm.com/fr-fr/think/insights/ai-adoption-challenges> (visité le 25/08/2026).
- LEWIS (Michael), OKSANEN (Eljas), EHRNSTEN (Frida), RANTALA (Heikki), TUOMINEN (Jouni) et HYVÖNEN (Eero), « The Impact of Human Decision-Making on the Research Value of Archaeological Data », *ACM Journal on Computing and Cultural Heritage*, 18–3 (9 sept. 2025), 47 :1-47 :22, DOI : 10.1145/3736770.
- LEZER (Arthur), *Cinéma & IA : Incorporer une intelligence artificielle pour (ré)écrire l'histoire du cinéma ? Une exploration de méthodes et d'analyses possibles*, INA le lab, DOI : 10.58079/q4f6.
- *inaSpeechSegmenter : décompte du temps de parole des femmes et des hommes*, INA le lab, DOI : 10.58079/q4fe.
- LIAO (Q. Vera) et VARSHNEY (Kush R.), *Human-Centered Explainable AI (XAI) : From Algorithms to User Experiences*, 19 avr. 2022, DOI : 10.48550/arXiv.2110.10790, arXiv : 2110.10790 [cs.AI].
- LIU (Ze), NING (Jia), CAO (Yue), WEI (Yixuan), ZHANG (Zheng), LIN (Stephen) et HU (Han), *Video Swin Transformer*, 24 juin 2021, DOI : 10.48550/arXiv.2106.13230, arXiv : 2106.13230 [cs.CV].
- LUO (Ziqian) et PAN (Xueting), *A Multi-Modal Framework for Text-Image to Video Synthesis with Enhanced Artistic Control*, 4 août 2024, URL : <https://hal.science/hal-04667390> (visité le 11/05/2026).
- MARCQ (Sarah), « Des usages archivistiques pour l'intelligence artificielle : le cas de l'automatisation de l'inventaire des archives à la Chambre des Députés du Grand-Duché de

- Luxembourg » (, 24 sept. 2024), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-04765262> (visité le 26/02/2026).
- MASSON (Eef), OLESEN (Christian), NOORD (Nanne) et FOSSATI (Giovanna), « Exploring Digitised Moving Image Collections : The SEMIA Project, Visual Analysis and the Turn to Abstraction », *Digital Humanities Quarterly*, 14 (20 déc. 2020), DOI : 10.63744/r42r32rbvag4.
- MAULUD (Dastan Hussen), AMEEN (Siddeeq Y), OMAR (Naaman), KAK (Shakir Fattah), RASHID (Zryan Najat), YASIN (Hajar Maseeh), IBRAHIM (Ibrahim Mahmood), SALIH (Azar Abid), SALIM (Nareen O. M) et AHMED (Dindar Mikael), « Review on Natural Language Processing Based on Different Techniques », *Asian Journal of Research in Computer Science*, 10-1 (juin 2021), p. 1-17, URL : <https://hal.science/hal-05279931> (visité le 05/05/2026).
- MCGILLIVRAY (Barbara), POIBEAU (Thierry) et RUIZ (Pablo), « Digital Humanities and Natural Language Processing : “Je t’aime... Moi Non Plus” », *Digital Humanities Quarterly*, 14-2 (juill. 2020), DOI : 10.17863/CAM.55816.
- MELLOT (Jean-Dominique), « Confiscations Révolutionnaires et Histoire Des Bibliothèques Françaises : Un “Moment Fondateur à Revisiter” », *French History and Civilization*, 08 (2019).
- MENDONÇA (Diogo), BARROS (Tiago), PREMEBIDA (Cristiano) et NUNES (Urbano J.), *Seg2Track-SAM2 : SAM2-based Multi-object Tracking and Segmentation*, version 2, 2025, DOI : 10.48550/ARXIV.2509.11772.
- Modèles FRBR, FRAD et FRSD / BnF - Site Institutionnel, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsd> (visité le 09/03/2026).
- MOTURI (Pradeep), KHANNA (Mukund) et SINGH (Kunal), « 3D Attention Based YOLO-SWINF for Real-Time Video Object Detection », dans *IFIP Advances in Information and Communication Technology*, dir. Ilias Maglogiannis, Lazaros Iliadis, John MacIntyre et Manuel Dominguez, León, Spain, 2023 (Artificial Intelligence Applications and Innovations), t. AICT-675, p. 491-502, DOI : 10.1007/978-3-031-34111-3_41.
- MOURAVIEFF (Raphaël), PIWOWARSKI (Benjamin) et LAMPRIER (Sylvain), « Structural Deep Encoding for Table Question Answering » ().
- NetVLAD : CNN Architecture for Weakly Supervised Place Recognition, URL : <https://www.di.ens.fr/willow/research/netvlad/> (visité le 15/05/2026).
- NIELSEN (Jakob), « Enhancing the Explanatory Power of Usability Heuristics », dans *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, New York, NY, USA, 1994 (CHI '94), p. 152-158, DOI : 10.1145/191666.191729.

- NIKOLAOU (Polina), « Museums and the Post-Digital : Revisiting Challenges in the Digital Transformation of Museums », *Heritage*, 7 (20 mars 2024), p. 1784-1800, DOI : 10.3390/heritage7030084.
- NLP : *Qu'est ce que le NLP au juste ?*, URL : <https://www.data-bird.co/blog/nlp> (visité le 06/05/2026).
- NORMAN (Don), « The Design of Everyday Things » (, 2013), p. 325.
- PAAS (Fred), RENKL (Alexander) et SWELLER (John), « Cognitive Load Theory and Instructional Design : Recent Developments », *Educational Psychologist*, 38 (8 juin 2010), p. 1-4, DOI : 10.1207/S15326985EP3801_1.
- PAPICCHIO (Simone), ROSSI (Simone), CAGLIERO (Luca) et PAPOTTI (Paolo), *Think2SQL : Blueprinting Reward Density and Advantage Scaling for Effective Text-to-SQL Reasoning*, févr. 2026, URL : <https://hal.science/hal-05523999> (visité le 06/05/2026).
- PINEL (Vincent) et PINEL (Christophe), *Dictionnaire technique du cinéma*, 2016, DOI : 10.3917/arco.pinel.2016.01.
- PKU-YuanGroup/Video-LLaVA, PKU-YUAN-Lab (-), 30 avr. 2026, URL : <https://github.com/Video-LLaVA> (visité le 07/05/2026).
- POHL (Allison M), « Collections Management Systems at Natural History Museums : A Centralized Approach » ().
- POIBEAU (Thierry), « Le traitement automatique des langues pour les sciences sociales : Quelques éléments de réflexion à partir d'expériences récentes », *Réseaux*, 188-6 (2014), p. 25-51, DOI : 10.3917/res.188.0025.
- POOLE (Nick) et DAWSON (Alex), *Gestion Des Biens Numériques SPECTRUM*, Collection Trust, 2013, p. 24.
- POULOT (Dominique), *Une histoire du patrimoine en Occident (XVIIIe-XXIe siècle). Du monument aux valeurs*, 2006, DOI : 10.3917/puf.poulo.2006.01.
- Préparer les archives pour l'ère de l'IA / Memoriav*, 12 févr. 2026, URL : <https://memoriav.ch/fr/actualite/preparer-les-archives-pour-lere-de-lia> (visité le 15/05/2026).
- Présentation du modèle Gemma 4*, Google AI for Developers, URL : <https://ai.google.dev/gemma/docs/core?hl=fr> (visité le 31/08/2026).
- PRIEUR (Benoît), *Traitement Automatique Du Langage Naturel Avec Python - Le NLP Avec spaCy et NLTK*, 2024, URL : <https://hal.science/hal-04610717> (visité le 05/05/2026).
- PyannoteAI : une IA pour retranscrire parfaitement les conversations*, URL : <https://www.cnrsinnovation.com/actualite/pyannoteai-une-ia-pour-retranscrire-parfaitement-les-conversations/> (visité le 18/08/2026).

- PyAV-Org/PyAV*, PyAV, 7 mai 2026, URL : <https://github.com/PyAV-Org/PyAV> (visité le 07/05/2026).
- Qu'est-ce qu'Elasticsearch ?* / IBM, 29 sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/elasticsearch> (visité le 25/07/2026).
- Qu'est-Ce Que La Named Entity Recognition ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/named-entity-recognition> (visité le 23/08/2026).
- Qu'est-ce qu'un chatbot ?* / IBM, 15 oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/chatbots> (visité le 04/08/2026).
- Qu'est-Ce Que l'algorithme Des k plus Proches Voisins ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/knn> (visité le 28/08/2026).
- Qu'est-Ce Que l'expérience Utilisateur (UX) ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/user-experience> (visité le 22/05/2026).
- Qu'est-ce que la recherche intelligente ?* / IBM, 8 oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/intelligent-search> (visité le 05/05/2026).
- Qu'est-Ce Que La Vision Par Ordinateur ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 23/08/2026).
- Qu'est-Ce Que Le Chunking Agentique ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/agentic-chunking> (visité le 29/07/2026).
- RADFORD (Alec), KIM (Jong Wook), XU (Tao), BROCKMAN (Greg), MCLEAVEY (Christine) et SUTSKEVER (Ilya), « Robust Speech Recognition via Large-Scale Weak Supervision » ().
- *Learning Transferable Visual Models From Natural Language Supervision*, 26 févr. 2021, DOI : 10.48550/arXiv.2103.00020, arXiv : 2103.00020 [cs.CV].
- RANJGAR (Babak), SADEGHI (Abolghasem), SHAKERI (Maryam), RAHIMI (Fatema) et CHOI (Soo-Mi), « Cultural Heritage Information Retrieval : Past, Present, and Future Trends », *IEEE Access*, 12 (1^{er} janv. 2024), p. 42992-43026, DOI : 10.1109/ACCESS.2024.3374769.
- RAVI (Nikhila), GABEUR (Valentin), HU (Yuan-Ting), HU (Ronghang), RYALI (Chaitanya), MA (Tengyu), KHEDR (Haitham), RÄDLE (Roman), ROLLAND (Chloe), GUSTAFSON (Laura), *et al.*, « SAM 2 : SEGMENT ANYTHING IN IMAGES AND VIDEOS » (, 2025).
- REASON (James), *Human Error*, Cambridge Aspire website, 26 oct. 1990, DOI : 10.1017/CB09781139062367.
- RESHETNIKOV (Artem), « What AI Can Bring to GLAM? Experience of "Saint George on a Bike" Project » ().

- RIEGER (Oya Y.), SCHONFELD (Roger) et SWEENEY (Liam), *The Effectiveness and Durability of Digital Preservation and Curation Systems*, Ithaca S+R, 2022, DOI : 10.18665/sr.316990.
- ROSSETTO (Luca), GIANGRECO (Ivan), TANASE (Claudiu) et SCHULDT (Heiko), « VitriVR : A Flexible Retrieval Stack Supporting Multiple Query Modes for Searching in Multimedia Collections », dans *Proceedings of the 24th ACM International Conference on Multimedia*, New York, NY, USA, 2016 (MM '16), p. 1183-1186, DOI : 10.1145/2964284.2973797.
- SAM 2 : *Segment Anything Model 2*, Ultralytics Docs, URL : <https://docs.ultralytics.com/fr/models/sam-2> (visité le 11/05/2026).
- SCHMIDT (Thomas), EL-KEILANY (Alina), EGER (Johanes) et KUREK (Sarah), « Exploring Computer Vision for Film Analysis : : A Case Study for Five Canonical Movies », dans Krasnoyarsk, Russia, 2021.
- SCHROFF (Florian), KALENICHENKO (Dmitry) et PHILBIN (James), *FaceNet : A Unified Embedding for Face Recognition and Clustering*, arXiv.org, 12 mars 2015, DOI : 10.1109/CVPR.2015.7298682.
- SERGEEV (Alexander), GOLOVIZNINA (Valeriya), MELNICHENKO (Mikhail) et KOTELNIKOV (Evgeny), « Talking to Data : Designing Smart Assistants for Humanities Databases » ().
- SEYIDOVA (Zenfira), « Collection Management in Museums : Conservation, Risk Management, and Climate Control Protocols », *Acta Globalis Humanitatis et Linguarum*, 3 (9 févr. 2026), p. 65-81, DOI : 10.69760/aghe1.026001007.
- SKÖLD (Olle) et HUVILA (Isto), « User Needs in the Digital Archives of the Popular Movement », *Archives & Manuscripts*, 52-2 (2024), p. 73-95, DOI : 10.37683/asa.v52.11049. *Spectrum*, Collections Trust, URL : <https://collectionstrust.org.uk/spectrum/> (visité le 18/07/2026).
- SPRIGATH (Gabriele), « Sur le vandalisme révolutionnaire (1792-1794) », *Annales historiques de la Révolution française*, 242-1 (1980), p. 510-535, DOI : 10.3406/ahrf.1980.4227. *Standards – MPEG*, URL : <https://www.mpeg.org/standards/> (visité le 15/05/2026).
- State of Open Models : Summer 2026 Observations*, 12 août 2026, URL : <https://huggingface.co/blog/state-of-open-models-summer-2026> (visité le 25/08/2026).
- STOCKINGER (Peter), *Animer Une Base de Connaissance : Des Ontologies Aux Modèles d'I.A. Générative*, 1^{er} sept. 2025, DOI : 10.48550/arXiv.2509.01304, arXiv : 2509.01304 [cs.DL].
- STUTZMANN (Dominique), MOUFFLET (Jean-François) et HAMEL (Sébastien), « La recherche en plein texte dans les sources manuscrites médiévales : enjeux et perspectives du projet HIMANIS pour l'édition électronique », *Médiévales. Langues, Textes, Histoire*, 73-73 (73[2017/déc./15]), p. 67-96, DOI : 10.4000/medievales.8198.

- SUN (Shuo), ZHANG (Yuchen), YAN (Jiahuan), GAO (Yuze), ONG (Donovan), CHEN (Bin) et SU (Jian), *Battle of the Large Language Models : Dolly vs LLaMA vs Vicuna vs Guanaco vs Bard vs ChatGPT – A Text-to-SQL Parsing Comparison*, 16 oct. 2023, DOI : 10.48550/arXiv.2310.10190, arXiv : 2310.10190 [cs].
- Techniques et formats de conversion en mode texte*, BnF - Site institutionnel, URL : <https://www.bnf.fr/fr/techniques-et-formats-de-conversion-en-mode-texte> (visité le 23/08/2026).
- Text-to-SQL : interroger vos bases en langage naturel*, Flowt, 27 févr. 2026, URL : <https://flowt.fr/blog/text-to-sql-ia-generative-interroger-bases-donnees-langage-naturel/> (visité le 06/05/2026).
- The Power of Natural Language Interfaces in Applications* / LinkedIn, URL : <https://www.linkedin.com/pulse/power-natural-language-interfaces-applications-rakesh-mullassery-v4rrc/> (visité le 22/05/2026).
- TUAL (Solenn), ABADIE (Nathalie), CHAZALON (Joseph), DUMÉNIEU (Bertrand) et PERRET (Julien), « Extraction et interprétation sémantique de tables anciennes : défis et perspectives » ().
- TUZA (Bénédicte), *Interroger la mémoire d'entreprise par l'IA : le RAG face aux archives orales. Enjeux et limites pour l'histoire appliquée*, other, Perles d'Histoire, 40 rue de Paris, 92100 Boulogne-Billancourt, 2025, p. xxxii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05390427> (visité le 26/02/2026).
- ULTRALYTICS, *Qu'est-ce qu'un reranker ? Optimiser la recherche et l'IA*, Ultralytics, 29 janv. 2026, URL : <https://www.ultralytics.com/fr/glossary/reranker> (visité le 29/07/2026).
- Universal bibliographic control and international MARC programme et Fédération internationale des associations de bibliothécaires et des bibliothèques (éd.), *Functional Requirements for Bibliographic Records : Final Report*, München, 1998 (UBCIM Publications, 19).
- USABILIS, *Qu'est-ce que l'UI Design ? Définition et exemples d'UI Design*, Usabilis, 27 oct. 2020, URL : <https://usabilis.com/ui-design/> (visité le 20/08/2026).
- Usability of Data-Oriented User Interfaces for Cultural Heritage : A Systematic Mapping Study* - Maria de La Paz Diulio, Juan Cruz Gardey, Analía Fernanda Gomez, Alejandra Garrido, 2023, URL : <https://journals.sagepub.com/doi/10.1177/01655515211001787> (visité le 25/05/2026).
- VALLET (Yannick), *La grammaire du cinéma. De l'écriture au montage : les techniques du langage filmé*, 2019, DOI : 10.3917/arco.valle.2019.01.
- VARRY (Dominique), « Les confiscations révolutionnaires », dans *Histoire des bibliothèques françaises*, 2009, p. 7-36, DOI : 10.3917/elec.verne.2009.01.0007.

- Hélène Verdier et France (éd.), *Système descriptif des objets mobiliers*, Paris, 1999 (Documents & méthodes, no 6).
- WANG (Liang), YANG (Nan), HUANG (Xiaolong), YANG (Linjun), MAJUMDER (Rangan) et WEI (Furu), *Multilingual E5 Text Embeddings : A Technical Report*, 8 févr. 2024, DOI : 10.48550/arXiv.2402.05672, arXiv : 2402.05672 [cs.CL].
- WANG (Xin-Yang) et JIANG (Jie), « Examining the Weak Cosmic Censorship Conjecture of RN-AdS Black Holes via the New Version of the Gedanken Experiment », *Journal of Cosmology and Astroparticle Physics*, 2020–07 (23 juill. 2020), p. 052-052, DOI : 10.1088/1475-7516/2020/07/052, arXiv : 1911.03938 [hep-th].
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, 2026, DOI : 10.48550/arXiv.2603.10285.
- WARWICK (Claire), TERRAS (Melissa), HUNTINGTON (P.) et PAPPA (N.), « If You Build It Will They Come? The LAIRAH Study : Quantifying the Use of Online Resources in the Arts and Humanities through Statistical Analysis of User Log Data », *Literary and Linguistic Computing*, 23 (14 déc. 2007), p. 85-102, DOI : 10.1093/llc/fqm045.
- WHITELAW (Mitchell), « Generous Interfaces for Digital Cultural Collections », *Digital Humanities Quarterly*, 009–1 (21 mai 2015).
- WILLFRIED BAATZ, *Photography*, 1997, URL : <http://archive.org/details/photography00baat> (visité le 09/07/2026).
- XU (Anbang), LIU (Zhe), GUO (Yufan), SINHA (Vibha) et AKKIRAJU (Rama), « A New Chatbot for Customer Service on Social Media », dans *Proceedings of the 2017 CHI Conference on Human Factors in Computing Systems*, New York, NY, USA, 2017 (CHI '17), p. 3506-3510, DOI : 10.1145/3025453.3025496.
- XU (Guoping), UDUPA (Jayaram K), YU (Yajun), SHAO (Hua-Chieh), ZHAO (Songlin), LIU (Wei) et ZHANG (You), « Segment Anything for Video : A Comprehensive Review of Video Object Segmentation and Tracking from Past to Future » ().
- XUE (Dongge), PU (Zhili), XIA (Zhentao), SUN (Hongli), HOU (Ruihui), YU (Guangya), LIN (Yupian), FAN (Yongqi), LIU (Jingping) et RUAN (Tong), « Text-to-ES Bench : A Comprehensive Benchmark for Converting Natural Language to Elasticsearch Query » ().
- YUAN (Cheng), JIANG (Jian), YANG (Kunyi), WU (Lv), WANG (Rui), MENG (Zi), PING (Haonan), XU (Ziyu), ZHOU (Yifan), SONG (Wanli), *et al.*, « Systematic Evaluation and Guidelines for Segment Anything Model in Surgical Video Analysis », *npj Digital Surgery*, 1–1 (1^{er} avr. 2026), p. 2, DOI : 10.1038/s44484-025-00002-2.

- ZHANG (Chunhui), CUI (Yawen), LIN (Weilin), HUANG (Guanjie), RONG (Yan), LIU (Li) et SHAN (Shiguang), *Segment Anything for Videos : A Systematic Survey*, 31 juill. 2024, DOI : 10.48550/arXiv.2408.08315, arXiv : 2408.08315 [cs].
- ZHANG (Yifu), WANG (Chunyu), WANG (Xinggang), ZENG (Wenjun) et LIU (Wenyu), *Fair-MOT : On the Fairness of Detection and Re-Identification in Multiple Object Tracking*, arXiv.org, 4 avr. 2020, DOI : 10.1007/s11263-021-01513-4.

Introduction

La conservation du patrimoine et la gestion des collections patrimoniales soulèvent des enjeux politiques, sociaux, culturels et identitaires. Avec l'arrivée du numérique, ces notions n'ont cessé d'évoluer comme le souligne Marcello La Guardia et Mila Koeva :

« Recent years have been characterised by a profound transformation in the field of Cultural Heritage, shaped by interdisciplinary methodologies, digital innovation, and the demand for more inclusive, sustainable management approaches. »¹

Dès lors nous devons définir ce que nous entendons par **patrimoine** et **gestion des collections**. Quels sont les objets, lieux et pratiques encadrés par ces notions ? Quels en sont les problématiques et limites particulières ? Et enfin, comment patrimoine, gestion des collections et numériques s'imbriquent ?

Patrimoine et gestion des collections sont des notions variant en fonction des contextes institutionnels et culturels. En France, elles prennent racines au XVIII^{ème} siècle lors de la Révolution française au travers des confiscations révolutionnaires.

Entre 1790 et 1793, les biens monarchiques et ecclésiastiques sont placés sous patronage de la Nation. Certains sont revendus pour pallier la crise financière en vigueur, d'autres sont précieusement conservés.² Mais la position révolutionnaire n'est pas unanime : si certains cherchent à conserver pour la Nation, d'autres souhaitent détruire ces symboles de l'Ancien Régime ce qui entraîne des destructions, dégradations et vols.³

Le patrimoine s'affirme en réaction à ces actes au travers du rapport du 31 août 1794 sur les exactions révolutionnaires de l'Abbé Henri Grégoire (*04 décembre 1750 - 28 mai 1831*).

¹Marcello La Guardia, Mila Koeva et Mauro Lo Brutto, « Digital Innovation for the Documentation, Management, and Fruition of Cultural Heritage », *Heritage*, 8-8 (août 2025), p. 292.

²Dominique Varry, « Les confiscations révolutionnaires », dans *Histoire des bibliothèques françaises*, 2009, p. 7-36, p.21.

³Jean-Dominique Mellot, « Confiscations Révolutionnaires et Histoire Des Bibliothèques Françaises : Un "Moment Fondateur à Revisiter" », *French History and Civilization*, 08 (2019), p.134.

Il y dénonce le vandalisme⁴ des «[...] mobiliers appartenants à la Nation [...]»⁵. L'historien Dominique Poulot approfondit : en réalité on souhaite préserver ce qui est justifié par « l'appel à l'avenir » pour un idéal associant « légitimité nouvelle, utilité savante, et conservation raisonnée. »⁶.

Le projet de *Bibliographie Universelle de la France*⁷ de 1790, première grande entreprise de catalogage national, ainsi que la recherche constante de lieu de conservation pour ces biens, témoignent de cette naissance de la notion de Patrimoine et de ses particularités françaises.

L'archiviste paléographe Olivia Brissaud soulève dans son article de 2013⁸ les particularités patrimoniales françaises suivantes : d'abord le patrimoine est « inaliénable » et « inviolable ». Ensuite, il relève d'une responsabilité commune. De plus, il devient le fondement identitaire et culturel de la Nation. Enfin, l'État s'octroie la souveraineté juridique sur le patrimoine à l'aide d'un appareil bureaucratique dédié, placé sous sa juridiction directe, devenu depuis le Service des Musées de France.

Ainsi, le patrimoine est une notion culturelle, aux racines profondément politiques et juridiques, constituant le socle identitaire national. Il se matérialise dans des collections d'objets, dont la constitution a permis l'émergence de la notion de patrimoine.⁹ Leur gestion relève directement de la juridiction de l'État français chargé de répondre aux enjeux politiques, juridiques et culturels associés.

Cependant, le patrimoine est un objet vivant qui ne cesse de se diversifier notamment avec l'inclusion de l'image animée¹⁰ en 1936¹¹ puis celle de la photographie¹² en 1964¹³. D'autres typologies d'objets entrent au patrimoine comme les espaces naturels et le patrimoine immatériel en 2003, avec la *Convention pour la sauvegarde du patrimoine culturel* promulguée par l'Organisation des Nations unies pour l'éducation, la science et la culture

⁴Gabriele Sprigath, « Sur le vandalisme révolutionnaire (1792-1794) », *Annales historiques de la Révolution française*, 242-1 (1980), p. 510-535.

⁵L'abbé Grégoire (31 Aout 1794) - *Assemblée Nationale*.

⁶*Ibid.*, p.183-184.

⁷J.D. Mellot, « Confiscations Révolutionnaires et Histoire Des Bibliothèques Françaises : Un "Moment Fondateur à Revisiter" »...

⁸Olivia Brissaud, « L'élaboration du principe d'inaliénabilité pour les collections muséales et les biens du domaine public mobilier sous la Révolution française », *Livraisons de l'histoire de l'architecture*-26 (2013/déc./10), p. 141-156.

⁹Ministère de la Culture, *Guide de Gestion Des Documents Patrimoniaux*, Paris, Ministère de la Culture, 2021, p.17.

¹⁰L'invention de « l'image animée » en tant que tel est difficile à dater. Le brevetage en 1895 du cinématographe des frères Auguste et Louis Lumière consacre cette nouvelle typologie documentaire.

¹¹Création de la Cinémathèque française

¹²Bien que Louis Daguerre grâce à son Daguerrréotype, le premier « appareil photo », a été considéré comme l'inventeur de la photographie, son invention remonterait aux travaux de Nicéphore Niépce et de son héliographe. Voir Willfried Baatz, *Photography*, 1997

¹³Création du Musée Français de la photographie

appelé l'UNESCO

Pour la gestion des collections, depuis la tentative de normalisation en 1890¹⁴, les pratiques de catalogage n'évoluent pas beaucoup malgré la diversification des collections. C'est l'informatique qui apporte un nouveau souffle à ce domaine.

En 1970, la première base de données informatique patrimoniale est créée afin de constituer un premier catalogue des collections mutualisées : c'est JOCONDE qui est destinée aux Musées de France¹⁵. En parallèle, des systèmes de gestion des collections, ou **SGC** pour Système de Gestion des Collections, sont développés : c'est le cas du projet GRIPHOS *Museum Computer Network* à New York en 1967 qui permet de créer un inventaire et suivi informatique des collections physiques dans des musées.

La réduction de la taille des ordinateurs permet d'équiper informatiquement les institutions en masse. Ainsi en 1985 est installé le **SGC** « Micromusées » à l'échelle nationale sous l'impulsion du Service des Musées de France.¹⁶ L'invention d'internet en 1983 et du *World Wide Web* en 1989 permettent de faire de JOCONDE et Micromusée des outils nationaux pour une mutualisation complète des collections et pratiques.

Des organisations comme l'IFLA ou le CIDOC, profitent de l'essor de l'informatique pour normaliser mondialement les pratiques de gestion des collections. Ainsi, des normes de description, leurs traductions informatiques appelées « standards d'encodage » et des modèles conceptuels de gestion des collections sont créés.

Le patrimoine devient un bien commun à normaliser dans sa description afin d'en faciliter l'échange et la diffusion nationale et mondiale. Pour ces deux raisons, l'État français incite à informatiser les musées dans un premier temps, puis toute institution possédant des collections patrimoniales.

La dématérialisation des catalogues amène à penser une solution de conservation numérique des collections pensée pour concilier conservation et communication. Alors apparaît la numérisation, processus qui aboutit à la création d'un « jumeau numérique »¹⁷ afin de protéger l'objet physique tout en offrant la possibilité de le consulter¹⁸. Pour certaines typologies telles

¹⁴Charlotte Denoël, « L'apport de Léopold Delisle à la catalographie : de l'élaboration des Instructions pour la rédaction d'un catalogue de manuscrits (1884) à l'interopérabilité des métadonnées numériques », *Bulletin du bibliophile*-2 (2019), p. 342-353.

¹⁵Hélène Verdier et France (éd.), *Système descriptif des objets mobiliers*, Paris, 1999 (Documents & méthodes, no 6), p. 2.

¹⁶Villeneuve De Janti, « Muséologie et Informatique : L'œuvre d'art à l'époque de Sa Reproduction Numérique », dans 2018, p.2.

¹⁷Patrick Bergeot et Morgane Estavoyer, *Le jumeau numérique dans le patrimoine : fantasme ou réalité ?*, Livre Blanc, Paris, Centre des monuments Nationaux, 2025, 193p.

¹⁸Pour plus d'informations : <https://www.culture.gouv.fr/thematiques/innovation-numerique/sou>

que l'image animée, le numérique devient le moyen de création et de conservation privilégié. Cela s'explique par les avancées technologiques dans ce domaine ainsi que la popularisation de la vidéo numérique.

La numérisation du patrimoine amène en 1997 la BNF à ouvrir son site de consultation de documents numérisés : Gallica. C'est le premier service web dédié à la consultation de documents patrimoniaux numérisés. Puis en 2009, l'UNESCO reconnaît aux objets numériques, natifs ou numérisés, une valeur patrimoniale¹⁹. Dès lors, le patrimoine numérique connaît une croissance sans précédent : par exemple la BNF possédait environ trois-cent cinquante mille documents numériques en 2007 contre plus de dix millions en 2026.

Les diverses évolutions du patrimoine et de la gestion des collections que nous avons retracées imposent de nouvelles limites et difficultés. Les collections patrimoniales sont aujourd'hui doublement hétérogènes : plusieurs typologies documentaires y coexistent et les objets physiques côtoient leurs équivalents numériques²⁰. Une seule collection appelle une gestion plurielle à travers l'application de différentes normes, standards et modèles conceptuels. À cela s'ajoute l'intensification de l'expansion des collections patrimoniales notamment due au numérique.

La production intensive de données numériques participe à l'explosion quantitative des données que l'on appelle la *Big Data*. À titre d'exemple, en 2023 l'INA stocke plus de 60 pétaoctets de données, soit 60 000 000 de gigaoctets de données.²¹ Avec de telles quantités de données, deux enjeux se renouvèlent : celui du stockage, qui engage des questions d'infrastructures, et celui de l'accès, qui amène à repenser les moyens d'accès aux collections.

Si l'informatique a apporté des solutions de gestion des collections, la diversité des modalités et pratiques ainsi que l'importance desdites collections appellent d'autres solutions. Depuis 2020, le domaine de l'intelligence artificielle semble proposer des solutions face aux défis posés par les collections patrimoniales aujourd'hui.

On entend par « intelligence artificielle » la technologie capable d'effectuer des tâches assimilées à l'intelligence comme l'apprentissage et le raisonnement. Cela se concrétise notamment avec le *machine learning* et le *Deep Learning* permettant une autonomisation de ces outils demandant moins de supervision humaine. L'intelligence artificielle est de plus en plus intégrée au monde culturel et patrimonial : d'abord avec la *computer vision* pour l'analyse d'image et de vidéo et le NLP pour le traitement des textes. Puis ensuite avec l'arrivée des

tenir-la-creation-numerique-et-l-innovation/numerisation-des-contenus-culturels

¹⁹Charte Sur La Conservation Du Patrimoine Numérique - UNESCO Digital Library.

²⁰Voir la notion de « jumeau numérique » dans Id., *Le jumeau numérique dans le patrimoine : fantasme ou réalité ?*...

²¹Joanna, *Stocker les données : la piste prometteuse de l'ADN*, Interstices, 13 janv. 2023.

Vision Language Model permettant de faire aussi bien de la *computer vision* que du NLP à l'aide d'un seul outil.

Toutes ces nouvelles technologies se mettent peu à peu au profit du patrimoine à l'instar du projet HIMANIS a permis l'indexation massive des 75 000 pages manuscrites du corpus médiéval du Trésor des Chartes grâce au HTR, ou reconnaissance d'écriture manuscrite.²² La conduite ponctuelle de projet d'intelligence artificielle apporte plus de profondeur dans notre connaissance du patrimoine possédé. Mais aujourd'hui l'attention se concentre sur l'intégration pérenne d'outils d'intelligence artificielle. Des institutions nationales intègrent progressivement de tels outils constituant de véritables processus automatiques : on peut penser à LECTAUREP pour les archives notariales aux Archives Nationales et Gallica Images à la BNF pour l'indexation automatique de documents numérisés. Ces outils sont cependant marginaux puisque les institutions plus petites, mais plus nombreuses, se dirigent vers des solutions de **SGC** sur étagère. Ces dernières intègrent rarement ces outils et seulement de manière partielle avec une prise en main limitée.

Mon stage porte précisément sur ce sujet avec pour angle particulier de penser les outils et la manière de les intégrer dans une solution de **SGC** développée par l'entreprise SkinSoft à destination de professionnels du monde patrimonial.

Établie à Besançon, SkinSoft est définie comme une PME française, composée d'environ 50 personnes, ainsi qu'un laboratoire de recherche qui fournit une solution de **SGC**. Cette entreprise est une actrice de premier plan sur le marché international des **SGC**, fournissant aussi bien des institutions publiques (*Château de Fontainebleau, The Royal BC Museum, ...*) que privées (*Fondation Jérôme Seydoux-Pathé, Lacoste, ...*). Elle opère en France principalement, mais aussi en Amérique, en Europe centrale et de l'Est allant même jusqu'en Asie. Au titre de laboratoire de recherche, elle cherche à développer de nouveaux outils pour la gestion des collections notamment basés sur l'intelligence artificielle.

Plusieurs missions ont été définies, chacune portant sur un point d'attention particulier quand on parle d'intégration d'outils intelligence artificielle dans un **SGC**. La première a été de réfléchir à ce que l'intelligence artificielle peut apporter dans l'application à un utilisateur²³, sur des aspects d'usages et d'accessibilités des collections. La seconde mission a consisté en l'identification des besoins utilisateurs et la conception d'outils y répondant. La troisième et dernière mission a été de conceptualiser une chaîne de traitement basée sur l'intelligence artificielle²⁴ afin d'automatiser le traitement de l'image animée directement dans

²²Pour plus d'informations voir : Dominique Stutzmann, Jean-François Moufflet et Sébastien Hamel, « La recherche en plein texte dans les sources manuscrites médiévales : enjeux et perspectives du projet HIMANIS pour l'édition électronique », *Médiévales. Langues, Textes, Histoire*, 73–73 (73[2017/déc./15]), p. 67-96

²³Ici le mot « utilisateur » désigne tout professionnel membre d'une institution, privée ou patrimoniale, possédant la solution SkinSoft et qui utilise cette dernière pour gérer la collection de ladite institution

²⁴Ici, le terme « intelligence artificielle » est utilisé au sens global. Nous ne parlons pas encore de domaine,

l'application.

La réalisation de ces missions a pour objectif de produire différents outils basés sur l'intelligence artificielle afin de permettre une meilleure gestion des grandes quantités de données patrimoniales. D'offrir de meilleurs outils de gestion et d'exploitation des collections et données. Et enfin de faciliter les processus assurés par un *SGC*, comme l'indexation, notamment dans le champ du traitement de l'image animée.²⁵

Finalement, cet objectif pose la question suivante : dans quelle mesure l'implémentation d'outils basés sur l'intelligence artificielle dans un CMS permet de répondre aux défis des collections composites sans dénaturer les pratiques de gestion ?

La réponse se fait en 3 temps. Le premier est consacré à l'analyse des *SGC*, notamment le système SkinSoft, et des difficultés actuelles qu'ils rencontrent. C'est également l'occasion de quelques considérations générales sur l'intelligence artificielle dans le domaine de la gestion des collections. L'objectif est de solidifier nos connaissances sur le monde dans lequel cette étude s'inscrit et de comprendre en profondeur chaque élément d'attention ciblés quand nous parlons de gestion de collections d'intelligence artificielle appliquée à ce domaine particulier.

Le second temps est dédié à l'exploration de deux technologies d'intelligence artificielle : en particulier le NLP et l'indexation semi-automatisée²⁶. L'analyse de l'indexation automatisée notamment via une réflexion à son application au domaine de l'image animée. Nous ferons un état de l'art afin de comprendre l'envergure de ces technologies, les problématiques qu'elles résolvent et comment la recherche actuelle conçoit leurs utilisations sur des données patrimoniales. La solution SkinSoft sert ici de cadre d'étude permettant de mieux saisir le périmètre et les limites de chaque technologie.

Le troisième et dernier temps de ce mémoire est dédié à un retour d'expérience sur les deux projets d'intelligence artificielle. En présentant les solutions conceptualisées et comment leurs implémentations ont été pensées. L'objectif est de présenter les apports et limites de ces solutions ainsi que les difficultés rencontrées et les choix effectués. Avant de conclure notre travail, ce temps se termine sur une analyse d'écart entre l'apport envisagé par l'implémentation de ces technologies au début des projets, et l'apport réellement envisageable une fois les projets aboutis.

sous-domaine et d'outils précis.

²⁵Il est important de noter que ce travail ne porte pas uniquement sur l'image animée. Le travail effectué explore d'autres typologies que la seule image animée, bien que cette dernière possède une place particulière ici.

²⁶Ce n'est pas vraiment une technologie à part entière, mais plutôt un ensemble de technologies mobilisées pour une tâche particulière. Par facilité de langage, nous parlerons souvent de l'indexation semi-automatisée comme d'une technologie à part entière.

Première partie

La gestion numérique de collections
composites dans le monde patrimonial
et le secteur privé.

Chapitre 1

Système de gestion de collection et suite SkinSoft

I. Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes

Les **SGC** sont aujourd'hui au cœur des pratiques de gestion des collections et de l'activité des institutions conservatrices. Mais pour comprendre ce qu'est un **SGC** et son rôle, il faut comprendre que ces systèmes ont redéfinis le concept de gestion des collections. De fait, le terme « système de gestion des collections » désigne une toute autre réalité que celle d'origine.

À l'origine, le **SGC** transpose toute les pratiques de gestion des collections pratiquée au moment de son invention dans un logiciel informatique. Ainsi, il assure la pérennité des objets patrimoniaux et de leur histoire afin de léguer les connaissances. Les premiers logiciels comme GRIPHOS puis Micromusées ont pour but principal de répertorier chaque objet possédé, de consigner sa description et son évolution matérielle dans le temps. Finalement, ces premiers **SGC** ne déterminent pas de nouvelles pratiques.

L'explosion des moyens informatiques et leur implémentation à large échelle conduit à la multiplication des bases de données institutionnelle. Chaque institution possède sa propre base dans lequel elle décrit simplement ces collections avec ses propres méthodes et vocabulaires. Cela créer un paradoxe : conçu comme un atout à la normalisation des descriptions, ils ont paradoxalement renforcé le cloisonnement des inventaires. Cela devient évident avec l'invention du *World Wide Web* qui rend envisageable la communications de ces inventaires numériques entre institutions et au public mais qui a besoin d'homogénéité. De plus, de nouvelles exigences juridiques sont développées afin de répondre à la rigueur scientifique requise

par la recherche.

Les **SGC** permettent ainsi d'améliorer des pratiques pré-existantes tout en amenant de nouveaux enjeux scientifiques et communicationnels. Plus qu'un outil de transition informatique, il devient le vecteur d'un éveil des consciences sur le besoin de changement des pratiques de gestion des collections.

À partir de la décennies 1980, la gestion des collections commence à être repensée de même que les principes fondamentaux des **SGC**. L'article de 1987 de David Bearman, spécialiste en stratégie d'informations documentaire,²⁷ est fondamental dans la définition de ce que doit être un **SGC**.

Il y définit de nouveaux principes clés, délaissant le simple rôle d'inventaire descriptif pour un rôle de gestionnaire de l'activité globale générée par la gestion des collections²⁸.

Dans sa thèse, il distingue deux systèmes répondant à deux besoins différents : le système d'*Information Retrieval* et les *Collections management information system*. Le premier se rapproche des **SGC** contemporain de David Bearman. Ils sont concentrés autour des « [...] facilities that support curatorial description and information retrieval for collections management purposes [...] »²⁹, à savoir : la collecte et recherche d'informations de description d'objets. Le second est une notion plus large incluant l'*Information Retrieval* sans s'y limiter, mais surtout une gestion du cycle de vie des objets culturels. Cela se fait au travers de 5 notions : le temps, l'espace, les fonds financiers, le personnel et les fonds de collections³⁰. C'est le fondement de nos systèmes actuels.

David Bearman soulève un paradoxe : les "**SGC**" de première génération n'incluent pas de dimensions managériales concrètes mais uniquement du stockage et de la recherche d'informations statiques. Il y a donc un écart entre les besoins croissants des institutions souhaitant établir des stratégies d'utilisations de ces objets et ce que ces outils permettent. Les "**SGC**" centrés sur la gestion de la description des collections répondent à la question de la connaissance des possessions, quand finalement un véritable **SGC** devrait répondre aux nouvelles problématiques de diffusion, de communication, d'exigence juridique et scientifique et d'optimisation de gestion.

Cette problématique croise celle de l'hétérogénéité des collections. Le terme "objet culturel" désigne des réalités différentes qui demandent des modèles de gestions différents³¹ ce

²⁷ *Archives & Museum Informatics : Publishing : Archives : Functional Requirements for Collections Management Systems : Table of Contents.*

²⁸ *Ibid.*, p.1.

²⁹ *Ibid.*, p.2.

³⁰ *Ibid.*, p.3.

³¹ *Ibid.*, p.4.

qu'un **SGC** de l'époque ne fait pas réellement. Différents vocabulaires cohabitent contribuant à rendre les inventaires plus complexes.

Ainsi, un **SGC** doit gérer des données sur le cycle de vie des objets patrimoniaux³² et des données centrées sur la gestion de ces derniers³³.

Pour le premier point, il s'agit de consigner des données descriptives et historique de l'objet mais aussi tout ce qui va relever de son intégration dans les collections. Ainsi, on doit consigner tout ce qui concerne : son achat, dépôt, ses conditions d'accès, les localisations temporaires et fixes, les prêts, conditions de conservation mais aussi d'exposition et tout document relatif à l'activité ayant lieu autour de cet objet jusqu'à sa destruction ou retrait des collections.

Pour le second point, il comprend la création, la catégorisation et la réutilisation de toutes les données produites au sujet de l'activité d'un objet patrimonial au sein des collections. C'est à dire qu'on veut consigner et décrire avec la même précision tout ce qui gravite autour de la gestion des collections : les événements, les agents de l'institutions, les autorités, c'est à dire les personnes liées aux objets, toutes les ressources et actions reliées à ces objets. Chacun de ces éléments doit être décrit, catégorisé, défini dans ses fonctions et limites et reliés à des objets de la collection afin d'en nourrir le cycle de vie.

Ce qu'il faut comprendre c'est que le fonctionnement d'une institutions est défini en fonction de sa gestion des collections. Il y a un lien de dépendance : la gestion des collections définit le fonctionnement de l'institutions et inversement.

Sans aller plus loin dans l'article de David Bearman, on comprends alors que l'objectif d'un **SGC** est d'être un outil stratégique et de pilotage des activités et politiques institutionnelles. La gestion des collections étant le cœur de ces institutions, elle en influence nécessairement les activités institutionnelle et sa capacité d'actions.

C'est pour cela que ces systèmes sont très réglementés par des cahiers des charges précis observant des conventions internationales. C'est le cas de la norme SPECTRUM³⁴ de la *Collections Trust* définissant des procédures fondamentales sur : l'entrée, l'acquisition, la localisation, l'inventaire périodique, la catalogage, la sortie, les prêts entrants, les prêts sortants et les mouvements, la conservation, la gestion des risques, l'utilisation des collections et le déclasserment des objets patrimoniaux. Tout **SGC** doit pouvoir les documenter, les renseigner et les tracer dans le respect de l'interopérabilité des données.

Cette norme concerne aussi bien la gestion des objets numériques, que celle des objets

³² *Ibid.*, p.4-11.

³³ *Ibid.*, p.12-22.

³⁴ *Spectrum*, Collections Trust.

physiques. C'est un point important qui fait du **SGC** l'outil de gestion des collections aussi bien physiques que numériques. Cela amène donc à créer un outil multi-facettes afin de correspondre à différentes réalités : celle du numérique et celle du physique. Ainsi, cet outil doit répondre aux enjeux stratégiques institutionnels mais aussi de gestion de fond doublement hétérogène.

Ajoutons à cela que les institutions publiques ne sont pas les seules demandeuses de solutions informatiques pour la gestion des collections. Les entreprises privées de différents secteurs, notamment du luxe, sont aujourd'hui demandeuses de ces solutions informatiques. En effet, de grandes entreprises renommées souhaitent aujourd'hui développer une gestion des collections solides afin d'appuyer le développement d'image de marque par la mise en avant du patrimoine. Il y a ici un véritable enjeu de productivité et d'activités, les collections devenant des outils commerciaux au cœur des stratégies de développement des entreprises.

Ce qui explique cet intérêt pour ces outils et peut être sa nature d'outil stratégique et de pilotage d'activité. Les logiques de rendements et de gain de temps de ces entreprises amènent à voir en ces logiciels une manière d'optimiser une image de marque et des activités de productions.

Finalement, aujourd'hui un **SGC** est un outil informatique d'une grande complexité. Devenu le cœur de la gestion des collections dès les années 1970, ces outils sont très vite devenus les points centraux des institutions conservatrices. Ils assurent la gestion des collections, des stratégies patrimoniales et institutionnelles ainsi que tout les activités et événements liées à ces deux points.

Pour cette raison, les **SGC** doivent assurer la documentation de l'objet, de sa vie au sein des collections, de son histoire mais aussi de la vie institutionnelle. Au delà de ces aspects, les **SGC** sont au cœur de politiques internationales d'harmonisation des pratiques de gestion des collections et des données produites au sein des activités concernées. Pour cette raison, ce sont des logiciels très contrôlés avec des cahiers des charges précis et complet qu'il convient de respecter.³⁵

Cela en fait des logiciels complexes et complets qui doivent s'adapter à différentes collections, différents volumes de données et différents buts notamment avec l'arrivée du secteur privée dans le domaine de la gestion des collections.

Ainsi, un **SGC** doit affronter un grand nombre de difficultés. C'est ce que nous allons aborder ensuite.

³⁵en témoigne la liste dressée par l'organisme *Collection trusts* des logiciels approuvés : <https://collectionstrust.org.uk/software/>

II. Défis et difficultés que doit relever un système de gestion des collections aujourd'hui : Bigdata et harmonisation des données

- Quels sont les défis que doivent relever ces systèmes aujourd'hui afin de rester pertinents. Concentration sur la manière dont ces systèmes doivent s'adapter aux standards (EAD, RIC, EAC, MARC, UNIMARC) et aux modèles conceptuels/normes (ISAD(g), FIAF, FRBR, CIDOC CRM). Je vais me baser sur des lectures de cahier des charges (sans les citer) afin de faire un état des lieux des besoins des structures désireuses ou nécessiteuses de gérer des collections.
- **Plan :**
 1. Les particularités du monde patrimonial : interopérabilité des données, masses de données, sensibilités des données, standards/normes/modèles conceptuels (*Plus en détails que dans l'introduction*)
 2. Besoins des infrastructures potentiellement intéressées par ce genre d'outils : gestion de thésaurus, connexion à d'autres infrastructures, visibilité des collections, s'adapter aux normes/standards et modèles en partant d'une base dite "maison" ou d'un logiciel qui n'est plus à la page.
 3. Cas pratiques : gestion de l'image animée dans le monde patrimonial. En prenant exemple sur cette typologie documentaire, l'idée est de mettre en exergue les enjeux et besoins précédemment cités comme ceux de la typologie en question.

III. Présentation de la solution SkinSoft

- Partie soumise à validation de l'entreprise. Mais l'idée serait de montrer comment fonctionne le logiciel et comme il tend à répondre aux besoins et difficultés que nous avons citées plus haut. En faire un cas d'étude en un sens. Et comme la suite va beaucoup être liée à ce logiciel, c'est aussi le moment de poser le vocabulaire et concept de base.
- **Plan :**
 1. Descriptions du marché dans lequel elle s'inscrit : concurrence, monopole Axiell en Europe, dimensions internationales donc pluralité des normes.
 2. Spécificité de la solution et intérêt de chaque spécificité : modularité, personnalisation de l'expérience
 3. Composition techniques et raison des choix (*autant que possible*) : architecture No-SQL, appui sur le système de *Information Retrieval* Elastic-Search
 4. Limites

Chapitre 2

L'intelligence artificielle dans la gestion des collections patrimoniales : réalités techniques, attentes et enjeux

I. Définition de l'intelligence artificielle appliqués à la gestion des collections patrimoniales

De nos jours, dans le domaine de la gestion des objets patrimoniaux et de leurs données reviens régulièrement le terme d'« intelligence artificielle » . En réalité, nous l'entendons aujourd'hui dans toute sortes de contextes et de sphères professionnelles offrant des définitions souvent très différentes.

Nous utilisons ce terme générique pour désigner toute sortes de technologies, processus et outils qui s'apparentent à cette technologie. Cependant, cela amène une confusion technique et technologique importante.

Avant d'approfondir notre travail, il semble important de consacrer un temps à la définition de l'intelligence artificielle. Mais aussi aux réalités techniques désignées dans le cadre de son application aux données patrimoniales.

Le Parlement Européen défini l'intelligence artificielle comme : « la possibilité pour une machine de reproduire des comportements liés aux humains, tels que le raisonnement, la planification et la créativité » .³⁶ La CNIL³⁷ élargie cette notion à toutes technologie avec des « comportements dépassant les capacités humaines, puisque les ordinateurs actuels

³⁶ *Intelligence artificielle : définition et utilisation*, Thèmes | Parlement européen, 9 juill. 2020.

³⁷ Commission nationales informatiques et des libertés

parviennent aujourd'hui à les surpasser dans certaines tâches » .³⁸ Rajoutons que l'autonomie et la capacité de traitement de masse sont des caractéristiques de ces technologies.

Dès lors, on désigne un ensemble de technologies et d'outils capable d'effectuer des tâches relevant de comportements humains sur de grandes quantités de données en autonomie. Ces outils sont créés et appliqués à une très grande variété d'univers métier. Cela à des fins d'accélération de production et d'automatisation de tâches répétitives.

De nos jours, l'intelligence artificielle s'articule autour de notions et domaines clés qu'il convient de présenter.

D'abord les « réseaux de neurones artificiels » . Cette technologie est aujourd'hui au cœur de tout système d'intelligence artificielle. Il s'agit d'un système informatique inspiré du cerveau humain, organisé en couche, ou réseaux, d'unités de calcul appelés « neurones » . Ces réseaux permettent de faire preuve d'apprentissage, d'analyse et d'autonomie dans diverses tâches. Il en existe plusieurs type, comme les réseau de neurones convolutifs et les transformers, sur lesquels nous nous attarderons par la suite.

Ensuite la notion de *machine learning* et *Deep Learning*. La première notion désigne l'ensemble des moyens permettant aux intelligences artificielles d'apprendre et de s'entraîner à accomplir des tâches. La seconde notion est un sous domaine du *machine learning* centré sur l'apprentissage de l'autonomie. Cela passe par la complexification des réseaux de neurones artificiels et des méthodes d'entraînements spécifiques. Aujourd'hui, la tension technologiques amène à privilégier cette méthode.

Pour finir, l'intelligence artificielle générative. Outil basé sur des transformers et du *Deep Learning* afin de générer automatiquement du texte, des images ou encore du son. Ils constituent des modèles à part entière, différent des modèles d'intelligence artificielle ne pouvant qu'analyser des données mais pas d'en générer.

Ainsi, le terme « intelligence artificielle » renvoie à une pluralité d'outils et de réalités techniques. Notons également que le développement constant de ce domaine amène la naissance de tout un langage propre à cet univers. L'utilisation de ce langage n'accorde pas au terme « intelligence artificielle » de définition fixe : il dépend avant tout du contexte dans lequel nous nous trouvons.

Ainsi, deux personnes issues d'univers métier différents peuvent parler de réalités technologiques complètement différentes en employant le même terme. La gestion des collections n'échappent pas à cette règle : on désigne une réalité techniques précises dans ce contexte. Cela s'articule autour de trois domaines : le NLP, la *computer vision* et le *Retrieval Augmented*

³⁸ *Intelligence artificielle, de quoi parle-t-on ?*

Generation.

1. Le NLP : définition

Ce domaine consiste à « permettre aux machines de comprendre, interpréter, et répondre au langage naturel ».³⁹ Cela est possible par la réunion de trois disciplines : la linguistique, la science computationnelle et l'intelligence artificielle.

L'objectif principal de ce domaine est de permettre le dialogue entre l'homme et la machine en se délestant du biais du langage informatique. Ce domaine est très vite devenu un fondement de l'intelligence artificielle. Couplé au *Deep Learning* et aux réseaux de neurones, notamment à transformers, qui ont révolutionné le domaine⁴⁰, il a donné naissance aux intelligences artificielles génératives et *Large Language Model*.⁴¹

Dans le domaine de la donnée patrimoniale, le NLP offre la possibilité d'analyser les données en autonomie. Par sa compréhension du langage naturel, il permet de saisir le sujet, la grammaire et le sens profonds d'un texte à partir des données contenues.⁴² Cela représente une nouvelle opportunité d'analyse des vastes corpus documentaire conservés par les institutions patrimoniales.⁴³

Dès lors, il semble possible de créer des correspondances sémantiques entre les documents. En effet, ces systèmes peuvent comprendre un texte, mémoriser son sens grâce à une vectorisation (*principe que nous explorons plus tard*), et de le rapprocher à un autre texte sur la base de correspondances sémantiques.

Ce domaine recouvre un grand nombre d'outils qu'il convient de présenter :

1. Le *Name Entity Recognition*. Outil qui consiste à repérer tous les noms propres et les associer à une entité. Dans un texte, il saura alors reconnaître que « Paris », et toutes ces occurrences, correspond à un lieu.⁴⁴
2. La coréférence. Outil consistant en l'association d'une entité à des références implicites dans le texte. Par exemple dans « Paris, cette ville est magnifique », il sera compris

³⁹NLP : Qu'est ce que le NLP au juste ?

⁴⁰Jacob Devlin, Ming-Wei Chang, Kenton Lee et Kristina Toutanova, *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, 24 mai 2019, arXiv : 1810.04805 [cs].

⁴¹Cole Stryker Holdsworth Jim, *Qu'est-ce que le NLP (traitement automatique du langage naturel) ?* / IBM, 11 août 2024.

⁴²*Ibid.*

⁴³Thierry Poibeau, « Le traitement automatique des langues pour les sciences sociales : Quelques éléments de réflexion à partir d'expériences récentes », *Réseaux*, 188–6 (2014), p. 25-51.

⁴⁴*Qu'est-Ce Que La Named Entity Recognition ?* / IBM.

que « cette ville » renvoie à « Paris ».⁴⁵

3. Le *Part of Speech*. Il s'agit de pouvoir accorder à chaque mot la bonne valeur grammaticale au sein d'une phrase, ou alors au sein d'échelles plus larges. Ainsi, on met en exergue sa construction grammaticale et on en comprends le sens. Particulièrement utilisé dans les analyses de discours.⁴⁶

Ce dernier se décline dans une version plus poussée appelée le « parsing syntaxique ». Il permet de décoder les liens logiques entre les mots et pas uniquement grammaticale.

4. Lemmatiser. Principe linguistique qui consiste à réduire les mots à leurs formes d'origine que l'on appelle le lemme. Par exemple, un verbe conjugué sera renvoyé à son infinitif. Cela permet d'analyser la phrase dans un état simple, retirant un maximum d'ambiguïté permettant de mieux comprendre le sens des mots. Combiner à un *Part of Speech*, on peut alors distinguer des homonymes et rapprocher des synonymes.⁴⁷
5. L'*opinion mining*. Cet outil consiste à extraire un sentiment exprimé au sein d'une phrase par l'analyse de différents éléments linguistiques. Ainsi, le modèle peut comprendre si on exprime un sentiment négatif ou positif ce qui permet d'approfondir sa compréhension du sujet.⁴⁸

L'ensemble de ces outils consignés dans un modèle, basé sur des réseaux de neurones artificiels entraînés par *Deep Learning*, permet des analyses de documents textuel et sonore. Ces modèles peuvent alors déterminer le sens des documents.

On parle bien de déterminer ou estimer le sens car ces outils repose sur des calculs de probabilités. Cela les amènes à prédire le mot suivant plutôt que de « comprendre » le mot et le suivant. Cela peut amener à des erreurs, allant jusqu'à inventer de la données : c'est ce que l'on appelle l'hallucination.

2. La *computer vision* : définition

La *computer vision* vise à donner à des systèmes la capacité de percevoir, analyser et « comprendre » des images, aussi bien fixe que des images animées. L'objectif est de passer d'un amas de pixel à une informations structurées compréhensible par un modèle, comme une

⁴⁵Frédéric Landragin, « Anaphores et coréférences : analyse assistée par ordinateur » ().

⁴⁶Jacob Murel Ph D. Kavlakoglu Eda, *Qu'est-ce que la racinisation et la lemmatisation ?* / IBM, 18 févr. 2025.

⁴⁷*Ibid.*

⁴⁸Dominique Boullier et Audrey Lohard, *Opinion mining et Sentiment analysis : Méthodes et outils*, Marseille, 2012 (Sciences Po médialab).

image l'est pour un humain. Cela repose notamment sur la construction et l'entraînement de modèle pour des tâches, des types de documents et d'objets précis.⁴⁹

Ce domaine est en pleine expansion depuis l'apparition du *Deep Learning* et des réseaux de neurones de type réseau de neurones convolutifs. Grâce à cela, les modèles spécialisés sur la *computer vision* apprennent de manière autonome à extraire des caractéristiques des images sans interventions humaines.

Pour le monde patrimonial, la *computer vision* représente un avantage important. En plus de posséder des tableaux, ou des images animées, la numérisation massive des collections à produits bon nombre d'images de textes. La *computer vision* permet dès lors de procéder à des analyses de collections entières et de toutes typologies. une fois associée au NLP, on rend possible l'interprétation de ces documents.

Ce domaine repose sur plusieurs tâches fondamentales :

1. La classification. Procédé technique qui consiste à reconnaître un certains nombre de caractéristiques afin de déterminer sa typologie. Ainsi, le modèle différencie un tableau, d'une gravure, d'un texte, d'une image animée.⁵⁰
2. La détection d'objet. Méthode permettant de repérer une entité définie au sein d'une même image et d'en délimiter les contours. Cela permet de repérer un objet ou une entités cibles au sein d'un corpus.⁵¹
3. La segmentation. Procédé technique afin de déterminer et détourer précisément les objets et entités présentes sur une image. Cela peut être de reconnaître tous les éléments d'un tableaux, de repérer les lignes d'un texte ou de suivre des entités au sein d'images animées. Ce processus permet de distinguer tous les objets au sein d'une image, sans les identifier.⁵²
4. L'OCR et l'HTR. Outils de détection et d'extraction de texte, manuscrit ou typographié, au sein d'une image. Grâce au NLP, cet outil peut aussi le rendre interrogeable. Ces outils sont largement plébiscité au sein des institutions conservants de vaste corpus d'archives.⁵³

⁴⁹ *Qu'est-Ce Que La Vision Par Ordinateur ?* / IBM.

⁵⁰ *Ibid.*

⁵¹ *Ibid.*

⁵² *Ibid.*

⁵³ *Techniques et formats de conversion en mode texte*, BnF - Site institutionnel ; *Intelligence artificielle et collections de la BnF : l'exemple de l'HTR (Handwritten Text Recognition)*, BnF - Site institutionnel.

Dans le domaine patrimoniale, la *computer vision* permet l’analyser des collections numériques des institutions conservatrices. Couplée à des technologies NLP, cela peut permettre de rendre ces images interrogeables.

Cependant, la *computer vision* présentent deux limites dans sa conception actuelle a commencer par sa grande dépendance aux données d’entraînement. Les processus d’entraînement en *computer vision* sont lourds et mobilisent beaucoup de ressources. Ainsi, on produit souvent des modèles entraînés sur des données, tâches et typologies d’objets patrimoniaux précises. Lors de l’analyse, le modèle associe le document qu’il traite à ses données d’entraînement, soit ce qu’il « connaît » . Si le document traité sort de son champs de « connaissance » il est alors en proie à l’hallucination.

De plus, ces outils restent des outils basés sur des calculs statistiques et de probabilités. Ainsi, il n’y a pas de « compréhension » de ce qu’il analyse mais simplement des associations avec ces « connaissances » . C’est une limite importante pour des analyses très fines basées sur des connaissances précises.

3. le *Retrieval Augmented Generation* : définition

Le *Retrieval Augmented Generation* désigne une manière d’employer certaines technologies d’intelligence artificielle dans un but précis : un processus. On aborde donc un champs différents, puisqu’on parle d’un processus au cœur d’outils à destination du monde patrimonial.

L’objectif principal de ce processus est de limiter la capacité à halluciner d’un *Large Language Model*. Pour cela, on met à disposition une base de connaissance large, diversifié et spécialisée sur un monde professionnel afin de consolider le modèle sur ce contexte. Ainsi, le *Retrieval Augmented Generation* associe les capacités d’analyses et de générations de certains outils a une fiabilisation de son système de recherches. De cette manière, on produit un outil capable de distribuer de la connaissance et non de l’inventer.⁵⁴

Pour ce faire, on connecte un *Large Language Model* à une ou plusieurs bases de données externes. Il va dès lors y puiser des données et s’y appuyer afin de justifier ses réponses. Cela se base sur 3 principes : ⁵⁵

1. *Retrieval* : désigne la capacité à aller chercher de la donnée dans des sources externes désignées. Il récupère de la données exacte et pertinentes, c’est à dire qui correspond à la requête utilisateur.

⁵⁴Ivan Belcic, *Qu’est-ce que la génération augmentée par récupération (RAG) ?* / IBM, 3 oct. 2025.

⁵⁵Pour plus d’informations voir Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang et Haofen Wang, *Retrieval-Augmented Generation for Large Language Models : A Survey*, 27 mars 2024, arXiv : 2312.10997 [cs.CL]

2. *Augmented* : désigne la capacité d'enrichir la requête utilisateur et/ou la réponse générée à l'aide des données stockées. Pour la requête utilisateurs, il s'agit de lui associer les bonnes données stockées afin de mieux cerner son périmètre. Pour la réponse générée, il s'agit de pouvoir indiquer une source, ou un extrait, vers laquelle se référer.
3. *Generation* : désigne finalement la capacité inhérente aux *Large Language Model* de générer des réponses, le plus souvent en langage naturel.

Par le respect de ces principes, on assure la pertinence des réponses, leur adéquation à un contexte professionnel ou scientifique et la validité des données retournées. Les institutions patrimoniales voient en cette architecture la possibilité simplifier et consolider la recherche dans leurs collections ou corpus. Cela grâce à une interrogation de ces éléments facilitées et à des réponses générées plus exhaustives et fiables.

Nous abordons plus en détails son fonctionnement et ses apports dans des processus déterminés ici à la page 38 de ce travail.

Cette architecture prometteuse connaît quelques fragilités. Son efficacité dépend de sa capacité à bien « comprendre » les sources qui lui sont connectés, autrement tout résultat sera faussé. En fonction des sources, de leurs nombres et de leurs complexités, le résultat de cette première étape est hautement variable. De plus, le *Retrieval Augmented Generation* peut parfois ne pas suffire à contraindre les *Large Language Model* à l'utilisation de certaines sources. En effet, l'autonomie des modèles peut les conduire à outrepasser certaines instructions, sans jamais sortir de l'infrastructure.⁵⁶

4. Apports des outils et état des lieux de leur application dans la gestion des collections

Aujourd'hui, ces outils d'intelligence artificielle sont perçus comme des solutions potentielles face aux difficultés actuelles par les professionnels de la gestion patrimoniale. En effet, devant la massification des données, la diversité des standards de descriptions et modèles conceptuels, et l'ambition d'interopérabilité des données à des échelles internationales et mondiales, les institutions manquent de moyen.

Ces outils représentent des solutions car ils permettent les traitements de masses en relative autonomie. Cela peut réduire drastiquement la charge de travail reposant aujourd'hui sur le personnel souvent en sous-nombre. Grâce à leurs capacités d'analyses, de « compréhension » de contextes et d'utilisation du langage naturel pour expliquer des concepts et des

⁵⁶ *Ibid.*

analyses, ces outils sont particulièrement intéressants.

Ces logiques ont conduit alors à la mise en place de premières expériences ponctuelles, comme HIMANIS⁵⁷, puis aux premiers outils instaurés au sein d'institution comme LECTAUREP ou INASpeechSegmenter.⁵⁸ Ils permettent de réduire le temps de traitement de certaines typologies d'objets patrimoniaux, d'accélérer des tâches de traitement et d'offrir de nouvelles dimensions de recherches.

Ces outils émergent principalement dans les grandes institutions, comme les Archives Nationales ou l'INA, et viennent compléter des méthodes de gestions préexistantes. Cependant, ce n'est pas la réalité pour toutes les institutions conservatrices.

En effet, la plus part des structures utilisent aujourd'hui des systèmes de gestion des collections fournis par des entreprises externes, comme SkinSoft, situé au cœur de leurs pratiques. Ces structures plus petites, ont alors du mal à intégrer de nouvelles solutions. D'abord car il peut être difficile de les faire s'interfacer avec des systèmes de gestion des collections tierces. Ensuite par un manque de compétences techniques et de moyens financiers. Il y a donc un décalage entre l'avancée des pratiques de gestions patrimoniales et la possibilité de les inclure à toutes les échelles.

Pour ces raisons, nous constatons aujourd'hui un effort global des fournisseurs de solutions externes de tendre vers l'inclusion de tels outils. D'abord afin de correspondre aux nouveaux besoins professionnels. Ensuite, afin de permettre aux institutions utilisatrices de disposer de tels moyens à des coûts techniques et financiers relativement accessibles.

⁵⁷D. Stutzmann, J.F. Moufflet et S. Hamel, « La recherche en plein texte dans les sources manuscrites médiévales... ».

⁵⁸Arthur Lezer, *inaSpeechSegmenter : décompte du temps de parole des femmes et des hommes*, INA le lab.

II. Les enjeux techniques :

Ainsi, l'intelligence artificielle représente aujourd'hui une solution pour le traitement des données et collections patrimoniales. Elle offre l'opportunité de palier deux grandes difficultés : la masse et le temps de traitement. Par leur autonomie et capacité, relative fiabilité et rapidité de traitement sur des masses importantes de données, ces dernières pourraient ne plus être des freins à la gestion des collections. Cependant ces considérations, si elles prennent en compte les limites précédemment vues, semblent déconnectées des réalités techniques, technologiques et financières des institutions ciblées.

Les technologies d'intelligence artificielle connaissent aujourd'hui des évolutions rapides et importantes. Elles sont d'ordre technologique et de la popularité de ces outils. Prenons l'exemple des *Large Language Model* :

Leur popularité est croissante. En témoigne le rythme de création et de publication en ligne des *Large Language Models* passant de 1 modèles public en novembre 2022 à plus de 500 mille modèles en libre accès sur *Huggin Face*⁵⁹. Cette croissance impressionnantes démontre l'intérêt que l'on a envers ces derniers, également constatable par le nombre d'utilisateurs. Par exemple, ChatGPT est passé de 400 millions d'utilisateurs début 2025 à plus de un milliard en août 2026.⁶⁰

Pour ces technologies, notamment les *Large Language Model* il y a un nouveau enjeu. Il est amené par l'*open-source* : phénomène de publication en ligne des codes de ces outils pour permettre des déploiement dans des environnements locaux, sous conditions de licence ou d'achat. Cela pousse leur adoptions personnelles et professionnelles.

Pour l'aspect technologique, l'évolution entre 2022 et aujourd'hui est vertigineuse. Les corpus de données d'entraînement ne font que grossir, amenant l'ajout de ressources informatique pour créer des modèles plus puissants. De plus, les *Large Language Model* « classiques » sont peu à peu remplacé par des modèles multimodaux, capable de traiter du texte mais aussi des images, sons et vidéos. Ce qui démontre la caractéristique éphémères de ces technologies.

C'est une première limite : les technologies et processus employés sont rapidement dépassée par des éléments plus récents. Si cela signifie que ce qui n'est pas possible aujourd'hui le sera peut être demain, cela pose aussi de nombreuses questions techniques. Quel outil utiliser ? Quand arrêter de s'adapter à l'actualité ? Comment maintenir son processus si dans 2 ans le modèle n'est plus maintenus ?

Une seconde limite concernant l'utilisation de ces outils est celle des coûts financiers

⁵⁹ *State of Open Models : Summer 2026 Observations*, 12 août 2026.

⁶⁰ *AI & ChatGPT Statistics for 2026 (Usage & Adoption Data)*, Instant Press.

et de leur impact. Cela dissocie la question de l'usage de celle de l'implémentation, car il s'agit de déterminer les conditions dans lesquelles on dispose de cette technologie et les impacts provoqués. Ces choix sont d'ordres financiers, politiques, infrastructurels, éthiques et de l'ordre de la sécurité des données. C'est pour cela que l'on parle de "modèle" : ce sont deux modes de fonctionnements distincts, posant leurs propres enjeux sur chacun des points. Les deux modèles distincts sont les suivants :

Le modèle reposant sur un système d'abonnement à une solution proposée par une entreprise externe. Cette dernière n'est pas possédée par l'institution mais par un acteur externe qui en assume l'hébergement, les coûts et la maintenance. C'est sur ce principe que repose l'agent conversationnel public : c'est un service appartenant à une entreprise externe mais qu'on utilise sur nos données. Ce modèle économique repose sur trois principes :

1. Celui de l'abonnement. L'institution ayant souscrit à ce dernier paye régulièrement une somme définie au fournisseur de la solution afin de l'utiliser. Cela permet de prévoir les coûts, permettant à une institutions de choisir une solution selon un budget défini et connus.
2. Celui de la dépendance de l'utilisateur envers le fournisseur. En effet l'utilisation de l'outil et l'hébergement des données traitées relèvent dès lors de l'entreprise externe, provoquant une perte de contrôle. Si le fournisseur arrête de maintenir son modèle, l'institution se retrouve sans outil. Si le fournisseur connaît une faille de sécurité, ce sont les données patrimoniales qui sont en danger.
3. Celui de la souveraineté des données. Cette notion désigne la possibilité de gérer et contrôler ses propres données dans leur préservation, diffusion, usage et traitement. Utiliser une solution externe demande aux institutions d'y renoncer partiellement ou du moins de faire des concessions. Les données sont stockées, préservées et traitées par le fournisseur qui devient dès lors responsable de leur sécurité. C'est un véritable enjeu car confier ses données à une entreprise tierce est un véritable risque de sécurité informatique. En effet, il y a moins de visibilité sur l'utilisations de ces données et sur leurs sécurités, plus sensible face aux risques croissant de failles informatiques.

Dans le monde patrimonial, ce modèle est incarné dans des solutions comme Archipanion⁶¹ ou encore des systèmes de gestion des collections comme Axiell⁶² et à terme SkinSoft.

⁶¹ Archipanion pour le Ciné-Journal suisse.

⁶² Pour plus d'informations voir <https://www.axiell.com/fr/solutions/product/ai-for-museums-and-archives/>

Le second modèle est celui de l'intégration technologiques en local. L'enjeu est alors la capacité institutionnelle à développer et héberger ses propres processus et technologies d'intelligence artificielle par ses propres moyens. Cela permet de renoncer à un appui sur une entreprise externe et des risques et contraintes liées. Ce modèle est celui employé par les grandes institutions, comme les Archives Nationales ou l'INA. Il repose sur 3 principes clés :

1. La dimension locale. L'outil ou processus est développés ou adaptée, dans le cas de l'utilisation d'un modèle *open-source*, en interne facilitant l'adaptation à des besoins, contextes et pratiques précises. Cela permet un hébergement local, c'est à dire interne à l'institution amenant les données à ne pas sortir de l'institution. On limite ainsi les risques de faille de sécurité par plus de contrôle sur l'ensemble du processus.
2. Le coût des infrastructures et des compétences. Si on développe, traite et stocke localement il faut alors avoir les compétences et infrastructures adaptées. Cela demande de disposer de professionnels spécialisés dans différents domaines (*intelligence artificielle, sécurité informatique, développement, etc*). Ces derniers évoluent très rapidement et les compétences deviennent de plus en plus pointues, rares et coûteuses. Pour les infrastructures, les technologies sont de plus en plus lourde et demandeuse en puissance de calcul. Cela fait intervenir Il faut alors disposer de mémoire vive, mémoire vidéo, processeurs et processeur graphiques qui, avec les récents progrès technologiques, coûtent de plus en plus cher. Ajoutons que l'utilisations de ces composants informatique implique un coût électrique : plus la puissance disponible est importante, plus son côté potentiel augmente.
3. Le coût des technologies et de leurs maintiens. L'installation locale des technologie demande de les développer ou alors d'en utiliser des préexistantes. L'*open-source* permet de récupérer différents modèles ou processus et de les installer dans son propre environnement informatique. Cependant, ces technologies ne sont pas nécessairement gratuite : il peut être nécessaire de payer une licence et de la renouveler afin de pouvoir utiliser la technologie dans le temps.

Ce modèle est bien plus flexible et intéressant dans un aspect de sécurité et de contrôle des processus, outils et données. Pouvoir disposer de ces technologies en local permet de mieux répondre aux besoins de traitement institutionnels. C'est une solution idéale. Cependant, les coûts financiers et humains très élevés réservent cette possibilité à une sélection d'institutions qui ne représentent pas la réalité du monde patrimonial. Les institutions et entreprises de plus petits envergures sont majoritaires : elles ont des besoins parfois aussi importants, mais

des moyens bien plus limités.

On comprend dès lors qu'intégrer de l'intelligence artificielle, peu importe la réalité technique désignée, c'est avant tout faire des choix politiques, économiques, structurels et infrastructurels. Cela amène à se placer dans un modèle ou un autre : donc face à certains enjeux qu'il faut choisir.

Cela amène les institutions à se retrouver dans des dilemmes. Pour le modèle sur abonnement, le dilemme a lieu entre le besoin de disposer de ces outils et le besoin de souveraineté sur ces données et outils. Aujourd'hui, il est au cœur des ambitions de ces institutions de préserver leur souveraineté sur leurs données et outils. Pour le modèle local, c'est un dilemme de rationalisation entre les coûts engendrés, à court et long terme, et les performances nécessaires. Plus les performances recherchées sont élevées, plus le coût l'est également. Ce qui peut dès lors décourager la mise en place de ces solutions et rediriger vers le premier modèle, parfois inadapté aux besoins de traitement.

Cette réalité conduit les acteurs du monde patrimonial à introduire progressivement ces technologies sur des segments précis des collections. Autrement dit, en fonction des besoins de traitement et de communications au près d'un public cible, certains aspects de la collections seront plus rapidement traités par de l'intelligence artificielle que d'autres. C'est une introduction progressive qui entraîne une division du traitement des collections et données patrimoniales, ce qui peut créer des dissonances et des disproportions de traitement au sein des collections patrimoniales. Cela pourrait remettre en question les tentatives actuelles d'homogénéisation des descriptions, devant ainsi prendre en compte une double réalité : les processus automatisés et ceux encore manuels. Chacun entraînant une qualité de données et des possibilités de gestions différentes.

Pour conclure, nous pouvons dire qu'il faut s'attendre à des évolutions lentes et sélectives dans le domaine de la gestion des collections. Cela amène tout de suite à réévaluer la valeur à accorder à l'implémentation de l'intelligence artificielle dans la gestion des collections. Ce n'est pas une révolution, soudaine et absolue, mais une évolution progressive et nuancée qu'il faut accompagner.

Les enjeux financiers, humains et politiques sont aujourd'hui encore trop grands pour que chaque institutions et entreprises puissent se doter de tels outils. Et encore moins d'outils sur mesure. La tendance institutionnelle à reposer sur un modèle à abonnement peut aussi être une explication quant à l'intégration de ces outils dans des systèmes de gestion des collections externes. Cela place ainsi les systèmes de gestion des collections au cœur de l'évolution technologique en matière d'intelligence artificielle.

III. Les enjeux juridiques publics et privés :

- L'idée est de présenter le cadre juridique dans lequel doit s'inscrire la solution basée sur de l'IA. Au contact de données sensibles, à caractère non communicable ou autre, il faut forcément respecter des contraintes juridiques. La position de SkinSoft est intéressante, c'est une entreprise qui intervient sur les données patrimoniales ou d'autres entreprises. Donc en tant que fournisseur logiciel, comment on compose avec ce cadre juridique ?

- **Plan :**

Présentations des collections patrimoniales privées et publiques sous un aspect juridique. Sensibilité des données, respect des délais de communication, contact avec l'utilisateur qui demande des données personnelles, documents non communicables, etc.

Description de différents appareils juridiques mis en place pour contrôler et limiter l'IA sur des données sensibles, comme les données patrimoniales. Articles et textes de lois à l'appui

Interrogation sur la position d'un fournisseur de **CMS** vis-à-vis de tout cela. Il doit être conforme aux lois, mais aussi aux politiques internes de chaque institution et garantir le respect de leurs volontés. Montrer la complexité de la position.

Deuxième partie

**Implémenter l'IA dans un CMS : état
des lieux et ambitions de SkinSoft.**

Chapitre 3

Le traitement du langage naturel : faciliter l’usage et fiabiliser la recherche

I. La recherche et l’utilisation de la solution dans le logiciel SkinSoft

La première technologie d’intelligence artificielle envisagée dans le logiciel SkinSoft est le NLP au sens large. L’objectif est d’améliorer l’accessibilité aux données stockées ainsi que l’usage de l’application par le langage naturel. Ce dernier permet à l’utilisateur de contextualiser sa demande à la de phrase, augmentant la compréhension du besoin utilisateur. Ainsi, un besoin utilisateur mieux exprimer et mieux compris permettrait d’apporter des solutions et reponses de meilleure qualités. Permettre l’interaction en langage naturel entre l’utilisateur et l’application ouvre la voie à deux axes : l’amélioration du système de recherche dans les données, et l’amélioration de la compréhension et de l’utilisation de l’application.

Avant de développer les deux axes, auxquels le NLP répond au travers d’outils et processus différents, il est fondamental de comprendre le fonctionnement d’origine de l’application. Cette partie est donc consacré à l’exploration de la manière dont le logiciel SkinSoft fonctionne sur les deux axes dépeind. Ainsi, nous pourrions mettre en évidences les limites actuelles auxquelles l’intégration du NLP doit répondre.

Le stockage et la recherche des données sont fondamentale pour un **SGC**. David Bearman sépare deux éléments, le **SGC** qui ne doit pas se contenter de stocker et de retrouver l’information, et l’*Information Retrieval System* qui lui est spécialisé sur cet aspect. Pour autant,

ce ne sont pas des outils opposés mais au contraire des outils complémentaires, l'*Information Retrieval System* devant être un module intégré aux *SGC*.⁶³

Cette logique est encore conservée aujourd'hui comme en témoigne le fonctionnement du logiciel SkinSoft. Il s'appuie sur un *Information Retrieval System*, ce que désigne David Bearman par *Information Retrieval System*. Ce dernier est le logiciel open source ElasticSearch, spécialisé sur les bases de données No-SQL orientée document comme celle utilisée par SkinSoft.

ElasticSearch présente l'avantage d'être opensource. Ainsi, son code est accessible au public ce qui permet une grande transparence et adaptabilité applicative. De plus, c'est une solution dotée d'une grande scalabilité. C'est à dire qu'en cas d'augmentation de la masse de données à traiter, ses performances et les coûts engendrés restent stables.

Son fonctionnement est le suivant⁶⁴ :

1. Les données de la base sont importées dans ElasticSearch en format JSON⁶⁵ via son API dédiée.
2. Le logiciel analyse la structure de la base de données : pour chaque collection, ou table en langage SQL, ElasticSearch génère un index qui contient toutes les données associées. C'est avec ces index que l'utilisateur interagit en réalité.
3. Ces index sont ensuite morcelés en *shards* afin de pouvoir séparer les données dans l'objectif d'accélérer le temps de traitement. Rechercher dans des fragments demande moins de temps et de puissance que de chercher dans un index entier dès le départ.
4. Ensuite, ElasticSearch fonctionne sur des nœuds, c'est à dire des serveurs, qui ont des fonctions et tâches dédiées : configuration, prétraitement de données et simple stockage. Les *shards* vont se répartir sur les nœuds correspondant : les *shards* en rapport avec la configuration vont se répartir sur les nœuds de configurations, ceux pour le prétraitement des données sur les nœuds de prétraitement et toutes les autres données sur le dernier nœud. Ils sont interrogeables en parallèle : c'est à dire qu'on ne traite pas les nœuds successivement mais dans un même temps. Pour faciliter le travail, la taille de ces nœuds est limitée : ainsi on va avoir plusieurs nœuds d'une même nature.
5. Le logiciel constitue alors des *cluster*, c'est à dire des ensembles de 3 nœuds : un de chaque type.

⁶³Archives & Museum Informatics : Publishing : Archives : Functional Requirements for Collections Management Systems : Table of Contents..., p.43.

⁶⁴Juvénal JVC, Interrogez efficacement vos bases de données avec ElasticSearch, Data Transition Numérique, 21 juin 2022.

⁶⁵Dans le cadre de SkinSoft, la base de données No-SQL utilisée, MongoDB, stocke déjà les données sous format JSON. C'est donc une intégration facilitée.

Une fois toute cette étape de traitement terminée, Elasticsearch a constitué une base de données structurée à sa manière et interrogeable via son API. En voici un schéma :




FIG. 1 : Schéma du fonctionnement d'Elasticsearch

Ce système est donc lié à l'applicatif : il n'est pas un composant créé par l'application mais bien un élément externe relié à l'application. Elasticsearch propose ses propres modalités de recherche : recherche simple, recherche full-text⁶⁶, recherche par mots-clés, recherche avancée ou bien par facettes, disons par catégorie et récurrence des données. Pour faciliter l'usage, l'application à créer une barre de recherche qui permet à l'utilisateur de créer ces requêtes de manière visuelle et interactive. C'est une interface *no-code* qui permet d'envoyer les requêtes depuis l'application vers l'API Elasticsearch.

Cependant, ces *Information Retrieval System* comme Elasticsearch rencontrent des limites dans l'exploitation des données des institutions patrimoniales. En effet, leurs structures sont largement complexifiées : d'abord par l'arrivée de nouvelles normes, modifiant des structures, et ensuite par le phénomène de densification des bases de données rendant leurs interrogations plus difficiles. Ces éléments n'ont fait que de mettre en évidence des limites déjà présentes, mais qui n'était pas forcément bloquantes.

D'abord, ces systèmes ne prennent pas en compte la notion de contexte. La recherche s'effectue sur des critères de pertinences attribués par la correspondance de mots-clés. Ces mots clés sortent deux informations de leurs contextes : d'abord le mot qui peut avoir plusieurs significations en fonction du document et de la phrase, son contexte. Ainsi on risque d'avoir des résultats manquants de pertinence puisque la sémantique n'est pas intégrée. Ensuite, un document peut avoir un tout autre sens lorsqu'il est lié à un ensemble de documents. Or, l'analyse par mots-clés ne prend pas en compte cette notion. Ainsi, une recherche renverra vers une pièce d'archive d'un fonds mais pas vers les autres composants de ce même fonds. Seule la pièce pertinente sera renvoyée à l'utilisateur sans le fonds auquel il se rattache ce qui peut être bloquant pour un chercheur.

De plus, le système de correspondance par mots-clés des *Information Retrieval System* est fragile face aux variations d'indexation. Malgré les efforts de normalisation qui ont été menés, l'indexation humaine est par nature variable. Deux personnes vont décrire un même objet en utilisant des mots différents et le principe de correspondance par mots-clés est trop sensible à cette variabilité.⁶⁷ Elasticsearch, par exemple, s'appuie sur le modèle BM25 qui établit la pertinence en se basant sur la fréquence des termes. Il est donc en proie à deux limites : l'utilisation de même terme pour définir des réalités différentes d'une part, et leurs utilisations dans des contextes différents d'autres parts. Cela brouille les capacités d'analyses du logiciel ce qui impacte la qualité et l'exhaustivité des résultats. En effet, un document présentant une fréquence de terme "pertinents" moins haute qu'un autre ne signifie pas

⁶⁶méthode de recherche qui explore des documents entiers à la recherche de chaîne de caractères demandées.

⁶⁷Marijn Koolen, Jaap Kamps et Vincent Keijzer, « Information Retrieval in Cultural Heritage », *Interdisciplinary Science Reviews*, 34 (18 juill. 2013), p. 268-284, p.273.

qu'il est moins pertinent. Le *Information Retrieval System* n'intègrent pas cette notion et propose donc des résultats parfois non pertinents. Cette limite peut être élargie au contenu même des documents historiques, de plus en plus renseignés dans les bases de données grâce aux technologies d'OCR et d'HTR. Le vocabulaire employé provoque une double difficulté : la correspondance sémantique et terminologique avec le langage actuel, et la variation de l'écriture d'un même mot à travers le temps. Les *Information Retrieval System* n'associent pas les termes historiques à des équivalents actuels ou à leurs évolutions orthographiques. Certaines recherches peuvent alors manquer d'outil précis.⁶⁸

Ensuite, ces systèmes sélectionnent les données pertinentes par proximité thématique. C'est à dire que des données se rattachant à des thèmes similaires sont retournées à l'utilisateur ensemble. Dans le domaine patrimonial, des proximités thématiques existent entre des typologies documentaires différentes, ce que les *Information Retrieval System* n'exploitent pas puisqu'ils cloisonnent ces dernières.⁶⁹

Une autre difficulté est celle du cloisonnement terminologique des typologies patrimoniales. L'hétérogénéité des collections est prise en charge par la plupart des applications. SkinSoft le fait également à travers ces modules dédiés à chaque typologie⁷⁰. C'est ce qu'on appelle le traitement par silo : chaque typologie documentaire ayant son propre silo, schéma d'indexation et vocabulaire. Ainsi, les *Information Retrieval System* ont du mal à établir une porosité entre les silos ce qui ne reflète pas la réalité scientifique puisque des connexions sémantiques existent.⁷¹ Pour le logiciel SkinSoft, cette limite est à nuancer : un outil de "recherche fédérée" permet de faire des correspondances entre ces silos. Ainsi, il est possible de rechercher à travers toutes les typologies documentaires via des correspondances de champs. Cependant, il y a des limites : seules certaines typologies documentaires sont interrogeable et uniquement sur un nombre restreint de champs. Car si des correspondances existent, elles ne sont pour autant pas évidentes à traduire dans un *Information Retrieval System* qui est trop rigide.

De plus, il y a un décalage entre croissant entre les pratiques des utilisateurs et les outils proposés par ces systèmes. Ce n'est que très récemment que des études ont été menées sur ce sujet⁷² et elles révèlent 3 problèmes fondamentaux :

⁶⁸Babak Ranjgar, Abolghasem Sadeghi, Maryam Shakeri, Fatema Rahimi et Soo-Mi Choi, « Cultural Heritage Information Retrieval : Past, Present, and Future Trends », *IEEE Access*, 12 (1^{er} janv. 2024), p. 42992-43026.

⁶⁹M. Koolen, J. Kamps et V. Keijzer, « Information Retrieval in Cultural Heritage »...

⁷⁰Voir page III.

⁷¹*Ibid.*, p.274.

⁷²Claire Warwick, Melissa Terras, P. Huntington et N. Pappa, « If You Build It Will They Come? The

1. D'abord, l'amélioration des navigateurs en lignes, tels Google, ont habitué l'utilisateur à fonctionner par échantillonnage : la pertinence des résultats est analysée à partir de quelques pages seulement. Ainsi, quand les *Information Retrieval System* génèrent du bruit, il y a un désintérêt utilisateurs pour les résultats retournés.⁷³
2. Ensuite, la complexité des interfaces de recherches. En effet, les utilisateurs n'ont pas l'habitude d'utiliser la recherche avancée, la recherche fédérée, les facettes, la recherche plein texte ciblée ou bien encore la recherche croisée propres aux *Information Retrieval System*. C'est une interface simple, qui renvoie des résultats pertinents et qui est donc bien plus attractive. Ainsi, aux yeux d'utilisateur ses outils perdent en intérêt et en praticité.⁷⁴
3. Enfin les *Information Retrieval System* ont leurs propres manière de structurer et indexer les données. Cela impacte directement la qualité des résultats retournés. Ces éléments sont cependant opaque, ce qui freine les chercheurs, notamment, à accorder une confiance complète aux résultats retournés.

D'une manière plus générale, un utilisateur en face d'un outil opaque, proposant une interface complexe et des résultats bruités risque d'accorder moins de crédits au logiciel et s'en désintéresser.

Nous devons quand même nuancer ce propos. L'étude mentionnée traite des réactions et habitudes d'utilisateurs en tout genre face aux interfaces des sites d'institutions culturelles. Ce n'est pas une étude de comportement de professionnel face à des **SGC**.

Ainsi, l'impact des 3 points relevés n'est pas équivalents à ce qui est mentionné dans notre cas. Il est cependant une réalité que nos habitude d'utilisateur de moteur de recherche comme Google influence nos habitudes et attentes professionnelles. Au cours du stage, quelques retours utilisateurs m'ont permis d'associer les difficultés reportés dans l'article mentionné aux difficultés soulevées par des utilisateurs. C'est pour cette raison que figure ici ces limites, bien qu'ils soient nécessaire de les recontextualiser et de leurs accorder une moindre importance.

Finalement, dans des collections toujours plus vastes et complexe, les *Information Retrieval System* ont de plus en plus de difficultés à satisfaire les exigences utilisateurs et scientifiques. La démocratisation des moteurs de recherches et des outils d'intelligence artificielle changent drastiquement notre rapport à la recherche de données. Nos attentes et pratiques

LAIRAH Study : Quantifying the Use of Online Resources in the Arts and Humanities through Statistical Analysis of User Log Data », *Literary and Linguistic Computing*, 23 (14 déc. 2007), p. 85-102.

⁷³ *Ibid.*, p.9.

⁷⁴ *Ibid.*, p.23-24.

en mutation ont forcément un impact sur notre perception de ces outils, notre utilisation de ces derniers et donc leurs évolutions.

C'est particulièrement visible dans l'outil SkinSoft reposant sur une base de données No-SQL de plusieurs dizaines de collections et aux données très variées. L'utilisation d'une indexation par mots-clés traditionnelles offre des performances limitées : on obtient facilement beaucoup de bruit à moins de savoir comment retrouver ce que l'on cherche. L'une des causes est la répétition des champs dans l'application : un même champ peut apparaître plusieurs fois et contenir des données de nature différentes. De plus, SkinSoft propose son logiciel afin de gérer tous les types de collections : des plus petites et homogènes, aux plus vastes et hétérogènes. Plus la collection est vaste et hétérogène, plus le *Information Retrieval System* atteint ses limites et offre des performances moindres.

L'*Information Retrieval System* est également mal adapté au principe de recherche fédérée. En effet, chaque typologie de collections est sujette à son propre module de gestion qui coexiste avec les autres. SkinSoft tire partie de cela par la recherche fédérée des modules permettant d'interroger plusieurs typologies de collections à l'aide des mêmes champs. Cependant, seulement quelques champs sont pris en compte et le manque de compréhension contextuelle et syntaxique du *Information Retrieval System* est une grande limite.

Ainsi, le logiciel SkinSoft cherche à améliorer son système de recherche par le NLP afin de réduire le bruit généré, développer sa recherche fédérée, répondre à des requêtes plus exigeantes tout en offrant une plus grande simplicité d'usage. De plus, cela permettrait d'harmoniser les performances offertes par le moteur de recherche puisque cela permettrait de traiter plus facilement de plus grands jeux de données.

Pour l'axe de l'amélioration de l'usage applicatif, nous nous retrouvons dans un domaine moins exploré. Deux éléments sont centraux : le premier est l'amélioration de l'usage utilisateur de l'application et de la compréhension qu'il en a. C'est à dire qu'on envisage le NLP, notamment à travers un agent conversationnel, comme un moyen guider l'utilisateur au sein de l'application. Le second est de proposer un appui à la production de données patrimoniales propres et interopérables, toujours à travers un agent conversationnel. Il pourrait vérifier la saisie des métadonnées et les contradictions potentielles d'ordre sémantique. Ou encore les contradictions avec des normes descriptives appliquées aux domaines documentaires dans lequel on se trouve. Commençons par le premier point :

L'agent conversationnel, comme ChatGPT, connaît une dynamique de croissance technologique et de diffusion très importantes ces dernières années. L'outil se fait remarquer par sa capacité d'interaction avec un utilisateur par l'usage du NLP. Cette caractéristique a tout de suite été vue comme l'opportunité de faire parler les collections et de faciliter les parcours

utilisateurs sur les portails institutionnel. Plusieurs initiatives ont visées à concrétiser cette opportunité, comme celle des musées d'histoire naturelle Australien.⁷⁵

Ces études ont amené à réfléchir sur les interfaces métier des **SGC**. Il y a un véritable questionnement naissant sur l'impact des interfaces proposées dans les « logiciels métiers »⁷⁶ sur la gestion des collections.

Ces études abordent notamment la « surcharge cognitive » , c'est à dire quand une interface propose trop d'informations et d'interactions différentes au point de perdre l'utilisateur.⁷⁷ Dans un **SGC**, la principale source de surcharge cognitive est l'interactivité des éléments. En effet, un objet est reliés à énormément d'éléments individuel mais constamment en lien. Dès lors, la multiplicités de ces connexions et leurs complexités peut surcharger l'utilisateur et conduire à faire des erreurs. Cela peut également créer une charge mentale encombrante pour l'utilisateur réduisant sa concentration.⁷⁸ Cela relève de ce qu'on appel l'*User Experience Design*, c'est à dire la manière de simplifier l'expérience utilisateur.

Le second point est celui de l'interface en elle même. L'interface reflète bien souvent la complexité logicielle et perd l'utilisateur dans son usage applicatif. La multiplications des points d'entrées par exemple dénuée l'application de repère visuelle et exige une expérience de l'application.⁷⁹ Plus important encore, l'interface est importante pour la gestion de l'information. Quand trop d'options ou d'actions sont proposées, l'informations essentielles à extraire ou intégrer échappe à l'utilisateur. Cela peut pousser un utilisateur à éviter ces endroits surchargés et donc ne pas utiliser certaines fonctionnalités⁸⁰. Tout cela relève de ce qu'on appelle aujourd'hui l'*User Interface Design*, où la manière de créer des interfaces logicielles pratiques et simples.

Le logiciel SkinSoft se heurte à certaines de ses complexités. Prenons les points d'accès : bien que groupés à un même endroit dans l'applicatif ils sont nombreux et produise un effet de masse. C'est le propre des logiciels de **SGC** car la gestion d'un tel spectre de données mutliplient nécessairement les point d'accès. La simplifications de l'interface ne peut effacer cette première complexité car l'accès à chacun de ces points d'entrées est nécessaire. De plus, les interactions entre ces éléments sont nombreuses et demandent différentes fonctionnalités

⁷⁵Yiyuan Wang, Andrew Johnston, Zoë Sadokierski, Rhiannon Stephens et Shane Ahyong, *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, 2026.

⁷⁶Logiciel conçu pour répondre à des besoin professionnels.

⁷⁷Fred Paas, Alexander Renkl et John Sweller, « Cognitive Load Theory and Instructional Design : Recent Developments », *Educational Psychologist*, 38 (8 juin 2010), p. 1-4, p.1-4.

⁷⁸*Ibid.*, p.2.

⁷⁹Jakob Nielsen, « Enhancing the Explanatory Power of Usability Heuristics », dans *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, New York, NY, USA, 1994 (CHI '94), p. 152-158, p.153.

⁸⁰*Ibid.*, p.153-154.

situées à différents endroits. C'est encore une fois le propre des **SGC** : prenons l'objets, il reste au cœur d'un bon nombre d'éléments ce qui fait de lui un nœud central. Ainsi, il multiplie les points d'accès et les fonctionnalités associées : depuis un objet on peut créer un ensemble, un projet, une entrée, une sortie, un prêt, et bon nombre d'éléments.

Un autre problème rarement cités dans les études est la duplication de documentation externe. En effet, les fournisseurs logiciels produisent de la documentation métier destinées à guider l'utilisateur. Cependant, cette document n'est pas dans l'application : elle se trouve dans un dépôt externe. Ainsi, quand un utilisateur rencontre une difficultés, il doit ressort de l'application afin de consulter un manuel, ou plusieurs. L'accessibilité à l'informations est un véritable problème : une réponse complexe à trouvée entraîne la perte d'intérêt.

Si des chercheurs proposent de décharger les interfaces afin de les rendre intuitives⁸¹, l'ampleur de la tâche dans les **SGC** est telle qu'on envisage de nouvelles solutions. Le logiciel SkinSoft le démontre bien : l'interface épurée, les efforts de regroupement d'éléments et de leurs répartitions ne suffisent pas à pallier la complexité native dû au **SGC**. L'émergence des agents conversationnel ouvre une nouvelle possibilité : interagir avec l'application par de simple requête. De cette manière, il peut disposer d'un guide interactif qui a la capacité de s'appuyer sur cette documentation métier externe. Cet agent conversationnel peut d'ailleurs être le socle d'une technologie plus importante qu'est celle de l'agent IA, qui est capable lui d'interagir avec l'application.

Pour le second point, très peu d'articles, pour ne pas dire presque aucun, ont été produit sur le sujet. Beaucoup énonce l'idée de faire de l'agent conversationnel un assistant de production, mais très peu y apporte une véritable dimension académique ou des propositions d'implémentation. C'est donc une partie bien plus théorique et expérimentale qui est abordée dans ce point.

Des interfaces trop riches peuvent favoriser la saisie d'erreur dans les métas données, ce qui finit par constituer une bases de données instable. Mais ce n'est pas la seule explication : la redondance de la tâche ainsi que la difficulté à renseigner certains objets en sont des explications plus importantes encore.

Ainsi, sur de large jeux de données, toujours en expansion, les moyens de contrôle actuels mis en place, comme des formulaires de saisies et des champs contrôlés, sont de plus en plus limitées.⁸² En effet, plus la quantité de données à traiter est importante, plus la fiabilité

⁸¹Mitchell Whitelaw, « Generous Interfaces for Digital Cultural Collections », *Digital Humanities Quarterly*, 009–1 (21 mai 2015).

⁸²Michael Lewis, Eljas Oksanen, Frida Ehrnsten, Heikki Rantala, Jouni Tuominen et Eero Hyvönen, « The Impact of Human Decision-Making on the Research Value of Archaeological Data », *ACM Journal on Computing and Cultural Heritage*, 18–3 (9 sept. 2025), 47 :1-47 :22, p.2.

humaine laisse place à des oublis, des erreurs de saisies et des incohérences de données. Si les erreurs sont très nombreuses et variées, les résultats lors du requêtage perdent en qualité⁸³.

De plus, certaines collections spécifiques demandent des traitements particuliers. Prenons l'exemple des collections d'histoire naturelle, notamment des spécimens qui sont nombreux et centraux dans ces collections. Ils se rattachent à des classifications taxonomiques qui ne sont pas fixes : souvent hypothétiques, elles sont ensuite remaniées ou invalidées. Ces changements sont fréquents et concerne assez rapidement un grand nombre de spécimens et donc de notice dans un **SGC**. Il est donc souvent impossible d'assurer la mise à jour totale des espèces dans les grandes bases de données⁸⁴. Ainsi, un agent conversationnel capable de signaler à l'utilisateur la nécessité de mettre à jour certaines notices est particulièrement pertinent. Un agent IA capable de le faire seul, l'est d'autant plus.

Le logiciel *SkinSoft* est un bon exemple des difficultés actuelles rencontrées par les **SGC** et les limites des solutions déjà existantes. En effet, la simplification de l'interface et de l'expérience utilisateurs par l'application des principes d'*User Interface Design* et d'*User Experience Design* est limitée. La complexité native de ces systèmes ne peut être résolue entièrement de cette manière. La massification des données et l'hétérogénéité typologiques des collections constituent des défis demandant de nouveaux moyens de réponses. Ce manque de solutions est dû à un changement de problématique : la question n'est plus de faciliter, mais de créer de nouveaux outils pour combler l'écart entre la capacité de traitement humaine insuffisante face aux besoins du traitement des données massives et hétérogènes.

Ainsi, on comprends que l'intégration d'un agent conversationnel dans l'application a deux enjeux. Le premier enjeu est de simplifier la circulation et l'utilisation de l'application dans sa globalité. Cela est envisagé par la possibilité de converser avec un assistant spécialisé capable de guider en s'appuyant sur de la documentation métier contrôlée. Le second enjeu est donc de disposer d'un assistant capable de tracer l'activité faite, celle à faire et ainsi que la qualité de ce qui est déjà présent. De cette manière, il va pouvoir apporter une solution au problème principal que tout changement d'interface ne peut régler : la faillibilité humaine.

Le NLP semble aujourd'hui apporté des éléments de réponses afin de combler cet écart. La capacité de cette technologie à interagir avec l'utilisateur et à comprendre les données à une échelle massive ouvre de nouvelles possibilités d'usages et d'interfaces qui permettrait de résoudre les problématiques relatives aux **SGC**. Cependant, cette technologie recouvre

⁸³*Ibid.*, p.4.

⁸⁴Brandon P Hedrick, J Mason Heberling, Emily K Meineke, Kathryn G Turner, Christopher J Grassa, Daniel S Park, Jonathan Kennedy, Julia A Clarke, Joseph A Cook, David C Blackburn, *et al.*, « Digitization and the Future of Natural History Collections », *BioScience*, 70–3 (1^{er} mars 2020), p. 243-251.

un ensemble vaste d'outils et de réalités techniques⁸⁵, ce qui demande de les séparer en deux outils différents : la recherche augmentée, répondant aux problématique soulevées dans le premier point, et un « chatbot », répondant aux problématiques soulevées dans le second point.

⁸⁵Voir page 9

II. Recherche augmentée et Chatbot/Agent IA : état de l'art.

Les deux axes d'améliorations, dû au NLP, que nous venons de distinguer sont pensé en deux outils distincts. La « recherche augmentée » consistant en une recherche assistée par intelligence artificielle pour interroger le *Information Retrieval System* en langage naturel. Et un « chatbot » afin de converser avec l'utilisateur pour le guider dans l'application et dans son usage. Chaque outils possède sa propre interface bien qu'il s'agisse des mêmes technologies appartenant au NLP qui alimentent finalement deux processus de traitements différents. En effet, parler d'outils différents ne revient pas systématiquement à parler de technologies différentes. En effet on parle le plus souvent de processus divergents afin de traiter des données, identiques ou différentes, de manière différenciée.

Les deux outils en question sont aujourd'hui au cœur de différents projets académiques et professionnels sur la question de la gestion des données patrimoniales. Ces travaux ne sont pas nombreux et recouvrent des réalités techniques et professionnelles différentes de celles recouvertes par un **SGC**. Étant donné que nous nous sommes basés sur ces études, il convient de connaître ces derniers afin de comprendre les choix effectués dans l'implémentation de ces deux outils dans le logiciel SkinSoft. Ainsi, dans cette partie nous souhaitons établir un état de l'art de chacun des outils cités. Ce sera l'occasion d'analyser la réalité techniques se cachant derrière ces fonctionnalités. Cela amène à une discussion sémantique sur les termes d' « Agent IA » et de « Chatbot » afin de lever une confusion technique et terminologique autour de ces deux outils. C'est également l'opportunité de discerner les limites et enjeux des technologies et processus cités, ainsi que le décalage subsistant entre l'apport réel de ces derniers et le besoin utilisateur au sein de **SGC**.

1. La « recherche augmentée » :

a. La recherche intelligente :

Cet outil découle de différentes réalités techniques se faisant suite. L'origine est la recherche intelligente, un processus mis en place notamment par les grands moteurs de recherche comme Google afin d'offrir des résultats pertinents et de plus en plus sous forme de résumé.⁸⁶ Son objectif est double : augmenter l'accessibilité utilisateur aux données grâce à des requête en langage naturel et se baser sur le NLP afin d'offrir des résultats plus pertinents

⁸⁶Alexandre Flament, *Google SGE (AI Overviews) : définition, fonctionnement et impact SEO en France*, deux.io, 2 juill. 2025.

et sélectifs notamment par le dépassement des limites traditionnels des *Information Retrieval System*.⁸⁷ Il est important de le comprendre avant d'aborder des processus en dérivants et plus proche de l'outil mise en place.

Le processus repose sur l'utilisation de trois outils d'intelligence artificielle : le *Large Language Model*, le *Retrieval Augmented Generation* et les modèles de NLP notamment basé sur des architectures à transformers.

Le *Large Language Model* est un élément important car il est l'intermédiaire entre les données et l'utilisateur. Basé sur du *Deep Learning*, cet outil mobilise les technologies du NLP et les combine à une faculté de raisonnement et de calcul. Ainsi il est capable : d'analyser et d'extraire la sémantique d'une phrase mais aussi de formuler ces propres phrases. Dans un processus de recherche intelligente, le *Large Language Model* intervient au moment de la réponse afin de converser avec l'utilisateur. Son fonctionnement est le suivant : lorsqu'il reçoit une requête il en extrait des *token*, c'est à dire des mots. Il procède à une vectorisation : chaque morceau de texte devient une suite de nombres décimaux unique appelé vecteur. Cela créer une traduction informatique de la requête qui lui est compréhensible. Il applique ensuite les différents outils issus du NLP dont il dispose afin d'extraire du sens et des relations depuis ces vecteur. De cette manière, le *Large Language Model* « comprend » la requête utilisateur et peut ensuite lui répondre.

Le *Retrieval Augmented Generation* constitue le cœur du processus. C'est un processus d'intelligence artificielle employé pour fiabiliser et contextualiser les résultats. Son objectif premier est de limiter un phénomène récurrent avec les *Large Language Model* : les hallucinations. Dû à sa capacité de mémorisation, le modèle peut parfois être tenter de répondre à l'aide de ses propres « connaissances » . Cela peu conduire à répondre en mélangeant « connaissances » et données ce qui créer des éléments de réponses faussé.

Le *Retrieval Augmented Generation* consiste à connecter un *Large Language Model* à une ou plusieurs bases de données afin de forcer l'utilisation de ces données comme éléments de réponses. On empêche le *Large Language Model* de s'appuyer sur ses propres connaissances en lui donnant des données vérifiées et validées par un opérateur humain. Cela ne l'empêche pas de faire preuve de réflexion : grâce au NLP et *Deep Learning*, le modèle sera capable de reformuler et d'approfondir. Mais on vient nourrir ces actions avec des données externes servant de contexte et de connaissance que le *Large Language Model* doit analyser et formuler en réponse.⁸⁸

⁸⁷ *Ibid.*

⁸⁸ Pour plus d'informations sur le *Retrieval Augmented Generation* voir 14

Les modèles NLP basé sur des transformers sont essentiels. Nous ne reviendrons pas sur les notions vus lors du chapitre 2. Les modèles utilisé sont spécialisé sur des tâches précises du NLP tel que le *Part of Speech*, *Name Entity Recognition* ou encore lemmatiser permettant ainsi deux éléments : une compréhension approfondie des requêtes utilisateurs afin de saisir le besoin profonds, et une meilleure compréhension des données stockée dans le *Retrieval Augmented Generation* permettant ainsi de mieux les vectoriser augmentant la qualité et la pertinence des réponses.

C'est la combinaison de ces deux éléments qui permet de créer la recherche intelligente, soit la capacité d'utiliser un *Large Language Model* pour répondre à des requêtes en langage naturel à l'aide de données certifiées et fiables. On peut distinguer deux temps dans la recherche intelligente. Le premier temps est une tâche de fond : un processus constamment en activité mais jamais visible par l'utilisateur. Nous l'appelons, ici, la phase d'analyse. En voici un schéma :




FIG. 2 : Phase d'analyse de la recherche intelligente.

Ce que l'on voit ici est principalement le mécanisme du *Retrieval Augmented Generation*. Une fois connectées à une, ou plusieurs, source de données il y a une analyse des données grâce aux modèles NLP traitant la donnée dans des processus successif. De cette manière, on donne du sens aux mots et c'est ce sens sémantique qui créer le vecteur. Ces données dites enrichies, car analysées, sont ensuite réunis dans un index : comme un *Information Retrieval System*⁸⁹ le *Retrieval Augmented Generation* dispose de sa propre architecture de données. C'est sur les données de l'index que la vectorisation s'applique, créant des vecteur qui sont plus léger, plus facile à interroger et plus fiable que l'index des données.

Ainsi, on obtient un double avantage par rapport à une recherche par mots-clés traditionnels : une compréhension sémantique d'un référentiel de données, créant le contexte, et une rapidité dans l'interrogation des données. En théorie, nous gagnons en précisions des résultats ainsi qu'en rapidité d'exécution.

L'envoi d'une requête utilisateur formulée en langage naturel déclenche une nouvelle phase de traitement : la phase de requêtage. En s'appuyant sur le travail effectué en amont, le processus suis les étapes suivantes :




FIG. 3 : Phase dite « active » de la recherche intelligente.

⁸⁹voir 29

La phase « active » de ce processus commence donc dès l'envoi par l'utilisateur d'une requête en langage naturel. Le processus est relativement peu différent de celui appliqué à la phase d'analyse : le logiciel cherche d'abord à comprendre sémantiquement la requête à l'aide de modèles de NLP avant d'opérer une vectorisation des données composant la requête.

Ce sont les vecteur qui sont ensuite comparés : des vecteurs proches signifient des correspondances sémantiques. On sort des liens définis entre des mots-clés basé sur la ressemblance exact de chaînes de caractères. Ici on vient chercher le sens profonds de la donnée : l'idée qu'elle représente et exprime. C'est tout l'objectif du processus : créer la capacité à aller saisir les idées représentées par les mots plus que les mots en eux mêmes afin de répondre à une volonté, une question, plus qu'à des mots.

Voici un schéma représentant le fonctionnement final d'un processus de recherche intelligente :




FIG. 4 : Fonctionnement global de la recherche intelligente.

Ce que nous avons décrit ici s'apparente à un processus générique. En effet, cet architecture constitue le cœur du processus, mais il est largement optimisable de différentes manières. D'abord avec le *Chunking*, un processus informatique consistant en un découpage de documents très longs, qui est en informatique une seule chaîne de caractère, en plusieurs morceaux plus petits. Cela permet : une accélération du traitement, la parallélisation de

tâches⁹⁰, de limiter la perte de précision par des analyses restreintes et réduire la consommation de ressources computationnelles. Ce n'est qu'après qu'on peut extraire des *tokens*.⁹¹

Ensuite le *Re-Ranking* intervenant en fin de processus. À l'issue du processus classique, les résultats les plus pertinents sont sélectionnés et classés selon un ordre d'importance permettant au *Large Language Model* d'organiser sa réponse en priorisant certaines données. Cependant, le *Retrieval Augmented Generation* rencontre des lacunes sur cette partie. Ainsi, cet outil consiste à évaluer la pertinence des résultats, les valider et reclasser. Pour cela il effectue sa propre recherche dans les données propres et les compare aux données de la requête utilisateurs. Au regard des résultats obtenus, il analyse le classement des résultats d'origine et le réorganise selon ses propres résultats créant un nouveau ordre d'importance.⁹²

Cependant, ce processus de recherche intelligente présente des limites importantes mettant en doute la véracité scientifique des résultats. L'utilisation d'intelligence artificielle entraîne le risque d'hallucination et malgré le *Retrieval Augmented Generation*, ce risque est toujours présents notamment sur des requêtes utilisateurs basée sur des expressions communes, des expressions imagées ou des termes spécifiques à des « jargons » professionnels et/ou personnels. Ces modèles vont s'efforcer de trouver du sens afin de satisfaire la requête utilisateur : ainsi ils vont halluciner afin de créer une solution.⁹³

De plus, ce processus ne peut procéder à des calculs d'agrégation de données. En effet, les systèmes de recherche intelligentes ne peuvent calculer les données stockées : chiffres ou lettres ce sont des chaînes de caractères puis des vecteurs et donc on ne peut pas les calculer. Ainsi, on en peut avoir recours à des calculs comme des moyennes, ce qui est essentiels dans certains domaines de recherches.⁹⁴

Ensuite, la segmentation des documents par *Chunking* apporte des limites aux recherches complexes. Le *Chunking* est une pratique courante, cependant morceler les documents revient à multiplier les points d'informations et donc les recherches à mener. Lorsqu'une requête amène à analyser un grand nombre de segments, le *Retrieval Augmented Generation* peut entrer dans un état de confusion et générer du bruit.⁹⁵

De plus, la recherche intelligente n'est pas transparente quant aux modalités de recherche. Si le *Retrieval Augmented Generation* permet de mettre en avant la source utilisée, ils ne permettent pas présenter la manière dont on est arrivé à ce résultat et le *Large Lan-*

⁹⁰Désigne en informatique la capacité à traiter simultanément plusieurs tâches et données parfois dans des processus différents.

⁹¹*Qu'est-Ce Que Le Chunking Agentique ?* / IBM.

⁹²Ultralytics, *Qu'est-ce qu'un reranker ? Optimiser la recherche et l'IA*, Ultralytics, 29 janv. 2026.

⁹³Mirco Cazzaro et Gianmaria Silvello, « Querying LLMs as If They Were Digital Libraries » ().

⁹⁴*Ibid.*

⁹⁵*Ibid.*

guage Model est tout aussi opaque dans ces processus de réflexion. Ainsi, des doutes peuvent exister : a-t-il confondu des termes ? A-t-il halluciné ? A-t-il mal compris ? A-t-il analysé un document plusieurs fois ? Toutes ces questions restent sans réponse. Finalement, on retombe sur un problème déjà rencontré dans les *Information Retrieval System*⁹⁶.

Finalement, il y a aussi un enjeu de sécurité et de confidentialité des données. En effet, il peut arriver que l'on souhaite ne distribuer que certaines informations à certaines personnes notamment dans des entreprises. L'accès à l'information dépendra de droits d'accès. Ces derniers sont difficiles à gérer sur des vecteur, notamment car les systèmes le permettant ne sont pas encore totalement sécurisé. En effet, ils connaissent encore un certain nombre de faille trop importante ce qui pose problème dans les structures patrimoniale ou la sécurité de l'information et sa confidentialité sont deux principes clés.

b. Les processus *Text-to-SQL* et *Text-to-NoSQL* :

Cela a conduit la création de solutions similaires mais permettant de mieux répondre aux enjeux scientifiques et de dépasser ces limites. L'objectif globale a été d'adapter le processus de recherche intelligente à des technologies déjà utilisées : le SQL et No-SQL. Cela émerge d'un constat : les limites de la recherche intelligente ne sont pas retrouvées dans l'utilisation des bases de données SQL et No-SQL. D'abord, ces langages n'hallucine pas : si la requête n'est pas comprise ou la données inexistante il n'y a simplement pas de réponse. De plus, ils permettent des calculs mathématiques sur des données stockées en tant que chiffre. Ajoutons que les requêtes complexes, multipliant les sources, ne sont pas sujettes à confusion grâce aux jointures pour le SQL et aux pipeline d'agrégation pour le No-SQL, tout deux permettant le traitement de masses des données. Ces langages fonctionnent par des requêtes compréhensibles par l'humain, stockable et rejouable ce qui apporte une transparence au processus de recherche. Et pour finir, ces langages intègrent nativement des outils de contrôle des droits d'accès assurant la confidentialité des données. Ces processus hybrides visent à conserver l'objectif et le fonctionnement en deux temps de la recherche intelligente, mais en utilisant le NLP pour traduire une requête utilisateur en requêtes SQL ou No-SQL. De cette manière on évite la vectorisation et de trop se reposer sur l'interprétation de l'intelligence artificielle en plus de rester dans l'utilisation de technologie connues que sont les bases SQL et NoSQL. C'est ce que l'on appelle les processus *Text-to-SQL* ou *Text-to-NoSQL*.

Le *Text-to-SQL* est un processus plus « ancien » et plus éprouvé dans le monde patrimonial puisque déjà appliqué en partie. Cependant, il y a un manque considérable d'informations sur les projets menés par les institutions conservatrices à propos d'implémentation de

⁹⁶Voir page 30

tel processus. On trouve bien souvent des approches plus complexes remaniant le processus *Text-to-SQL* de différentes manières, ce qui en montre finalement l'adoption de tel processus.⁹⁷ ainsi, nous allons expliquer de manière générale et théorique comment fonctionne un pipeline *Text-to-SQL* et son adaptation en processus *Text-to-NoSQL*.

D'emblée, l'adaptation de la recherche intelligente en un processus hybridé avec le SQL pose 3 difficultés majeures.

La première difficulté est la compréhension des schémas SQL et du contexte métier. En effet, les bases SQL ont une structure souple afin de correspondre aux besoins de représentations de la données des institutions. Ces schémas incluent donc des besoins des biais de recherches et d'exploitations définis selon une stratégie institutionnelle et les « besoins métiers »⁹⁸. On attend de l'intelligence artificielle qu'elle puisse comprendre un univers métier institutionnel afin de pouvoir requêter correctement. On déplace le curseur : la compréhension des données stockées est un intérêt secondaire et la compréhension de l'univers professionnel prime.⁹⁹

La seconde difficulté est la compréhension du besoin utilisateur. Dans un processus de recherche intelligente, l'erreur courante est la mauvaise compréhension de la requête utilisateur. La souplesse du processus permet de changer le processus de réflexion du *Large Language Model* par la conversation. Cependant, dans un processus de *Text-to-SQL* pour changer cette réflexion cela demande de connaître la structuration de la base de données afin de reformuler efficacement et guider plus facilement le modèle. Cette compétence technique est cependant rare dans les institutions conservatrices ce qui amène le besoin de limiter les incompréhensions du besoin utilisateur et les interactions entre l'utilisateur et la base SQL.¹⁰⁰

Enfin, la notion de « [...] dialecte SQL [...] »¹⁰¹. Tout les systèmes de gestion des bases de données n'emploient pas exactement le même langage, et la plupart des *Large Language Models* ont souvent du mal à s'adapter aux différences. Ainsi, sur certains systèmes de gestion de base de données, la génération de requête complexes risque de s'en trouver complexifiée et réactivant le risque d'hallucination.¹⁰²

⁹⁷Nous ne développons pas ces approches divergentes mais les mentionnons par soucis d'exhaustivité. Pour plus d'informations sur ces approches divergentes, consulter Alexander Sergeev, Valeriya Goloviznina, Mikhail Melnichenko et Evgeny Kotelnikov, « Talking to Data : Designing Smart Assistants for Humanities Databases » (); M. Cazzaro et G. Silvello, « Querying LLMs as If They Were Digital Libraries »...

⁹⁸On parle de « besoin métier » pour exprimer les besoins inhérent à un domaine professionnel et propre à ce domaine. Il correspond souvent à la réalité des pratiques employées par les professionnels.

⁹⁹*Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL* / Blog Google Cloud, Blog Google Cloud.

¹⁰⁰*Ibid.*

¹⁰¹*Ibid.*

¹⁰²*Ibid.*

Deux approches permettent de combler cet écart : les *frameworks* spécialisés comme VANNA AI et les agents SQL comme LangChain¹⁰³. La première approche consiste à créer un processus de *Retrieval Augmented Generation* avec le schéma SQL, des exemples de requêtes et de la documentation professionnelle. Ceci permet à n'importe quel *Large Language Model* de s'entraîner sur ces données afin de comprendre les besoins, enjeux et possibilités de requêtage. C'est un processus qui atteint vite ses limites car manquant de souplesse et de scalabilité : chaque changement d'architecture de la base amène un réentraînement du modèle et la documentation doit être tenue à jour. La seconde approche consiste en la spécialisation d'un ou plusieurs *Large Language Model* pour la compréhension et la génération de requête SQL. Ces modèles spécialisés sont dès lors capables de traiter des bases plus complexes grâce à leur compréhension native du SQL. C'est cependant un outil plus complexe à mettre en place et énergivore demandant plus de compétences techniques.

Qu'il soit basé sur un agent SQL ou un *framework*, un processus *Text-to-SQL* ressemble à ceci :




FIG. 5 : Schéma d'un pipeline *Text-to-SQL*. Source : *Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL* / Blog Google Cloud, Blog Google Cloud

Nous en distinguons deux temps : le premier est consacré à la compréhension des besoins utilisateurs exprimés dans la requête initiale. Pour cela, on accorde la capacité au *Large Language Model* de relancer l'utilisateur à l'aide de question afin d'amener l'utilisateur à approfondir et clarifier son besoin. Cette première phase est facilitée par la capacité de compréhension de l'univers et des vocabulaires métiers, possible grâce aux deux outils présentés plus haut. C'est essentiel afin de mieux comprendre et répondre aux requêtes.

¹⁰³ *Text-to-SQL : interroger vos bases en langage naturel*, Flowt, 27 févr. 2026.

Le second temps est consacré à la génération de la requête SQL. Pour cela, le *Large Language Model* agit en traducteur et suit plusieurs étapes. D'abord il reformule la requête utilisateur afin de la rendre plus compréhensible afin d'augmenter la précision de la requête SQL générée en fin de processus. Cela donne naissance à un nouveau prompt généré par *Large Language Model* dans le seul but de générer du SQL. Ce prompt entre dans une boucle de traitement : il est examiné, puis refusé et reformulé ou bien validé. La validation entraîne la génération d'une requête SQL à partir du prompt et son envoi à un « parseur SQL », un logiciel de vérification syntaxique des requêtes SQL, pour une dernière vérification et validation. Cette requête est ensuite directement adressée à la base SQL en question. Dans le cas où l'institution possède plusieurs bases de données, le *Text-to-SQL* peut s'y adapter soit par l'intégration d'un moteur de recherche fédéré permettant de décliner la requête selon l'architecture propre à chaque base, comme DuckDB, soit en laissant l'intelligence artificielle déterminer quelle base de données est la plus pertinente afin de répondre à la requête.

Peu importe ces variations, le *Text-to-SQL* est un processus fréquemment utilisé et sa large adoption s'explique par sa capacité à s'adapter à toutes les bases de données existantes. Puisque le *Large Language Model*, entraîné sur du SQL, ingère directement la *data definition language* il peut ainsi se familiariser avec toutes les bases de données. De plus, ce processus assure des résultats fiables dès sa mise en place car il ne repose pas sur des « connaissances » du *Large Language Model* mais bien sur des métas-données saisies par l'institution conservatrice ce qui assure une plus grande véracité.

Il y a cependant quelques limites : d'abord, la dépendance à la *data definition language* de la base de données et à la documentation métier. Si le schéma de la base, les pratiques et ou besoins métiers évoluent si la documentation n'est pas mise à jour alors le processus peut rencontrer des situations d'échecs. Cela demande donc de surveiller et mettre à jour fréquemment cette documentation techniques demandant des compétences particulières. Le manque de compétences techniques, ou l'absence de personnel ayant à charge le maintien de ce socle, entraînent l'échec du processus.

Ensuite, son manque de scalabilité. En effet, une bases de données est rarement figées. Régulièrement, de nouveaux besoins émergent, ou gagnent en importance, ce qui peut demander d'adapter la base de données. Plus la base se complexifie, plus les requêtes vont elles aussi se complexifier. En fonction du *Large Language Model* choisi et des technologies sur lequel repose le pipeline la génération de requête complexes, comme des requêtes imbriquées, représente une difficulté plus ou moins importante. En réalité, même des *Large Language Model* puissants s'en retrouvent limitées. Cela peut alors conduire à des hallucinations de

requête : soit les requêtes ne retournent pas les bonnes données, soit la syntaxe de la requête est en partie hallucinée et donc non valide. Cela fini par créer une boucle dans le processus : le parseur SQL refuse de valider la requête SQL et le *Large Language Model* continu cependant d'halluciner.

Un processus *Text-to-NoSQL* n'est pas très différent. En réalité, il repose sur l'exact même architecture ¹⁰⁴ et ne diverge que dans les implications techniques et les limites.

D'abord, au niveau du processus en lui même on distingue deux variations importantes. La première survient lors de la récupération de la documentation offrant le contexte de réponse. Une base NoSQL ne connaît pas de schéma fixe : chaque objets contenus, notamment dans les bases orientées documents, est définis selon son propre schéma créant une très grande variétés de données. Sans structure globale fixée par une *data definition language*, le processus passe par une étape d'échantillonnage : le *Large Language Model* parcourt un nombre déterminés d'objets afin de cerner la variété des schémas stockés. Cette variation constitue une limite : sans la constance du schéma SQL on perd en fiabilité et en taux de réussite car à partir d'un échantillon, un *Large Language Model* ne peu pas se parer à toute éventualité augmentant le risque de se retrouver en situation d'échec ou pouvant pousser à l'hallucination.

La seconde variation intervient sur ce que le *Large Language Model* génère. Le fonctionnement reste le même mais en NoSQL orienté documents on génère un pipeline d'agrégation. C'est un outil faisant passer chaque objet à travers des étapes de traitement successives, chaque résultats d'un traitement devient l'entrée du traitement suivant. C'est un changement de paradigme : en SQL on récupère les données brutes quand en NoSQL on récupère les bons objets afin d'en extraire les bonnes données via les bons traitements. Cela ajoute donc de nouvelles couches de complexité puisque cette fois il ne s'agit de comprendre chaque objet afin d'en établir la pertinence. En somme, la sélection du document pertinents à partir d'une « connaissance » par échantillonnage peut sembler hasardeuse.

La dernière variation intervient sur la validation de la requête et son exécution. Dans un processus *Text-to-NoSQL*, il n'y a pas d'analyse syntaxique car le pipeline d'agrégation est plus souple, plus dense et donc plus complexe à examiner et valider. La solution qui a été apportée est l'exécution du pipeline d'agrégation dans un environnement isolé dit de test. Si le pipeline semble fonctionner, alors il est exécuté sur les données. Cependant, ces pipelines sont complexes à générer : ils sont très verbeux, utilise des syntaxes complexes et les *Large Language Model* sont encore peu habitué à ce fonctionnement.

¹⁰⁴voir schéma du pipeline *Text-to-SQL* page 44

Ce qui caractérise également les limites du processus *Text-to-NoSQL* sont celles propres aux typologies des bases NoSQL. En effet, les bases NoSQL sont de typologies variées : orientées documents, orientées graphes ou bien colonne. Chaque typologie à sa propre manière de stocker les données et de les interroger. Ainsi, un processus *Text-to-NoSQL* créé pour une base de données NoSQL ne pourra pas s'appliquer à une base d'une autre typologie, et parfois même à un autre système de gestion de base appartenant pourtant à la même typologie. Il y a donc une problématique d'interopérabilité du processus, le rendant spécifique à chaque base et besoins. Ainsi, si un processus *Text-to-SQL* peut interroger plusieurs bases de données différentes ce n'est pas le cas d'un processus *Text-to-NoSQL* à cause de ces variations logiques, syntaxiques et architecturales.

Avant de conclure cette exploration des différents processus aujourd'hui existant pour améliorer la recherche sur des données, voici un tableau récapitulatif. Chaque processus est décrit sur 3 niveaux : son principe de fonctionnement, ses apports et limites. De cette manière, il est plus évident de comprendre les différences entre chaque processus.

Processus	Principe de fonctionnement	Apport	Limites
Recherche intelligente	Indexation vectorielle du langage naturel et des données contenues dans une base	Recherche sémantique et contextualisée via des vecteurs	Hallucinations, opacité, absence de calculs et risques de sécurité
Text-to-SQL	Traduction d'une requête en langage naturel en code SQL	Fiabilité des résultats retournés, prises en compte des données structurées et gestion des droits	Dépendance à la <i>data definition language</i> , requêtes imbriquées complexes et scalabilité complexe
Text-to-NoSQL	Traduction de requêtes en langage naturel en pipeline d'agrégation	Souplesse face aux structures JSON/Documents évolutives, haute scalabilité	Fonctionne sur échantillonnage, absence de schéma fixe et manque d'interopérabilité

TAB. 3.1 : Comparaison des architectures des systèmes de recherche cités.

Cette exploration de la recherche intelligente, du *Text-to-SQL* et *Text-to-NoSQL* nous a amené à voir comment répondre aux enjeux d'interrogation des données patrimoniales, massives et hétérogènes. Les processus *Text-to-SQL* et *Text-to-NoSQL* permettent de faciliter l'interrogation des bases de données et d'optimiser les réponses obtenues. Résolvant ainsi les problèmes posés par les *Information Retrieval System* traditionnels ainsi que les enjeux d'accessibilités aux données.

Le *Retrieval Augmented Generation*, représente la clés de voute de ces ambitions. Sa capacité à contextualiser des données et requêtes grâce à la construction d'une base de connaissance contrôlée représente un atout. Cependant, sa capacité à halluciner de l'intelligence artificielle et l'opacité du processus ont tout de suite créé un décalage avec la rigueur scientifique exigée par ce milieu professionnel. Par un changement de paradigme, de la recherche intelligente sont nés deux autres processus : le *Text-to-SQL* et le *Text-to-NoSQL* permettant de satisfaire les exigences exprimées.

Cependant, placer ces processus au sein de **SGC** pose un certains nombre de difficultés. Tout d'abord, ces technologies sont dépendantes d'un socle de connaissance métier propre à l'institution. Le logiciel SkinSoft s'adressant à une pluralité de profil métier et de typologie de collection y rencontre une limite. En effet, chaque institution a ses propres besoins, pratiques et enjeux métier et la « recherche augmentée » doit pouvoir y répondre.

De plus, les processus décrit ne prennent pas en compte l'usage d'un *Information Retrieval System*. Ils souhaitent s'y substitue mais cependant, la plus part de ces logiciels reposent sur cet outil fondamental pour leur système de recherche. Ainsi, *Information Retrieval System* et les principes des processus examinés sont mélangés dans une approche hybride associant les *Information Retrieval System* aux approches méthodiques des processus *Text-to-SQL* et *Text-to-NoSQL* que nous explorerons par la suite. Mais une telle avancée pose la question des coûts financiers et écologiques, du contrôle des données, de leur sécurité, ainsi que de l'expérience utilisateur.

Cet état de l'art et ouverture que nous venons de faire vont nous permettre d'explorer plus en détails la conception et l'intégration de tel moyens dans le **SGC** SkinSoft par la suite. Mais avant cela, nous allons explorer la question du « chatbot » dans le monde patrimonial.

2. Le « chatbot » :

La majorité des recherches en humanités numériques ont portées sur la recherche intelligente et les processus *Text-to-SQL* et *Text-to-NoSQL*. Cependant, il est illusoire de croire que rendre l'accès aux données plus évident et naturel par ces processus résoud toutes les problématiques professionnelles.

L'accessibilité aux données dans un logiciel métier se joue également dans les notions

d'*User Interface Design* et d'*User Experience Design*. Un logiciel métier doit placer l'utilisateur au centre de son application et lui en proposer une utilisation simple et intuitive. Ce n'est pas le cas des **SGC** présentant souvent des interfaces complexes et des parcours utilisateurs nombreux et sinueux. Notons que la production d'un professionnel dépend surtout de sa capacité à utiliser le logiciel et donc de sa clarté d'usage. Ainsi, la « recherche augmentée » n'aborde pas cette problématique de front et n'y apporte pas de solutions.¹⁰⁵

L'accessibilité à l'application impact la qualité de production. Un logiciel à l'*User Interface Design* et l'*User Experience Design* limpide et pensée pour l'utilisateur favorise sa productivité. Puisque l'utilisateur peut se repérer, il est plus évident pour lui d'indexer les bons éléments aux bons endroits et de la bonne manière.

Ainsi, dans un environnement de production comme un **SGC**, une « recherche augmentée » , peu importe le processus désigné, ne permet pas seul de résoudre les problématiques de productivités et d'accès. Il faut chercher la solution dans un autre outil d'intelligence artificielle : le « chatbot »

Les récentes évolutions technologiques en matière d'intelligence artificielle ont amené des transformations d'usages mais aussi terminologiques. Aujourd'hui, le terme chatbot porte un sens confus que nous devons clarifier.

Le premier chatbot voit le jour en 1966 : c'est le programme ELIZA¹⁰⁶. Assez simplement, ce programme interagit avec l'utilisateur en transformant les phrases qui lui sont donné en question. Il s'appuie sur les premières technologies de NLP qui sont alors basées sur de l'analyse computationnelle du langage naturel.¹⁰⁷ Cette première expérience démontre la capacité à transformer une phrase en langage naturel en vecteur permettant à l'ordinateur d'interagir indirectement avec le langage naturel.¹⁰⁸

L'apparition du mot chatbot date de 1994 avec le programme *Julia* de Michael Loren Mauldin. Ce dernier peut générer des phrases en temps réel permettant l'interaction avec l'utilisateur. Il repose sur l'accumulation de règles de réponses prédéterminées à utiliser en fonction d'un contexte. En somme, le programme analyse la phrase, détermine à quel ensemble de règles la phrase se rattache et renvoie les réponses prédéterminées. C'est ce que l'on appelle l'intelligence artificielle symbolique. Nous n'avons pas encore de « réflexion » , le programme ne reposant pas sur une architecture de neurones artificiels. Mais c'est cela que le mot chatbot représente à l'origine.

¹⁰⁵Voir page 32

¹⁰⁶Eleni Adamopoulou et Lefteris Moussiades, « Chatbots : History, Technology, and Applications », *Machine Learning with Applications*, 2 (15 déc. 2020), p. 100006.

¹⁰⁷voir page 11

¹⁰⁸*Ibid.*

Très vite, cette technologie a été utilisée afin de diriger l'utilisateur vers les bons endroits dans le site. Cela est possible par une interface simple : une fenêtre flottante avec un endroit où rédiger et envoyer la requête et un endroit où afficher la réponse.

L'arrivée des modèles d'intelligence artificielle reposant sur du *Deep Learning* et des neurones artificiels change le paysage du chatbot. Il n'est plus nécessaire de spécifier des ensembles de règles : le programme est capable de réfléchir et de s'exprimer par une génération autonome. Chose que les « chatbot » traditionnels ne pouvaient pas faire.¹⁰⁹

Ces premiers modèles sont implémentés dans des assistants vocaux comme Siri, de Apple, en 2011. On ne les considérait pas comme des « chatbot » : ces programmes sont des assistants vocaux, dotée d'une faible capacité d'apprentissage.

Peu à peu, des technologies d'apparences similaires, mais techniquement différentes, ont émergées. Leurs capacités de génération et de compréhension ne faisant que grandir, les « chatbot » traditionnels ont peu à peu disparu. Cependant, l'assistant vocal et le chatbot restaient bien différenciés.

L'explosion des *Large Language Model* en 2020 auprès du grand public a brouillé la barrière sémantique. En effet, les modèles comme ChatGPT sont capables de comprendre une requête, de générer des réponses en langage naturel et de mémoriser des conversations entières. Très différents d'un chatbot ils en adoptent pourtant la même forme : un espace de rédaction et d'envoi de la requête, un espace d'affichage et de réception de la réponse. C'est ce qu'on appelle les agents conversationnels.

Et cela vient briser la barrière sémantique car dans la position d'un utilisateur ce sont les mêmes outils visuellement. Ainsi, le terme « chatbot » fini par désigner les deux outils.

Très récemment, les *Large Language Model* ont commencé à se développer dans un autre sens : celui des agents IA. Si les agents conversationnels ont pour objectif de simuler une conversation avec un être humain, les agents IA visent à accomplir des tâches complexes en autonomie. Un agent conversationnel converse uniquement, quand un agent IA exécute des processus à l'aide d'outils. On constate que les agents IA prennent la même forme que les agents conversationnels et chatbots : une interface de chat permettant d'envoyer une requête et de recevoir une réponse.

Ainsi, de nos jours, dans le langage courant, le terme de « chatbot » est profondément confus. Il désigne à la fois sa technologie historique, les agents conversationnels et les agents IA.

¹⁰⁹ *Ibid.*

Ce sont pourtant trois ensembles technologiques et processus différents.

Au sein de SkinSoft, la discussion autour de l'intégration d'un chatbot dans le logiciel a fait ressortir cette évidente confusion. Lorsque l'on élargi le spectre à des projets et logiciels concurrents ayant implémenté un « chatbot » on se rend compte de la même confusion.

Ainsi, dans ce présent mémoire lorsque nous parlons de « chatbot » nous désignons en réalité un agent conversationnel. Cela dans une volonté de s'inscrire dans une tendance terminologique actuelle et dominante. Lorsque nous évoquerons l'agent IA, nous le ferons sous ce terme là et pareil pour le chatbot.

La question de l'intégration d'un chatbot dans une *SGC* est assez peu discutée à l'échelle académique. Cela peut s'explique par les risque d'hallucination dû à l'utilisation d'un *Large Language Model*, cependant nous n'avons aucune certitude. Notre attention doit se tourner alors vers les projets professionnels.

Lorsque l'on regarde d'autres *SGC* comme Axiell¹¹⁰, ou Terentia¹¹¹ on remarque les éléments suivants. D'abord, les termes de chatbot, de agent conversationnel ou de agent IA ne sont pas employés. Il est mention « d'outils d'intelligence artificielle », sans précisions sur les technologies employées. De plus, les outils cités semblent peu orienté vers l'accessibilité applicative et les questions d'usages. Que ce soit chez Axiell ou Terentia, les « outils d'intelligence artificielle » ont pour but principaux de produire de la méta-donnée et de faciliter des liens avec des thésaurus externes. En sommes ce sont de nouveaux outils pensé pour simplifier l'utilisation d'aspect très précis des applications citées.

Cependant, la combinaison entre le *Retrieval Augmented Generation* et la capacité conversationnel d'un chatbot ouvre d'autres perspectives. Ce système à déjà été appliqué à l'exploration de corpus documentaires, souvent, historiques afin d'accompagner les chercheurs dans leurs explorations.¹¹² Ces tentatives visent à permettre des explorations plus rapides et approfondies de coprus important grâce aux capacités de conversation et de réflexion des chatbot limités par un *Retrieval Augmented Generation* aux seuls corpus.

Dès lors, appliquer ce principe à de la documentation métier et d'usage d'une application permet d'envisager un chatbot capable d'accompagner l'utilisation applicative. Cette perspective mérite d'être approfondie.

D'abord, cela pose plusieurs questions. La première est le choix de la documentations

¹¹⁰Pour consulter leurs innovations, voir : <https://www.axiell.com/fr/solutions/product/ai-for-museums-and-archives/>

¹¹¹Pour consulter leurs innovations, voir : <https://terentia.io/collections-management>

¹¹²Bénédicte Tuza, *Interroger la mémoire d'entreprise par l'IA : le RAG face aux archives orales. Enjeux et limites pour l'histoire appliquée*, other, Perles d'Histoire, 40 rue de Paris, 92100 Boulogne-Billancourt, 2025, p. xxxii.

professionnelle, propre aux collections traitées. Pour exploiter pleinement le *Retrieval Augmented Generation* il faut proposer une documentation limitée et uniforme. Ce n'est pas tout à fait le cas dans l'univers de la gestion des collections. La documentation est massive et prend des formes diverses. Une institutions gérant des fonds très diversifiés peuvent donc rencontrer une première limite.

La seconde question est le choix de la documentation propre au fonctionnement de l'application. Étant donné la complexité native des **SGC** et du logiciel SkinSoft, cette question semble la plus importante. Il faut pouvoir différencier ce qui relève des fonctionnalités communes et ce qui relève des fonctionnalités propres aux modules adaptés à chaque typologies.

Ces deux points viennent souligner une limite du *Retrieval Augmented Generation* : sa rigidité. Par définition, ce processus recherche toujours dans la même base de données, dans un même contexte et donc dans des objectifs toujours similaire. L'hétérogénéité des collections représentées, la variétés des institutions utilisant ce logiciel et des pratiques entre en contradiction avec ce principe.

Alors pourquoi envisager l'élaboration d'un chatbot plutôt que d'une agent IA peut être plus adaptés à ces problématiques? Tout d'abord car cette technologie est bien plus quotidienne, moins révolutionnaires, à l'échelle des pratiques, et moins coûteuses.

Sans projets ni études à l'appuis, il est difficile de faire un état de l'art de cette em-
ploie, encore peu répandue, de cette technologie. Cependant, notre rapide examen permet de
conclure que cette perspective est encore expérimentale et semble rencontrer bien des soucis
de définitions.

Cependant, ses capacités conversationnelles du chatbot ainsi que la possibilité de l'in-
tégrer dans des processus plus large permettent d'envisager cette technologie comme une
solution quant à l'accessibilité des **SGC**. Loin de remettre en question les notions d'*User
Interface Design* et d'*User Experience Design*, le chatbot semble constituer un outil complé-
mentaire utile pour améliorer l'accessibilité de tels outils.

III. Enjeux utilisateurs : comment implémenter ces fonctionnalités en respectant l’utilisateur dans son usage de l’application et son rapport avec l’intelligence artificielle ?

Avant toute choses, notons qu’il s’agit ici d’une partie réflexive qui n’a pas pour objectif d’aboutir à des solutions concrètes. L’ambition est de présenter un état des lieux et des pistes de réflexions pouvant être l’objet de logiques d’implémentations et d’usage de ces outils.

Lors de notre exploration du chatbot, deux notions fondamentales ont été évoquées : l’*User Experience Design* et l’*User Interface Design*. Ils visent à placer l’utilisateur au cœur des conceptions logicielles car l’usage utilisateur offerte définit l’attractivité et la qualité logicielle. Ils visent alors à garantir une utilisation optimale, fluide et intuitive d’un logiciel par le respect d’un certains nombres de principes, de normes et de méthodes. On y distingue l’expérience, gérée par l’*User Experience Design*, et l’interface, gérée par l’*User Interface Design*.

Arriver à garantir ces aspects permet de renforcer l’adoption du logiciel au près du public cible. Au cœur de ces aspects se trouve l’expérience utilisateur, c’est à dire l’ensemble de ressenti, sensations et « émotions » qu’une utilisation de l’application produit ou doit produire. L’*User Experience Design* vise à garantir une expérience globale positive et qualitative lors de l’interaction entre l’utilisateur et l’application.¹¹³ Un certains nombre de principes et de règles¹¹⁴ constituant ce domaine sont déterminées dans cet objectif. L’*User Experience Design* régit un aspect pratique créé au moment de l’élaboration et du codage du logiciel, mobilisant ainsi un certains nombre de méthodes pour concevoir une expérience idéale dans une application orientée utilisateur.¹¹⁵

L’expérience utilisateur est transmise au travers d’un intermédiaire spécifique qu’est l’interface. Pour l’utilisateur l’interface fait partie intégrante de l’expérience globale, du côté des développeurs l’interface se différencie de l’expérience car n’étant qu’un outil de diffusion et d’interactivité. Ainsi, la création d’interface qualitative permettant une interaction « positive » entre l’utilisateur le logiciel est régit par son domaine propre : l’*User Interface Design*. Les fondements de ce dernier sont profonds. Dès 1990, le psychologue Don Norman démontre la responsabilité des *design* dans les erreurs humaines dans un contexte industriel :

¹¹³WEBQAM Groupe, *L’UX Design : Définition, enjeux et mise en pratique* - Webqam, Site Webqam Groupe, 21 févr. 2022.

¹¹⁴Notamment *ISO 9241-112 :2025*, ISO

¹¹⁵Carine Lallemand, *Méthodes de Design UX. 30 Méthodes Fondamentales Pour Concevoir Des Expériences Optimales. (2e Edition)*, 2018.

« *Most industrial accidents are caused by human error : estimates range between 75 and 95 percent. How is it that so many people are so incompetent ? Answer : They aren't. It's a design problem.* »¹¹⁶ C'est le fondement de ce domaine : une interface mal conçue entraîne nécessairement une erreur. L'*User Interface Design* a pour objectif de traduire l'*User Experience Design* via des repères visuels et des parcours graphiques permettant d'activer des fonctionnalités. À l'instar de la notion précédente, l'*User Interface Design* s'appuie sur des principes graphiques pour créer des interfaces intuitives au service de l'utilisateur.

Soulignons que ces domaines ne sont pas rigide et ne posent pas de contraintes ni d'obligations. Ils ne font que proposer des méthodologies et outils obéissant à des principes et règles pensées pour atteindre des objectifs. Chaque développement logiciel n'a pas d'obligation à les utiliser ou à en respecter les principes. Ils peuvent adapter ces éléments où bien créer leurs propres principes, règles et méthodologies.

Prenons l'exemple de la norme ISO 9241-112 abordant la question de l'expérience et interface des systèmes informatiques. Elle ne fixe pas de cadre rigide et obligatoire, elle « [...] énonce des principes de conception ergonomique pour des systèmes interactifs dont la présentation d'information de l'interface utilisateur est contrôlée par logiciel »¹¹⁷. Son objectif est de proposer des principes clés pour conceptualiser une structure logicielle optimisée pour la compréhension des informations par l'utilisateurs. Il subsiste une certaine liberté et un flou conceptuel qui rendent l'application de ces concepts parfois délicate.

1. *User Experience Design* et *User Interface Design* dans les systèmes de gestion des collections :

Nous l'avons déjà exploré, les systèmes de gestion des collections sont des applications aux architectures denses et complexe ce qui impact nécessairement l'expérience et l'interface. Ils sont basés sur l'intégration d'une multiplicité d'informations avec une haute interactivité entre elles réparties dans de multiples fonctionnalités. Une notice d'objet disposera de ces propres fonctionnalités et interfaces, de même pour une notice de prêt. Ainsi, les interfaces sont multiples car elles correspondent à des expériences multiples adaptées à des modalités de gestion spécifiques. Cette multiplicité de parcours entraîne des complexités structurelles dans l'organisation de l'application et des données contenues et diffusées.

Dans ce contexte, l'*User Experience Design* et l'*User Interface Design* sont fondamentales pour simplifier l'apparence et l'usage d'outils destinés à manipuler de très grands vo-

¹¹⁶Don Norman, « *The Design of Everyday Things* » (, 2013), p. 325.

¹¹⁷ISO 9241-112...

lumes de données et à appuyer des décisions stratégiques. Il n’existe aucun principes, règles ou méthodologies spécifiques à l’application de ces domaines aux systèmes de gestion des collections. Cela s’explique par l’existence de questionnement et de contradiction, entre les principes généraux de ces domaines et les besoins auxquels répondre. La conception de ces domaines vise à simplifier l’usage applicatif et l’affichage par une logique d’épuration pour plus d’efficacité. Cependant, les besoins patrimoniaux au cœur de la raison d’être de ces logiciel est l’exhaustivité des données ou plutôt la possibilité d’interagir avec des données dans toutes leurs complexités. Cette logique amène à dupliquer les expériences utilisateurs et à charger les interfaces avec deux informations : des fonctionnalités, représentées par des boutons dit d’actions, et les données stockées.

inclure une photo

Aujourd’hui, des discussions académiques et professionnelles amènent à repenser ces notions appliquées aux système de gestion des collections. Deux idées principales en émergent : l’application du concept de simplicité sans tendre vers l’épuration, limitant l’exhaustivité naturelles de ces collections, et la recherche de nouvelles solutions d’interactions et graphiques. L’idée étant de simplifier l’exhaustivité, et non de la limiter et de la biaiser ce qui est aujourd’hui le cas lorsque l’on parle de rationalisation des interfaces et expériences utilisateurs.

De plus, on ne s’adresse pas à des utilisateurs grands publics mais à des professionnels aux objectif précis et aux contraintes professionnelles devant être prise en compte. Ces objectifs et contraintes professionnelles varient en fonction de la typologie de collections traitées et de l’aspect de la collection qui est traité. On peut imaginer qu’une collection d’histoire naturelle ne demandera pas les mêmes expériences et interface que pour une bibliothèques.

Aujourd’hui, des tentatives de compromis entre simplicité, exhaustivité et particularité de chaque collections tendant à apparaître dans une logique de communication vers un large public.¹¹⁸ On peut tout à fait s’attendre à voir émerger le souhait d’une cohérence de traitement, poussant les système de gestion des collections dans cette direction. A savoir : l’utilisation de moyens graphiques (*comme des graphes*) pour représenter l’envergure de la collection et s’adapter à des usages et objectifs précis.¹¹⁹

Aujourd’hui, les ambitions d’*User Experience Design* et d’*User Interface Design* appliquées à des système de gestion des collections semblent suivre la voix tracée par deux éléments. D’abord, la théorie de la surcharge cognitive¹²⁰ qui démontre qu’une surcharge informationnelle impact directement la productivité utilisateurs en réduisant les capacité

¹¹⁸M. Whitelaw, « Generous Interfaces for Digital Cultural Collections »...

¹¹⁹*Ibid.*

¹²⁰F. Paas, A. Renkl et J. Sweller, « Cognitive Load Theory and Instructional Design... ».

d'attentions et de concentration de l'utilisateur. Transposé à un environnement logiciel, un surplus d'outils et de données risque d'entraîner une saturation chez l'utilisateur conduisant alors à un rejet du système. Ce phénomène est au cœur du (*Technology Acceptance Model*)¹²¹, rappelant que l'utilité perçue et la facilité d'utilisation conditionnent directement l'adoption d'un outil. Modèle vers lequel les logiciels présentant de tels densités d'informations tendent aujourd'hui à appliquer.

2. Les outils d'intelligence artificielle :

L'inclusion de l'intelligence artificielle dans toutes sortes de logiciel bouscule la réalité de l'*User Experience Design* et de l'*User Interface Design*. En effet, il est tentant de considérer le développement de fonctionnalités basées sur l'intelligence artificielle comme identique aux autres développements mais ce n'est pas tout à fait la réalité.

Les outils d'intelligence artificielle sont souvent développés par des entreprises externes sans lien avec le système souhaitant l'inclure. Ils sont donc pensés indépendamment de systèmes tiers, avec leurs propres interfaces et expériences. Ceci pose un premier défi qui est celui de l'inclusion de l'outil à inclure dans le système. L'outil possède ses propres besoins et propositions d'expérience et d'interface de même que le système hôte ce qui peut créer un important décalage entre les éléments et poussant à adapter son *User Experience Design* et *User Interface Design* d'origine afin de créer un dialogue entre les deux éléments.

Ajoutons également que ces outils entendent parfois « révolutionner » certaines pratiques et procédures communes. Ceci pose la question des habitudes utilisateurs et de leurs changements, ce qui peut impacter la qualité d'expérience globale. En effet, trop changer en profondeur une fonctionnalité habituelle peut déstabiliser un utilisateur, parfois définitivement. Par exemple, l'apparition d'un chatbot peut être déstabilisant : on est dès lors capable de converser à travers une fenêtre dédiée et de l'utiliser pour effectuer des tâches différemment, voir parfois les automatiser.

Pour finir, l'utilisation d'intelligence artificielle pose aussi la question de la transparence. Nous l'avons vu, ces outils agissent sur des données parfois personnelles et/ou sensibles et des questions légales et éthiques imposent une obligation de transparence. Cela dans le but que l'utilisateur puisse savoir les données utilisées, dans quels buts ses données sont utilisées notamment. Cela demande donc de créer une expérience rassurante et transparente, amenant à modifier les interfaces pour permettre la diffusion de ces nouvelles informations.

¹²¹Atmane Badda, « Technology Acceptance Model (TAM) : Literature Review », *International Journal of Accounting, Finance, Auditing, Management and Economics*, 6–11 (oct. 2025), p. 459-492.

Ces quelques points nous permettent de comprendre que l’intégration d’intelligence artificielle dans des logiciels demande plus que la création d’une fonctionnalité technique. Il faut aussi, et surtout, réussir à intégrer de nouvelles expériences et interfaces rassurantes dans des cadres préexistants sans perturber l’utilisateur. C’est une tâche difficile dont dépend l’adoption de ces outils par les utilisateurs.

3. intelligence artificielle et système de gestion des collections : des attentes *User Experience Design* et *User Interface Design* particulières

L’inclusion d’outils basés sur l’intelligence artificielle dans des système de gestion des collections pose des problématiques particulières. Les utilisateurs sont des professionnels souvent alerte sur l’utilisation des données par ce type d’outils, sensibles à la conservation de leurs données et engagés dans des démarches de rigueur scientifique. Ainsi, trois aspects semblent être au cœur de tensions :

D’abord la confiance envers l’outils. Malgré des efforts de contrôles, l’hallucination reste fréquentes et gênantes. La gestion des données patrimoniales est gouvernée par un besoin d’exactitude scientifique autant dans sa production que dans sa recherche. L’hallucination peu compromettre cette rigueur et entraîner une méfiance, un désintérêt légitime voire un rejet de l’outil. L’*User Experience Design* doit pouvoir prendre en compte ses éléments en proposant des solutions comme des processus dit *humain in the loop* et de gestion des erreurs, plaçant ainsi l’utilisateur comme contrôleur de la qualité des données et donc en position de contrôle.

Le second élément est celui de l’interactions de ces outils avec l’environnement logiciel préexistant. Par exemple, la recherche augmentée comme le chatbot génèrent de la donnée en masse pouvant amener à créer une surcharge informationnelles. La problématique se situe dans l’insertion de ces outils dans des environnements métiers déjà maîtrisé par l’utilisateur. Il faut s’assurer que ces outils amènent une plus values, qu’ils permettent une simplification des parcours d’usages sans créer des incohérences de parcours.

Le dernier élément est celui de la perception. Notre examen de la recherche intelligente démontre que le public auxquels on s’adresse aujourd’hui est méfiant envers les intelligences artificielles. Ceci peut expliquer partiellement le manque de travaux sur l’utilisation de chatbot dans la production et la gestion de données patrimoniales. Faire de ces outils de véritables assistants à la productivité plutôt que des contraintes visuelles et technique constitue un enjeu majeur.

4. Conclusion

L'intégration du NLP en deux outils différents, la recherche augmentée et le chatbot, soulève des problématiques d'*User Experience Design* et d'*User Interface Design* inédites. Il ne s'agit pas d'ajouter des fonctionnalités supplémentaires ou de modifier légèrement une expérience utilisateur et l'interface. Il s'agit de changer drastiquement des éléments préexistant par un changement de rapport et de dialogue entre l'utilisateur et son système professionnel dans un domaine exigeant et attentif aux questions de sécurités et de qualités.

Ces nouveaux outils doivent donc amener la conception de nouvelles expériences et interfaces respectant les exigences professionnelles fortes et réduisant la surcharge visuelle et cognitive. Ou du moins, ne pas l'alourdir.

Il faut penser à l'adoption de ces technologies plus qu'aux simples performances technologiques. Cette adoption passe par la nécessité d'un dialogue transparent entre l'outil et l'utilisateur, placé au cœur du processus. Ce qui déplace les enjeux de l'*User Experience Design* et l'*User Interface Design* des questions visuelles et de confort vers des questions de confiance et d'accessibilités.

Chapitre 4

Faciliter l'indexation par sa semi-automatisation : le cas de l'image animée

I. La gestion de l'image animée dans le logiciel SkinSoft

Dans cette partie, l'indexation semi-automatisée est pensée dans son application à un objet patrimonial particulier : l'image animée. Les différentes spécificité de cet objet patrimonial l'amène aujourd'hui au cœur de la problématique que nous explorons. De plus, sa complexité de traitement permet de mettre en exergue les limites de gestions actuelles, les potentiels apports de ces processus et leurs limites.

1. Définition de l'indexation et de l'image animée :

Il convient avant tout de comprendre ce qu'est l'indexation. C'est une opération d'analyse et d'extraction de concepts contenus dans des objets patrimoniaux afin de produire des méta-données descriptives. Cela permet d'attribuer des caractéristiques uniques à chaque objet conservé afin d'en faciliter sa recherche dans une base de données. Pour cela, l'indexation s'appuie sur différents outils comme des thésaurus ou des classifications, en fonction des typologies de collections, afin d'en faciliter l'exécution et de créer une homogénéité.¹²²

La « semi-automatisation » d'un tel processus repose sur l'utilisation d'outils d'intelligence artificielle dans des fins d'analyses et de production de métas-données homogènes et perti-

¹²²Direction des Archives de France, *Note d'information DITN/RES/2007/008*, Notes d'informations DITN/RES/2007/008, Paris, Ministère de la Culture et de la Communication — Direction des Archives de France (DITN), 2007, p.2.

nente pour la conservation à long terme de l'objet. On attend par là des suggestions de métas-données à intégrer dans les bons champs de données restant soumise à validation humaine. Un tel processus doit s'appliquer à tout type d'objet patrimonial et dans les respects des normes et standards appropriés.

Pour penser de tels processus appliqués à l'image animée, il convient d'en comprendre la nature et complexité. La Fédération Internationale des Archives du Film définit l'image animée comme un objet regroupant des images enregistrées successivement dont la diffusion donne une impression de mouvement.¹²³ Cela peut être *rush*, c'est à dire une image issue directement de l'enregistrement, ou bien modifiée en « post-production ». En plus d'exister en deux états, elle peut intégrer des bandes sonores constituées de sons et musiques enregistrés au moment de la capture des images ou rajoutées en « post-production ». Ainsi, dans le langage courant un film, une vidéo, un extrait, une bande annonce, une publicité sont des images animées.

On la distingue des autres typologies par sa diversité matérielle. L'image animée a d'abord été enregistrée sur des bandes au nitrate d'argent photosensible. Puis sur des bandes vidéos magnétiques permettant l'enregistrement sonore en simultané. Puis sur des supports optiques, comme les DVD, reposant sur un mécanisme de gravure du support. Et enfin les supports numériques, tel des clés USB ou des *clouds*, stockants des formats digitaux comme le MP4, le MXF ou le MKV. Tous ces supports servent de support d'enregistrement original et/ou de support de diffusion. Pour le format numérique, on distingue les formats numériques de production des formats numériques de diffusion. Les formats varient en fonction du matériel utilisé pour enregistrer et celui utilisé par diffusé. Pour des raisons de conservations, on rencontre un principe similaire sur l'image animée physique ce qui fait qu'une même œuvre existe dans différentes matérialités simultanément ou successivement.

Il y a également une notion d'état amenée par la « post-production ». Prenons un film récent comme *Avatar* (2009) du réalisateur James Cameron. Le film diffusé au public est uniquement fait d'images de synthèses et d'effets spéciaux numériques. Cependant, tout cela a été produit à partir de *rushs* sur lesquels figurent des acteurs, d'autres décors et matériels. Il existe donc deux états ou versions originales du film : la version « brute », composée de *rushs*, et la version diffusée au public qui est complètement différente. Ces transformations extrêmes restent rares, cependant la « post-production » a tendance à prendre une place grandissante. Si à l'origine cela consistait en la modification des couleurs, le réagencement des

¹²³Natasha Fairbairn, Maria Assunta Pimpinelli, Thelma Ross et Viviane Thill, « Le Manuel de catalogage des images animées de la FIAF » (), p.5.

images animées au montage et l'ajout de musique, aujourd'hui cela consiste en la création de visuel, de décor, de personnages par des procédés numériques.

Contrairement à beaucoup d'objets de collections, l'image animée nécessite un matériel de diffusion. En effet, la projection de l'image animée est un aspect fondamental : c'est ce qui lui donne vie et fait apparaître la notion de mouvement propre à cette typologie. La nécessité de diffusion, dans un souci de communication et d'exploitation de la notion de mouvement, implique la conservation des équipements de diffusions propre à chaque matérialité de l'image animée et parfois rare.¹²⁴ Cela conditionne l'image animée et sa préservation car la communication et diffusion de ces dernières ne peut se faire que grâce au matériel adapté. Ce qui demande donc de l'entretenir, car certains matériels ne sont plus fabriqués. Ainsi l'image animée fait face à une double obsolescence qui lui est propre : celle des supports de diffusion et celle de l'objet patrimonial. Prenons l'exemple d'une image animée produite au début du XX^{ème} siècle sur une bande en nitrate d'argent. Sa composition chimique est une véritable difficulté de conservation car son altération provoque des dégradations allant jusqu'à la combustion du support. Si il est parfaitement conservé, le matériel nécessaire à sa projection est devenu rare. Ainsi, la bonne gestion des collections doit intervenir sur les deux fronts.¹²⁵

À cette double diversité matérielle s'ajoute une diversité conceptuelle. Nous ne parlons pas de film, de vidéos ou encore de documentaire car ils représentent des réalités différentes de l'image animée aussi bien dans la réalisation, l'utilisation, l'objectif, la diffusion et la conservation. L'image animée concerne aussi bien un film amateur que professionnel, ces derniers variants : films d'animations, films d'images de synthèses, documentaires ou encore films pédagogiques. Mais aussi les séries, publicités, etc.¹²⁶. Chaque typologie regroupe certains nombres de caractéristiques uniques venant modifier l'indexation que l'on doit faire.¹²⁷

Ainsi, dans sa production et conservation physique l'image animée est un objet éminemment complexe comprenant différentes réalités conceptuelles et techniques. C'est un objet patrimonial et documentaire unique, faisant face à ces propres défis non partagés avec les autres objets documentaires et patrimoniaux. Dès lors, au sein de collections hétérogènes l'indexation de l'image animée ce doit d'être particulière afin de prendre en compte toutes les complexités brièvement explorées.

¹²⁴Ray Edmondson, « PHILOSOPHY AND PRINCIPLES » ().

¹²⁵*Ibid.*, p.39 et 54.

¹²⁶N. Fairbairn, M. A. Pimpinelli, T. Ross, *et al.*, « Le Manuel de catalogage des images animées de la FIAF »..., p.5.

¹²⁷R. Edmondson, « PHILOSOPHY AND PRINCIPLES »..., p.18 et 34.

2. Le FRBR et le WEMI

Les prémices de cette gestion particulière apparaissent en 1998. l'IFLA publie un modèle conceptuel de gestion des œuvres de bibliothèques. Il repense notre manière de décrire les livres conservés afin d'arriver à une nouvelle structure des données bibliographiques.¹²⁸ Jusqu'alors, la norme internationale qu'est l'ISBD structurait les données bibliographiques autour du seul objet physique ce qui ne permettait pas de créer du lien au sein des collections ou avec d'autres collections. De plus, l'apparition de déclinaisons comme l'ISBD(A) pour les livres anciens a finalement fragilisé l'homogénéité des données.

Devant l'évolution des besoins utilisateurs cherchant à gagner en simplicité dans ses requêtes, l'ISBD s'est révélé y être peu adapté. En effet, cette norme ne permet pas de présenter une œuvre et les déclinaisons qu'elle a connue à travers le temps, ni ses liens avec d'autres œuvres ou sujet ce qui limite la démarche exploratoire de l'utilisateur provoquant une frustration d'usage. Ainsi, la proposition de l'IFLA réside dans la réorganisation conceptuelle de la structure et de la description des œuvres en déplaçant le point d'intérêt de l'exemplaire vers un ensemble conceptuel plus vaste et structuré : c'est le modèle FRBR.

Ce modèle répartit les données bibliographiques en 3 groupes d'informations.¹²⁹ D'abord le groupe des informations sur le contenu intellectuel et artistique de l'œuvre indexée. Ces informations sont réparties sur 4 entités hiérarchisée entre elles, chacune représente un niveau intellectuel du contenu artistique et intellectuel de l'œuvre indexée. Ce sont les niveaux WEMI pour : *Work*, ou œuvre, *Expression*, *Manifestation* et *Item*.

L'œuvre est le niveau hiérarchique le plus haut et représente l'idée intellectuelle ou artistique. C'est l'élément central auquel les niveaux expression, manifestation et item se rattache et duquel ils héritent les informations principales comme l'auteur, le synopsis, etc. C'est uniquement l'idée intellectuelle d'origine, sans matérialité définie. Par exemple, *les Misérables* de Victor Hugo est une œuvre et est donc décrite dans le niveau *Work*.¹³⁰

L'expression est une réalisation, une forme que prend l'œuvre. Il n'y a toujours pas de matérialité mais simplement une réalisation sous une forme définie à un moment précis de laquelle découlent ensuite des objets physiques. Si on reprend l'exemple précédent, *Les Misérables* connaît plusieurs expression par exemple : le texte original de 1862, sa traduction

¹²⁸Universal bibliographic control and international MARC programme et Fédération internationale des associations de bibliothécaires et des bibliothèques (éd.), *Functional Requirements for Bibliographic Records : Final Report*, München, 1998 (UBCIM Publications, 19).

¹²⁹*Ibid.*, P.12 à 16.

¹³⁰*Ibid.*, p.16 à 18.

en 1863 en anglais par Charles Wilbour et son adaptation en film en 2012 par Tom Hooper. Ces 3 éléments distincts sont rattachés à la même idée intellectuelle qu'elles expriment.¹³¹

La manifestation est une forme concrète prise par une *Expression*. Elles ont un contexte de production, de nouveaux acteurs qui ont fabriqué une version de l'expression, des dates propres, des lieux de diffusions, etc. Par exemple, le manuscrit original de Victor Hugo a été édité une première fois en 1862 par l'éditeur Albert Lacroix, puis en 1972 aux éditions Gallimard puis en édition numérique ebook en 2010. Ce sont des matérialités différentes de cette *Expression*.¹³²

L'item représente ce que l'on possède. Un item est un exemplaire issu de la production d'une *Manifestation* physique ou numérique. Il est doté de caractéristique uniques relatives à sa vie dans les collections des institutions conservatrices.¹³³

Chaque niveau hérite des informations contenues au niveau supérieur en plus des portées des informations lui étant propre. Ce qui créer donc 4 niveaux d'indexations, et 4 niveaux de liens normalisé pouvant donc s'effectuer d'une institution à une autre.

En voici un schéma :




FIG. 6 : Schéma d'un WEMI fictif d'une œuvre.

¹³¹ *Ibid.*, p.18 à 20.

¹³² *Ibid.*, p.20 à 22.

¹³³ *Ibid.*, p.22 à 23.

Le second groupe est celui des personnes physiques et morales en lien avec chacun des niveaux WEMI et parfois plusieurs WEMI.

Ainsi, une personne liée au niveau *Work* en est la créatrice. Il s'agit de l'autrice de l'œuvre, celle qui a pensé l'idée intellectuelle et artistique ensuite réalisée.

Puis, quand elle est liée au niveau *Expression*, elle en est la réalisatrice au sens général plaçant cette personne comme celle qui a donné forme à une idée.

Si elle est liée à un niveau *Manifestation*, alors elle en est la productrice. C'est elle qui est responsable de la production de l'*Expression* dans cette forme. On y retrouve le plus souvent des personnes morales comme des entreprises.

Enfin, au niveau *Item* cette personne en est la possesseuse. C'est à dire qu'elle détient les droits sur l'exemplaire.

Notons que la créatrice peut aussi être réalisatrice, productrice et possesseuse au sein d'un même WEMI. Ou alors créatrice dans un WEMI et productrice dans un autre. Simple-ment, le lien avec un niveau WEMI est toujours de même nature.

Enfin, le troisième groupe est celui des éléments complémentaire au niveau *Work* d'un WEMI. on y retrouve les événements, les objets, les lieux ou les sujets qui servent donc à enrichir le niveau *Work* afin de mieux l'indexer. Ce niveau peut être lié à plusieurs éléments de ce groupe et permet de créer des relations entre les *Work* d'une même collection ou entre plusieurs collections. De cette manière, un utilisateur intéressé par un sujet précis peut obtenir plus de résultat à ses requêtes.

De manière schématique, voilà ce que représente un WEMI complet :




FIG. 7 : Schéma de fonctionnement des liens dans un WEMI. Source : https://mediadix.parisnanterre.fr/medias/fichier/catalogage-isbd-unimarc-apports-theorique-maj-2025_1736242651118-pdf

Ce modèle générique c'est peu à peu diffuser dans le reste du monde patrimonial, certaines institutions allant même jusqu'à adapter ce modèle à des besoins plus spécifiques ce qui est possible grâce à sa souplesse. C'est notamment le cas de la Fédération Internationale des Archives du Film qui l'adapte aux particularités de l'image animée notamment en modifiant la notion d'œuvre et rajoutant celle de variante.

Pour l'image animée, l'œuvre et l'*Expression* sont une seule et même entités. En effet, dans ce domaine l'œuvre désigne à la fois le concept intellectuel ou artistique et le processus de création de l'image animée.¹³⁴ Ainsi, elle intègre également les circonstances de création originale de l'image animée, des notions de temporalités, de localisations et de matérialités définies. Elle a également des relations différentes avec les personnes puisqu'elle est dotée d'une personne créatrice, mais aussi réalisatrice et productrice. Ajoutons à cela la diversité typologiques importantes de l'image animée qui est incluses dans la notion d'œuvre. Sans revenir sur le sujet, déjà traité, la diversité typologique amène une fluctuation dans le niveau d'informations attendu dès le niveau œuvre.

¹³⁴N. Fairbairn, M. A. Pimpinelli, T. Ross, *et al.*, « Le Manuel de catalogage des images animées de la FIAF »..., p.21.

L'image animée se caractérise également par son caractère évolutif. Il est facile, bien que sujet au débat, de partir du principe qu'une œuvre d'art, comme un tableau, une fois créée, ne connaîtra pas de grandes évolutions. Il sera restauré, certes, mais jamais modifié dans son concept et grandes lignes. Ce n'est pas le cas d'une image animée qui outre les restaurations peut être modifiée de multiples manières avant même son entrée dans une collection. Prenons l'exemple de la censure : elle peut altérer la bande son, le montage ou encore l'intégrité visuelle de l'œuvre ce qui impacterait parfois le concept artistique exprimé. Sans constituer une œuvre à part entière, elle n'est plus l'œuvre originale exprimée dès la création artistique. Ainsi, la Fédération Internationale des Archives du Film crée une entité WEMI unique : la variante.

Cette nouvelle notions permet de créer une œuvre modifiée, légèrement différentes, découlant de la version originale. On l'utilise dès lors qu'une modification impacte la description de l'image animée, que ce soit des ajouts ou des retraits de séquences, scènes ou plans. Cela concerne également des modifications dans sa production, dans les comédiens ou dans sa bande son comme par exemple un doublage, etc.¹³⁵

Ces particularités changent l'organisation du WEMI de deux manières. D'abord sur le découpage structurel puisque le niveau expression disparaît laissant place à un niveau facultatif qu'est la variante. Ensuite, sur la répartition des informations à indexer sur les 4 entités puisque ces deux remaniements induisent nécessairement un changement d'indexation.

Le modèle WEMI proposé par la Fédération Internationale des Archives du Film est surtout plus souple. En effet ce n'est pas un modèle de gestion qui est proposé, mais 4 modèles. Chacun présentent une répartition différentes des informations.¹³⁶ Nous n'allons pas tous les présenter ici afin de pouvoir nous attarder sur les choix effectués par SkinSoft.

3. La gestion de l'image animée dans l'application SkinSoft

Dans le logiciel SkinSoft, la gestion des image animée est réservée au module S-Movies. Nous ne reviendrons pas sur cette notion de module, déjà vu précédemment¹³⁷.

Ce qui distingue S-Movies des autres modules de la suite logiciel est sa gestion totalement transparente des niveaux WEMI. Chaque entité WEMI possède sa propre table, donc ses propres données et points d'accès ce qui permet de bien cloisonner les niveaux WEMI et de diriger l'utilisateur plus facilement entre ces derniers. La structure WEMI adoptée est la suivante :

¹³⁵ *Ibid.*, p.23.

¹³⁶ Pour plus d'informations voir *Ibid.*, p.9 à 13

¹³⁷ Voir page 8




FIG. 8 : Schéma du modèle WEMI implanté dans la solution S-Movies. Source : FAIRBAIRN (Natasha), PIMPINELLI (Maria Assunta), ROSS (Thelma) et THILL (Viviane), « Le Manuel de catalogage des images animées de la FIAF » ()

La variante est considérée comme une *Manifestation*, comme cela est recommandé par la Fédération Internationale des Archives du Film si l'entité propre n'est pas utilisée.¹³⁸ Ce choix s'inscrit dans la volonté de simplifier le parcours utilisateur en rendant son inclusion similaire à celle d'une *Manifestation*. Elle se distingue des *Manifestation* par un champs d'indexation permettant de renseigner le type de variante dont il s'agit.

Les différents niveaux WEMI sont connectés au sein de l'application via des champs de lien créant une filiation entre chaque niveau. Ces liens sont souples, modifiables à tout moment et multi-relationnels. Ainsi, la gestion des images animées reste fidèle aux principes de gestion proposés par la Fédération Internationale des Archives du Film¹³⁹.

Cette souplesse fait de S-Movies un logiciel permissif permettant à l'utilisateur d'adopter différents parcours afin d'effectuer les mêmes actions. Nous allons donc essayer de retracer un parcours utilisateur typiques, privilégiés, tout en énonçant les diverses possibilités s'ouvrant à lui.

L'utilisateur commence toujours par la création d'une notice œuvre dans la table dédiée, constituant également la page d'accueil de l'application. En fonction de sa configuration¹⁴⁰, l'utilisateur peut rentrer manuellement une certaine quantité de données ce qui demande donc, en amont, une étape d'analyse afin de correctement distinguer où stocker l'information.

On peut lier cette dernière à des notices bibliographiques, des archives et des objets de collections contenus dans d'autres modules. De cette manière, il peut indiquer si l'œuvre est une adaptation cinématographique d'un livre, ou si elle est liée à des objets en tout genre. En somme, par cet aspect de connexion on peut circonscrire des univers cinématographique entier tout en gardant les spécificités de gestion de chaque objet.

Ensuite, il peut créer une manifestation depuis la table dédiée ou depuis une notice œuvre. Si la création se fait depuis la table elle peut être reliée à n'importe quelle œuvre, et si elle est créée depuis une notice d'œuvre elle y est automatiquement reliée. Tout dépend de la configuration utilisateur, la seconde option ne pouvant se faire que par l'usage de grille de recherche configurable par l'utilisateur. Peu importe la modalité, cette étape demande une analyse humaine importante car l'utilisateur doit préciser la nature de la manifestation, notamment si c'est une variante. Cela demande donc une analyse effectuée au moment de la création du WEMI et basée sur des connaissances cinématographiques. Notons qu'une manifestation peut être liée à plusieurs œuvres comme les coffrets qui réunissent plusieurs œuvres différentes dans une même manifestation autour d'une thématique précise.

¹³⁸ *Ibid.*, p.23.

¹³⁹ Voir (*Ibid.*)

¹⁴⁰ Pour plus d'informations voir page 8

Enfin, il peut créer un *Item* en suivant les mêmes choix de création que précédemment. Cependant, la notice d'*Item* représentant un exemplaire conservé, on peut par exemple le créer en même temps qu'une notice d'entrée créée dans la table dédiée. Il existe une pluralité de modalité de création qui s'explique par le fait que c'est ce niveau pour lequel on gère le « cycle de vie » pensée de David Bearman¹⁴¹. Ainsi, en plus de pouvoir être lié ou créé par une entrée, l'*Item* peut être créé ou lié à des expositions, des prêts, des diffusions, des mouvements, des restaurations, ou encore lié à des objets tels que du matériel de diffusion.¹⁴² Notons que plusieurs *Item* peuvent être liés à une seule *Manifestation*.

Le logiciel essaie d'assurer au maximum dans l'application l'application d'un modèle FRBR aux spécificités de traitement de l'image animée sans créer d'incohérence. Sur l'indexation en elle même, l'application se confronte de plein fouet à une réalité complexe de l'indexation de cette typologie d'objet patrimoniaux. Il nous faut l'explorer afin de comprendre les complexités inhérentes à l'indexation d'un tel objet documentaire appliqué à un modèle FRBR.

4. Complexité et limite de l'indexation des images animées :

Les images animées sont très riches en informations visuelles. Les productions cinématographiques professionnelles, en plus de ce qui figure dans les images les crédits fournissent une quantité importante de données à indexer. Il faut donc pouvoir récupérer ces données visuelles différentes, qui demandent des traitements différents tout en gardant l'objectif de devoir les répartir sur les différents niveaux WEMI. Dans les productions amatrices les informations à indexer sont souvent uniquement présente dans les images en elles mêmes. Cela demande de visionner et d'analyser chaque œuvre afin d'en extraire des mots-clés, des caractéristiques uniques, des personnes, des lieux, des objets et d'en déterminer leurs niveaux WEMI d'appartenance.

Rajoutons également que ce processus d'indexation se complexifie avec la question de l'héritage des champs. Prenons l'exemple d'une variante : elle se caractérise par des changements modérés impliquant des divergences de données sur un même champs. Donc une donnée portée par l'œuvre, comme les comédiens ou l'équipe technique, peut se retrouver non valide dans une variante. Cela peut créer une incohérence d'indexation et des difficultés de modifications de la données.

¹⁴¹ *Archives & Museum Informatics : Publishing : Archives : Functional Requirements for Collections Management Systems : Table of Contents...*

¹⁴² *Ibid.*

Pour illustrer ces limites, prenons le cas d'une institution aux besoins de gestion spécifiques et utilisant l'application pour gérer ses image animée.¹⁴³

Certaines images animées conservées ont été réunies sur des support de conservations communs sans séparation entre les œuvre. Deux problématiques en émerge : d'abord un WEMI complexe puisque plusieurs œuvres sont réunies en une seule manifestation, la bobine, dont en découle plusieurs items, chaque entités d'image animée horodatées. De plus, un besoin de pouvoir séparer matériellement dans l'application chaque bande vidéos et sonore de chaque item afin de pouvoir les associer à leurs notices propre.

Cette institution peut s'appuyer sur la souplesse du logiciel et du modèle FRBR. Son schéma WEMI est réalisable, mais toute l'étape de traitement est problématique. Il repose sur l'analyse de bobines entières, l'identification du nombre d'entités présentes et leur identification propre ainsi que leur association au segment de bobine concerné. Cependant, cela ne peut être fait que par l'humain et à l'aide de logiciels de traitement externes ce qui complexifie d'autant la tâche.

De plus, ces films ne présentent aucun crédits permettant des identifications de personnes, lieux, de caractéristiques clés. Après avoir segmenté les bobines en plusieurs image animée, il faut les analyser individuellement pour en extraire des informations clés. Cela peut être long et fastidieux, surtout appliqué à des collections denses, poussant l'humain à commettre des erreurs.

Plus globalement, les besoins descriptifs des institutions conservatrices d'image animée sont aujourd'hui satisfait par l'utilisation de plusieurs logiciels externes et l'analyse humaine de chaque élément de collections possédé. En fonction de la densité de la collection, les étapes de traitement sont plus ou moins longue et redondante augmentant ainsi le risque d'indexation erronée. Les système de gestion des collections n'intègrent ces processus faisant aujourd'hui partie intégrante de la gestion des collections des images animées.

SkinSoft cherche aujourd'hui à faire évoluer S-Movies pour proposer des modalités de gestions plus adaptées. Le déploiement d'un outil d'indexation semi-automatisée entre dans cette politique. Ce serait un *pipeline* basé sur l'intelligence artificielle commençant lors de l'intégration dans l'application d'une vidéo, et prenant en charge sa segmentation en différentes images animées accompagnées de propositions d'indexations pour chaque notices produites. Cela dans le but d'automatiser et homogénéiser les indexations. De manière plus générale, cette question a été relativement traitée et il existe déjà quelques tentatives. Nous allons les analyser dans la partie suivante

¹⁴³Pour des raisons de sécurité et de confidentialité, le nom de l'institution est anonymisé.

II. Les différentes réalités de l'indexation semi-automatisée : focus sur l'image animées, un objet documentaire particulier.

L'indexation semi-automatisée se définit comme un processus basé en partie sur de l'intelligence artificielle, basée sur du *Deep Learning*, et des opérations humaines dans le but de faciliter et d'homogénéiser l'indexation à grandes échelles.

Ce processus est né de plusieurs constat sur l'indexation des textes, notamment, dans les bases de données patrimoniales. D'abord, l'indexation des textes et objets patrimoniaux par mots-clés, comme pratiquée encore aujourd'hui, permet d'optimiser l'interrogation des bases de données. Cependant, sur de grandes quantités de données procéder à une indexation manuelle, souvent effectuée par plusieurs personnes, amène à créer de la variation là où les bases ont besoins de constances. De cette cohérence et stabilité descriptive dépend l'accessibilité à la base et la précision des résultats : plus la cohérence et stabilités sont basses, plus les résultats seront imprécis.¹⁴⁴

Le second constat vient de la masse documentaire à traiter et de sa typologie. En effet, les textes concernées dans le monde patrimonial concerne de vaste périodes chronologiques ce qui demande la compréhension d'un vocabulaire vaste et évolutif, et l'adaptation des mots clés utilisés. De plus, ces collections sont en expansion constante et avec l'arrivée du numérique et l'inclusion des documents nativement numérique dans la notion de patrimoine, cette expansion n'est que plus rapide.¹⁴⁵

Ces deux éléments mènent à penser que l'indexation par seul moyens humains devient une limite important des bases de données patrimoniales. En effet, la perte en stabilité que ces deux éléments provoquent mènent à une perte de qualité de la donnée rendant la tâche des *Information Retrieval System* intégré dans les **SGC** plus complexes.

Mais alors pourquoi une indexation « semi-automatisée » et pas une indexation automatisée ? Cela pourrait permettre de traiter une plus grande masse de documents, plus rapidement et d'enlever le facteur humain à l'origine d'incohérences. C'est en réalité une fausse solution car si cela permet bien d'accélérer le traitement, on remarque des défaillances similaires. Les outils d'intelligence artificielle ont tendances à produire les mêmes erreurs d'indexation que les humains et sont, de plus, moins précis dans le choix des mots utilisés.¹⁴⁶

¹⁴⁴Laurent Kevers, « Indexation Semi-Automatique de Textes : Thésaurus et Transducteurs », dans *Sixième Conférence Francophone En Recherche d'Information et Applications (CORIA)*, Presqu'Île de Giens, France, 2009, p.1.

¹⁴⁵*Ibid.*

¹⁴⁶*Ibid.*

Finalement, le traitement automatique sacrifie la précision pour la rapidité et nous avons déjà exploré précédemment avec la recherche intelligente que ce n'est pas le point privilégié par les institutions conservatrices.

Une indexation semi-automatisée permet de faire de l'intelligence artificielle un outil d'appui, capable de suggérer des indexations et de proposer une base de travail propre très rapidement¹⁴⁷. L'humain n'a plus à lire l'entiereté de chaque document, d'analyser et d'indexer lui-même : il n'est plus que le vérificateur qui peut valider la proposition issues du processus ou alors créer une alternative. De cette manière, on exploite la capacité de traitement de masse des processus d'intelligence artificielle et en y associant l'analyse humaine, ce qui permet d'augmenter drastiquement la précision des mots-clés choisis. C'est ce que l'on appelle l'approche *Humain in the loop*. En somme, l'intelligence artificielle analyse, l'intelligence artificielle suggère et l'indexeur valide, invalide ou modifie.

Avant d'examiner ce qui se fait ou non dans le cadre de l'image animée, commençons par l'analyse du principe appliqué à des collections de musées plus statiques. Pour cela, je m'appuierai principalement sur le projet mené par Pierre Husson¹⁴⁸, promotion TNAH 2025, au sein du projet *IconographIA* consistant en l'application de tel processus sur des tableaux italiens du RETIF¹⁴⁹.

Cette étude est intéressante car elle démontre toute la complexité de l'indexation dans le milieu patrimonial. Tout d'abord, la notion de vocabulaire¹⁵⁰ dans l'univers patrimonial et de l'art est une notion complexe. Le vocabulaire est pluriels, d'abord car adaptés à chaque typologie patrimoniale et ensuite car au sein même de ces typologies existe des subdivisions avec leurs propres besoins terminologiques. Ces vocabulaires sont standardisés et contrôlés dans des thésaurus auxquels se rattachés comme ceux du Getty Research Institute ou encore OpenTheso pour l'échelle française.

Bien qu'on puisse s'appuyer sur ces thésaurus pour contrôler les termes générés par un outil d'indexation automatique¹⁵¹, il existe un fossé entre la compréhension de ce que l'intelligence artificielle voit et la sémantique des thésaurus. En effet, appliqué aux tableaux les modèles utilisés n'ont pas eu de mal à repérer des formes génériques : humains, animaux, épées, etc. Cependant, les thésaurus représentent des concepts propres à l'art et vont donc proposer des vocabulaires plus spécifiques représentant des sujets ou motifs propres à ce

¹⁴⁷Pierre Husson, *Indexation Iconographique et Intelligence Artificielle : Expérimentations Autour Du Répertoire Des Tableaux Italiens Dans Les Collections Publiques Françaises (RETIF)*, mém. de mast., 2025, p.69 à 71.

¹⁴⁸*Ibid.*

¹⁴⁹Répertoire des tableaux italiens dans les collections publiques françaises

¹⁵⁰*Ibid.*, p.9 à 17.

¹⁵¹*Ibid.*, p.38 à 40.

domaine. L'intelligence artificielle rencontre des difficultés à intégrer ces notions et peine à dépasser cette généralisation afin de se rapprocher des valeurs sémantiques contenues dans les thésaurus.¹⁵²

De plus, cette étude démontre que les modèles ne sont pas encore tout à fait adaptés aux spécificités de l'art.¹⁵³ En effet, plusieurs expériences ont démontré que les *Large Language Model* génériques ont tendances à ne pas reconnaître avec suffisamment de précisions les genres iconographiques et picturaux des images fournies. Des outils spécialisés connaissent un développement récents et prometteur, permettant donc la reconnaissance des genres picturaux. Cependant, il est souligné que ces modèles demandent des compétences techniques précises et qu'ils n'atteignent toujours pas les taux de précisions attendus dans le domaine du monde patrimonial.

À la lumière de ces éléments, Pierre Husson conclut que l'indexation iconographique est loin d'être un processus automatisable. Cependant, les récents avancées notamment avec les modèles multimodaux capables de traiter texte, images, vidéos et sons en même temps, permettent d'envisager un appui sur des outils d'intelligence artificielle au profit d'une indexation plus précises et produisant des données de grande qualité.

L'indexation semi-automatisée est ainsi un domaine en pleine construction. Nous nous sommes concentrés sur l'indexation de tableaux par leurs ressemblances avec les images animées, mais ce constat peut se faire sur toutes les typologies sujettes à l'indexation.

Mais alors, pourquoi faire de l'indexation automatisée ou semi-automatisée sur l'image animée ? La première raison est l'explosion quantitative des collections d'images animées : la Cinémathèque française conserve à titre d'exemple plus de 40 000 œuvres cinématographiques.¹⁵⁴ Cela s'explique par l'intensification de la production de film professionnel : plus de 9511 films sont réalisés à l'échelle mondiale en 2023 contre 7620 en 2016 selon le WIPO¹⁵⁵. Cela ne prend pas en compte la production de films amateurs, également conservés pour certains, et toutes images animées produites dans des cadres professionnels autres que le monde du cinéma. De même, cela ne prend pas en compte ce qui est déjà produit et qui continue d'être conservé. Ainsi, l'indexation manuelle devient de plus en plus compromise car elle ne permet pas aux institutions conservatrices de suivre la cadence de production et l'automatisation est un levier afin d'accélérer ces processus d'indexation.

La seconde raison est la diversité typologiques des images animées. En effet, nous avons

¹⁵² *Ibid.*

¹⁵³ *Ibid.*, p.41 à 43.

¹⁵⁴ Pour plus d'information, consulter : <https://www.cinematheque.fr/les-collections-de-films.html>

¹⁵⁵ Pour plus d'informations, consulter : <https://www.wipo.int/fr/web/global-innovation-index/w/blogs/2025/global-film-production>

brièvement vus que « image animée » est un terme vaste pour désigner tout document à base d'une succession d'image fixe donnant l'impression de mouvement. À ce titre, on désigne une typologie très vaste que nous avons légèrement dépeinte et qu'il est impossible à dépeindre de manière exhaustive. Chaque typologie possède ces propres caractéristiques et biais demandant d'autres méthodes d'indexations : un épisode de série ne s'analyse pas de la même manière qu'un film professionnel, qu'un documentaire ou qu'un film d'archives produits dans le cadre d'une activité. Cela complexifie d'autant plus l'indexation humaine puisqu'il faut pouvoir déterminer une méthodologie et s'y conformer pour chaque typologie conservée. L'intelligence artificielle pourrait également résoudre cette aspect par sa capacité d'adaptation.

Enfin, et surtout, l'indexation de l'image animée est d'une relative complexité dû à ces particularités que nous allons explorer.

Tout comme les tableaux, l'image animée pose ses propres difficultés à commencer par la notion de mouvement. L'analyse d'un tableau repose essentiellement sur l'analyse d'une image à travers différents domaine de l'intelligence artificielle, comme la *computer vision*, et une succession de traitement pour transformer l'image en mots-clés. Cependant, pour créer cette impression de mouvement une œuvre d'image animée est composée de plusieurs centaines ou milliers d'images capturées à la chaîne sur un instant plus ou moins long. Ces images sont donc porteuse de sens seule, car elles représentent quelques choses et y font figurer des éléments, mais aussi et surtout au sein d'ensemble que sont les séquences et les scènes. L'indexation de vidéos ou de films entier repose donc principalement sur l'analyse de ces images individuellement mais aussi ensemble, en corpus, car c'est ensemble qu'elles prennent sens.

De plus, on retrouve des besoins d'indexations similaires à ceux des tableaux : reconnaître des entités, comme des personnes, des objets, des similarités avec d'autres œuvres, des genres et des sujets. Cependant, cela doit se faire au sein de l'œuvre dans son entièreté donc pour chaque image animée et ensemble d'images animées. Rajoutons que l'image animée à aussi ces propres besoins d'analyse et d'indexation dont voici les trois principaux :

Le premier besoin est celui d'un découpage automatique des œuvres à l'échelle des séquence ou les scène qui constituent le cœur de l'œuvre. Cela correspond à une volonté de pouvoir effectuer une analyse fine des œuvres afin de proposer une indexation optimale et des résultats de recherches précis. Par exemple, le besoin institutionnel formulé précédemment était de pouvoir automatiquement déterminer le début et la fin de chaque œuvre contenue dans les bobines en rassemblant plusieurs. On peut également penser à un chercheur intéressé uniquement par certaines scène de certaines œuvres unies selon une thématiques communes ou la présence d'un même objet ou acteur. Disposer d'un outil capable de découper automa-

tiquement les œuvres d'image animée en des unités documentaires plus petites et indexées à cette échelle est essentiels.

Un second besoin est de pouvoir faire des liens entre différentes scène et/ou séquence d'une même œuvre, ou idéalement entre différentes œuvres. De tels liens au sein d'une même œuvres pourraient permettre de suivre et reconstituer des arcs narratifs multiples, l'évolution de thèmes ou encore le suivis de sujets et d'entités d'un bout à l'autre de l'œuvre. Si l'analyse et le découpage chronologique est important, il subsiste ce besoin de découpage thématique plus complexe dans le cadre de l'image animée. L'idée étant de pouvoir saisir la richesse des liens caractérisant les œuvres d'image animée. Ces liens peuvent être fait entre les œuvres puisque, comme des tableaux, il existe des suites d'œuvres thématiques. Par exemple, les duologies et trilogies, qui sont des suites de deux ou trois œuvres, ou encore la notion de saisons au sein d'une série. Des liens et porosités existent nécessairement, et l'institutions conservatrice souhaite les saisir afin d'offrir une indexation optimale.

Enfin l'association entre le visuel et le son. En effet, de nos jours le son est une caractéristique principale des images animées que ce soit la musique, les bruits ou encore les dialogues. Ainsi, les objets, entités et thèmes sont exploités à la fois visuellement et auditivement. Par exemple une séquence triste peut être identifiée visuellement, avec les changements colorimétriques et les émotions véhiculées par les acteurs notamment, mais aussi par l'environnement sonore, les dialogues et la musique diffusée notamment. Dès lors, une image animée possédant une bande son, ce qui n'est pas le cas de tous, doit pouvoir être indexée et requêtée à l'aide cette dernière. Cela sous entends que le processus doit pouvoir « comprendre » le son et l'associer à des scènes, des séquences, des objets et des entités.

Finalement, les besoins d'indexation de l'image animée peuvent sembler similaire à ceux existant pour l'iconographie et les tableaux de manière générale. La reconnaissance d'entités, comme des personnes, des objets, de thèmes et de sujet sont déjà exploité par différent outils d'intelligence artificielle. Le travail de Pierre Husson pose des limites claires à ces éléments : la précision de ces outils n'est pas encore suffisante¹⁵⁶ et les outils spécialisés sur des typologies très précises ne sont encore que peu développés.

Cependant, les caractéristiques uniques de l'image animée, la notion de mouvement et l'association de l'image à une bande son, en complexifie le traitement. Il ne s'agit non plus de retrouver des éléments dans une image fixe, mais dans un ensemble d'image liées chronologiquement et thématiquement au sein d'une alliance complexe entre image et son demandant deux plans d'analyse. Sans créer de nouveaux besoin à proprement parler, le traitement de l'image animée requiert de nouveaux moyens adaptés aux difficultés du besoin original de-

¹⁵⁶ *Ibid.*, p.47.

mandant ainsi de nouvelles technologies dès lors que l'on parle de l'automatisation de son indexation.

En somme, le traitement assisté par intelligence artificielle de l'image animée demande deux phases de traitement. Une phase de « pré traitement » essentielle afin de décomposer l'œuvre soumises à analyse en autant d'entités que nécessaire que cela soit un film, dans le cas de bobine en contenant plusieurs, en scènes ou séquences. Et une seconde phase de traitement permettant de reconnaître des éléments d'indexations, de les identifier et cela de manière normalisée généralement conforme à un ou plusieurs Thésaurus.

Après des recherches sur le sujet, un premier constat s'offre à nous. Tout d'abord, il n'existe pas encore de solutions « *open source* » permettant d'effectuer cette chaîne de traitement. Il existe seulement des outils, plus ou moins nombreux et plus ou moins efficaces, permettant d'effectuer des bouts de ce processus mais pour le moment aucun processus aboutit n'a été élaboré à partir de ces outils.

Du côté des solutions privées, nous remarquons que certaines solutions à destinations du monde patrimonial existent et sont déjà utilisées par des institutions patrimoniales. Cependant, comme souvent, ces solutions manquent de transparence : nous n'avons pas connaissance de la méthodologie appliquées, des outils utilisés et des compatibilités avec des standards de descriptions. Le plus connu est l'outil proposé par Archipanion que nous allons étudier par la suite :

Les Archives fédérales Suisses utilisent ce service à des fins de reconnaissance et d'extraction de méta données à partir d'images et de vidéos. Grâce à cela, il a été possible d'indexer plus de 200h de vidéos de l'émission *Ciné-Journal Suisse* diffusé de 1940 à 1975.¹⁵⁷ L'article reste succinct et nous n'avons pour information que l'extrait suivant : « Grâce à sa fonction de recherche par contenu visuel, Archipanion permet, en les décrivant, de rechercher des scènes ou des textes figurant dans le fonds du Ciné-Journal suisse et de trouver ainsi des contenus de manière exploratoire [...] Outre la recherche textuelle par description, Archipanion permet aussi de trouver des contenus visuels similaires au sein de la collection. » . On comprend que cette solution permet deux choses : l'indexation des documents multimédias et leurs interrogations par la suite en langage naturel.

Sur le site d'Archipanion¹⁵⁸ voilà les conclusions que nous pouvons établir. Le processus établit agit sur chaque images données en entrée : donc sur chaque image individuelle ou sur chaque image composant une image animée. En s'appuyant sur de la *computer vision* ou

¹⁵⁷ *Archipanion pour le Ciné-Journal suisse...*

¹⁵⁸ Pour plus d'information, consulter : <https://www.archipanion.com/fr/>

bien des modèles multimodaux, il semble y avoir un processus de vectorisation : chaque image se voit attribuer un identifiant unique, propre au processus, en fonction des entités, des lieux et du style général reconnus.

Lorsqu'un utilisateur interroge ces documents indexés, le processus est le même. L'utilisateur décrit ce qu'il souhaite trouvé, il décrit une scène ou une image qui est transmise à l'intelligence artificielle. Un exemple de description est donné, en anglais, : « *women at work* » . Cette requête est également mise sous forme de vecteur et comparé aux vecteurs des image animée analysées. Plus des vecteurs sont proches, plus il est probable qu'il existe une correspondance.

Des questions subsistent. Les personnes sont-elles reconnues ? Qu'en est-il des réalisateurs et membre d'équipes techniques ? Qu'elle est la précision des métas données extraite ? Il y'a-t-il une indexation de toute l'œuvre de l'image animées, scènes par scènes ou séquences par séquences ? La recherche peut-elle s'effectuer de manière plus précise que sur une scène générique ?

L'opacité des solutions privées ne nous permet pas d'apporter des réponses à ces questions. Et les articles d'institutions utilisant cette solution ne sont pas nombreux, en réalité seul celui-ci semble exister ce qui peut s'expliquer par le caractère récent de tels outils. Nous pouvons cependant déterminés deux choses : dans les deux sources, il n'y aucune mention de reconnaissance précises d'entités nommées. Une actrice célèbre, un monument ou encore un objet unique et identifiable ne semble être identifier suffisamment précisément afin de l'indexer de cette manière. Les analyses semblent rester très générales : une voiture, une femme, un homme, etc. Ensuite, il n'y aucune mention de reconnaissance de l'architecture documentaire. Par exemple, une bobine comportant 3 œuvre différentes semble être analysées comme une seule et même œuvre ce qui ne permet de corriger un problème de mélange des supports et des œuvre rencontrées par les institutions sur cette typologies.

Finalement, c'est une solution assez générale appliquant des principes déjà éprouvées sur les images fixes à des objets en mouvements. L'image animée semble être confondu avec une image statique, et est donc analysée de la même manière ce qui amène à perdre la richesse amenée par cette typologie documentaire. De plus, traiter chaque image animée composant une œuvre représente un processus long et coûteux qui, appliqué à des collections comme celles de la Cinémathèque française, peu ne pas présenter un rapport coûts / bénéfices suffisant.

Du côté des solutions dites *open source*, le seul processus de traitement des image animée connu est *vitriivr-engine*¹⁵⁹ développé par l'Université de Bâle, en Suisse, et sur lequel est basé

¹⁵⁹Pour plus d'informations, consulter le github du projet : <https://github.com/vitriivr>

la solution Archipanion.

Cette solution est basée sur la recherche de contenu, c'est à dire qu'on offre la capacité à l'utilisateur de décrire ce qu'il recherche et de l'orienter vers le bon passage d'une vidéo.¹⁶⁰

Son architecture est modulaire, c'est à dire qu'elle se compose, ici, de 3 briques logicielles qui interagissent ensemble mais qui ne composent pas un outil unique. Une interface d'interrogation, *vitivr-ng*, une base de donnée, *Cottontail DB*, et un logiciel multimodal pour la recherche dans des documents multimédia, *Cineast*. Voici un schéma du fonctionnement global applicatif :




FIG. 9 : Schéma de fonctionnement de la solution vitivr. Source : site officiel vitivr à l'URL <https://vitivr.org/vitivr.html>.

Le logiciel fonctionne sur deux étapes. La première étape est celles de prétraitement des données : à l'intégration des documents multimédias dans la base de données, cela passe par *Cineast* qui analyse l'image animée, en extrait les entités visibles et lui donne un vecteur associé. La base de donnée stocke à la fois les œuvres multimédias et leurs représentations vectorielles au sein d'une base PostGreSQL adapté au stockage vectoriel¹⁶¹. La seconde étape

¹⁶⁰Luca Rossetto, Ivan Giangreco, Claudiu Tanase et Heiko Schuldt, « Vitivr : A Flexible Retrieval Stack Supporting Multiple Query Modes for Searching in Multimedia Collections », dans *Proceedings of the 24th ACM International Conference on Multimedia*, New York, NY, USA, 2016 (MM '16), p. 1183-1186.

¹⁶¹*Ibid.*

est celle de l’interrogation utilisateurs : la requête peut être formulée de différentes manières, par phrase, par recherche de similarité avec une image ou un schéma¹⁶², et est d’abord vectorisée par *Cineast* avant d’être envoyée à la base de données par une API. Les vecteurs sont ensuite comparés, et les résultats sont renvoyés à l’utilisateur soit directement dans l’interface *vitriiv-ng* soit en format 3D via *vitriiv-VR*.

Ce qui est intéressant, c’est l’absence des différentes modalités d’interrogations des documents multimédias dans la solution de Archipanion. En effet, seule la recherche par requête textuelle ou par mots-clés semble intégrée. Destinée à la gestion des collections, on peut penser que l’approche par schéma et images similaires ait été jugée non ou peu pertinente notamment dans des questions d’usages et de pratiques.

Finalement, nous nous retrouvons un peu face aux mêmes limites pour une intégration dans le monde patrimonial. Ce logiciel est concentré sur le contenu, le visuel, mais délaisse l’aspect documentaire. Les images animées sont annotées, identifiées, mais elles ne sont pas indexées, mises en relations, décortiquées et encore moins manipulées comme un objet patrimonial. Une institution patrimoniale avec des besoins forts en matière de gestion risque de se trouver limitée : pas d’identification des personnes, pas d’identification technique, pas de rédaction d’une notice, pas de séparation en scènes ou séquences ou même entre œuvres.

Nous pouvons donc conclure que les solutions proposées pour la gestion de l’image animée par intelligence artificielle sont orientées gestion des contenus et non gestion documentaires. C’est insuffisant lorsque l’on souhaite gérer une collection patrimoniale.

Cela nous amène donc à voir plus large que des solutions sur étagères afin de trouver des outils permettant de répondre à l’ensemble des besoins institutionnels. Nous allons donc présenter des outils *open-source* qui, articulés ensemble, peuvent amener à penser et créer une solution d’indexation complète de l’image animée.

1. Manipulation de l’image et des plans

Le premier élément est le besoin de manipulations des documents multimédias en tant que tel. Une institution patrimoniale peut souhaiter séparer différentes œuvres d’image animée présentes sur un même support physique, ou bien une même œuvre en différentes sous-unités qui sont la scène et la séquence. Cela demande nécessairement de pouvoir manipuler le document multimédia afin de le découper à des endroits précis et de pouvoir placer des repères temporels sur ces découpages. De cette manière, on pourrait segmenter une bande vidéo en différents segments indépendants avec chacun un « horodatage », c’est à dire un

¹⁶² *Ibid.*

marqueur temporel au début et à la fin du segment afin de le situer à l'échelle de l'œuvre originale.

Pour cela, il existe le logiciel FFmpeg qui permet de manipuler des bandes vidéos et des bandes sons. Logiciel *open-source* pouvant traiter tous les formats vidéos et audios, il est très utilisé par des plateformes multimédia comme Youtube afin de permettre de manipuler les vidéos (*diffusion, manipulation du flux, etc*). Le gros avantages de ce logiciel est sa compatibilité avec des langages de programmation comme python, qui permettent de l'intégrer dans des workflows automatisés de traitement de données assez facilement.¹⁶³

Avec FFmpeg, la segmentation audio et vidéos est rendu possible. Autrement dit, on peut créer un extrait d' une œuvre avec la granularité désirée. Cependant, FFmpeg demande une action humaine : il n'intègre pas de système afin de repérer des variations justifiant un découpage. L'outil PySceneDetect permet d'identifier dans une piste vidéos chaque changement de plans. Il fonctionne selon le principe de *threshold* c'est à dire que l'utilisateur définit un palier indiquant au logiciel que toute comparaison entre image produisant un score inférieur à ce palier signifie que c'est un seul plan. Si le score de comparaison y est supérieur, alors ce sont des plans différents.¹⁶⁴

Cet outil est très intéressant : d'abord c'est une librairie python ce qui le rend parfaitement intégrable à un script automatique. On peut ainsi lier FFmpeg à PySceneDetect afin de lier la détection à l'extraction. De plus, il s'appuie sur d'autres librairie python reconnues et approuvées pour l'analyse d'image. On peut notamment penser à OpenCV, MoviePY et PyAV pour l'analyse images par images dans une vidéo ou bien d'images fixes. Ce sont des solutions très souples permettant de choisir un détecteur, c'est à dire un algorithme qui permet d'analyser une image et de la comparer avec l'image suivante afin de déterminer si il y a un changement de plan ou non. Chaque détecteur est spécialisé sur l'analyse d'un composant de l'image, par exemple :¹⁶⁵

1. *ContentDetector* : ce détecteur est le plus utilisé car le plus complet et souple. Chaque image est analysées dans son contenu notamment colorimétrique et structurel et obtient un score de détection. En fonction de cette analyse, il calcule un score pour chaque image, disons une forme de vecteur, et compare les score entre eux. La différence entre les scores est ensuite reportée au *threshold*.
2. *AdaptiveDetector* : ce détecteur reprend le principe précédent. Il analyse les mêmes

¹⁶³Pour plus d'informations, consulter : <https://www.ffmpeg.org/documentation.html>

¹⁶⁴Pour plus d'informations, consulter : <https://www.scenesdetect.com/>

¹⁶⁵Pour consulter la documentation relative à chaque détecteur, consulter : <https://www.scenesdetect.com/docs/latest/api/detectors.html>

points, de la même manière. Le changement opère au niveau du système de comparaison. En effet, au lieu de se référer au *threshold* ce détecteur calcule lui même une moyenne glissante entre les images. C'est à dire que le *threshold* change automatiquement en fonction du cas présent. Cela rend le détecteur moins sensible aux mouvement de caméras, qui n'indique pas un changement de plan nécessairement.

3. *ThresholdDetector* : si les deux détecteurs précédents sont basé sur des analyses structurales afin de repérer des coupures, celui ci s'attarde sur les pixels afin de repérer les changements plus fins comme des transitions.
4. *HistogramDetector* : à l'échelle d'une vidéo, l'histogramme est un graphique permettant de visualiser, et parfois gérer, l'équilibre entre ombres et lumières. Ce détecteur analyse cet histogramme, et compare les histogrammes des images afin de détecter des changements d'équilibre. Efficace afin d'identifier les coupures rapides.
5. *HashDetector* : il est similaire à *ContentDetector* et *AdaptiveDetector* si ce n'est qu'il se base sur la création d'un *hash*, c'est à dire une empreinte de taille fixe et propre à chaque image, pour chaque image. Ensuite, les *hash* sont comparés et leurs écarts calculés puis mis en relation avec le *threshold*

Ces détecteurs peuvent s'accumuler, permettant ainsi des analyses multiples mais alourdissant fortement le processus. Plus il y a de détecteurs, plus le traitement s'alourdit et plus on multiplie la finesse de l'analyse ce qui peut amener à faire de chaque petites variations une raison suffisante pour segmenter.

L'extraction se fait à l'échelle du plan puisque cet outil repère les ruptures de prises de vues ce qui caractérise les différents plans. Les scènes et séquences, beaucoup plus intéressantes pour une institutions patrimoniales, ne sont pas encore saisissables par des solutions informatiques. Il est cependant tout à fait possible d'utiliser cet outil pour découper une œuvre en autant de scènes et séquences qui la compose. Commençons d'abord par définir ce qu'est scène puis une séquence

Une scène représente l'unité de base d'une œuvre d'image animée. Il s'agit d'un ensemble de plans mettant en scènes les mêmes acteurs, dans les même lieux, souvent autour des mêmes objets et toujours autours des mêmes actions, sujets et objectifs. Ainsi, pour recréer une scène il faut pouvoir identifier ces éléments de continuité au sein de plan adjacent et cela jusqu'à l'identification d'une rupture nette. Si nous sommes capables d'identifier ces éléments, on peut tout à fait penser à créer des vecteur pour chaque plan basé sur l'identification de ces éléments. Comme dans un système de « recherche augmentée » , c'est la comparaison entre

les vecteurs qui va déterminer l'action et le résultat à retourner. Si au sein de plan adjacents les vecteurs sont extrêmement proche alors ils peuvent regrouper en une scène et cela jusqu'à détecter une rupture avec un autre plan.

Une séquence est un ensemble de scènes regroupées autour d'éléments bien plus abstrait. Ces scènes partagent une thématique commune, un sujet qui bien souvent sert au développement d'une partie de l'intrigue de l'œuvre. En arrivant à saisir un motif, sujet ou thème commun il serait possible d'agir de la même manière que précédemment : vectoriser les scènes sur ces éléments et ressembler les vecteurs proches en séquences.

Ainsi on comprends que pour indexer une œuvre d'image animée il faut aller bien plus loin dans le processus de traitement que la simple détection de plan autrement dit de rupture visuelle. Il faut pouvoir identifier des acteurs, et leurs apparitions dans les plans successif. Mais aussi reconnaître ou du moins caractériser en partie les lieux, parfois fictif, qui permettent d'ancrer l'action dans un élément « concret » . En allant plus loin, il faut également des outils capable de déterminer la thématique générale des plans : dramatique, comique, action, etc. Ce n'est qu'à l'aide de ces éléments on peut envisager deux choses : indexer des éléments d'une œuvre et utiliser ces éléments pour créer des regroupements de plans.

Nous allons donc présenter des outils intégrable dans un script d'automatisation de l'indexation d'images animées permettant la détection et l'analyse des éléments identifiés. Comme nous l'avons déjà abordé, nous ferons l'impasse sur le module *Cineast* de *Vitriivr*. Gardons simplement à l'esprit que ce module ne propose pas une indexation assez fine et précise et que de plus, l'image animée est traitée comme une image fixe. Débutons par l'outil *SAM 2*¹⁶⁶ et son *framework* dérivé *Seg2Track-SAM2*¹⁶⁷.

2. Segmentation d'une image animée

Développé par l'entreprise Meta, *SAM 2* est un modèle d'intelligence artificielle spécialisé en *computer vision* afin de segmenter une image ou une vidéo : c'est à dire de détecter et isoler tout élément composant une image. Ce modèle est particulièrement intéressant pour 3 spécificité :

D'abord sa capacité de *zero-shot*, c'est à dire sans être entraîné à détecter un objet spécifique il pourra tout de même le segmenter au sein d'une image.¹⁶⁸

¹⁶⁶*SAM 2 : Segment Anything Model 2*, Ultralytics Docs.

¹⁶⁷Diogo Mendonça, Tiago Barros, Cristiano Premebida et Urbano J. Nunes, *Seg2Track-SAM2 : SAM2-based Multi-object Tracking and Segmentation*, version 2, 2025.

¹⁶⁸Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, *et al.*, « SAM 2 : SEGMENT ANYTHING IN

Ensuite, sa capacité à recevoir des *prompts* de la part de l'utilisateur ce qui permet deux choses : de mieux diriger la segmentation et de la réitérer si nécessaire dans un but d'affinage.¹⁶⁹

Enfin, son système de mémorisation des formes détectées. Dans une œuvre d'image animée il n'est pas rare qu'un objet soit totalement visible puis ensuite peu à peu caché par un autre élément. Ce modèle mémorise ce qu'il détecte, de cette manière si l'objet détecté est partiellement couvert à un moment donné le modèle garde la forme initiale de l'objet. C'est particulièrement utile afin de traquer les objets.¹⁷⁰

Cependant, cet outil possède trois limites importantes. La première est l'absence d'une attribution et d'une gestion d'identité à des objets. Un objet détecté est gardé en mémoire, ainsi si il disparaît partiellement de l'image le modèle garde en mémoire son emplacement et sa forme. Cependant, comme il n'est pas identifié si cet objet disparaît puis réapparaît, *SAM 2* le reconnaît comme un nouvel objet ce qui est faux. Appliquer à des institutions patrimoniales, l'absence de cette identification risque de poser deux problèmes : d'abord car le modèle risque de détecter constamment le même objet, et ensuite car cela complexifie la reconnaissance d'un même objet dans différentes séquences ou scènes. La seconde est la mise en mémoire en elle même car sur une volumétrie importante, le nombre d'objets à détecter est exponentielle ce qui alourdit la mémoire du modèle et en ralentit le traitement.¹⁷¹ La dernière limite est l'absence de classification des objets. En effet, *SAM 2* reconnaît des formes mais ne pourra pas déterminer que ceci est une voiture et ceci un vase. C'est ce que l'on appelle un modèle « classe-agnostic »

Seg2Track-SAM2 permet d'apporter quelques solutions. Cet outil est un framework permettant d'associer *SAM 2* à un modèle de reconnaissance d'objet pré-entraîné comme YOLO ou bien Faster R-CNN et au module *Seg2Track* qui s'occupe de gérer l'attribution et la mise en mémoire d'identifiant des objets.¹⁷²

L'association à un modèle de reconnaissance d'objet externe, choisi par l'institution, permet de spécialiser le *framework* pour la détection de certains objets et en déterminer la nature. Ainsi on brise la nature « classe-agnostic » de *SAM 2* en apportant, par une ressource extérieure, la possibilité d'identifier des classes d'objets comme des voitures, des vases, etc. Au delà, cela permet d'accélérer le traitement et de le fiabiliser par l'application de deux modèles. *SAM 2* est surtout utiliser afin d'assurer le suivis de l'objet au travers des différents plans

IMAGES AND VIDEOS » (, 2025), p.8 à 10.

¹⁶⁹ *Ibid.*, p.3 à 4.

¹⁷⁰ *Ibid.*, p.4 à 5 ; *SAM 2*...

¹⁷¹ Id., « SAM 2 : SEGMENT ANYTHING IN IMAGES AND VIDEOS »..., p.22 à 40.

¹⁷² D. Mendonça, T. Barros, C. Premevida, *et al.*, *Seg2Track-SAM2*...

se succédant. Le module *Seg2Track* permet de résoudre l'attribution d'identifiant à chaque objet identifié. En effet, ce module permet d'attribuer un identifiant à chaque objet identifié, de le garder en mémoire et de l'associer à la forme de l'objet détecté elle aussi mémorisé, et ainsi de pouvoir reconnaître si le « nouvel objet » détecté est bien un nouvel objet ou un même objet.

Ce *framework* se place aujourd'hui comme une référence dans la segmentation d'images et d'images animées. Sur le jeu de données KITTI MOTS du *benchmarks* KITTI, ce *framework* s'est placé 4ème en 2025 sur l'analyse de ce dernier, essentiellement composé de voiture et de piétons, sans entraînement préalable.¹⁷³ Dans un tout autre domaine, celui de la chirurgie, ce *framework* a montré des résultats prometteurs sur la segmentation multi-objets en *zero shot* avec notamment une possibilité de *fine-tuning* en temps réel permettant de réellement fiabiliser les résultats.¹⁷⁴

Dans l'indexation d'une image animée, disposer d'un tel outil est pertinent. Parfois chargée en informations visuelle, l'application de *SAM 2* ou du *framework Seg2Track-SAM2* permettrait de faire un tri informatif via une segmentation de l'image. Chaque objet et personne pouvant être détectés et isolés les uns des autres tout en étant suivis au fur et à mesure des images composant l'œuvre analysée.

3. La compréhension des sous-titres

Un autre élément pouvant être analysé pour l'indexation ce sont les sous-titres. Ils peuvent servir d'appui afin d'extraire du sens au sein d'une scène ou séquence. Des outils comme VideOCR¹⁷⁵ sont spécialisés sur le sujet et permettent d'isoler les sous-titres de l'image, et de le transcrire en chaîne de caractère brute pouvant ensuite être interprétée soit par l'humain soit par un *Large Language Model*.

Cependant cet outil a une limite importante. En effet, il ne repère pas automatiquement la zone de sous-titres et demande une intervention humaine : il doit désigner où se situe cette zone à l'aide de son curseur. Il est pertinent de laisser cette possibilité à l'utilisateur : le texte n'est pas uniquement présent dans les sous-titres mais peut aussi l'être dans l'image elle-même et il faut pouvoir contraindre l'analyse afin d'éviter tout mélange d'informations. De plus, la zone de sous-titre a une position variable : en fonction des dimensions de l'image

¹⁷³*Ibid.*, p.5.

¹⁷⁴Pour plus d'informations sur le sujet, voir : (Cheng Yuan, Jian Jiang, Kunyi Yang, Lv Wu, Rui Wang, Zi Meng, Haonan Ping, Ziyu Xu, Yifan Zhou, Wanli Song, *et al.*, « Systematic Evaluation and Guidelines for Segment Anything Model in Surgical Video Analysis », *npj Digital Surgery*, 1–1 [1^{er} avr. 2026], p. 2)

¹⁷⁵Pour plus d'informations, consulter : <https://github.com/timinator/VideOCR>

animée et de sa conception, cette zone peut varier en taille et en localisation. Ainsi, sur un grand jeu de données, cela offre une performance assez limitée puisqu’il faudrait définir à chaque fois la zone à traiter.

4. La reconnaissance de lieux et de personnes

L’indexation demande de reconnaître des éléments tels des acteurs ou des lieux de manière précises. Commençons par l’indexation des lieux :

La reconnaissance des lieux est une thématique assez massivement traitée. En effet, les institutions conservatrices ont assez rapidement exprimé le souhait de pouvoir géolocaliser des prises de vues photographiques à partir d’une analyse photographiques. Cette capacité a alors été conférée à des modèles d’intelligence artificielle qui, à partir d’image peuvent estimer une géolocalisation : c’est la géolocalisation visuelle. Domaine à part entière en intelligence artificielle, la géolocalisation visuelle est composée d’outils multiples et de réalités multiples.

À l’origine, la géolocalisation visuelle a été développée pour les images fixes et donc les algorithmes, modèles et outils répondent aux besoins de ces derniers. On peut penser à l’outil *PIGEON*¹⁷⁶, développé en 2023 et entraîné afin de surpasser l’humain sur le jeu *Geoguesser* dans lequel il s’agit d’estimer une géolocalisation à partir de simple images fixes à 360°. Cet outil extrait des éléments clés de l’image, les analyse et estime à partir de ces derniers une localisation géographique.¹⁷⁷ Pour cela, il est entraîné sur un corpus de plus de 4 millions d’images et possède son propre moteur de découpage géographique permettant d’estimer des positions avec une marge d’erreur d’environ 25 kilomètres.

Cependant, cet outil est également limité. D’abord, les analyses successives ralentissent le processus et le rendent de plus en plus coûteux. De plus, ce modèle n’est pas public : en effet, pouvant estimer des positions très précises il a été souligné que cela comporter un véritable risque de sécurité. Pour cela, il n’est destiné qu’à des usages académiques contrôlés, ce qui échappe à notre domaine d’application.¹⁷⁸

C’est aussi un outil inadapté à l’image animée. En effet, il traite des images fixes sans notions d’ensemble d’images. On sait, par définitions, qu’une scène est constituée d’une succession d’images pouvant faire figurer le même lieu, parfois sous des angles différents. Cela implique donc deux limites : d’abord l’analyse de chaque image ou chaque plan ce qui à l’échelle d’une scène constitue une tâche répétitive et coûteuse. Et de plus, en fonction du

¹⁷⁶Pour plus d’informations, consulter le github : <https://lukashaas.github.io/PIGEON-CVPR24/>

¹⁷⁷Lukas Haas, Michal Skreta, Silas Alberti et Chelsea Finn, *PIGEON : Predicting Image Geolocations*, arXiv.org, 11 juill. 2023.

¹⁷⁸*Ibid.*, p.11.

plan la prédiction du modèle peut varier : il n'est pas capable de comprendre qu'il s'agit simplement d'un autre angle et non d'un nouveau lieux.¹⁷⁹

L'application de la géolocalisation visuelle sur l'image animée est relativement récente. L'avancée majeure est de prendre en compte cette notion d'ensemble d'images et donc de repérer différents éléments à différents moment d'une même scène. Cela présente deux avantages : réduire la fréquence d'analyse et n'analysant non pas toutes les images mais certaines images, et éviter les erreurs de prédictions.

Deux outils y répondent, chacun avec leurs avantages et inconvénients :

D'abord *SeqNet*, un modèle d'intelligence artificielle basé sur un réseau de neurones convolutifs. Il prend en entrée un extrait vidéo et y récupère des « échantillons » de vidéos répartis sur toute la durée de l'extrait. L'avancée majeure est que chaque « échantillons » est analysé séparément puis réunis afin de donner lieux à une prédiction unique qui s'applique donc à l'ensemble de l'extrait.¹⁸⁰

Ce modèle présente deux limites majeures : sa sensibilité à la taille des extraits fournis, qui doivent avoir une durée et un nombre d'images fixe, et à la continuités visuelle dans ces mêmes extraits. En effet, le modèle attend d'avoir des extraits de taille fixe, avec un nombre d'image fixe et sans variations importantes en terme de plans et de lumière ce qui ne correspond à la réalités des œuvres conservées.

Un second outil est *Video Swin Transformer*¹⁸¹. L'innovation réside ici dans le passage de l'utilise d'une architecture réseau de neurones convolutifs à une architecture de transformers. Sans rentrer dans les détails techniques, ce modèle reprend les innovations apportées par *SeqNet* et, grâce à un changement d'architecture, y apporte de l'auto-attention appliquée à la 3D ce que *SeqNet* n'intègre pas. De cette manière, le modèle devient moins sensibles aux différentes variations visuelles qu'il peut y avoir, tant qu'il ne s'agit pas d'un changement de lieu, et moins sensibles aux variations de durées et de nombre d'images dans un extrait.

Cependant, il y existe de nombreuses limites. La première est le coût en ressource : en effet, l'analyse d'éléments en 3D demande d'importante capacité en processeur graphique ce qui est cher. De plus, on observe une perte de performance croissante en fonction de la taille des extraits : plus l'extrait est long, plus il contient d'image et moins le modèle est efficace. Enfin, le modèle nécessite un pré-entraînement et est très dépendant des données fournis à ce moment là. En effet, il ne possède pas de capacité *zero-shot* ce qui limite très fortement son champs d'applications notamment sur des données patrimoniales.

¹⁷⁹Sourav Garg et Michael Milford, *SeqNet : Learning Descriptors for Sequence-based Hierarchical Place Recognition*, 24 févr. 2021, arXiv : 2102.11603 [cs.CV], p.1 à 2.

¹⁸⁰*Ibid.*

¹⁸¹[liuVideoSwinTransformer2021a](#).

Finalement, le domaine de la géolocalisation visuelle est actuellement en pleine mutation. L'arrivée des *Vision Language Model* et de la diversité des modèles d'architecture d'intelligence artificielle amènent de nouvelles innovations et de nouveaux outils toujours plus légers, rapides et moins coûteux. Cela reste cependant un domaine peu appliqué aux images animées, ce qui amène à questionner la faisabilité d'indexer automatiquement les lieux figurant dans des œuvres.

L'indexation des acteurs et actrices est elle aussi complexe car composée de différentes réalités. Dans un film professionnel par exemple, les acteurs et membres de l'équipe technique sont répertoriés dans ce que l'on appelle des crédits : ces images avec uniquement du texte présentant la liste des acteurs, actrices et membres des équipes techniques. Cependant, dans un film amateur ce n'est pas la même réalité : les personnes sont souvent inconnues et surtout il n'y a pas de crédit. Imaginons une vidéo amateur sur laquelle figure une personne célèbre, il n'y aura pas de crédit pour l'indiquer.

Il est difficile d'indiquer quel cas est le plus rencontré dans les institutions conservatrices car tout dépend de la typologie de leurs fonds. Ainsi, nous allons présenter deux outils correspondant aujourd'hui à ce qu'il est possible de réaliser dans ce domaine.

Commençons par les films professionnels. Pour cela, il faut pouvoir repérer les images dites de crédits, en extraire les chaînes de caractère et en analyser le contenu sémantique afin de l'indexer dans les bons champs. Aucun outil ne permet de réaliser les 3 tâches en un seul temps, ce qui constitue un des points de tensions entre le besoin des institutions conservatrices et ce que proposent les solutions d'indexation d'images animées actuelles. Cependant, cela ne signifie qu'il n'existe pas de solution. Nous traiterons cela plus en détail par la suite, mais présentons trois outils pouvant être combinés afin de répondre au besoin.

Tout d'abord, il s'agit de pouvoir identifier et extraire les images animées sur lesquelles figurent les crédits ou non. Ils se distinguent de la majorité des autres images composant un film par leurs fonds noirs, et le texte blanc réparti en général sur une seule colonne et défilant sur plusieurs minutes. Pour cela, des algorithmes de *computer vision* comme ce qui est faisable avec *OpenCV* peuvent permettre de les reconnaître et de les isoler du reste de l'œuvre. En effet, cette bibliothèque python est très souple : elle permet de segmenter une image, comme de la manipuler ou bien encore de l'analyser. Cette analyse sans fait sans appui sur du *Deep Learning* et se base sur une analyse structurale comme nous l'avons vue avec la question des détecteurs de *PySceneDetect* ¹⁸²

¹⁸²Voire page 80

Ensuite, il s'agit de pouvoir extraire l'informations écrite dans l'image. Bien que les crédits tendent aujourd'hui à se diversifier dans la police d'écriture et leurs organisation, cela reste plutôt stable. Et on peut penser que pour une institution conservatrice conservant des films relativement « ancien », la stabilité est encore plus grande. Il faut ainsi un modèle d'OCR qui sera capable de reconnaître dans l'image le texte et de l'extraire sous forme de chaîne de caractères brutes. Des outils comme *Tesseract* ou *Kraken* qui sont *open-source* peuvent permettre cette extraction brute.

Cependant, à ce stade nous n'avons pas de compréhension sémantique. D'autant plus que les crédits sont fait de deux manières : pour le casting, nous avons d'un côté le nom de l'actrice et de l'autre côté son rôle, et pour l'équipe technique, des catégories avec des listes de noms sous formes de paragraphes ou bien de liste. Le risque ici est de ne pas réussir à associer l'actrice à son rôle, et de considéré le rôle comme étant une personne réelle à indexée, et de ne pas associer le membres des équipes techniques à leurs bons rôles. Pour cela, le *Large Language Model* constitue un bon outil d'analyse afin de réorganiser l'informations. A l'aide de sa capacité de « compréhension » du langage naturel et grâce à sa capacité d'analyse, le *Large Language Model* peut très bien réorganiser l'informations.

Pour les films amateurs, ou plutôt dénué de crédits, il faut envisager de nouveaux outils permettant de reconnaître l'identité des personnes souhaitées. C'est le cas de *FaceNet* développé par Google qui permet de reconnaître des personnes grâce à son modèle d'intelligence artificielle basé sur une architecture de réseau de neurones convultifs. Voilà comment il fonctionne :

D'abord, on l'entraîne sur un jeux de données qui constitue sa base de connaissance. Cela peut être un jeux de données dit « maison », afin de reconnaître des personnes propres aux besoins institutionnels, ou des jeux de données *open-source* plus génériques comme *CelebA*¹⁸³ ou *Kaggle*¹⁸⁴, plus petit, qui contiennent plusieurs centaines d'images par célébrités. Pour chaque image de visage, il analyse un certains nombre de caractéristiques pré-définies, comme les yeux et la bouche, et vectorises ces derniers.¹⁸⁵ Les images avec les vecteurs proches sont rassemblés afin de constituer des identités : ce seront nos personnes. Il va ensuite constituer des « triplets », c'est à dire des ensembles de 3 images : une images dite « positive », une image dite « réferece » et une image dite « négative ». Ainsi, il maximise ces chances de reconnaissance par la construction de « triplet » permettant de représenter la personne à

¹⁸³Lien vers le *dataset* : <https://www.innovatiana.com/fr/datasets/celeba>

¹⁸⁴Lien vers le *dataset* : <https://www.kaggle.com/datasets/vishesh1412/celebrity-face-image-dataset/data>

¹⁸⁵Florian Schroff, Dmitry Kalenichenko et James Philbin, *FaceNet : A Unified Embedding for Face Recognition and Clustering*, arXiv.org, 12 mars 2015.

différents stades de sa vie ou dans différentes situations d'éclairages ou position.

Une fois entraîné, on peut l'appliquer à des image animée. Ce modèle détecte les visages présents sur nos images, vectorise leurs caractéristiques physiques et les compares avec les vecteurs des « triplets » sélectionné pour représenter chaque personne identifiée en phase d'entraînement. En fonction de la proximité des vecteurs des visages à analysé et des visages connus, il établit une correspondance : des vecteurs proches indiquant qu'il s'agit de la même personne.¹⁸⁶

Notons que cet outil possède une limite importante. En effet, ces outils de reconnaissance faciales sont sensible aux variations de lumières¹⁸⁷ et donc aux variations physiques. Si un acteur se trouve être maquillé avec des prothèses par exemple ou simplement derrière une image de synthèse ,comme dans le cas des films *Avatars*, cet outil risque de ne pas reconnaître la personne en question.

Soulignons alors la pluralité des outils existants. Que ce soit pour reconnaître des lieux ou des personnes figurants à l'écran, il existe plusieurs manière d'y parvenir, avec des degrés de précisions différents et demandant une mobilisation de ressources toujours plus importantes. Cette pluralité des outils correspond à une pluralité des besoins. Assez généralement, un film amateur demandera, pour être aussi bien indexé qu'un film professionnel, des moyens plus poussés étant donné l'absence de crédits, l'utilisation de lieux plus quotidiens et la figuration de personnes moins connus.

Ces outils peuvent alors très vite alourdir le traitement si l'on souhaite pouvoir tout indexer. Il faut garder à l'esprit que plus il y a d'éléments à analyser, plus le traitement sera long et couteux. Ce qui pose la question de la limite de l'indexation semi-automatisée : jusqu'où souhaitons nous guider le professionnel dans son indexation ? Nous explorerons tout cela plus tard.

5. Les *Vision Language Model*

L'indexation semi-automatisée est aussi plus large. En effet, elle demande de pouvoir repérer des lieux et surtout des personnes de manière précises et cela afin de faciliter la saisie de données et la recherche sur ses éléments précis. Mais nous avons aussi vus qu'il était essentiel de pouvoir capturer le sens des scènes afin de pouvoir les rassembler en séquences.

Cela demande donc de pouvoir prendre en charge une compréhension sémantique d'images animées présentant des actions sur des thématiques précises. Cela fait intervenir une autre

¹⁸⁶ *Ibid.*

¹⁸⁷ *Ibid.*

technologies, capable de tirer du sens depuis une vidéo : les *Vision Language Model*.

En combinant la puissance de raisonnement des *Large Language Model* au domaine de la *computer vision* notamment dans l'analyse vidéo, cet outil est capable de générer des résumé de plans, scènes ou séquences. C'est à dire que plus qu'une simple détections d'objets, ou d'identification de lieux et de personnes, ces modèles peuvent comprendre et exprimer ce qu'il se passe. Ainsi, ils peuvent cerner un sujet ou une thématique et générer un texte qui permettra de l'expliquer et de le développer.

Pour cela, le *Vision Language Model* va d'abord analysé l'image à l'aide de différents outils de *computer vision* intégré en son sein, ce qui conduit à sa représentations en vecteur. Ces derniers sont créer à partir des formes, couleurs, répartitions de pixels et objets détectés au sein d'une image. Ces vecteurs sont incompréhensibles pour la partie *Large Language Model*, chargé de l'analyse complète et de la génération du résumé. Ainsi, ces vecteurs sont en quelques sorte « traduits » par un composant dédié qui permet de passer des vecteurs vers des *tokens* avec lesquels le *Large Language Model* peut interragir. Enfin, tous ces *token* sont ensuite donné directement au *Large Language Model* qui les analyses un par un avant de générer un résumé général.

Pour cela, les *Vision Language Model* s'appuient assez largement sur un outil qui peut être utilisé seul que l'on appel CLIP. Ce modèle d'intelligence artificielle est créé afin d'associer le texte, le NLP, à l'image, la *computer vision*, afin de reconnaître non pas des formes mais des objets clairement identifiés. Mettons en contraste avec *SAM2* : ce dernier reconnaît les formes mais ne les catégorise pas. Il peut reconnaître plusieurs formes, les délimiter même quand elles sont confondus et les suivre mais en aucun cas il ne pourra dire que ceci est une voiture ou bien un vase. CLIP permet cette reconnaissance multi-objet, c'est à dire qu'il est capable de dire que dans cette image nous avons tel objet qui effectue tel action.

Cela est possible par l'association du NLP à la *computer vision*. Ce modèle est entraîné sur des paires associant un concept exprimé en langage naturel par une chaîne de caractère à une image.¹⁸⁸ De cette manière, plus que de reconnaître une image, il reconnaît un concept et est capable de l'identifier en *zero-shot*.¹⁸⁹

Rajoutons que les *Vision Language Model* sont en plein développement et les modèles sont donc nombreux. Pour les modèles propriétaire nous pouvons cité GPT-4 et Gemini 2.5 Pro qui sont excellent pour l'analyse visuelle globale et la compréhension de l'image. Du côté de l'*open-source* nous pouvons citer les modèles QWEN-VL et Llama3.2 Vision qui sont parmi les plus performants. Notons cependant que ces modèles sont volumineux et demande

¹⁸⁸Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, *et al.*, *Learning Transferable Visual Models From Natural Language Supervision*, 26 févr. 2021, arXiv : 2103.00020 [cs.CV], p.3 à 4.

¹⁸⁹*Ibid.*, p.6 à 11.

des ressources processeur graphique et processeur très importantes

Cependant, les *Vision Language Models* possèdent des limites d’utilisations importantes. La première est son coût. En effet, le *Vision Language Model* mobilise une grande quantité de ressources afin d’analyser et résumer chaque image qui lui est fournis et plus l’œuvre est longues plus le coût sera important.¹⁹⁰ De plus, l’analyse quantitative amène la mémoire de ces modèles à leurs limite. Cristóbal Eyzaguirre¹ écrit : « *a car that has driven for an hour is, in principle, harder to query than one that just started* »¹⁹¹. Autrement dit, plus l’œuvre est longue plus il est difficile de retenir tous les éléments et donc de créer une compréhension globale.

6. Le traitement des pistes audios

Comme vu précédemment, l’image animée se compose d’une bande vidéo, qui contient les images, et d’une bande sonore contenant les dialogues, la musique, et les bruits ambiants. C’est en tout cas vrais pour la majeure partie des images animées : le son étant enfin capturé en même temps que les images à partir des années 1930, celles étant antérieure à cette date ne sont généralement pas dotée de son.

C’est un composant essentiel lorsqu’il s’agit de comprendre le contexte, l’action ou bien la thématique et le genre d’une scène. Une scène triste se caractérise par une ambiance sonore particulière par exemple. De plus, si une scène se détermine à l’aide de repère visuels cela peut aussi être à l’aide du son. Par exemple, une scène peut être composé d’images très différentes mais unis autour d’une thématique exprimé par une voix dites hors-champs.¹⁹²

Un des points centraux est de pouvoir comprendre les dialogues et d’en associer la prononciation à la bonne personne. Deux outils ce sont vite distingué sur ces deux champs : *Whisper* afin de faire de l’audio-transcription et *Pyannote.audio* afin de faire une diarisation de l’image animée. Ces outils sont complémentaire et souvent utiliser au sein d’un pipeline.

Whisper est développé par OpenAI, publié en *open-source*, et basée sur une intelligence artificielle à architecture de transformers permettant la transcription d’un audio comme un

¹⁹⁰Cristobal Eyzaguirre, Jiajun Wu et Juan Carlos Niebles, *Linear Scaling Video VLMs for Long Video Understanding*, 29 mai 2026, arXiv : 2605.31598 [cs.CV], p.2.

¹⁹¹*Ibid.*

¹⁹²La voix hors-champs, ou *voix-off*, est un procédé où l’on rajoute sur un ensemble d’images la voix d’une personne sans voir son visage. Cela permet souvent, par un monologue, de guider le spectateur au travers de différentes images dès lors liées par une explication orale ou pour exprimer les pensées intérieures d’un personnage.

discours par écrit.¹⁹³ Ce modèle est capable de transcrire la parole en texte et de traduire vers l'anglais une langue étrangère. Cependant, ce modèle reste relativement limité dans son application d'abord car il s'agit d'une plateforme en ligne à laquelle on transfère ces données. Ensuite, car elle est majoritairement concentrée sur l'Anglais, bien que des modules supplémentaires prennent en charge d'autres langues. Enfin c'est un modèle qui demande beaucoup de ressources informatiques mais qui, malgré ça, reste sensible aux hallucinations notamment si il y a beaucoup de bruit ambiants ou de la musique. Rajoutons que ce modèle ne prends pas en charge la diarisation.

C'est pour cette raison qu'on combine souvent *Whisper* avec *Pyannote.audio* afin de transcrire la parole tout en l'attribuant à un locuteurs identifié et cela sur toute la durée de l'image animée. Cette librairie python fonctionne sur plusieurs intelligence artificielle forunis par la librairie python *PyTorch*, librairie open source pour le *Deep Learning* largement utilisée aujourd'hui. Son fonctionnement est le suivant : elle commence par segmenter les différentes prises de paroles, leurs attribues des vecteurs et ensuite agrège les segments audios aux vecteurs les plus proches. De cette manière, le modèle est capable d'associer les bons temps de paroles aux bons locuteurs permettant ainsi de retracer le discours de chaque personne. Cependant, cet outil est assez limité notamment dans notre domaine d'application. Tout d'abord, au delà de deux voix distincte les confusions deviennent de plus en plus fréquente et plus il y a de locuteurs plus cette confusion s'intensifie. Ensuite, les chevauchements de paroles ou les coupures dûes à deux locuteurs parlant en même temps ne sont pas traité par le modèle : il n'arrive pas à identifier les interlocuteurs et leurs paroles.¹⁹⁴

C'est une première réalité très morcelée et finalement partielle du traitement audio. La recherche ayant été très concentrée sur le discours, sa transcriptions et son attribution aux bons locuteurs notamment afin de résumer des réunions professionnels. Or, notre besoin est plus large et ne demande pas nécessairement de transcrire un discours mais au moins d'en comprendre la tournure, le genre et surtout d'analyser l'ambiance sonore de la scène donc la musique et les bruits ambiants.

De plus, notons qu'aucun de ces outils ne permet de tendre vers une logique d'indexation. Il n'y a pas d'analyse et de compréhension des discours, de la répartition de la parole et des tons employés. Finalement, ils n'abordent aucun point qui serait intéressant pour une indexation complète d'une image animée patrimoniale.

¹⁹³A. Radford, J. W. Kim, Tao Xu, Greg Brockman, Christine McLeavey et Ilya Sutskever, « Robust Speech Recognition via Large-Scale Weak Supervision » ().

¹⁹⁴Hervé Bredin, « Pyannote.Audio 2.1 Speaker Diarization Pipeline : Principle, Benchmark, and Recipe », dans 2023, p. 1983.

Cela conduit naturellement à nous diriger de nouveaux vers les modèles multimodaux orientés texte et analyse sonore : les *Audio Large Language Model*. Ces modèles sont plus puissants que les outils précédemment cités : plus robuste et polyvalent, ils permettent de réellement saisir le « sens sonore » d’une image animée, de l’analyser et de l’exprimer.

L’outil le plus utilisé est alors *Qwen-Audio* ou *Qwen2-Audio*, sa version plus avancée et actuelle. Ce modèle permet notamment de traduire une entrée sonore en une analyse textuelle en sortie. Il combine deux architectures neuronales, le réseau de neurones convolutifs et les transformers avec notamment deux outils clés : un *Large Language Model* et un encodeur audio. La première architecture prétraite la bande son et la rend plus facilement analysable, la seconde architecture constitue le cœur de ce modèle en permettant l’analyse.

Il permet d’effectuer une diarisation de la bande son, comme *Pyannote.audio*, mais en pousse l’analyse jusqu’à pouvoir comprendre le ton du discours employé par chaque locuteur. Comme *Whisper*, il permet de transcrire des paroles en texte mais de manière plus poussée puisqu’il prend nativement en charge plus de langue. *Qwen2-Audio* apporte aussi des nouveautés dans le domaine de l’analyse audio : il reconnaît et identifie la nature des bruits ambiants et traite la musique afin d’en caractériser l’ambiance sonore.¹⁹⁵

Tout comme les *Vision Language Model* précédemment cités, les *Audio Large Language Model* sont gourmand en processeur graphique. On remarque aussi que ces modèles ont généralement tendance à être en grande difficultés face à des enregistrements sonores de faible qualités que ce soit à cause de conditions d’enregistrement difficile ou aux conditions de conservation. Cela renforce la possibilité d’hallucination, déjà présente dès lors que l’on parle d’intelligence artificielle. De plus, ces modèles sont très sensibles à leurs entraînement. La plus part de ces modèles sont entraînés sur des langues internationales comme l’anglais et le français, car on dispose de très grandes quantités de données sur ces langues ce qui provoque des difficultés face à des langues plus régionales. Ainsi *Qwen-Audio* est fiable sur les langues internationales mais rencontre de grandes difficultés sur des langues régionales.

7. Vers une révolution des modèles multimodaux : les *native multimodal modeling* ?

Nous avons parlé jusque là de *Vision Language Model* et d’*Audio Large Language Model* de manière séparé. Car fondamentalement, ils constituent deux outils séparés obéissant ainsi à la logique première de la multimodalités des modèles qui est de mêler deux domaines

¹⁹⁵Yunfei Chu, Jin Xu, Xiaohuan Zhou, Qian Yang, Shiliang Zhang, Zhijie Yan, Chang Zhou et Jingren Zhou, *Qwen-Audio : Advancing Universal Audio Understanding via Unified Large-Scale Audio-Language Models*, 21 déc. 2023, arXiv : 2311.07919 [eess.AS].

d'analyses. Cependant, avec les progrès technologiques récent la multimodalités voit ses limites repoussées et certains modèles sont maintenant capable d'agir sur le son, l'image et le texte. C'est ce que l'on appelle : la multimodalité native

Jusqu'à présent, un modèles multimodaux combine soit un encodeur visuel soit un encodeur sonore avec un *Large Language Model*. C'est ce qui conférait cette capacité de transiter de l'un vers l'autres et donc de comprendre et d'analyser du son ou de l'image. Ainsi, pour indexer une image animée il fallait créer ce que l'on appel une « architecture en cascade » c'est à dire que l'on traité le son et la vidéos dans des *pipelines* différencié avant de fusionner les résultats.

Cependant, cet architecture n'est pas sans problème. Traiter le son et l'image de manière séparée ne permet pas une analyse profonde de l'image animée à l'état brute ce qui finalement retire une profondeur d'analyse.¹⁹⁶ Les traitements différencier, dans des moments différencier et avec des moyens différents entraîne un manque de cohérence et de profondeur dans les résultats. On peine à faire des liens entre l'audio et la vidéo ce qui, dans une logique d'indexation patrimoniale, constitue une limite importante d'application de tels modèles.

En réponse à cela est entrain de se développer les *native multimodal modeling* qui sont des modèles plus large et puissant embarquant nativement des encodeurs vidéos et sonore en plus d'un *Large Language Model* afin de traiter simultanément son et images.¹⁹⁷ L'objectif étant de créer des modèles basées sur une architecture dite « *unimodal* »¹⁹⁸

Nous ne rentrerons pas dans les détails et nous contentons de rester succinct afin de ne pas aborder trop de détails techniques. Cette « unimodalités » pourrait prendre diverses formes : d'abord il y aurait les modèles dit de *Mid-fusion* qui traite chaque élément de manière distincte, en gardant des frontières entre les éléments, mais au sein d'un même réseau permettant de conserver et exploiter les liens. Ensuite, les modèles dit de *Early-fusion*, qui traite chaque modalité de la même manière via une seule modalité de traitement adaptée à toutes les typologies¹⁹⁹

Les différences de résultats entre les modalités ne sont pas très clairs car il s'agit avant tout de théoriser deux manière d'opérer ce traitement multimodal. Car la problématique est que les *native multimodal modeling* sont aujourd'hui en expansion croissante sans pour autant se construire autour de démarche définie, ce qui risque, à long terme, de poser problème.

¹⁹⁶Siyu An, Junru Lu, Junnan Dong, Qiufeng Wang, Yinghui Li, Weizhi Fei, Zichao Yu, Zheng Yuan, Biao Liu, Haopeng Wang, *et al.*, *Toward Native Multimodal Modeling : A Roadmap*, 25 mai 2026, arXiv : 2605.25343 [cs.CV], p.1.

¹⁹⁷*Ibid.*

¹⁹⁸*Ibid.*

¹⁹⁹*Ibid.*, p.1 à 5.

On a de plus 3 typologies de modèles : les modèles *Multi-to-Text*²⁰⁰ qui peuvent prendre en charge de la vidéos, du son et du texte et de générer des résultats d’analyses sous forme de texte. Les *Multi-to-Target*²⁰¹ qui, en somme, conviennent à des usages spécifiques et désignés ne gérant qu’une entrée spécifique et désignée. Et enfin les *Multi-to-Multi*²⁰² capables de prendre en charge toute les entrées simultanément, de les traiter de la même manière et de générer n’importe quel type de sortie : autant une analyse textuelle, qu’une image ou qu’une vidéos.

Des modèles comme *GPT-4o*, propriétaire, ou *Qwen2.5-Omni*, *open-source* mettent déjà en application les préconisations effectuées par le chercheur An Siyu sur lequel nous nous basons.

Ces modèles, peu importe leurs modalités de traitement et typologies, permettent d’envisager des traitements unifiés et des analyses plus importantes des images animées. En analysant dans un même temps, de la même manière et avec la conservation des liens entre chaque composant de l’image animée alors on peut penser atteindre une nouvelle dimension de l’indexation automatique.

Cependant, l’article reste assez flous quant aux limite des ces *native multimodal modeling* mais certaines paraissent être évidente. D’abord le consommation de ressources de ces modèles. Nous avons déjà vus précédemment que les *Vision Language Model* et *Audio Large Language Model* demandent des ressources importantes en processeur graphique et processeur. Alors que devons nous penser du coût potentiel d’un *native multimodal modeling* sur des image animée de plusieurs heures ? Appliquer à des institutions publiques, cette réalité techniques risque d’être peu atteignable.

De plus, quel est la quantité de données nécessaire afin d’entraîner ces modèles ? La stratégie d’entraînement annoncé avance un entraînement sur 4 axes distincts, abordant plusieurs jeux de données certainement spécialisés sur chacune des typologies à traiter.²⁰³ Bien que non estimé, cela demande des compétences techniques précises et nombreuses représentant un coût humain important. La mise en place de ces modèles peut donc être complexe.

²⁰⁰ *Ibid.*, p.3 à 9.

²⁰¹ *Ibid.*, p.10 à 12.

²⁰² *Ibid.*, p.12 à 14.

²⁰³ *Ibid.*, p.14 à 25.

8. Conclusion

Ce bref état d'art n'est pas exhaustif. En effet, il existe encore bon nombre d'outils et de technologies pouvant être employée à des fins d'indexation de l'image animée. Cependant, l'objectif ici était de se concentrer sur quelques outils différents permettant de traiter les différents besoins sur ce sujet.

Cela nous a permis de mettre en lumière la complexité de l'indexation de cet objet patrimonial et documentaire. Si dans les technologies développées il y a eu une légère tendance à penser que l'image animée n'était que peu différente de l'image fixe, la réalité est toute autre. La notion de mouvements, l'association entre l'image et le son et la complexité des structures des différentes œuvres demande des technologies et moyens de traitement propre.

De fait, les moyens sont assez divers et on constate un éclatement des traitements. En effet, peu de solutions permettent d'indexer une image animée ou alors pas avec le niveau de précision et de fiabilité scientifique attendus. Cela s'explique tout d'abord par le manque de dialogue entre les différentes technologies et domaines d'intelligence artificielle sollicités aujourd'hui. Chaque domaine a développé ces propres technologies qui ne sont pas élaborées afin de satisfaire les besoins plus globaux de l'indexation automatique de l'image animée. Ces moyens divers amènent également des résultats divers ce qui pose deux contraintes : articuler entre elles les données différentes issues de *pipeline* différenciés et s'assurer de leur conformité aux principes d'interopérabilité des données. Nous aborderons ces points plus en détails, mais il est intéressant de garder cela en tête comme des premières limites.

Ces différents outils sont largement intégrables au sein de *pipeline* de traitement dans du code, notamment en python. Bien que cela reste accessible, ces outils demandent donc des compétences spécifiques afin de les articuler correctement mais aussi de pouvoir les mettre en places. Les *Vision Language Model* et *Audio Large Language Model* notamment demandent généralement à être entraînés sur des données spécifiques, ou alors à passer par un processus de *fine-tuning* pour obtenir de meilleurs résultats.

De plus, l'articulation de ces outils en un *pipeline* demande des ressources computationnelles importantes afin de le faire fonctionner. Outre la puissance demandée par ces outils, le nombre de données générées semblent être considérable à l'échelle d'institutions patrimoniales ce qui entraîne un coût de stockage important. De fait, posséder une telle puissance peut sembler hors d'atteinte pour la plus part des institutions conservatrices.

Les *native multimodal modeling* semblent présenter une piste prometteuse. En réunissant en un seul outil les *Vision Language Model* et *Audio Large Language Model* afin de traiter son et images en un seul temps et de la manière adaptée, cela résout la question de la cohérence des données. Cependant, ces technologies n'en sont qu'aux prémices et ne sont pas encore assez éprouvées afin de constituer une base de traitement stable. De plus, il n'y a pas

encore d'évaluations précises quant à leurs applications à des documents patrimoniaux, leurs coût et limites. Mais on ne peut que, à l'instar des connaissances et technologies actuelles, penser qu'ils seront plus gourmands que les *Vision Language Model* et *Audio Large Language Model* actuels.

Finalement, l'indexation automatique d'image animée n'en semble qu'à ces prémices. Le traitement automatisée de la vidéos et du sons, séparément et simultanément, par intelligence artificielle sont en pleine effervescence et de nouvelles technologies et procédés apparaissent chaque année. Dans cette perspective, établir un processus adapté aux besoins institutionnel et patrimoniaux revient à se concentrer sur les besoins d'indexations plus que sur les possibilités actuelles. Car il est hautement probable que de nouvelles technologies permettent d'aller dans le sens du processus pensé et décrit ici dans la suite de ce mémoire, à commencer par le développement des *native multimodal modeling*

III. Enjeux utilisateurs : comment implémenter cette fonctionnalité en respectant l'utilisateur dans son usage de l'application et son rapport avec l'intelligence artificielle ?

Nous ne reviendrons pas dans cette partie sur les notions d'*User Experience Design* et d'*User Interface Design* largement traitée page 53. Il s'agit ici de reprendre les considérations précédentes et de se questionner sur l'inclusion de l'indexation semi-automatisée dans un système de gestion des collections.

Comme précédemment, il s'agit plus d'une partie menant à des réflexions qu'à des solutions techniques ou des prises de décisions concrètes. Cela s'explique en grande partie par le manque d'informations sur ces domaines.

Nous avons donc mis en exergue la complexité que représente l'intégration du NLP, sous deux outils différents, dans l'application. Cela revient à changer presque totalement le rapport de l'utilisateur avec son système de production par l'introduction de technologies envers lesquelles une certaines méfiances existent. Ce changement important ne doit pas provoquer de bouleversement graphiques et d'expérience utilisateur : si à l'échelle technique les changements sont important, l'impact utilisateur se doit d'être contrôlé.

Finalement, le cœur de l'enjeu réside dans l'adoption de ses outils, ou du moins leurs non rejet, ce qui passe par deux besoins. D'abords la transparence des processus et résultats. Ensuite, le besoin de placer l'humain au cœur des processus notamment par la possibilité de valider ou invalider des résultats.

Mais qu'en est-il de l'indexation semi-automatisée ? Les enjeux d'*User Experience Design* et d'*User Interface Design* sont-ils similaires ? Ont-ils les mêmes réponses ? La réponse est en réalité assez nuancée.

Avec l'intégration d'un chatbot et d'une recherche augmentée, on amène des changements dans le rapport et l'interaction entre l'utilisateur et le système. Cependant, il n'y a pas de changement drastique dans l'usage de l'application : on offre une nouvelle manière d'explorer et d'interagir sans pour autant effacer ce qui préexiste. Au contraire, ces outils agissent comme des compléments et améliorations afin d'approfondir des parcours préexistant.

L'approche ici est très différente puisqu'il s'agit de créer quelques choses d'inexistant dans l'expérience et l'interface utilisateur et de manquant. Cette création ne vient pas compléter un parcours, mais viens en remplacer un préexistant autant à l'échelle de l'application

qu'à celle des institutions. Ainsi, on bouleverse nécessairement l'expérience utilisateur d'indexation de l'image animée et l'interface par la création de nouveaux parcours avec des interfaces dédiées. En somme, on ne parle de changer quelques points plus ou moins généraux dans un système mais bien de changer des pratiques et logiques dans un univers métier.

En effet, les chaînes de traitement d'indexation de l'image animée sont bien définies, comme nous l'avons vus, et n'intègrent le système de gestion des collections que partiellement. C'est l'endroit où on stocke les données et extraits obtenus par différentes chaînes de traitement basées sur des processus et outils externes.

Si l'indexation semi-automatisée intégrée dans un système de gestion des collections change certains aspects logiciels, devant maintenant pouvoir afficher des propositions et proposer un parcours simple menant à cela, elle vise surtout à mettre fin à ces traitements externes. Ce qui change la réalité métier et les logiques de productions de métas-données. Ainsi, il incombe au logiciel et à la nouvelle fonctionnalité de pouvoir accompagner les utilisateurs dans un changement à si grande échelle.²⁰⁴ Ceci nous amène à faire face à différentes problématiques, et à présenter différentes logiques en réponse :

1. On peut par exemple penser à fait de ce processus, un processus optionnel. L'utilisateur ne doit pas changer drastiquement sa manière de faire et produire de la méta-données, il peut choisir une option ou l'autre. Cela signifie qu'il faut inclure la notion de choix dans l'expérience et l'interface.
2. Dans l'univers métiers dépeint, on comprend qu'un tel outil peut donner une sensation de perte de contrôle. En effet, la production de méta-données revient à une intelligence artificielle qui va également créer les extraits selon sa propre logique. L'aspect semi-automatisé et optionnel risque de ne pas être suffisant pour rassurer l'utilisateur, notamment dans la capacité de l'outil à respecter les WEMI et à produire de la données scientifiques et certaines. Il faut donc intégrer un système « *human in the loop* », plaçant l'utilisateur au centre de tout et en position de contrôle.²⁰⁵
3. Intégrer une distinction visuelle claire entre les données suggérées par intelligence artificielle et les données validées ou saisies par un utilisateur. L'interface doit traduire cette différence afin de donner à l'utilisateur des moyens visuels à des fins de distinctions et de contrôle. De plus, cela peut permettre de réduire la surcharge cognitive²⁰⁶ en offrant

²⁰⁴A. Badda, « Technology Acceptance Model (TAM)... ».

²⁰⁵Saleema Amershi, Kori Inkpen, Jaime Teevan, Ruth Kikin-Gil, Eric Horvitz, Dan Weld, Mihaela Vorvoreanu, Adam Fourney, Besmira Nushi, Penny Collisson, *et al.*, *Guidelines for Human-AI Interaction*, 2019, p. 13.

²⁰⁶F. Paas, A. Renkl et J. Sweller, « Cognitive Load Theory and Instructional Design... ».

à l'utilisateur un moyen de distinction rapide, sans avoir besoin de réflexion. C'est ce que l'on appelle, entre autre, le principe de *explainable artificial intelligence* c'est à dire le fait de pouvoir expliquer et constater les choix et productions effectués par intelligence artificielle.²⁰⁷

Mais différents éléments relevant des logiques d'implémentations et des questions d'usages semblent devoir trouver des inspirations nouvelles. À l'échelle de l'expérience il faut distinguer deux éléments : le souhait d'implémentation et le confort d'usage. Il existe une tension entre la direction que l'on souhaite prendre, son objectif final et l'envergure du changement que cela amène, et le besoin d'un certain confort de l'utilisateur passant surtout par la confiance accordable à l'outil.

Par exemple, comment gérer les erreurs d'indexation semi-automatisée ? Par définition, ce processus n'est pas infallible et c'est pour cela qu'il ne fait que de proposer des éléments d'indexation. Il peut très bien mal segmenter une image, créer des extraits mal identifiés, ou ne pas reconnaître une entité sur l'image et ne pas pouvoir l'indexer. Tout cela peut créer des omissions et des fausses détections qui risquent de mettre à mal le confort utilisateur, n'ayant finalement pas de gain de temps. Si l'utilisateur doit corriger sans cesse, le gain de temps est finalement minime et l'outil peut désintéresser.

Ou encore comment gérer la surcharge informationnelle ? En effet, indexer une image animée c'est prendre le risque de produire d'énormes quantités de données et dès lors de submerger l'utilisateur. De plus, cette quantité de données doit être répartie sur l'ensemble des WEMI ce qui pose des problématiques techniques, mais aussi d'usage puisque chaque institution peut utiliser le WEMI de différentes manières. Adopter une position « *human in the loop* » risque de surcharger l'utilisateur avec un nombre de décisions à prendre trop important.²⁰⁸

En somme, comme avec le chatbot et la recherche augmentée, le succès de l'implémentation de l'indexation semi-automatisée des images animées réside moins dans la précision technologique de l'outil que dans ses caractéristiques graphiques et d'expérience utilisateur. L'objectif est de réussir à instaurer un climat de confiance suffisant avec l'utilisateur afin de l'amener à changer ces habitudes métiers. L'outil doit donc d'être inventif en terme d'*User Experience Design* et d'*User Interface Design*.

²⁰⁷Q. Vera Liao et Kush R. Varshney, *Human-Centered Explainable AI (XAI) : From Algorithms to User Experiences*, 19 avr. 2022, arXiv : 2110.10790 [cs.AI].

²⁰⁸Martin Eppler et Jeanne Mengis, « The Concept of Information Overload : A Review of Literature from Organization Science, Accounting, Marketing, MIS, and Related Disciplines », *The Information Society*, 20 (1^{er} nov. 2004), p. 325-344.

Troisième partie

**Solutions élaborées et résultats
obtenus**

Chapitre 5

Recherche Augmentée et “chatbot” : conception technique, conception utilisateur et résultat.

La gestion des collections est aujourd’hui pleine de complexité et de frein. Que cela soit à cause des collections massives et doublement hétérogène ou à cause de la complexité des système de gestion des collections. Par nos différentes état de l’art, nous constatons que la création d’outils d’intelligence artificielle répondants aux besoins professionnels est aujourd’hui secondaire.

Ajoutons que les système de gestion des collections sont aujourd’hui devenu trop complexe pour être pleinement exploité et ne permettant plus de faciliter suffisamment la gestion des collections. De plus, l’hétérogénéité et massivités croissantes des collections amènent aujourd’hui ces logiciels à leurs limites. Prenons l’exemple des *Information Retrieval System* dit « classique » qui sont de plus en plus limité afin de répondre aux besoins professionnels.

L’implémentation d’outil d’intelligence artificielle pour les professionnels pourrait aujourd’hui constituer une solutions à cette double limite. D’abord en simplifiant le traitement des collections par l’automatisation de processus ou l’apport d’une puissance de calcul pour en faciliter l’exploration. Ensuite en permettant de simplifier l’usage d’un système de gestion des collections en appuyant l’utilisateur dans son utilisation de l’application et sa productivité de différentes manières. Cependant, la réalité des outils d’intelligence artificielle pour le patrimoine est diversifiés en fonction des outils :

Soit il existe des projets et travaux mais orientés usage grand public. Leurs objectifs sont d’améliorer la relation du grand public avec les collections en augmentant leurs découvrabilités et les possibilité d’interactions. C’est dans ce cadre qu’est créer le *pipeline Text-to-SQL* par exemple.

Ou alors, on a une absence presque totale de projets et de travaux peu importe l’usage envisagé. C’est le cas des domaines en pleine émergence au sein du patrimoine comme chatbot.

Il y a finalement un manque d’outils à destination des professionnels de la gestion des collections. Afin de créer cette littérature à destination d’usage professionnel de tels outils, il convient de questionner et examiner leurs implémentations dans des logiciels métiers comme des système de gestion des collections. Cela permettra de déterminer les conceptions techniques a retenir, les parcours utilisateurs a penser, et les apports et limites de ces outils dans ces univers professionnels. C’est ce que nous allons explorer ici au sein du logiciel SkinSoft en commençant par la recherche augmentée, avant d’aborder le cas du chatbot.

1. La recherche augmentée :

Une des limites principales des système de gestion des collections sont les *Information Retrieval System* sur lesquels reposent les systèmes de recherche. Rappelons les deux limites exploré :

1. D’abord la complexité de l’outil. Sans aborder son fonctionnement,²⁰⁹, rappelons qu’ils proposent différentes modalités de recherches²¹⁰. C’est à l’utilisateurs de juger quelles modalités utiliser et accumuler. Aujourd’hui, cette conception de la recherche par accumulation manuelle des modalités constitue un frein important ralentissant l’usage.
2. Ensuite, les limites techniques ²¹¹ de ces logiciels. Ils s’appuient sur une correspondance par mots clés offrant des résultats d’une pertinence relative appliqué aux masses de données gérée s’expliquant par l’absence de compréhension sémantique. Cela peut conduire à attribuer de mauvaises clés ou à fausser la valeur d’un objet aux yeux de l’application.

L’axe de conception est double. D’abord offrir à l’utilisateur un outil plus simple, demandant moins de manipulations entre différentes modalités de recherches. Ensuite, permettre une meilleure *recherchabilité*²¹² des objets grâce à une compréhension sémantique et contextuelle des données.

²⁰⁹Voir Chapitre I. « La recherche et l’utilisation de la solution dans le logiciel SkinSoft » page 26

²¹⁰Voir Chapitre 2 « La recherche et l’utilisation de la solution dans le logiciel SkinSoft » page 30

²¹¹Voir Chapitre I. « La recherche et l’utilisation de la solution dans le logiciel SkinSoft » page 28 page

²¹²Anglicisme couramment utilisé dans le milieu de l’informatique et provenant de *searchability*. Désigne la capacité d’un contenu, d’un objet à être recherche correctement et facilement.

a. Conception de l’outil

Nous avons précédemment décrit trois processus : la recherche intelligente, le *Text-to-SQL* et le *Text-to-NoSQL*. Nous avons également énoncé une quatrième possibilité²¹³ mêlant les *Information Retrieval System* aux *pipelines* de *Retrieval Augmented Generation*. C’est ce que l’on appelle l’approche *Text-to-ElasticSearch*²¹⁴ sur laquelle repose entièrement la structure de la « recherche augmentée ». Voici un schéma :




FIG. 10 : Schéma d’un *pipeline Text-to-ElasticSearch*.

Cette approche hybride associe les forces d’un *Information Retrieval System* à celles d’un *pipeline* de *Retrieval Augmented Generation*. Associer ces deux éléments permet de :

1. Disposer d’une recherche flexible exploitant la diversité du langage naturel. Le système de mots-clés de ElasticSearch écarte toute notions sémantique pour la seule exactitude orthographique impactant la pertinence résultats. L’intégration à ElasticSearch de NLP, les mots-clés deviennent des marqueurs porteur de sens. Ils sont moins rigide et ouvert à des liens conceptuels ou lemmatique.
2. S’affranchir de la rigidité du schéma de données. Le SQL repose sur un schéma de base de données fixe et des requêtes exactes. Or, la nature des collections patrimoniales produit une variété de « schémas » incompatible avec ce principe. Le NoSQL épouse cette diversité, mais la base de données est trop difficilement interrogeable par le *Text-to-NoSQL*. L’index ElasticSearch offre un entre-deux. Généré pour chaque table de l’application, il repose sur un schéma d’indexation précis et connu à l’avance. Cependant, chaque objet indexé ne possède qu’une sélection de champs s’y rattachant. Ainsi, un *Large Language Model* connaissant le schéma d’indexation de base peut s’adapter à la diversité de chaque objet.

²¹³Voir Chapitre b. « Les processus *Text-to-SQL* et *Text-to-NoSQL* : » page 48

²¹⁴Dongge Xue, Zhili Pu, Zhentao Xia, Hongli Sun, Ruihui Hou, Guangya Yu, Yupian Lin, Yongqi Fan, Jingping Liu et Tong Ruan, « Text-to-ES Bench : A Comprehensive Benchmark for Converting Natural Language to Elasticsearch Query » ().

3. Disposer de fonctions d’agrégations. ElasticSearch dispose nativement de fonctions d’agrégations permettant de répondre à cette attente scientifique. Ce sont des fonctions propres à ElasticSearch qui, dès lors, sont utilisable facilement par le logiciel. En associant cela à une compréhension des requêtes par *Large Language Model*, on décuple les possibilités de recherches.

Voici un tableau de différence entre l’approche *Text-to-SQL*, *Text-to-NoSQL* et *Text-to-ElasticSearch* :

Critère	<i>Text-to-SQL</i>	<i>Text-to-NoSQL</i>	<i>Text-to-ElasticSearch</i>
Recherche & tolérance au langage naturel	Correspondance exacte, requêtes qui échouent à la moindre imprécision	Non traité comme un avantage propre dans le paragraphe	Mots-clés enrichis par le NLP : tolérance aux variations typographiques, liens sémantiques et lemmatisation
Structure & schéma des données	Schéma de base de données fixe et rigide, incompatible avec la diversité des collections patrimoniales	Schéma inexistant ou totalement hétérogène : impossible de connaître exhaustivement tous les champs à l’avance	Schéma d’indexation fixe et connu à l’avance, mais champs variables selon les objets indexés (entre-deux)
Fonctions d’agrégation	Disponibles nativement, mais nécessitent des requêtes exactes	Non disponibles nativement	Disponibles nativement et combinables avec une recherche floue

TAB. 5.1 : Comparaison des trois approches

de plus, le *Text-to-ElasticSearch* permet de ne pas trop changer la structure du système de gestion des collections. Prenons l’exemple d’un *pipeline Text-to-NoSQL*, ce processus nécessite une connexion directe avec la base de donnée NoSQL. Or le *Information Retrieval System* est un intermédiaire entre l’application et la base de données NoSQL. Cela pourrait conduire à retirer le *Information Retrieval System* demandant de repenser entièrement la structure du logiciel. Cela représente un danger pour l’*User Experience Design* et des coûts financiers trop élevés.

Ajoutons que cela permet de respecter l’expérience utilisateur déjà par la conservation du *Information Retrieval System* qui maintient un usage préexistant. Les modalités de re-

cherches restent les mêmes de même que l’*User Interface Design*. La « Recherche augmentée » devient ainsi une alternative possible, offrant plus de précision et de puissance à la recherche.

Ainsi, la « recherche augmentée » est pensée comme un assistant de requêtage. D’une requête en langage naturel, le processus détermine les moyens de recherches à utiliser, génère les requêtes correspondantes et les propose à l’utilisateur. En comprenant les besoins utilisateurs, cette fonctionnalité dispense l’utilisateur d’analyser son propre besoin et elle détermine les moyens de recherches pertinents. Elle aboutit à une génération de requête en utilisant toutes les modalités de recherches nécessaire. L’utilisateur est en position de contrôle sur sa requête : il peut la modifier ou l’invalidier à tout instant.

Cette fonctionnalité est limitée à chaque table de l’application. Les index Elasticsearch sont générés par table présente dans l’application en fonction des « documents » y étant rattaché et des champs utilisés. De cette manière, récupère le bon index, servant de contexte pour la « compréhension » de la structure des données.

Pour la compréhensions des besoins institutionnels, ce la se fait par la possibilité dans l’application d’inscrire des informations complémentaire pour chaque champs. Elle permettant d’indiquer aux utilisateurs l’utilisation souhaitée d’un champs selon l’institution. Cela permet de modifier la valeur sémantique d’un champs pour chaque table et index. Le processus de *Retrieval Augmented Generation* se base autant sur l’index Elasticsearch ²¹⁵ que sur ces informations institutionnelles complémentaires. De cette manière, l’institution peut modifier la « compréhension » d’un champs en lui attribuant une nouvelle valeur sémantique.

Voici un schéma du processus :

²¹⁵Autre livrable technique avec ce mémoire.




FIG. 11 : Schéma du processus de « recherche augmentée » .

b. Choix des composants techniques

Avant toute choses, notons que la « recherche augmentée » mise en place au cours du stage n’est qu’expérimentale. Le processus n’en est qu’à un *Proof of concept*²¹⁶ représentant un stade basique de développement suffisant pour estimer que la fonctionnalité peut fonctionner. Des changements techniques, dans le processus où les technologies utilisées, sont à prévoir.

Ici nous explorons le choix des technologies utilisées. La capacité de traitement, leurs puissances et qualité déterminent la fiabilité d’un outil. Le choix dépend de trois éléments : le besoin à satisfaire, les performances attendues et les capacités infrastructurelles et financières. Dans notre contexte, les technologies employées doivent être *open-source* et compatible avec la dimension commercial du produit.

En ce qui concerne le *Large Language Model*, nous avons choisi le modèle *open-source* et *zero-shot* Gemma-4-31B développé par Google.²¹⁷ Il peut être installé localement pour stocker et traiter les données en toute sécurité. Ce modèle peut ingérer jusqu’à 256 000 *tokens* en même temps, permettant la compréhension de contextes longs et détaillés. Il repose sur 31 milliards de paramètres ajustable : c’est un bon compromis entre légèreté du modèle et capacité de réflexion.²¹⁸ Il nécessite plus de 65 go de mémoire vidéo et rencontre des difficultés de génération lorsque le contexte à ingérer avoisine sa limite de *tokens*.

Pour l’architecture *Retrieval Augmented Generation*, l’attention se porte sur deux outils : le modèle de vectorisation et le mode de calcul de similarité. Pour le premier, aujourd’hui nous en utilisons deux :

1. *intfloat/multilingual-e5-small* à 384 dimensions²¹⁹. Ce modèle de vectorisation prend en charge le multilinguisme : il peut s’appliquer avec fiabilité à des données dans les langues les plus parlées. L’application étant exportée à l’internationale et permettant l’usage de plusieurs langues, ce modèles est tout à fait pertinent. Les 384 dimensions déterminent la complexité des vecteur qu’il génère. Plus un modèle comporte de dimensions, plus les vecteur générés sont complexes et unique. 384 dimensions représente une moyenne basse, offrant en contre partie plus de rapidité de calcul.²²⁰
2. *intfloat/multilingual-e5-base*, la version supérieure au modèle précédent avec 768 dimen-

²¹⁶Test informatique sans vocation à être diffusé servant à vérifier si un projet est réalisable.

²¹⁷Présentation du modèle Gemma 4, Google AI for Developers.

²¹⁸Google/Gemma-4-31B-it · Hugging Face, 20 août 2026.

²¹⁹Intfloat/Multilingual-E5-Small · Hugging Face.

²²⁰Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder et Furu Wei, *Multilingual E5 Text Embeddings : A Technical Report*, 8 févr. 2024, arXiv : 2402.05672 [cs.CL].

sions, ce qui constitue une moyenne.²²¹ Par exemple, le modèle d’intelligence artificielle BERT qui révolutionné le NLP²²², base ses calculs de vecteur sur 784 dimensions. C’est un standard.

Ce second modèle est utilisé de manière conditionnelle. Sur les tables volumineuse et complexe, l’utilisation d’un modèle de vectorisation à 384 dimensions est assez risqués. Les vecteur risquent d’être trop proches. Des vecteur plus précis se distinguent plus facilement ce qui permet de se recentrer sur les liens sémantiques très proches.

En ce qui concerne le calcul de similarité, basé sur les vecteurs, il existe différentes méthodes calculs. Nous utilisons la plus répandue : la similarité de cosinus basée sur une méthode dite KNN.

Très courante dans les modèles de NLP, cette méthode consiste à représenter les vecteur dans leurs espaces multidimensionnel et de calculer l’angle les séparants. Si cet angle est inférieur à 90°, les vecteur sont alors très proches et les similarités importantes. Si il est supérieur à 90°, alors il est fort à parié que ces vecteur n’ont aucune, ou très peu, de connexion.²²³ De cette manière, il tri et classe la pertinence des vecteurs par rapport à une requête ou des documents vectorisés.

Ainsi, la présence de deux modèles de vectorisation relativement léger permet de fiabiliser le processus. Cela répond également à un enjeu financier et infrastructurel. Rien que le *Large Language Model* peut consommer à lui seul jusqu’à 65 go de mémoire vidéo, représentant plusieurs centaines d’euros. on équilibre ainsi les coûts.

Il faut penser que, dans le cadre de SkinSoft, cette technologie va être utilisée par différentes institutions et utilisateurs en simultané. Impliquant des analyses fréquentes de différentes requêtes, sur différents jeux de données. Pour le moment le processus n’est qu’expérimental et n’est donc déployé que sur un serveur dédié avec peu de données.

Mais il est réaliste de penser que ce processus va connaître des déclinaisons technologiques en fonctions des cas d’usages. Des processus plus léger, et moins gourmands pour les bases de données les plus petites. Et des processus plus importants pour le traitement des volumétries et complexité de données bien plus importantes. Cela permet de disposer de deux types d’infrastructures et d’adapter la solution au cas d’usage, et donc d’adapter les coûts potentiels.

²²¹Y. Wang, A. Johnston, Z. Sadokierski, *et al.*, *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums...*

²²²J. Devlin, M.W. Chang, K. Lee, *et al.*, *BERT...*

²²³*Qu’est-Ce Que l’algorithme Des k plus Proches Voisins ? / IBM.*

c. Conception du parcours utilisateur final

Le parcours utilisateur n'est pas nettement défini. Une spécification a été rédigée afin d'établir les lignes directrices du parcours utilisateurs.²²⁴ Il n'y a donc pas de visuel à l'appui et il s'agira ici de balayer une possibilité d'implémentation avec sa raison d'être.

Il s'agit de la modification d'une fonctionnalité préexistante de recherche et non de la création d'une nouvelle fonctionnalité. Pour ne pas perturber l'utilisateur, il faut trouver l'équilibre permettant de différencier la recherche simple de la « recherche augmentée » sans les opposer. Elles composent la même grande fonctionnalités : la recherche.

Trois principes clés ont été défini :

1. Transparence afin de permettre à l'utilisateur de comprendre quand il utilise la recherche simple, et quand il utilise la « recherche augmentée » .
2. Stabilité afin que son parcours ne change que très légèrement. C'est à dire ici : permettre l'interrogation de la base de données par des phrases et de ne pas avoir à manipuler les différentes modalités de recherches.
3. Simplicité, c'est à dire de ne pas surcharger l'utilisateur en informations visuelles ou peu utiles.

Ainsi, seul un bouton doit être, à terme, ajouté à côté de la barre de recherche afin de passer de la recherche simple à la « recherche augmentée » .

À son activation, la barre de recherche devient interrogeable en langage naturel. Pour le signaler et être transparent : le bouton d'activation se colorie dans la couleur de l'institution. Le message de la barre de recherche passe de « Rechercher » à « Interrogez-moi » . Et un symbole rouge apparaît dans l'extrémité droite de cette barre de recherche. À son survol, un message se déploie : « Recherche augmentée activée. Vous utilisez l'intelligence artificielle pour interroger vos données. » .

Lors de l'envoi d'une requête, ce processus génère un résumé visible juste à côté de la barre de recherche. il indique : les modalités de recherches utilisées et les requêtes générées pour chacune. Au clic sur l'une de ces modalités, il accède à l'interface dédiée pour la modifier. C'est une fonctionnalité nouvelle qui met en avant les principes de transparences et de simplicité : c'est un moyen de communiquer avec l'utilisateur et de lui offrir un centre de contrôle.

On offre également à l'utilisateur la possibilité de reporter une erreur. En remplissant un formulaire, l'utilisateur peut faire part d'un problème rencontré. Si ce problème concerne

²²⁴Cette spécification constitue le livrable technique de notre travail.

l’analyse du *Large Language Model* ou le modèle de vectorisation, il est utilisé pour leur amélioration. Les modalités sont encore mal défini, mais nous souhaitons utiliser la capacité de *fine-tuning* des *Large Language Model* sur les rapports pour évoluer en autonomie.

Ce parcours hypothétique montrent qu’il faut repenser non pas l’usage de l’application mais le dialogue entre cette dernière et l’utilisateur. Cela permettant de ne pas repousser ce dernier

d. Analyse réflexive

Ici, nous allons articuler deux éléments. D’abord les résultats obtenus lors du *Proof of concept*. Ce sera l’opportunité d’apprécier l’apport et les limites de cet outil appliqué au logiciel SkinSoft. Ensuite, les différentes difficultés encore non résolue et différentes réflexions sur les évolutions à mener.

Le *Proof of concept* a été mené sur la seule table des archives au sein de l’application ainsi que sur un jeu de données fictif de tests. On ignore ainsi encore son comportement sur plusieurs indexs et des données réelles.

La première limite qui en ressort, c’est la compréhension des dates. Il existe de multiples dates : date de création de l’instrument de recherche, date de création de l’archive ou encore de son entrée dans les collections. Quand on demande à la « recherche augmentée » de rechercher une archives avec une date d’entrée de collections et de création précises, il peut inverser les valeurs. Sur des requêtes plus simples, il arrive à ce qu’il ne reconnaisse pas le bon champs de dates à interroger. Aux yeux du *Large Language Model* les champs de dates ne sont pas différenciés.

Nous n’avons pas encore détecté l’origine de la confusion. Est ce l’index qui est trop flou à ce sujet ? Ou alors simplement un manque de compréhension pouvant provenir des vecteur générés ? Ou encore un manque de compréhension du *Large Language Model* ? Des examens futurs devraient permettre de le déterminer.

La seconde limite est l’utilisation de formulation trop longue et alambiquée. Les vecteurs générés sont bien trop éloigné de ceux des champs présents dans l’index. Plus la requête est simple, plus le vecteur se rapproche de ceux des champs et cela fiabilise le résultat.

La troisième limite, est la prise en charge du multilinguisme. L’application gère les langues d’une manière particulière : chaque application peut disposer d’un certains nombre

de langues souhaitées. Ainsi, elle peut remplir ces données dans chaque langue disposées de manière manuelle. Le passage d’une langue à une autre se fait par un bouton de sélection, changeant la langue d’affichage ou des données en fonction. Par défaut, si une donnée n’a pas été traduite dans une langue le logiciel affiche la donnée dans la langue dite principale.

Grâce à ses composants techniques, notre processus peut interroger différentes langues. Une requête rédigée en Anglais interrogera les données disponible dans cette langue. Cependant, il ne gère les correspondances linguistiques : je ne peux pas requêter en français pour chercher des données en Anglais.

Cette problématique peut se résoudre avec la mise en place d’un autre processus permettant de créer ces correspondances. Il faudrait un *Large Language Model* capable d’effectuer une telle opération et un outil capable d’accéder aux données dans la langue précisée dans la requête. Ils risquent d’allourdir le processus et être plus gourmand en mémoire vive.

Au delà de ces limites techniques, cet outil pose un certains nombre de questionnement venant redéfinir le parcours utilisateurs ou certaines fonctionnalités.

D’abord, à propos des modalités de recherches. L’application en propose plusieurs²²⁵ mais elles peuvent être assez poreuses. Par exemple, la recherche plein-texte ciblée et la recherche avancée permettent d’interroger en texte des livres des champs de données. La première modalité est spécialisée sur cette tâche. Bien que la recherche plein-texte ciblée ne soit pas encore incluse, on se demande si cette dernière sera utilisée par l’outil. Ce qui pose la question de l’usage de cette fonctionnalité à plus large échelle : est-elle vraiment pertinente et utilisée ?

Les réponses pourrons amener soit à dissocier plus clairement la recherche avancée de la recherche plein-texte ciblée. Soit à supprimer la recherche plein-texte ciblée en la confondant avec la recherche avancée, afin de correspondre à une réalité d’usage majoritaire.

Cela montre également que la mise en place d’outil d’intelligence artificielle vient ébranler les acquis applicatifs. Penser la mobilisation de ces fonctionnalités par une intelligence artificielle permet de mettre en évidence leurs fragilités et pousse alors à améliorer l’application sur d’autres aspects.

Finalement, la place et l’usage de cette application est encore assez flous. Le modèle de parcours utilisateurs proposé correspond à un idéal, mais n’a pas encore été éprouvé. Ainsi, des questionnements subsistent encore quant à l’utilisation d’une même barre de recherche pour deux modalités de recherches. Ne faudrait-il pas les dissocier afin de mieux les distinguer ? Ou bien encore, est-il pertinent de maintenir une fonctionnalité de recherche simple

²²⁵Voir Chapitre 2 « La recherche et l’utilisation de la solution dans le logiciel SkinSoft » page 30

si la « recherche augmentée » prend place au même endroit ? À cette question nous pensons que oui, car l'utilisateur doit avant tout avoir le choix d'utiliser l'intelligence artificielle sur ces données ou non.

Un autre exemple de problématique liée à cette fonctionnalité, est celle de sa capacité à générer des résumés. C'est sur ce principe que repose la recherche intelligente, et pendant un moment cela a été envisagée. Nous avons pris la décision de la rendre muette pour deux raisons. D'abord, pour ne pas créer de confusion avec le chatbot capable de générer des résumés nativement. Ensuite, pour assurer que le processus ne génère pas de données mais utilise celles de l'institutions. Cependant, cela est-il le reflet d'une réalité d'usage souhaitée ?

Ainsi, c'est encore un outil à développer notamment dans des questions d'*User Experience Design* et d'*User Interface Design* difficile à cerner. La nouveauté de cette typologie d'outil dans les systèmes de gestion des collections nous invitent à expérimenter et tâtonner afin de trouver différents équilibres. Cela implique d'avoir recours à de multiples étapes de développement dans l'objectif de définir précisément toutes ces notions.

2. Le chatbot :

Ce processus n'a pas fait l'objet d'une *Proof of concept* ou de spécification très définie. Ce n'est encore qu'une idée, un concept assez flou.

Cela tient à plusieurs raisons. D'abord, la « recherche augmentée » a été définie comme plus importante et urgente attirant l'essentiel des efforts. Ensuite, les changements techniques et applicatifs à mener pour le chatbot sont plus importants et coûteux que pour la « recherche augmentée » .

Nous allons tout de même aborder cet outil d'abord en présentant les conceptions fonctionnelles y étant reliées. Cela permet d'ouvrir la discussion sur l'implémentation de cette technologie dans des systèmes de gestion des collections. Nous présenterons également une proposition technique et de parcours utilisateurs. Et enfin une analyse réflexive, qui cette fois ne retracera pas les défis rencontrés mais les défis potentiels.

a. Conception de l'outil

La conception du chatbot n'est en réalité pas très différente de la « Recherche augmentée » . Dans les deux cas, il s'agit de recevoir une requête en langage naturel, de l'analyser et d'y répondre avec les bonnes informations. Ce qui change, c'est la définition que l'on donne à différents concepts et le rôle que ces outils ont.

Pour la « recherche augmentée », il s’agissait de pouvoir améliorer la recherche d’objets patrimoniaux dans la base de données institutionnelles. Ainsi, par « répondre avec les bonnes informations » nous entendons la diffusion dans l’interface des bons objets patrimoniaux.

Pour le chatbot, son rôle premier est de guider l’utilisateur dans l’utilisation de l’application en répondant à ses questions. Ainsi, il doit pouvoir disposer de documentation sur toutes les fonctionnalités de l’application pour alimenter ses réponses. Ainsi par « répondre avec les bonnes informations » nous entendons la génération d’un écrit permettant d’expliquer une fonctionnalité et de présenter des étapes d’utilisations. À terme, il est pensé comme un assistant de production. Pour cela, il devra pouvoir vérifier les métadonnées, leurs homogénéité et leurs propreté au sein même de l’application. Il doit avoir accès à des fonctionnalités et des documents institutionnels.

Voici une représentation de ce processus :




FIG. 12 : Schéma du processus de chatbot.

b. Proposition technique

Ici, nous allons présenter un ensemble d’outils pour chaque besoins du processus imaginé. Ils sont sélectionné au regard des outils utilisés précédemment afin de conserver une cohérence de coûts.

D’abord, il faut pouvoir reconnaître le bon cas d’usage exprimé dans la requête. Il faut ainsi vectoriser requête utilisateur ce qui conduit à réutiliser *intfloat/multilingual-e5-small*. À partir de ces vecteur, des outils peuvent en retirer du sens et faire de la *function-calling* : c’est à dire utiliser le bon codes pour appliquer le bon traitement. Nous proposons d’utiliser *Semantic Router*, un outil d’intelligence artificielle capable d’extraire du sens à partir des vecteur généré et d’effectuer un *function-calling*. Il est léger, local et fiable et peu s’appuyer sur les vecteurs générer par l’outil en notre possession. Il est également capable de sélectionner le bon index à interroger.

Si le cas définis est celui de l’usage applicatif :

1. En amont à lieu une étape de *Retrieval Augmented Generation* sur la documentation fournie par SkinSoft sur l’application. On réutilise la même architecture que précédemment : *intfloat/multilingual-e5-small*, le calcul de similarité KNN puis leurs injections dans un index ElasticSearch dédié. De cette manière, la documentation est pré-traitée est accessibles directement dans l’application. Cela permet au chatbot de gagner en rapidité lors de l’interrogation des données et de ne pas rendre cette documentation visible par l’utilisateur. Cette dernière n’est pas encore déterminée, mais cela peut inclure des documents sensible tels que des spécifications ou du code auxquels on ne souhaite pas donner accès.
2. Lors du requêtage, on se sert des vecteurs afin de les comparer à ceux de l’index dédié. Une fois la bonne documentation trouvée, le modèle *Gemma-4-31B* se charge de récupérer les passages, les analyser et de formuler une réponse.

Si le cas définis est celui de l’assistance à la production alors le procédé change quelques peu. Le problème principal étant les données à traiter. En effet, il existe plusieurs centaines de thésaurus, plus ou moins volumineux, et un nombre exponentiel de notices. La volumétrie des données brutes à analyser est telle qu’une simple analyse par *Large Language Model* amène le risque d’une saturation totale du processus. Cela ralentir le processus, le rendre imprécis voire inefficace. Il faut donc penser à un tout autre processus, par exemple un script python en 3 temps :

1. La librairie python *Polars*. Elle permet de stocker les données dans un format colonnaire²²⁶ en mémoire vive. Cela accélère le traitement des données par la suite. Elle permet aussi d’analyser les données et de détecter les doublons, les manques, et erreurs typographiques. Ainsi, on peut repérer l’existence d’un terme en double, orthographié de deux manière différentes, et déterminer lequel garder. *Polars* peut se connecter à l’API d’ElasticSearch et interroger avec ces différents index.
2. La librairie python *Pydantic*. Elle reçoit les données générées par *Polars* et les transforme en format JSON . Ce dernier étant un schéma fixe, cela pousse à reformuler les erreurs trouvées dans une forme standardisée où chaque champs à une signification.
3. Notre *Large Language Model Gemma-4-31B* peu lire le JSON généré, « comprendre » le problème et le reformuler dans un résumé. De cette manière, il communique l’erreur à l’utilisateur et lui permet de se corriger. Par sa capacité de mémorisation et de contextualisation, il garde en mémoire les conversations avec chaque utilisateur sans les mélanger.

Ces processus sont assez léger et souple, ce qui permet de proposer une rapidité de réponse assez satisfaisante. De plus, on réutilise les outils utilisé par la « recherche augmentée » ce qui simplifie l’implémentation technique.

c. Proposition de parcours utilisateurs

Contrairement à la « recherche augmentée » il s’agit ici d’inventer un tout nouveau parcours utilisateur. À savoir une nouvelle interface et une nouvelle expérience devant s’intégrer dans ce qui préexiste.

La réponse à la construction de ces deux élément peut se trouver dans ce qui préexiste au sein de l’application. Afin de ne pas créer de confusion chez l’utilisateur, il faut créer une continuité, une logique graphique et d’expérience. Ainsi, il faut se baser au maximum sur ce qui préexiste dans l’application.

L’expérience est assez simpliste. Le chatbot doit être un outil disponible n’importe où et à n’importe quel moment, pouvant prendre en entrée une requête et afficher un texte en sortie. Pour cela, nous réutilisons la conception du chatbot classique.

En fonction de la requête utilisateurs, le processus s’adapte et utilise certaines technologies dans un certains buts. Ainsi, l’utilisateur n’a pas à modifier des paramètres car le

²²⁶Les données sont disposées sur une seule colonne et non plusieurs lignes, facilitant le traitement des données

processus se charge d’interpréter et d’appliquer le traitement adapté. C’est une expérience assez intéressante, car elle permet de faciliter au maximum l’utilisation de l’outil.

Ajoutons que le chatbot à une limite définie il ne modifie, ne supprime ou ne crée pas de la donnée directement dans la base institutionnelle. Les intelligence artificielle générative, sont sources de méfiances de la part des professionnels de la gestion des collections. Leurs capacités à générer de la données faussée et de l’inscrire durablement dans les bases institutionnelles et vu comme un danger à la rigueur scientifique de cet univers métiers. En limitant le chatbot à redistribuer de l’information et de l’analyse de cette dernière, on place l’utilisateur au centre de la validation de la rigueur scientifique. L’outil se contente de recommander et expliquer, l’utilisateur modifie selon sa propre volonté. Cet aspect vise à mettre l’utilisateur dans une position de confiance vis à vis de l’outil.

Pour l’affichage, nous disposons d’une zone de requêtage avec un bouton d’envoi, et d’une zone d’affichage des résultats. Cela constitue l’interface principale avec laquelle l’utilisateur va interagir.

L’affichage et l’activation de cette interface sont des questions aux réponses beaucoup moins définis.

On peut s’inspirer de la saisie tabulaire proposée par l’application permettant la modification des données en grille de recherche. On l’active par un clique sur le bouton dédié puis sur une case. À ce moment, une interface se déplie sur la droite de l’écran provoquant un redimensionnement du reste. On peut s’en inspirer : on créer un bouton dédié au chatbot. À son activation, la même interface se déploie et on peut interagir avec son chatbot. Cependant, cela risque de créer une confusion entre la saisie tabulaire et le chatbot.

Une autre piste est celle de la fenêtre flottante comme cela est d’usage aujourd’hui. Cela permet de placer SkinSoft dans un réseaux plus large d’usage de cet outil. Malheureusement, plusieurs problématiques émergent : une fois dépliée, la fenêtre recouvre-t-elle des éléments ? Redimensionne-t-on ce qui existe ? Doit-on laisser un espace vide pour ce déploiement ? Ce sont des questions complexes mettant en jeu l’*User Experience Design* et l’*User Interface Design* de l’application en général ce qui peut sembler risqué.

Une dernière piste est celle des agents conversationnels grand public comme ChatGPT. Ils sont sur une page entière, sans chevauchement d’éléments et sans surcharge de données. Intégré à l’application, on pourrait considérer le chatbot comme une « notice » à ouvrir. Nous aurions ainsi une interface unique dans l’application qui n’entrerais pas en conflit avec ce qui préexiste. Cependant, cela peut briser l’aspect assistant disponible dans l’application à tout moment. Il n’est pas constamment avec nous, il faut aller dans un endroit précis de l’application pour l’interroger.

d. Perspective d’avenir

Ainsi, l’implémentation du chatbot est assez mal définie. Car son intégration dans une solution préexistante impact de front les rapports existants entre l’utilisateur et son application métier. Ajoutons également que de l’acceptation de la « recherche augmentée » par les utilisateurs dépend les choix d’implémentation du chatbot.

Si l’accueil de la « recherche augmentée » est favorable, cela amène à valider : le choix du *Large Language Model* et du modèle de vectorisation choisis. Mais aussi le choix d’une architecture technique locale et la disposition des utilisateurs à faire confiance à l’intelligence artificielle au sein d’un environnement de travail. Au contraire, le rejet de cette dernière amène à reconsidérer l’implémentation du chatbot dans un tel environnement.

Comme nous ne disposons pas d’une expérience d’un *Proof of concept* pour le chatbot, nous ne pouvons pointer des difficultés techniques réelles. Nous ne pouvons qu’attirer l’attention sur des choix à effectuer et des défis techniques potentiels :

1. D’abord les défis d’infrastructure. En effet, il mobilise finalement bien plus de ressources que la « recherche augmentée » et peut amener à les surexploiter. Il est crucial d’adapter son processus et son *pipeline* technologique à ses contraintes d’infrastructures. C’est pour cela que ce processus est pensé pour éviter d’exploiter le *Large Language Model* sur d’énormes quantités brutes de données.
2. Ensuite le défis de l’implémentation vis-à-vis d’un équilibre entre la visibilité de l’outil et la surcharge cognitive dûes à l’encombrement de l’espace de travail. La densité d’informations présente et présentée par un système de gestion des collections complexifie l’implémentation de cette technologique. Tout choix d’implémentation devient très complexe. Le chatbot doit respecter l’*User Experience Design* et l’*User Interface Design* applicatif.
3. Enfin, le chatbot souligne le défis de la recherche d’un équilibre entre l’apports de ces technologies intelligence artificielle et les besoins scientifique et métiers. Cela doit amener à placer l’humain au centre de la rigueur scientifique. Il doit donc garder la charge de la décision afin que ce soit lui qui définisse la rigueur scientifique des collections. Ces outils ne doivent être que de simples assistants. Car tendre vers trop d’automatisation, c’est amener à retirer le facteur humain de son propre patrimoine et à corrompre certains éléments. Au delà, cet équilibre passe par une question de sensation et de ressenti à l’usage. Ces outils doivent observer et conserver cet approche profondément humaine.

Chapitre 6

Indexation semi-automatique : conception technique, conception utilisateur et résultat.

La facilité d'usage d'un système de gestion des collections n'est pas le seul frein rencontré. Face à la complexification de gestion de certaine typologie, ces logiciels atteignent leurs limites. C'est le cas de l'image animée dont la description et la gestion sont éminemment complexe.²²⁷.

Les systèmes de gestion des collections rencontrent aujourd'hui des limites particulières à la gestion de cet objet. À l'image de S-Movies, l'indexation et le stockage de segments vidéos liés à des notices WEMI ne rencontrent pas de frein particulier. Mais l'absence de moyen de traitement et d'indexation automatisée directement intégré à l'application constitue un frein.

Les besoins descriptifs et la réalité de conservation de cet objet font de l'absence d'un module de traitement dédié une limite d'usage.²²⁸.

Alors disposer d'un outil d'indexation semi-automatisée devient un objectif. Cependant, les tentatives d'indexation semi-automatisée ou automatisée de l'image animée sont aujourd'hui en demi-teinte. Il existe certaines solutions propriétaires, assez peu convaincante dans un usage patrimonial. Et pour l'*open-source*, il n'existe qu'une myriade d'outils traitant de points spécifiques.²²⁹

Notons que cet outil fait face à ces propres enjeux bien différents de ceux soulevés par les précédents outils.

²²⁷Voir *Chapitre I. « Dans le logiciel Skinsoft »* page 59

²²⁸*Chapitre 4. « Complexité et limite de l'indexation des images animées : »* page 70

²²⁹*Chapitre II. « Outils et réalité technique »* page 71

Pour l’indexation semi-automatisée des images animées, il s’agit bien de produire de la donnée scientifique afin d’indexer les collections. On touche au cœur des missions des institutions conservatrices pour en changer les modalités.²³⁰ Cela implique deux contraintes : une haute fiabilité du processus et un parcours utilisateur solide dans un but de transition.

Ajoutons qu’il subsiste également un véritable enjeu de compréhension et d’utilisation de la solution existante. Cet outil doit intégrer la notion de WEMI, rattacher les bonnes données aux bons niveaux et donc réussir à créer et gérer les bonnes notices.

Enfin, l’enjeu le plus délicat est sans doute celui de la flexibilité. La gestion de l’image animée est surtout une question de choix institutionnel : il n’existe pas une unique modalité de gestion comme dans les archives. Les préconisations sont assez permissives et chaque institution peu les adaptées selon ses propres besoins. Notre outil doit faire de même.

En plus de devoir faire preuve de souplesse face aux modalités de gestions, cela doit être fait également pour les besoins utilisateurs. L’exemple de besoin institutionnel que nous avons soulevés n’est pas un cas répandus et d’autres institutions ont des besoins plus simples. Par exemple l’indexation d’extrait déjà créé avec une faible granularité d’information.

La création d’un tel outil est donc particulièrement complexe

1. Conception de l’outil

Nous proposons un processus au plus exhaustif, calqué sur le besoin institutionnel servant de cas d’étude. C’est un besoin complexe permettant la mise en avant des possibilités et limites actuelles dans ce traitement.

Nous avons donc réfléchi à une solution prenant en charge chacun de ces besoins. Elle doit prendre en entrée une bande vidéo et son, la diviser en plusieurs extraits, à savoir scènes et séquences, identifier les personnes et entités présentes et inscrire les bonnes données dans les bons champs.

Nous divisons ce processus en deux parties. Une première partie de traitement de la bande vidéo et sonore afin d’extraire des scènes, des séquences, des œuvres et des métadonnées. Puis une seconde partie centrée sur l’intégration des métadonnées dans les notices WEMI dédiées.

Pour la première partie du processus, voici ce qui a été conceptualisé :

²³⁰ Chapitre III. « Enjeux utilisateurs » page 99




FIG. 13 : Schéma du processus d'indexation semi-automatisée.

Ce processus technique à deux objectifs :

Le premier est de reconstituer les scènes et séquences à partir des plans. Les scènes sont des regroupements de plans proches, et les séquences des regroupements de scènes proches chronologiquement. Il y a également une stabilité importante des éléments : mêmes acteurs, même musique, même entités, etc. Par la vectorisation de ces éléments dans un plan, on peut ensuite comparer les vecteur générés et les regrouper par correspondance afin de reconstituer une scène. Le principe est similaire pour la séquence avec l'ajout d'une analyse sonore car la musique et les voix hors champs peuvent donner corps à la séquence.

Le second est la génération de métadonnées sur chaque élément analysé afin de pouvoir procéder à une indexation exhaustive.

1. Notre première étape traite directement les bandes vidéos et sonores. Nous la découpons en plan, donc à chaque rupture visuelle, et isolons les plan de crédits. De cette manière, ont produit des unités de traitement plus petites et légères et on facilite l'extraction des données contenues dans le texte des crédits. Chaque plan est horodaté, c'est à dire qu'on indique à quel moment du film il se place.
2. Dans la seconde étape, l'objectif est d'accélérer le traitement en déterminant une image et un extrait sonore clés par plan. De cette manière, on « résume » un plan en une image présentant le plus d'informations ce qui facilite le traitement. Au besoin, les images adajacentes reste traitable notamment pour mieux saisir les mouvements.
3. Dans la troisième étape, l'objectif est d'identifier tout ce qui compose l'image clés. On génère ici les métadonnées en détectant les objets, les personnes, les personnages et les actions. Toutes ces méta-données sont consignées dans un fichier JSON à la structure fixe de manière à toujours trouver les mêmes métadonnées au même endroit.
4. Notre quatrième étape est la plus importante. On récupère l'image clés, l'extrait audio et le fichier JSON et nous les analysons. Cela produit une description qui viens enrichir notre corpus. Nous nous appuyons sur l'ensemble de ces 4 fichiers pour générer un vecteur par plan représentés par son image clés.
5. Pour notre cinquième étape, les vecteurs et horodatages de chaque plans sont utilisé pour recréer les scènes. Deux critères sont observés : la continuité temporelle et visuelle. Des vecteurs de plan très proches indiquent une continuité des éléments visuels et sonore. On peut donc les rassembler en une scène. La seule continuité visuelle ne suffit pas : on analyse la proximité temporelle grâce à l'horodatage. Ainsi, plus deux plans sont éloigné l'un de l'autre moins ils peuvent constituer une scène malgré la proximité vectorielle. À l'issus de cette étape, nous avons nos scènes reconstituée avec un horodatage indiquant son début et sa fin. Enfin, nous recalculons un vecteur pour chaque scène.

Cette cinquième étape possède un second temps de synthétisation des JSON des plans regroupés en scènes pour garantir une stabilité des descriptions. On parcourt chacun des JSON de chaque plans, on en extrait le sens et on les agrèges en un JSON pour la scène.

6. Notre sixième étape réitère l'étape cinq mais à l'échelles des séquences. Nous ne revenons pas sur cette étape qui connaît également un même second temps de traitement.
7. Notre septième et dernière étape reconstitue les œuvres dans le cas où plusieurs co-existent dans la même bande vidéo. On procède de la même manière qu'à l'étape cinq. Si une œuvre ne comporte pas de séquence, on applique le même traitement sur les scènes en lieu et place de notre sixième étape actuelle.

En plus de se conclure sur la reconstitution des scènes, séquences et œuvres, ce processus offre un certains nombre d'éléments essentiels pour la suite. Nous avons des fichiers JSON structurant la méta-données de manière fixe et des vecteur pour chaque plan, scène et séquence. Ces éléments constituent notre bases de connaissances à indexer dans chaque WEMI de notre application.

Cependant, ce premier processus est assez lourd. Sans aborder la question technique, les multiples vectorisation et analyse de ressources de nature différentes alourdissent ce dernier. Ajoutons que les failles sont nombreuses :

1. La reconstitution des scènes et séquences est loin d'être infaillible leurs limites pouvant être flous. C'est notamment le cas de la séquence où l'analyse des thèmes et sujets est centrale. Il pourrait être pertinent d'ajouter une nouvelle étape d'analyse par *Large Language Model* dans ce but. Cependant cela peut alourdir le processus sans garanti d'une meilleure détection.
2. La détection d'images clés limite fortement le champs d'analyse. Il est possible d'exclure des éléments qui ne seront donc pas analysé ce qui fausse les résultats obtenus.
3. La reconstitution des œuvres reste expérimentale. Aucun travaux n'a été mené sur ce sujet, ainsi rien n'en garantit le fonctionnement.
4. La génération de fichier JSON est également problématique. En cas d'erreur d'analyse par nos outils, la correction manuelle demande à entrer et corriger le fichier JSON . Il faut donc en connaître la structure afin de pouvoir se repérer et comprendre ce que l'on modifie. Cela peut demander des compétences techniques.

Notre deuxième partie de processus consistent à redistribuer les métadonnées dans les bonnes notices WEMI et de les stocker. Voici une représentation de cette deuxième partie de processus :




FIG. 14 : Schéma du processus d'intégration des données générées par le traitement des images animées.

Grâce à la première partie du processus, nous disposons des méta-données à mettre dans les bons champs et niveaux WEMI ainsi que des vecteurs des plans, scènes et séquences à associé aux notices correspondantes.

Le cœur de ce processus se situe à notre étape 2. Il s’agit d’assurer l’intégration de ces différentes ressources aux bons endroits applicatifs. Pour les méta-données, il s’agit d’établir des règles de correspondances entre les champs de nos JSON et ceux champs de notre index ElasticSearch rattachés aux bons WEMI. Grâce à la stabilité du JSON et des champs ElasticSearch, on s’assure de la répétabilité de la procédure.

Pour cela, on établi la structure du JSON et la correspondes des champs en amont. Ainsi, on donnera à nos différents outils les *templates* à remplir en fonction de ce qui est attendu. Chaque *template* sera dors et déjà compatible avec les champs ElasticSearch ciblés.

Les vecteurs étant associé aux JSON , ils seront automatiquement rattachés aux bonnes notices items. L’avantage de les stocker dans ElasticSearch est de permettre, par la suite, l’utilisation de la « recherche augmentée » . On peut imaginer une utilisation alternative de cette dernière centrée sur la table des médias. Une requête basée sur une description d’une action ou d’un thème créer un vecteur comparable avec ceux des plans, scènes et séquences. Ce qui permet donc de rechercher des extraits par des requêtes imprécises.

2. Proposition de conception technique

Ici, nous allons proposer des outils à utiliser pour ce processus. Notons cependant qu’un tel processus demande des technologie variées. Un effort de réutilisations des mêmes technologies à été menée. Ajoutons que, bien que non estimée, la mobilisation de toutes ces technologies demande des ressources informatiques importantes.

Nous allons prendre chacun de nos deux traitements et présenter les outils à utiliser pour chaque étape en nous concentrant sur leur utilisation dans notre processus.

Commençons par notre processus de traitement²³¹ qui articule au sein d’un script python :

1. Pour la première étape, nous utilisons PySceneDetect²³², FFmpeg²³³ et le *Vision Language Model SmolVLM2-2.2B-Instruct*²³⁴. En combinant la détection des ruptures vi-

²³¹Voir figure 13 page 123

²³²Voir Chapitre 1. « Manipulation de l’image et des plans » page 80

²³³Voir Chapitre 1. « Manipulation de l’image et des plans » page 80

²³⁴*HuggingFaceTB/SmolVLM2-2.2B-Instruct* · *Hugging Face*, 6 mai 2024.

suelles de PySceneDetect et la manipulation vidéo de FFmpeg, on extrait tous les plans. Avec *SmolVLM2-2.2B-Instruct*, on pourra dès lors lire les crédits et les stocker dans le fichier JSON dédié. Nous proposons ce modèle car il est très léger, pesant 2,2 giga octets seulement, tout en étant précis et fiable.

2. Pour notre seconde étape, l'extraction d'une image clé d'un plan et de son extrait audio, FFmpeg l'intègre nativement. C'est une fonction dédiée basée sur la détections des points clés des images et sur la sélection de celles en contenant le plus.
3. Pour notre troisième étape, afin d'identifier et reconnaître les entités, les personnes et l'ambiance sonore nous utilisons 3 outils. SAM2 pour la segmentation et leu suivis des objets²³⁵. FaceNet pour la reconnaissance de visages²³⁶. Puis QWEN2-Audio pour l'analyse de la bande son.²³⁷. L'application successive de ces outils, dans un ordre à définir, permet d'identifier les célébrités et d'analyser l'ambiance sonore ainsi que les entités présentes.
4. Pour notre quatrième étape, celle de vectorisation des éléments identifiés, il y a deux approches possibles :

L'utilisations de *SmolVLM2-2.2B-Instruct* et QWEN2-Audio pour générer des analyses sémantiques textuelles. Sur ces analyses, nous appliquons notre modèle de vectorisation déjà éprouvé *intfloat/multilingual-e5-small*, ou *intfloat/multilingual-e5-base*, pour générer des vecteur. La problématique se situe dans le fait qu'on génère des vecteur sur du texte et non à partir de l'image ou du son. Cela implique un intermédiaire pouvant créer un décalage.

Ou l'utilisation de modèles multimodaux comme CLIP²³⁸ capable d'analyser aussi bien le son que la vidéo. Contrairement aux processus précédent, les vecteur générés par CLIP à partir des vidéos et sons et non d'analyse textuelles précédemment générées.

5. Pour notre cinquième étape, nous avons recours à une matrice de proximité. C'est une méthode de calcul tabulaire permettant d'établir le degré de similarité entre deux objets à partir de différents éléments. En somme, cela permet d'établir des proximités entre les plans selon leurs vecteur et leurs horodatages. Ainsi, deux plans à l'horodatage proche seront plus facilement rapproché que deux plans à l'horodatage très éloignés. Cela permet d'éviter de consituer des scènes avec des plans éparpillés dans la bande vidéos.

²³⁵Voir Chapitre 2. « Segmentation d'une image animée » page 82

²³⁶Voir Chapitre 4. « La reconnaissance de lieux et de personnes » page 88

²³⁷Voir Chapitre 6. « Le traitement des pistes audios » page 93

²³⁸Chapitre 5. « Les Vision Language Model » page 90

6. Pour la deuxième partie de cette cinquième étape, nous utilisons notre *Large Language Model Gemma-4-31B*²³⁹ afin d’analyser tous les JSON des plans rassemblés et de constituer un JSON pour la scène.
7. Pour les séquences et œuvre, aux étapes 6, 6 « bis » et 7, nous réitérons ce traitement. En effet, le traitement n’est guère différent si ce n’est qu’on ne l’applique plus aux plans mais aux scènes. Cela ne nécessite pas de changement.

Pour le processus d’intégration des données dans l’application, les technologies sont déjà présentes. En effet, pour notre étape numéro 3 sur le stockage et la mise à disposition des données dans ElasticSearch, c’est le logiciel qui s’en charge. Nous n’avons donc pas d’ajout à effectuer.

Cependant, l’étape précédente d’injection des données demande une technologie précise afin de créer les correspondances de champs entre les JSON et ElasticSearch. La librairie *Pydantic*, déjà utilisée pour la *recherche augmentée*, permet d’établir et de vérifier ces règles en amont. L’intégration est alors exécutée après validation des fichiers JSON. Les vecteurs sont quant à eux déjà pris en charge par un module spécifique d’ElasticSearch.

Ce processus mobilise un grand nombre de technologies différentes, certains sont assez volumineux même lorsqu’on prend les options « légères ». Nous pensons notamment aux *Vision Language Model* et *Audio Large Language Model* qui mobilisent énormément de ressources.

Le poids du processus est donc conséquent. Il s’agit de procéder à énormément de calculs complexes dans une chaîne de traitement itérative. En effet, elle s’applique sur chaque image clé de chaque plan sachant qu’une œuvre cinématographique peut se composer aisément de plus de 1000 images clés. C’est donc un processus long, répétitif et très demandeur en ressources. Modifier le processus pour traiter toutes les images clés en lots, et non successivement, ne représente pas une solution. Cela risque de saturer la mémoire vive et les capacités des outils conduisant à des hallucinations.

3. Proposition de conception du parcours utilisateurs

Nous allons ici procéder à une analyse afin d’identifier les points d’attentions en terme d’*User Experience Design* et d’*User Interface Design*.

²³⁹Voir Chapitre b. « Choix des composants techniques » page 109

D’abord, le processus présenté est pensé comme étant interne à l’application. Ce qui demande donc de le connecter à des éléments déjà présents afin de ne pas perturber l’utilisateur. C’est ce que nous avons fait avec la « recherche augmentée ». Dans SkinSoft l’utilisateur a la possibilité d’intégrer des fichiers dans le logiciel par simple « glisser / déposer ». On peut alors penser qu’au moment de déposer une vidéo, l’application génère une fenêtre d’interaction demandant à l’utilisateur de choisir soit une intégration simple, soit l’indexation semi-automatisée.

Il faut établir un choix et message clair, permettant de faire comprendre qu’il ne s’agit de produire automatiquement une indexation mais d’en suggérer une. À ce titre, l’humain garde son rôle de décisionnaire et peut valider, modifier ou invalider la production. Si l’utilisateur choisit l’indexation semi-automatisée alors le processus décrit s’applique. Cependant, ce processus doit s’appliquer sous contrôle de l’utilisateur. Ce qui demande donc une interface et une expérience d’utilisations.

Cela nous amène à la notion de choix. Notre processus est complexe et prend en charge divers aspects de traitement. La division d’une vidéo à différentes échelles, l’extraction de différentes données et la création de notices WEMI pré-remplies. Chacun de ces aspects demande des choix utilisateurs.

En premier lieu, il se peut qu’un utilisateur ne souhaite pas diviser sa vidéo en unités plus petites notamment car il s’agit déjà d’un extrait. Il faut donc offrir cette possibilité.

Ensuite, il se peut que l’utilisateur souhaite créer l’item d’un WEMI préexistant. Au quel cas, l’analyse des crédits et l’analyse d’éléments appartenants aux niveaux œuvre et expression ou manifestation ne sont pas nécessaires.

Enfin, il se peut également qu’un utilisateur souhaite seule compléter des notices pré-existantes. Cet usage implique un changement de la fonctionnalité afin qu’elle s’applique sur des éléments préexistants, et des champs déjà remplis.

Chacun de ces cas d’usages place la notion de choix au cœur de l’*User Experience Design* et de l’*User Interface Design*. Cela implique que la fonctionnalité doit être hautement modulable afin de répondre à différentes attentes simples comme complexes. Ainsi l’*User Experience Design* doit être basée sur la notion de choix et l’*User Interface Design* doit présenter une interface permettant à l’utilisateur de moduler la fonction. Cela peut se faire via la sélection ou désélection de certaines options de traitements.

De plus, il faut offrir la possibilité de modifier, valider ou invalider le travail effectué à chaque étape de traitement. Par exemple, le découpage en plans, scènes ou séquences peut

ne pas être satisfaisant, ainsi une interface doit permettre de modifier cela simplement. Cela doit aussi être valable pour les données générées dans les JSON . Il faut penser à une façon de présenter les informations en retirant l’aspect technique du JSON . Cela peut être par une pré-visualisation de la notice créée avec les champs pré-remplis avec les données correspondantes. Les modifications effectuées ici se répliquent ensuite sur le fichier JSON .

En somme, l’intégration des questions du parcours utilisateurs, centré sur une approche *human in the loop*, complexifie techniquement le processus. Notamment en imposant divers stade de gestion d’erreur et une modularité du code.

De plus, le nombre d’éléments à prévoir en terme de validation et d’étape de contrôle demande une interface dédiée. Ce qui amène à complexifier encore le système de gestion des collections par l’ajout d’une fonctionnalité supplémentaire avec sa propre expérience et interface.

4. Analyse réflexive

Finalement, le processus d’indexation semi-automatisée soulève des enjeux relatifs aux outils de productions assistés par intelligence artificielle. De manière générale, mais aussi propre au domaine de la gestion des collections. Mise à part des enjeux techniques et des questions d’*User Experience Design* et d’*User Interface Design*, ce processus remet en question des principes fondamentaux.

D’abord le principe de rigueur scientifique. Contrairement à la « recherche augmentée » ou au chatbot, l’indexation semi-automatisée génère de la données qui doit avoir une valeur scientifique. Ce processus s’appuie sur des formes d’intelligence artificielle générative : les *Large Language Model*, *Vision Language Model* et *Audio Large Language Model*. La génération des données par ces outils peut être compromise par des hallucinations impactant la qualité des données et donc leurs véracités scientifiques.

Limiter l’hallucination est encore un domaine d’amélioration. Nous avons vus que l’architecture *Retrieval Augmented Generation* est la plus fiable dans ce domaine, sans être infaillible, mais elle ne semble pas applicable ici. Finalement, cela contraint à adopter des architectures *human in the loop* assez lourde, pouvant compromettre le gain de temps que l’on cherche à obtenir. Cela demande de nouveau procédé afin de certifier une certaine véracité scientifique.

Ensuite, le principe de confiance des usagers. Fragiliser la véracité des informations des bases de données institutionnels amène à provoquer des doutes dans l’usage de ces applica-

tions. Les utilisateurs risquent de ne pas se servir de ce type d’outil, ou bien manière partielles par manque de confiance.

On entre ici dans un domaine flous, à la croisée entre le procédé techniques et les questions d’*User Experience Design* et d’*User Interface Design*. Habituellement, ces deux domaines permettent de rassurer l’utilisateurs dans son usage d’une fonctionnalité. Mais devant la complexité de ces processus et les risques d’hallucinations, finalement cela ne semble plus être suffisant. Cela demande de nouveaux moyens.

Il se pose également la question de la provenance des données indexées, qui revient à aborder des points éthiques et juridiques. Les institutions conservatrices doivent pouvoir retracer la provenance des données conservées en indiquant où la trouver. On entre dans une limite juridique et intellectuel : doit-on préciser que cela à été extrait par intelligence artificielle ? Ou doit-on simplement pousser l’intelligence artificielle à citer ces sources ? Comme nous l’avons vu,²⁴⁰ le cadre juridique impose de préciser quand un contenu à été généré par intelligence artificielle. Mais lorsqu’il s’agit d’une données générées par l’humain mais redistribuée par l’intelligence artificielle, devons-nous le préciser ?

De manière plus approfondie, la mise en place d’un tel outil revient à définir profondément les pratiques des métiers en rapports avec la conservation de cette typologie documentaire. L’utilisateur du système de gestion des collections n’est plus créateur de la données, mais vérificateurs et validateurs. Si cela peut permettre d’accélérer le traitement massif des données, cela peut causer de la fatigue à force de répéter les mêmes opérations en boucles.

Finalement, cet outil présente une triple complexité : technologique, d’usage et éthique. Nous avons encore du mal aujourd’hui à cerner et définir l’implications et l’impacts de tels outils dans le domaine de la gestion du patrimoine.

²⁴⁰Voir *Chapitre III. « Les enjeux juridiques publics et privés : »* page 21

Chapitre 7

Les véritables enjeux de l'implémentation de ces fonctionnalités : fiabilisation des collections, homogénéisation des données et meilleure connaissance des collections.

- J'aborde une partie plus théorique et basée sur de la réflexion autour d'une analyse d'écart entre l'apport envisagé/souhaité de ces nouvelles technologies, et l'apport réel ou réellement envisageable. Est-ce que vraiment ces outils "révolutionnent" une manière de gérer ces données et ces collections? Au quel cas pourquoi et de quelle manière? Ou alors, est-ce que ça n'a finalement qu'un impact limité sur la manière de gérer ses collections et ses données? Plus largement, le fond de la question c'est de savoir si la démocratisation de tels outils transforme en profondeur ou non les pratiques de gestion de collection et donc si cela impacte ou impacterait ce qui est déjà construit : je pense par exemple aux Thésaurus, format d'encodage, web sémantique.
- **Plan :**
 1. Si j'ai des résultats concrets je les utilise de nouveau. Sinon, analyses de différents projets et des constats qu'ils font sur l'impact de ces outils sur différents champs : qualités des données, productivité, etc. De cette manière, j'amène à analyser ce qu'offre réellement ces outils et l'impact qu'ils peuvent avoir sur leurs domaines respectifs.

2. J'élargis la question en me posant la question de l'impact de ces outils sur deux choses : les pratiques métiers d'une part, donc est-ce que cela va changer des manières de créer de la donnée, de la gérer, etc. Et d'autre part, l'impact sur ce qui est déjà existant : il existe déjà des solutions pour homogénéiser les données, les Thésaurus par exemple. Est-ce que notre outil est compatible avec cela, ou alors au contraire est ce qu'il y a un conflit entre les deux.

Conclusion

Glossaire

agent conversationnel L'agent conversationnel n'est pas une technologies mais un outils. Ce mot fait référence à la forme que peut prendre un programme avec lequel interagir sur le principe de l'envoi d'une requête et d'une génération de réponse. En somme, on désigne l'interface par lequel on interagit avec le programme, qui peut être un chatbot ou un *Large Language Model*, que le programme en lui même. Il y a cependant aujourd'hui une confusion claire dans le langage courant entre agent conversationnel et *Large Language Model*.. 27, 46, 47, 109

agent IA Contrairement à l'agent conversationnel, l'agent IA est un programme basé sur l'intelligence artificielle capable d'interagir avec son environnement informatique. Il est capable de prendre des décisions mais aussi d'utilisé des outils informatiques qui lui sont mis à disposition afin d'exécuter des tâches comme la manipulation de données.. 46–48, 109

agent SQL Désigne un *Large Language Model*, souvent sous forme d'un agent conversationnel, capable de comprendre, interagir et générer du code SQL et de bases SQL. Dans des processus de *Text-to-SQL*, il permet notamment de générer et vérifier la requête SQL générée avant de l'exécuter.. 40

Audio Large Language Model Sous typologie des modèles multimodaux, elle est spécialisée sur le traitement du texte et des bandes sons. Elle permet d'analyser, transcrire, décrire une bande son.. 89, 91–93

auto-attention Méthode courante du NLP permettant à une intelligence artificielle d'évaluer l'importance de mots au sein d'une phrase. Cette méthode permet de dépasser le cadre grammatical afin de comprendre les relations conceptuels entre les mots et le contexte d'une phrase, permettant ainsi de déterminé quel mot est plus déterminant qu'un autre.. 82, 118

Big Data Phénomène d'augmentation quantitative importantes de la données dans tous les domaines à l'échelles mondiale à partir de 2010. On utilise se terme pour faire références

aux nouvelles techniques de traitement de la données mis en place afin de répondre aux défis poser par ce phénomène. xxiv

BNF Successeure de la Bibliothèque Royale, la Bibliothèque Nationale de France, ou BNF, est l'institution en charge de la collecte, l'archivage et la préservation de l'édition en France notamment à travers le dépôt légal dont elle est la seule responsable. Elle a également à charge une des plus grandes collections patrimoniale française. xxiv, xxv

champs Dans une base de données No-SQL, le champs est l'unité de bases du documents. Un champs c'est une clés, un intitulé, qui contient un ensemble de valeur concernant le document et qui ont toutes le même rôle, la même valeur sémantique. Un champs "dates" contiendra, par exemple, toutes les dates. Chaque documents possède plusieurs champs, en fonction des différentes données qu'il stocke. La particularité du champs dans une base de données No-SQL est qu'il est rattaché au document et non à la collection, ainsi plusieurs documents d'une même collections peuvent ne pas avoir exactement les mêmes champs.. 27, 56

chatbot Désigne tout d'abord une réalité technique : un programme informatique conçu sur un système de règles permettant de répondre à un utilisateur avec des réponses pré-définies. Se base sur les premières expérimentations de NLP, ne correspondant plus à la réalité technique actuelle. Aujourd'hui, ce terme voit un nouvel usage, plus large, puisque désignant tout programme, intelligence artificielle ou non, permettant d'interagir avec l'utilisateur par le texte. ²⁴¹. 32, 45–49, 53, 54, 94, 96, 109

Chunking Procédé informatique fortement utilisé dans les différents domaines de l'intelligence artificielle, qui consiste à diviser une informations en unité plus petites afin de la stocker plus facilement et d'être plus précis notamment dans des processus de *Retrieval Augmented Generation*.. 36, 37

CIDOC Le Comité international pour la documentation est un comité international représentant les musées à l'échelle mondiale. Ce comité se spécialise dans la rédaction et l'application de normes pour la gestion et description des collections des musées.²⁴². xxiii

classification Dans le domaine de la *computer vision*, désigne la capacité d'une intelligence artificielle à analyser une image et de lui attribuer une étiquette agissant comme une identité globale. Elle rattache des images à des groupements déjà prédéfinis selon des

²⁴¹Pour plus d'informations sur cette transition, consulter : ??

²⁴²Pour plus d'informations voir <https://cidoc.mini.icom.museum/>

caractéristiques prédéfinies également. De cette manière, un modèle peut faire la distinction entre une photo, une peinture et une gravure par exemple.. 13

CLIP Développé par Open-AI, il s'agit d'un modèles multimodaux capable de comprendre une image dans son sens global et de la décrire avec des mots. Ce modèles est aujourd'hui utilisé dans la plus part des *Vision Language Model* afin de faciliter le traitement des images et image animée.. 86

collections Propre aux bases de données No-SQL orienté documents, comme MongoDB, les collections sont un équivalents des tables SQL. On y stocke des documents, c'est à dire des données, de même nature sans schéma particuliers ce qui permet donc une grande souplesse et élasticité.. 22, 27

computer vision La *computer vision*, ou vision par ordinateur en français, est sous-domaine multidisciplinaire de l'intelligence artificielle, cela désigne la capacité d'analyse et d'interprétation des images donnée à un ordinateur ou système informatique.. xxiv, xxv, 11–14, 70, 72, 78, 83, 86, 123

coréférence Méthode de traitement propre au NLP permettant d'associer un mot, une entité, à toutes ses références au sein d'une phrase ou d'un texte entier.. 12

data definition language C'est un composant du langage SQL constituant à lui seul un langage à part entière. C'est part ce langage que l'on peut créer une base de données SQL ou en modifier sa structure par différentes opérations appelées CRUD pour *Create*, *Read*, *Update* et *Delete*. 41–43

Deep Learning Branche du *machine learning*, il désigne à la fois un modèle d'architecture de réseaux neuronaux d'intelligence artificielle et une méthode d'entraîner les technologies basée sur cette architecture. Désigne tout outil d'intelligence artificielle reposant sur une architecture en couche successive de réseaux neuronnaires artificiels, conçu pour imiter le cerveau humain. Cette architecture est ensuite entraînée en autonomie, ou presque, sur de grandes quantités de données. De cette manière, ces outils se spécialisent et développent la capacité de traiter de nouvelles données.. xxiv, 10–13, 33, 46, 67, 83, 88, 113

diarisation Processus informatique basé sur de l'intelligence artificielle consistant à pouvoir détecter au sein d'une image animée qui parle et quand. De cette manière, on peut associer un dialogue au bon personnage.²⁴³. 87–89

²⁴³Pour plus d'information, consulter : <https://sonix.ai/resources/fr/diarisation-des-locuteurs/>

détection d'objet Dans le domaine de la *computer vision*, désigne la capacité d'une intelligence artificielle de repérer et identifier un objet précis, pour lequel elle a été entraîné, au sein d'une image. On confonds souvent segmentation et détection d'objet. Contrairement à la segmentation, il ne s'agit pas de reconnaître tout les objets et toutes les entités au sein d'une image.. 13

expression Niveaux WEMI qui désigne une réalisation concrète d'un concept exprimé au niveau œuvre. Sans avoir encore de forme physique très définies, ici on définit une forme intellectuelle qui incarne l'idée intellectuelle exprimée plus tôt.. 58, 62, 114, 115, 119

fine-tuning Technique en intelligence artificielle qui consiste au réentraînement d'un modèle, comme un *Large Language Model*, sur un nouveaux jeux de données. Cela afin de le spécialiser sur une tâche précise, pour laquelle il ne l'est pas à l'origine. En l'entraînant sur un nouveau jeu de données, le modèle réajuste ces paramètres afin de se spécialiser sur le jeux de données en question. Un *fine-tuning* trop poussé peu conduire à une sur-spécialisation du modèle, devenant efficace uniquement sur le jeux de données en question.. 80, 92

FRBR Définis par l'IFLA en 1997, c'est un modèle conceptuel conçu pour améliorer la gestion des collections bibliographiques dans les bibliothèques. Cela s'inscrit dans le mouvement de transition numérique de la gestion des collections et insiste sur la création de liens entre les exemplaires. Il repose essentiellement sur une architecture précise : le WEMI. Depuis, ce modèle est adopté par de plus en plus d'institution notamment celles conservant des images animées.. 58, 65, 66, 119, 124

Fédération Internationale des Archives du Film Fondée en 1938, fédération à portée internationale qui a pour objectif de protéger et d'assurer la préservation de la culture cinématographique, et plus largement de l'image animée. Aujourd'hui, elle assume également un rôle de guide dans la standardisation et l'homogénéisation des pratiques dans la gestion des collections d'image animée.. 56, 61, 62, 64, 115, 119

grille de recherche Notion propre à l'application SkinSoft. La grille de recherche constitue un moyen simple d'afficher les données souhaitées des objets recherchés au sein de l'application. Hautement modifiable, l'utilisateur choisit quelle donnée il souhaite visualiser.. 64, 112

histogramme La définition accordée à ce terme ici est celle de l'histogramme d'une bande vidéo. Désigne le graphique destiné à représenter la distribution de la lumière, de l'ombre

et des tons au sein d'une image notamment une image animée. Permet d'analyser la composition lumineuse d'une image.. 77

HTR L'*Handwritten Text Recognition* basé sur la même idée que l'OCR, la reconnaissance d'écriture manuscrite, ou HTR, applique le même principe à l'analyse des écritures manuscrites. On l'applique surtout aux documents anciens nécessitant des connaissances paléographiques.. xxv, 13, 25

IFLA La Fédération internationale des associations et institutions de bibliothèques est une organisation internationale représentant les bibliothèques mondiale. Cette organisation se charge de défendre les intérêts de ces institutions et de développer la gestion des collections de bibliothèques de manière commune.²⁴⁴. xxiii, 58, 111

image animée ce terme désigne tout objet constitué par une suite d'image capturée par différents procédés et dont la diffusion à la chaîne crée du mouvement. Par image animée, on désigne bien souvent les documents audiovisuels comme les films, les séries, les documentaires, vidéos que ce soit amateur ou professionnel. xxii, xxiv–xxvi, 12, 13, 55–96, 111, 112, 114, 116, 117, 119, 124

inaliénable En terme juridique, cela désigne ce qui ne peut être retiré, altéré ni même vendu ou donné. Un droit inaliénable est un droit qui ne peut être modifié. xxii

Information Retrieval System Logiciels spécialisés sur la recherche d'information dans des données non structurées. Le plus souvent, ces logiciels sont connectés à une base de données afin de stocker les données dans un index permettant de faciliter l'interrogation de volumes de données massifs. Ils fonctionnent comme un intermédiaire entre l'utilisateur et la base de données : il se charge de l'analyse des données, de les découper en segments qu'il répartit ensuite dans des nœuds qu'il indexe.. 22, 24–27, 32, 33, 35, 38, 44, 67

intelligence artificielle Ensemble vaste de technologies et procédés informatiques et d'ingénierie qui visent à permettre à l'ordinateur d'effectuer des tâches assimilés à l'intelligence humaines. Ses origines remontent aux travaux de John McCarthy en 1956 et qui voit ses premières expériences concluantes apparaître dans les années 1990. xxiv–xxvi, 9–11, 14, 15, 21, 26, 32, 33, 37–39, 41, 44–47, 52–55, 66–73, 75, 78, 81–84, 86–89, 92, 93, 95, 96, 109–111, 113–118, 124

²⁴⁴Pour plus d'informations voir <https://www.ifla.org/>

intelligence artificielle générative Typologie de modèle d'intelligence artificielle, généralement des *Large Language Model*, capable de générer, à partir d'une requête, du texte, des images, des vidéos ou du sons. Ils ne se contentent pas d'analyser des données, mais de générer quelques choses qu'on lui a demandé à partir de ces analyses. Ces modèles sont aujourd'hui extrêmement répandus et utilisés dans plein de domaines. Les agents conversationnels publics comme ChatGPT, Mistral et Claude sont des intelligences artificielles génératives. 10, 11

interopérabilité des données Désigne la capacité à rendre les données d'un système compréhensibles, utilisables et échangeables avec un autre système sans intervention humaine. Cela repose sur des normes et standards permettant de structurer les données de manière uniforme.. 5, 92

inviolable En terme juridique, désigne un caractère protégé qu'on ne peut enfreindre. Un droit inviolable ne peut être enfreint et si il est associé à un objet, cela rend ce dernier également inviolable. . xxii

item Niveaux WEMI le plus petit, il désigne l'exemplaire physique que l'on conserve au sein d'une institution ou que l'on détient. Il a des caractéristiques propres à sa vie en tant qu'objet indépendant du reste de son WEMI.. 58, 59, 66, 115, 119

Large Language Model Souvent abrégé par LLM, les *Large Language Model*, ou grands modèles de langues en français, sont des intelligences artificielles basées sur des transformateurs. Ils sont spécialisés dans la compréhension de requête, l'analyse de données textuelles, le raisonnement et la génération de réponse. Pour cela, elles sont entraînées sur de très grandes quantités de données par *Deep Learning* afin de leur conférer ces capacités. Ces intelligences artificielles sont concentrées autour de l'alliance entre les technologies regroupées et développées au sein du NLP afin de pouvoir effectuer de tel traitement.. 11, 14, 15, 33, 34, 37, 39–42, 46, 47, 69, 80, 84, 86, 89, 90, 109, 114, 116, 117

lemmatiser Procédé appliqué dans le domaine du NLP, il désigne le fait ramener un mot conjugué, accorder ou décliner à son état de base que l'on appelle le lemme. Un verbe conjugué sera ainsi ramené à son infinitif par exemple. On l'utilise afin d'épurer le texte et d'en faciliter sa « compréhension » sémantique. 12, 34

machine learning Domaine d'étude de l'intelligence artificielle qui vise à permettre à un système informatique basé, généralement, sur des réseaux de neurones artificiels d'apprendre. Ce domaine se consacre à développer de nouvelles manières de conférer à l'in-

telligence artificielle des moyens d'apprendre de différentes manières.. xxiv, 10, 111, 114

manifestation Niveaux WEMI qui désigne toute forme concrète prise par expression. Une manifestation correspond à une matérialité bien définie, que l'on peu daté au moins sur une pério de production, obéissant à des critères strictes tels que la durée, le nombre de page, le lieux de production, la maison d'éditions, le réalisateurs, etc.. 58, 59, 64, 66, 115, 119

modèles multimodaux Modèles d'intelligence artificielle permettant d'associer plusieurs domaines de traitement au sein d'un même outil afin de traiter plusieurs types de données. Ils associent généralement un *Large Language Model* à un encodeur dédié à un autre type de données. Ils permettent notamment d'analyser des vidéos ou des sons et de générer à partir de là, le plus fréquemment, des analyses textuelles.. 69, 73, 89, 90, 114, 124

multimodalité native Dans l'intelligence artificielle, désigne un système conçu pour traiter tout type de données en entrée et créer tout type de donnée en sortie. Plus précisément, ce système doit être capable de traiter des données vidéos, sonores et textuelles en même temps, de la même manière et en conservant les liens les unissant si tel est le cas afin d'améliorer sa capacité d'analyse et de compréhension. Ce principe souhaite révolutionner les modèles multimodaux actuels, ne prenant en charge qu'un seul type de données en entrée et en sortie. Cela pourrait révolutionner la compréhension de documents composites et complexe comme les image animée. 90, 114

Name Entity Recognition Technologie d'intelligence artificielle composant une partie du sous-domaine des technologies d'intelligence artificielle : le NLP. Le *Name Entity Recognition*, ou NER, est la capacité de reconnaître une chaîne de caractère signifiante comme un nom de personne, de lieux, de marque, d'événements ou encore les dates. . 11, 34

native multimodal modeling Désigne les modèles d'intelligence artificielle correspondants aux principes de multimodalité native. Ils couvrent des modalités et typologies de modèles différentes, obéissant aux mêmes grandes logiques de traitement tout en divergeant un peu les uns des autres. ²⁴⁵. 89–93, 124

NLP Le *Natural Language Processing*, ou traitement automatique du langage naturel, est un sous-domaine multidisciplinaire de l'intelligence artificielle, faisant notamment appelle

²⁴⁵Pour plus d'information, voir : 93 et (S. An, J. Lu, J. Dong, *et al.*, *Toward Native Multimodal Modeling...*)

à l'ingénierie informatique et la linguistique, baser sur l'utilisation du *machine learning* pour conférer à un système informatique la capacité d'analyser, comprendre et communiquer dans ce que l'on appelle le langage naturel ou langage courant.. xxiv–xxvi, 11, 13, 14, 21, 27, 30, 32–36, 38, 45, 54, 86, 94, 110, 113–115, 118, 123

NoSQL Acronyme de *Not Only SQL*, désigne un ensemble de base de données, de typologies variées, ne fonctionnant pas sur un système de table comme le SQL. Ces bases de données ont leurs propres manière de structurer la données, de manière beaucoup plus souple puis que variable, et ont leurs propres manière d'interroger les données stockées. Les différentes typologies sont : les bases clés-valeurs comme Redis, les bases orientés documents comme MongoDB, les bases orientées colonnes comme Cassandra et les bases orientées graphes comme Neo4j.. 38, 42, 43, 115, 117

OCR l'*optical character recognition* créé par l'ingénieur Autrichien Gustave Tauschek, ou reconnaissance optique de caractère en français, désigne la capacité conféré à un sytsème informatique de reconnaître des mots typographiés. Le premier système à pouvoir le faire est la machine Gismo inventé en 1951 par David Shepard.. 13, 25, 84

œuvre Niveaux WEMI le plus haut, il désigne une idée artistique et intellectuelle que l'on réalise par la suite dans une expression, une manifestation et un item qui est le témoins de sa production. C'est le niveau le plus conceptuel, qui, en dehors du modèle adopté par la Fédération Internationale des Archives du Film, n'a pas de matérialité physique.. 58, 59, 61, 62, 64–66, 73, 78, 111, 119, 121

open-source Désigne un mouvement informatique de mise à disposition du public le code informatique d'un logiciel. Cela permet donc de récupérer ces logiciels ou modèle d'intelligence artificielle, de les modifier et de les utiliser au sein de *pipelines* ou d'autre logiciel. Ce mouvement s'oppose aux logiciels dit propriétaire, gardant le code logiciel secret et ne permettant pas de le modifier. Cependant, *open-source* ne signifie pas gratuité et liberté absolue. Les logiciels appartenants à ce mouvement sont encadrés par des licences, réglementant leurs usages et distributions et peuvent être payants.. 84, 86, 87, 91

opinion mining Méthode de traitement propre au NLP avec pour objectif d'identifier, extraire et analyser les sentiments, émotions et prises de positions exprimées au sein d'un texte. Permet l'analyse de texte dans le contenu intellectuel, notamment sollicité dans l'analyse de discours.. 12

Part of Speech Technologie d'intelligence artificielle composant une partie du sous-domaine des technologies d'intelligence artificielle : le NLP. Le *Part of Speech*, ou POS, c'est l'analyse grammaticale d'une phrase qui aboutit à l'étiquetage du rôle de chaque mot dans une phrase. Chaque mot est analysé au sein de la phrase, son contexte, et est catégorisé dans l'une des classes grammaticales. La décomposition grammaticale permet ainsi d'en faire sortie le sens. 12, 34

pipeline d'agrégation Spécifique au langage NoSQL, notamment le système MongoDB, désigne les étapes successives de traitement effectués sur les données afin de retourner à l'utilisateur les bonnes données. Il peut s'agir de calculs, de filtres ou bien de modification afin d'homogénéiser le traitement et le résultat.. 38, 42, 117

plan Dans le milieu de l'image animée, désigne une prise de vue simple, qui peut être fixe ou en mouvement, faisant figurer des personnes et/ou des lieux et des actions. Elle se compose de plusieurs images, et peuvent être plus ou moins courts en fonction des choix de réalisation. C'est l'unité la plus petites d'une image animée. Chaque changement d'angle entraînant une nouvelle prise de vue amène un nouveau plan.. 62, 75–79, 86, 116, 124

processeur Composant informatique agissant comme le centre de calcul de l'ordinateur. Il est chargé de réaliser tous les calculs nécessaires afin de lancer les applications, exécuter du code ou encore mobiliser des ressources comme la mémoire vive de manière intelligente pour des besoins précis. Il se compose de plusieurs caractéristiques essentielles : les cœurs, qui sont des composants physiques permettant de paralléliser les tâches, les threads, composant virtuels permettant la même chose, et la fréquence qui détermine la vitesse d'exécution des calculs. . 87, 91

processeur graphique Composant informatique spécialisé sur le traitement des images et dédiés aux calculs à effectuer de les afficher.. 82, 87, 89, 91

Re-Ranking Procédé informatique s'appuyant sur une intelligence artificielle généralement placée à la fin d'un processus de type *Retrieval Augmented Generation*. Il permet de réévaluer et réorganiser les résultats obtenus à l'issue du traitement avant transmission à l'utilisateur afin de s'assurer de leurs pertinences.. 37

Retrieval Augmented Generation Ici nous parlons d'une manière d'utiliser l'intelligence artificielle parce que l'on appelle un *pipeline* ici appelé *Retrieval Augmented Generation*. Il consiste à consolider la base de connaissance d'un *Large Language Model* en

le connectant à une source de données contrôlées sur laquelle se baser pour la génération de réponses suite à une requête. Il fonctionne en 3 étapes : l'étape de *retrieval* qui consiste en la recherche des données pertinentes afin de répondre à la question utilisateur. L'étape de *augmented* qui consiste à enrichir la réponse générées en faisant référence directement aux sources utilisées et identifiées lors de l'étape précédente. Puis l'étape de *génération* qui consiste en la rédaction d'une réponse prenant pour contexte la requête utilisateur.²⁴⁶. 11, 14, 15, 33–35, 37, 40, 44, 47, 48, 110, 116, 117, 123

rush Dans le milieu de l'image animée, désigne les plan qui sont enregistrer au moment de leurs prises de vues. Les *rush* sont par définition bruts, sans modification effectuées en post production.. 56

réseau de neurones convulsifs C'est un type de réseaux de neurones créer pour l'analyse d'image et de vidéos. Chaque couche de réseaux de neurones applique un traitement particuliié à l'image ou à la bande vidéo traitée. Chaque couche est dédiée à un traitement, qui s'effectuent de manière successive. Nous avons généralement trois couches : la couche dite de « convulsion » qui déconstruit l'image en zone et en extrait des motifs simples d'abord et complexes ensuite. La couche de regroupement qui sert à compresser les données afin d'accélérer et simplifier le traitement. La couche de connexion qui détermine le résultat final. Ces modèles permettent de faire de la classification, de la segmentation et de la détection d'objet.. 10, 13, 82, 84, 89, 118

scène Dans le milieu de l'image animée, désigne l'unité la plus importante, notamment, d'un film. Une scène est définis comme un ensemble de plan faisant figurer les mêmes personnages, dans les mêmes lieux, autours des mêmes actions et sujets. Notion surtout utilisée dans le domaine cinématographique, mais également applicable à toute image animée. 62, 70–73, 75, 77–82, 85–88, 117

segmentation Dans le domaine de la *computer vision* désigne la capacité d'une intelligence artificielle de diviser l'image en fonctions des objets et entités qu'elle y trouve. Sans les identifier précisément, la segmentation permet d'isoler les objets et entités présentent les unes des autres et donc de resituer la composition d'une image.. 13, 76, 78–80, 124

système de gestion des collections Logiciels particulièrement utilisé dans le monde patrimonial permettant de gérer des collections d'objets patrimoniaux de manière informatiques. Ces fonctions principales sont : le catalogage, le suivis, la gestion de l'inventaire et la description des collections numériques et physiques. Ce sont des logiciels

²⁴⁶Pour plus d'informations sur ce procédé, consulter (B. Tuza, *Interroger la mémoire d'entreprise par l'IA...*)

aujourd'hui très complexes et complets se comportant que de véritable outils de gestion et de prise de décision stratégique sur la gestion des collections patrimoniales. Ils constituent le cœur des processus de traitement des collections patrimoniales et sont au centre des pratiques et enjeux métiers. Pour plus d'informations, voir *Chapitre I. « Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes »* page 3. 16, 50–53, 66, 94, 95, 124

séquence Dans le milieu de l'image animée, désigne un regroupement de scène dans une unité de temps basée sur le partage d'une thématique commune, de sujet commun et contribuant à l'avancer d'un même point d'une intrigue. Notion surtout utilisée dans le domaine cinématographique, appartenant à la structure basique d'un film.. 62, 70–73, 75, 77–80, 85, 86

table La table constitue la structure de base d'une base de données SQL. Constituée de colonne et de ligne, elles permet de contenir des ensemble de données structurées. On parle d'enregistrement pour la donnée située sur la ligne, et d'attribus pour les colonnes.. 62, 64

Text-to-NoSQL Adaptation du procédé *Text-to-SQL* aux particularité du langage et des bases de données NoSQL. Encore en développement, l'objectif est de permettre de conférer à un *Large Language Model* la capacité de comprendre et d'interagir avec une base de données NoSQL et ses particularités comme les pipelines d'agrégation et la semi-structuration du langage. Il se base lui aussi sur un *Retrieval Augmented Generation*.. 38, 39, 42–44, 124

Text-to-SQL Procédé informatique basé sur l'intelligence artificielle, le *Retrieval Augmented Generation* et la recherche intelligente. Il consiste faciliter l'interrogation d'une base de données SQL par l'utilisateur à travers l'usage d'un *Large Language Model*. Il fonctionne en deux temps : d'abord la phase de compréhension de la base de données, permettant de construire le *Retrieval Augmented Generation* puis la phase de requêtage. L'idée générale est d'augmenter l'interrogeabilité de la base de données par la compréhension de la base de données et des requêtes lui étant adressé notamment grâce aux vecteur. ²⁴⁷. 38–44, 109, 117, 121, 124

thésaurus Les thésaurus sont des hiérarchies de terme représentant des concepts rattachés à des domaines. De cette manière, ils constituent des listes de vocabulaires contrôlés fixant ainsi la terminologie utilisable pour décrire certains domaine. Particulièrement

²⁴⁷Pour plus d'informations, voir (*Text-to-SQL...*)

utilisé dans le monde patrimonial et les **SGC** afin fixer la terminologie utilisée dans l'indexation.. 55, 68, 69

token En informatique, le *token* désigne une unité de stockage destiné à contenir une information de taille variable. En intelligence artificielle, on s'en sert notamment afin de contenir des mots ou des morceaux de mots et de phrases. Ils désignent ainsi aussi bien ce qui est envoyé par l'utilisateurs lors d'une requête que ce qui est généré par l'intelligence artificielle.. 33, 37, 86, 118

transformers Désigne une architecture neuronale développée par Google en 2017 et mise très tôt en application dans le domaine du NLP²⁴⁸. Ce modèle permet ce que l'on appelle l'auto-attention afin de saisir le sens global d'une phrase, d'un texte, et permet la parallélisation des tâches ce qui accélère le traitement et les tâches d'apprentissage. Il vient remplacer les modèles basé sur réseau de neurones convolutifs dans le domaine du NLP par son net avantage technologiques permettant de fiabiliser les résultats.. 10, 11, 33, 34, 82, 87, 89, 113

UNESCO L'Organisation des Nations unies pour l'éducation, la science et la culture est une organisation internationale créée en 1945 qui a pour but de promulguer la coopération internationale autour des champs de l'éducation, de la culture, de la science et de la communication. Ces missions sont pluriels, mais elle est très largement connus pour ses initiatives sur le patrimoine : reconnaissance du patrimoine immatérielle en 2003 et la construction d'un patrimoine mondial commencé en 1972.. xxiii

User Experience Design Domaine dans la conception de logiciel informatique visant à rendre l'usage de l'application intuitif, facile et accessible pour tout humain. Ce domaine définit un ensemble de règles et de méthodes à utiliser pour remettre l'humain au centre du logiciel. 28, 30, 45, 48–54, 94, 96, 124

User Interface Design Domaine dans la conception de logiciel informatique visant à rendre l'interface générale de l'application simple et attrayante afin d'en simplifier l'usage applicatif par un humain. Cela s'accompagne d'un ensemble de règles et de méthodes évolutive afin de créer des interfaces utilisables.. 28, 30, 45, 48–54, 94, 96, 124

vandalisme Inventé par l'Abbé Grégoire en 1792²⁴⁹ à l'occasion de son étude sur l'impact révolutionnaire sur les biens culturels français, il a assez peu changé depuis. Le vanda-

²⁴⁸J. Devlin, M.W. Chang, K. Lee, *et al.*, *BERT*...

²⁴⁹G. Sprigath, « Sur le vandalisme révolutionnaire (1792-1794) »...

lisme se définit comme tout acte de destruction ou de dégradation volontaire d'œuvres d'arts, de monuments ou de matériel. xxii

variante Notion propre au monde de l'image animée qui désigne une version divergente d'une œuvre originale sans constituer une œuvre à part entière. Introduit par la Fédération Internationale des Archives du Film dans le WEMI, il permet de conscrire les modifications que peut vivre une œuvre cinématographique durant son cycle de vie qui viennent en modifier la structure ou le contenu sans que cela soit drastique.. 61, 62, 64, 65

vecteur Issus d'une vectorisation, le vecteur est une suite décimale unique calculés à partir des caractéristiques uniques d'une données. Ils peuvent être plus ou moins complexes et donc éviter des confusions. Ces vecteurs calculés sont ensuite stockés dans une base de données vectorielles permettant la comparaison des vecteurs.. 33–36, 38, 43, 45, 73, 74, 76, 77, 86, 88, 117

vectorisation Méthode informatique de calcul et d'attribution d'un identifiant informatique unique à une données en fonction de certains facteurs clés. C'est à dire qu'en amont du processus nous allons lui donner une données, comme un mot, et en sortie nous allons obtenir un identifiant unique sous forme de suite décimales. De cette manière, nous évitons toutes confusion entre des données similaires mais non identiques.. 11, 33–36, 38

Vision Language Model Modèles d'intelligence artificielle avec des capacité multimodales. C'est à dire que ce modèle n'est plus limité à un champs d'action : il est capable de traiter l'image comme le texte en autonomie.. xxv, 83, 85–87, 89, 91–93, 124

WEMI Fondement du modèle FRBR, il s'agit d'un découpage en 4 entités d'une œuvre artistique y compris littéraire. On y distingue le œuvre, *Work*, qui désigne le concept. L'expression qui caractérise une réalisation de ce concept sous une forme définie comme une pièce de théâtre, ou un film. La manifestation qui désigne toute production découlant de l'expression. Puis l'item qui désigne l'exemplaire que l'on conserve. Cette descontruction en 4 entités permet de créer plus de liens au sein des catalogues et donc des recherches transversales.. 58, 60, 62, 64–66, 95, 96, 111, 113–115, 119, 124

zero-shot En intelligence artificielle désigne la capacité d'un modèle à reconnaître et traiter un objet ou une données sur laquelle il n'a pas été entraîné dès la première tentative. Pour cela, le modèle mobilise toutes ces connaissances afin de déterminer une méthode

de traitement adapté, la mettre en place et la sauvegardé pour des traitements futurs..

82

Table des figures

1	Schéma du fonctionnement d'Elasticsearch	27
2	Phase d'analyse de la recherche intelligente.	38
3	Phase dite « active » de la recherche intelligente.	39
4	Fonctionnement global de la recherche intelligente.	40
5	Schéma d'un pipeline <i>Text-to-SQL</i> . Source : <i>Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL / Blog Google Cloud</i> , Blog Google Cloud	44
6	Schéma d'un WEMI fictif d'une œuvre.	63
7	Schéma de fonctionnement des liens dans un WEMI. Source : https://mediadix.parisnanterre.fr/medias/fichier/catalogage-isbd-unimarc-approports-theorique-maj-2025_1736242651118-pdf	65
8	Schéma du modèle WEMI implanté dans la solution S-Movies. Source : FAIRBAIRN (Natasha), PIMPINELLI (Maria Assunta), ROSS (Thelma) et THILL (Viviane), « Le Manuel de catalogage des images animées de la FIAF » ()	67
9	Schéma de fonctionnement de la solution vitrivr. Source : site officiel vitrivr à l'URL https://vitrivr.org/vitrivr.html	78
10	Schéma d'un <i>pipeline Text-to-ElasticSearch</i>	105
11	Schéma du processus de « recherche augmentée ».	108
12	Schéma du processus de chatbot.	115
13	Schéma du processus d'indexation semi-automatisée.	123
14	Schéma du processus d'intégration des données générées par le traitement des images animées.	126

Table des matières

Résumé	i
Remerciements	iii
Introduction	xxi
 I La gestion numérique de collections composites dans le monde patrimonial et le secteur privé.	 1
1 Système de gestion de collection et suite SkinSoft	3
I. Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes	3
II. Défis et difficultés que doit relever un système de gestion des collections aujourd'hui : Bigdata et harmonisation des données	7
III. Présentation de la solution SkinSoft	8
2 L'intelligence artificielle dans la gestion des collections patrimoniales : réalités techniques, attentes et enjeux	9
I. Réalités de l'IA dans le domaine patrimonial	9
1. Le NLP : définition	11
2. La <i>computer vision</i> : définition	12
3. le <i>Retrieval Augmented Generation</i> : définition	14
4. Apports des outils et état des lieux de leur application dans la gestion des collections	15
II. Les enjeux techniques :	17
III. Les enjeux juridiques publics et privés :	21
 II Implémenter l'IA dans un CMS : état des lieux et ambitions	

de SkinSoft.	23
3 Le traitement du langage naturel : faciliter l'usage et fiabiliser la recherche	25
I. La recherche et l'utilisation de la solution dans le logiciel SkinSoft	25
II. Recherche augmentée et Chatbot/Agent IA : état de l'art.	36
1. La « recherche augmentée » :	36
a. La recherche intelligente :	36
b. Les processus <i>Text-to-SQL</i> et <i>Text-to-NoSQL</i> :	42
2. Le « chatbot » :	48
III. Enjeux utilisateurs	53
1. <i>User Experience Design</i> et <i>User Interface Design</i> dans les systèmes de gestion des collections :	54
2. Les outils d'intelligence artificielle :	56
3. intelligence artificielle et système de gestion des collections : des attentes <i>User Experience Design</i> et <i>User Interface Design</i> particulières	57
4. Conclusion	58
4 Traitement et indexation de l'image animée	59
I. Dans le logiciel Skinsoft	59
1. Définition de l'indexation et de l'image animée :	59
2. Le FRBR et le WEMI	62
3. La gestion de l'image animée dans l'application SkinSoft	66
4. Complexité et limite de l'indexation des images animées :	69
II. Outils et réalité technique	71
1. Manipulation de l'image et des plans	79
2. Segmentation d'une image animée	82
3. La compréhension des sous-titres	84
4. La reconnaissance de lieux et de personnes	85
5. Les <i>Vision Language Model</i>	89
6. Le traitement des pistes audios	91
7. Vers une révolution des modèles multimodaux : les <i>native multimodal modeling</i> ?	93
8. Conclusion	96
III. Enjeux utilisateurs	98

III Solutions élaborées et résultats obtenus	101
5 Recherche Augmentée et “chatbot” : conception technique, conception utilisateur et résultat.	103
1. La recherche augmentée :	104
a. Conception de l’outil	105
b. Choix des composants techniques	109
c. Conception du parcours utilisateur final	111
d. Analyse réflexive	112
2. Le chatbot :	114
a. Conception de l’outil	114
b. Proposition technique	116
c. Proposition de parcours utilisateurs	117
d. Perspective d’avenir	119
6 Indexation semi-automatique : conception technique, conception utilisateur et résultat.	121
1. Conception de l’outil	122
2. Proposition de conception technique	127
3. Proposition de conception du parcours utilisateurs	129
4. Analyse réflexive	131
7 Impact des outils sur les données et collections patrimoniales	133
Conclusion	137
Glossaire	137