

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Florian Martin

licencié.e ès lettres

diplômé.e de master

**Pour une nouvelle approche des
données patrimoniales dans un
système de gestion des collections**

**Skinsoft - *Natural Language Processing* et
indexation semi-automatisée pour des
archives cinématographiques**

Sous la direction de **Ségolène Albouy**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Ce travail à été réalisé dans le cadre d'un projet pour la conception d'outils d'intelligence artificielle pour le système de gestion des collections SkinSoft. L'objectif est d'explorer les contraintes et possibilités techniques liées au déploiement de trois fonctionnalités : une recherche assistée par *Natural Language Processing*, un chatbot interactif et un module d'indexation semi-automatisée des images animées.

À travers l'analyse de la suite logicielle SkinSoft, ce travail veille à dresser un état de l'art de l'univers des systèmes de gestion des collections. L'occasion d'en retracer les évolutions, le fonctionnement, les défis et les limites actuelles. Nous y questionons la pertinence de l'intégration de l'intelligence artificielle sous diverses forme au sein de ces plateformes. De cette manière, nous pourrions mettre en lumière les enjeux d'implémentation propres à ces logiciels et au monde du patrimoine.

La conception des trois outils développés constitue le point d'orgue de ce travail. Nous détaillerons les processus métiers modélisés, les modalités d'intégration envisagées ainsi que leurs limites respectives, y compris technologiques. Cela permet d'initier une réflexion globale sur l'impact potentiel de ces technologies émergentes dans le domaine du patrimoine.

Mots-clés : NLP ; *Computer Vision* ; Gestion des collections, Intelligence Artificielle ; *UX-Design* ; Système de gestion des collections.

Informations bibliographiques : Florian Martin, *Pour une nouvelle approche de la gestion des collections et données patrimoniales : mobilisations d'outils IA dans un système de gestion de collections. Skinsoft - Projet IA pour des archives cinématographiques*, mémoire de master « Technologies numériques appliquées à l'histoire », dir. [Ségolène Albouy], École nationale des chartes, 2026.

Remerciements

MES remerciements vont tout d’abord à ma directrice de mémoire, Madame Ségolène Albouy. Son encadrement, sa disponibilité et ses conseils ont sans aucune doute constitué les éléments porteurs de ce travail scientifique.

Mes remerciements vont également à l’entreprise SkinSoft et particulièrement à mes chères collègues de l’équipe métier. Ce stage a été particulièrement enrichissant et fondateur pour la suite de ma carrière.

Je souhaite également adresser des remerciements à mon entourage proche, et notamment ma compagne qui a été d’un soutien précieux et inconditionnel tout au long de cette rédaction.

Bibliographie exhaustive

- ADAMOPOULOU (Eleni) et MOUSSIADES (Lefteris), « Chatbots : History, Technology, and Applications », *Machine Learning with Applications*, 2 (15 déc. 2020), p. 100006, DOI : 10.1016/j.mlwa.2020.100006.
- AI & ChatGPT Statistics for 2026 (Usage & Adoption Data), Instant Press, URL : <https://www.instantpress.co/ai-statistics> (visité le 25/08/2026).
- AMERSHI (Saleema), INKPEN (Kori), TEEVAN (Jaime), KIKIN-GIL (Ruth), HORVITZ (Eric), WELD (Dan), VORVOREANU (Mihaela), FOURNEY (Adam), NUSHI (Besmira), COLLISSON (Penny), *et al.*, *Guidelines for Human-AI Interaction*, 2019, p. 13, DOI : 10.1145/3290605.3300233.
- AN (Siyu), LU (Junru), DONG (Junnan), WANG (Qiufeng), LI (Yinghui), FEI (Weizhi), YU (Zichao), YUAN (Zheng), LIU (Biao), WANG (Haopeng), *et al.*, *Toward Native Multimodal Modeling : A Roadmap*, 25 mai 2026, DOI : 10.48550/arXiv.2605.25343, arXiv : 2605.25343 [cs.CV].
- Archipanon pour le Ciné-Journal suisse, URL : <https://www.bar.admin.ch/fr/archipanon-pour-le-cine-journal-suisse> (visité le 10/08/2026).
- ARCHIVES DE FRANCE (Direction des), *Note d'information DITN/RES/2007/008*, Notes d'informations DITN/RES/2007/008, Paris, Ministère de la Culture et de la Communication — Direction des Archives de France (DITN), 2007, URL : https://francearchives.gouv.fr/file/0f68a1bf4a28b3d3788377df873c992542ee5545/Note_DITN_RES_2007_008.pdf.
- BADDA (Atmane), « Technology Acceptance Model (TAM) : Literature Review », *International Journal of Accounting, Finance, Auditing, Management and Economics*, 6–11 (oct. 2025), p. 459-492, DOI : 10.5281/zenodo.17450768.
- BEARMAN (David), *Archives & Museum Informatics : Publishing : Archives : Functional Requirements for Collections Management Systems : Table of Contents*, URL : https://www.archimuse.com/publishing/bearman_col_mgmt_sys.html (visité le 18/07/2026).

- BELCIC (Ivan), *Qu'est-ce que la génération augmentée par récupération (RAG) ?* / IBM, 3 oct. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/retrieval-augmented-generation> (visité le 23/08/2026).
- BERGEOT (Patrick) et ESTAVOYER (Morgane), *Le jumeau numérique dans le patrimoine : fantasme ou réalité ?*, Livre Blanc, Paris, Centre des monuments Nationaux, 2025, 193p. URL : https://www.monuments-nationaux.fr/content/download/9908945/file/Livre%20blanc%203D_web_compressed.pdf.
- BOULLIER (Dominique) et LOHARD (Audrey), *Opinion mining et Sentiment analysis : Méthodes et outils*, Marseille, 2012 (Sciences Po médialab), URL : <https://books.openedition.org/oep/198> (visité le 23/08/2026).
- BREDIN (Hervé), « Pyannote.Audio 2.1 Speaker Diarization Pipeline : Principle, Benchmark, and Recipe », dans 2023, p. 1983, DOI : 10.21437/Interspeech.2023-105.
- BRISSAUD (Olivia), « L'élaboration du principe d'inaliénabilité pour les collections muséales et les biens du domaine public mobilier sous la Révolution française », *Livraisons de l'histoire de l'architecture*-26 (2013/déc./10), p. 141-156, DOI : 10.4000/1ha.343.
- CAZZARO (Mirco) et SILVELLO (Gianmaria), « Querying LLMs as If They Were Digital Libraries » ().
- Charte Sur La Conservation Du Patrimoine Numérique - UNESCO Digital Library*, URL : https://unesdoc.unesco.org/ark:/48223/pf0000179529_fre (visité le 09/07/2026).
- CHU (Yunfei), XU (Jin), ZHOU (Xiaohuan), YANG (Qian), ZHANG (Shiliang), YAN (Zhijie), ZHOU (Chang) et ZHOU (Jingren), *Qwen-Audio : Advancing Universal Audio Understanding via Unified Large-Scale Audio-Language Models*, 21 déc. 2023, DOI : 10.48550/arXiv.2311.07919, arXiv : 2311.07919 [eess.AS].
- Code Du Patrimoine - Légifrance*, URL : https://www.legifrance.gouv.fr/codes/texte_lc/LEGITEXT000006074236/ (visité le 02/09/2026).
- Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL* / Blog Google Cloud, Blog Google Cloud, URL : <https://cloud.google.com/blog/fr/products/bases-de-donnees/comment-obtenir-du-code-sql-de-qualite-avec-lia-decryptage-des-techniques-de-text-to-sql> (visité le 06/05/2026).
- COOK (Tom), « Evidence, Memory, Identity, and Community : Four Shifting Archival Paradigms », *Archival Science*, 13 (28 juin 2012), p. 95-120.
- CULTURE (Ministère de la), *Guide de Gestion Des Documents Patrimoniaux*, Paris, Ministère de la Culture, 2021, URL : <https://www.culture.gouv.fr/content/download/272461/3169783?version=13>.
- DE JANTI (Villeneuve), « Muséologie et Informatique : L'œuvre d'art à l'époque de Sa Reproduction Numérique », dans 2018.

- DENOËL (Charlotte), « L'apport de Léopold Delisle à la catalographie : de l'élaboration des Instructions pour la rédaction d'un catalogue de manuscrits (1884) à l'interopérabilité des métadonnées numériques », *Bulletin du bibliophile*-2 (2019), p. 342-353, DOI : 10.3917/bubib.370.0140.
- DEVLIN (Jacob), CHANG (Ming-Wei), LEE (Kenton) et TOUTANOVA (Kristina), *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, 24 mai 2019, DOI : 10.48550/arXiv.1810.04805, arXiv : 1810.04805 [cs].
- EDMONDSON (Ray), « PHILOSOPHY AND PRINCIPLES » ().
- EPPLER (Martin) et MENGIS (Jeanne), « The Concept of Information Overload : A Review of Literature from Organization Science, Accounting, Marketing, MIS, and Related Disciplines », *The Information Society*, 20 (1^{er} nov. 2004), p. 325-344, DOI : 10.1080/01972240490507974.
- EYZAGUIRRE (Cristobal), WU (Jiajun) et NIEBLES (Juan Carlos), *Linear Scaling Video VLMs for Long Video Understanding*, 29 mai 2026, DOI : 10.48550/arXiv.2605.31598, arXiv : 2605.31598 [cs.CV].
- FAIRBAIRN (Natasha), PIMPINELLI (Maria Assunta), ROSS (Thelma) et THILL (Viviane), « Le Manuel de catalogage des images animées de la FIAF » ().
- FLAMENT (Alexandre), *Google SGE (AI Overviews) : définition, fonctionnement et impact SEO en France*, deux.io, 2 juill. 2025, URL : <https://deux.io/definition-google-sge/> (visité le 29/07/2026).
- FLINN (Andrew), STEVENS (Mary) et SHEPHERD (Elizabeth), « Whose Memories, Whose Archives? Independent Community Archives, Autonomy and the Mainstream », *Archival Science*, 9-1-2 (juin 2009), p. 71-86, DOI : 10.1007/s10502-009-9105-2.
- GAO (Yunfan), XIONG (Yun), GAO (Xinyu), JIA (Kangxiang), PAN (Jinliu), BI (Yuxi), DAI (Yi), SUN (Jiawei), WANG (Meng) et WANG (Haofen), *Retrieval-Augmented Generation for Large Language Models : A Survey*, 27 mars 2024, DOI : 10.48550/arXiv.2312.10997, arXiv : 2312.10997 [cs.CL].
- GARG (Sourav) et MILFORD (Michael), *SeqNet : Learning Descriptors for Sequence-based Hierarchical Place Recognition*, 24 févr. 2021, DOI : 10.48550/arXiv.2102.11603, arXiv : 2102.11603 [cs.CV].
- Google/Gemma-4-31B-it · Hugging Face*, 20 août 2026, URL : <https://huggingface.co/google/gemma-4-31B-it> (visité le 28/08/2026).
- GROUPE (WEBQAM), *L'UX Design : Définition, enjeux et mise en pratique - Webqam*, Site Webqam Groupe, 21 févr. 2022, URL : <https://www.webqam.fr/blog/ux-design-definition-enjeux-mise-en-pratique/> (visité le 22/05/2026).

- HAAS (Lukas), SKRETA (Michal), ALBERTI (Silas) et FINN (Chelsea), *PIGEON : Predicting Image Geolocations*, arXiv.org, 11 juill. 2023, URL : <https://arxiv.org/abs/2307.05845v6> (visité le 15/05/2026).
- HEDRICK (Brandon P), HEBERLING (J Mason), MEINEKE (Emily K), TURNER (Kathryn G), GRASSA (Christopher J), PARK (Daniel S), KENNEDY (Jonathan), CLARKE (Julia A), COOK (Joseph A), BLACKBURN (David C), *et al.*, « Digitization and the Future of Natural History Collections », *BioScience*, 70–3 (1^{er} mars 2020), p. 243-251, DOI : 10.1093/biosci/biz163.
- HOLDSWORTH (Cole Stryker Jim), *Qu'est-ce que le NLP (traitement automatique du langage naturel) ?* / IBM, 11 août 2024, URL : <https://www.ibm.com/fr-fr/think/topics/natural-language-processing> (visité le 05/05/2026).
- HuggingFaceTB/SmolVLM2-2.2B-Instruct · Hugging Face*, 6 mai 2024, URL : <https://huggingface.co/HuggingFaceTB/SmolVLM2-2.2B-Instruct> (visité le 01/09/2026).
- HUSSON (Pierre), *Indexation Iconographique et Intelligence Artificielle : Expérimentations Autour Du Répertoire Des Tableaux Italiens Dans Les Collections Publiques Françaises (RETIF)*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 08/08/2026).
- Intelligence artificielle : définition et utilisation*, Thèmes | Parlement européen, 9 juill. 2020, URL : <https://www.europarl.europa.eu/topics/fr/article/20200827ST085804/intelligence-artificielle-definition-et-utilisation> (visité le 22/08/2026).
- Intelligence artificielle et collections de la BnF : l'exemple de l'HTR (Handwritten Text Recognition)*, BnF - Site institutionnel, URL : <https://www.bnf.fr/fr/intelligence-artificielle-et-collections-de-la-bnf-l'exemple-de-lhtr-handwritten-text-recognition> (visité le 23/08/2026).
- Intelligence artificielle, de quoi parle-t-on ?*, URL : <https://www.cnil.fr/fr/intelligence-artificielle/intelligence-artificielle-de-quoi-parle-t-on> (visité le 22/08/2026).
- Intfloat/Multilingual-E5-Small · Hugging Face*, URL : <https://huggingface.co/intfloat/multilingual-e5-small> (visité le 28/08/2026).
- ISO 9241-112 :2025*, ISO, URL : <https://www.iso.org/fr/standard/87518.html> (visité le 20/08/2026).
- JOANNA, *Stocker les données : la piste prometteuse de l'ADN*, Interstices, 13 janv. 2023, URL : <https://interstices.info/stocker-les-donnees-la-piste-prometteuse-de-ladn/> (visité le 09/07/2026).

- JONKER (Alice Gomstyn Alexandra), *Qu'est-ce que l'interopérabilité des données ?* / IBM, 24 mars 2026, URL : <https://www.ibm.com/fr-fr/think/topics/data-interopérabilité> (visité le 03/09/2026).
- JVC (Juvénal), *Interrogez efficacement vos bases de données avec Elasticsearch*, Data Transition Numérique, 21 juin 2022, URL : <https://www.data-transitionnumerique.com/search-elasticsearch/> (visité le 25/07/2026).
- KAVLAKOGLU (Jacob Murel Ph D. Eda), *Qu'est-ce que la racinisation et la lemmatisation ?* / IBM, 18 févr. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/stemming-lemmatization> (visité le 23/08/2026).
- KEVERS (Laurent), « Indexation Semi-Automatique de Textes : Thésaurus et Transducteurs », dans *Sixième Conférence Francophone En Recherche d'Information et Applications (CORIA)*, Presqu'Île de Giens, France, 2009, URL : <https://hal.science/hal-02454216> (visité le 08/08/2026).
- KOOLEN (Marijn), KAMPS (Jaap) et KEIJZER (Vincent), « Information Retrieval in Cultural Heritage », *Interdisciplinary Science Reviews*, 34 (18 juill. 2013), p. 268-284, DOI : 10.1179/174327909X441153.
- L'abbé Grégoire (31 Aout 1794) - Assemblée Nationale*, URL : <https://www2.assemblee-nationale.fr/decouvrir-l-assemblee/histoire/grands-discours-parlementaires/l-abbe-gregoire-31-aout-1794> (visité le 08/07/2026).
- LA GUARDIA (Marcello), KOEVA (Mila) et LO BRUTTO (Mauro), « Digital Innovation for the Documentation, Management, and Fruition of Cultural Heritage », *Heritage*, 8-8 (août 2025), p. 292, DOI : 10.3390/heritage8080292.
- LALLEMAND (Carine), *Méthodes de Design UX. 30 Méthodes Fondamentales Pour Concevoir Des Expériences Optimales. (2e Edition)*, 2018.
- LANDRAGIN (Frédéric), « Anaphores et coréférences : analyse assistée par ordinateur » (). *Le droit d'auteur / INPI*, URL : <https://www.inpi.fr/ressources/propriete-intellectuelle/droit-dauteur> (visité le 03/09/2026).
- Le règlement général sur la protection des données - RGPD*, URL : <https://www.cnil.fr/fr/reglement-europeen-protection-donnees> (visité le 03/09/2026).
- LEWIS (Michael), OKSANEN (Eljas), EHRNSTEN (Frida), RANTALA (Heikki), TUOMINEN (Jouni) et HYVÖNEN (Eero), « The Impact of Human Decision-Making on the Research Value of Archaeological Data », *ACM Journal on Computing and Cultural Heritage*, 18-3 (9 sept. 2025), 47 :1-47 :22, DOI : 10.1145/3736770.
- LEZER (Arthur), *inaSpeechSegmenter : décompte du temps de parole des femmes et des hommes*, INA le lab, DOI : 10.58079/q4fe.

- LIAO (Q. Vera) et VARSHNEY (Kush R.), *Human-Centered Explainable AI (XAI) : From Algorithms to User Experiences*, 19 avr. 2022, DOI : 10.48550/arXiv.2110.10790, arXiv : 2110.10790 [cs.AI].
- LIU (Ze), NING (Jia), CAO (Yue), WEI (Yixuan), ZHANG (Zheng), LIN (Stephen) et HU (Han), *Video Swin Transformer*, 24 juin 2021, DOI : 10.48550/arXiv.2106.13230, arXiv : 2106.13230 [cs.CV].
- Livre III : L'ACCÈS AUX DOCUMENTS ADMINISTRATIFS ET LA RÉUTILISATION DES INFORMATIONS PUBLIQUES (Articles L300-1 à L351-1) - Légifrance*, URL : https://www.legifrance.gouv.fr/codes/section_lc/LEGITEXT000031366350/LEGISCTA000031367685/?anchor=LEGIARTI000031367687#LEGIARTI000031367687 (visité le 03/09/2026).
- Loi européenne sur l'intelligence artificielle*, Explorateur de la loi européenne sur l'IA, URL : <https://artificialintelligenceact.eu/ai-act-explorer/> (visité le 03/09/2026).
- MELLOT (Jean-Dominique), « Confiscations Révolutionnaires et Histoire Des Bibliothèques Françaises : Un “Moment Fondateur à Revisiter” », *French History and Civilization*, 08 (2019).
- MENDONÇA (Diogo), BARROS (Tiago), PREMEBIDA (Cristiano) et NUNES (Urbano J.), *Seg2Track-SAM2 : SAM2-based Multi-object Tracking and Segmentation*, version 2, 2025, DOI : 10.48550/ARXIV.2509.11772.
- NIELSEN (Jakob), « Enhancing the Explanatory Power of Usability Heuristics », dans *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, New York, NY, USA, 1994 (CHI '94), p. 152-158, DOI : 10.1145/191666.191729.
- NLP : Qu'est ce que le NLP au juste ?*, URL : <https://www.data-bird.co/blog/nlp> (visité le 06/05/2026).
- NORMAN (Don), « The Design of Everyday Things » (, 2013), p. 325.
- PAAS (Fred), RENKL (Alexander) et SWELLER (John), « Cognitive Load Theory and Instructional Design : Recent Developments », *Educational Psychologist*, 38 (8 juin 2010), p. 1-4, DOI : 10.1207/S15326985EP3801_1.
- POIBEAU (Thierry), « Le traitement automatique des langues pour les sciences sociales :Quelques éléments de réflexion à partir d'expériences récentes », *Réseaux*, 188-6 (2014), p. 25-51, DOI : 10.3917/res.188.0025.
- Présentation du modèle Gemma 4*, Google AI for Developers, URL : <https://ai.google.dev/gemma/docs/core?hl=fr> (visité le 31/08/2026).
- Qu'est-Ce Que La Named Entity Recognition ? / IBM*, URL : <https://www.ibm.com/fr-fr/think/topics/named-entity-recognition> (visité le 23/08/2026).

- Qu'est-Ce Que l'algorithme Des k plus Proches Voisins ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/knn> (visité le 28/08/2026).
- Qu'est-Ce Que La Vision Par Ordinateur ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 23/08/2026).
- Qu'est-Ce Que Le Chunking Agentique ?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/agentic-chunking> (visité le 29/07/2026).
- RADFORD (Alec), KIM (Jong Wook), XU (Tao), BROCKMAN (Greg), MCLEAVEY (Christine) et SUTSKEVER (Ilya), « Robust Speech Recognition via Large-Scale Weak Supervision » ().
- *Learning Transferable Visual Models From Natural Language Supervision*, 26 févr. 2021, DOI : 10.48550/arXiv.2103.00020, arXiv : 2103.00020 [cs.CV].
- RANJGAR (Babak), SADEGHI (Abolghasem), SHAKERI (Maryam), RAHIMI (Fatema) et CHOI (Soo-Mi), « Cultural Heritage Information Retrieval : Past, Present, and Future Trends », *IEEE Access*, 12 (1^{er} janv. 2024), p. 42992-43026, DOI : 10.1109/ACCESS.2024.3374769.
- RAVI (Nikhila), GABEUR (Valentin), HU (Yuan-Ting), HU (Ronghang), RYALI (Chaitanya), MA (Tengyu), KHEDR (Haitham), RÄDLE (Roman), ROLLAND (Chloe), GUSTAFSON (Laura), *et al.*, « SAM 2 : SEGMENT ANYTHING IN IMAGES AND VIDEOS » (, 2025).
- ROSSETTO (Luca), GIANGRECO (Ivan), TANASE (Claudiu) et SCHULDT (Heiko), « Vitivr : A Flexible Retrieval Stack Supporting Multiple Query Modes for Searching in Multimedia Collections », dans *Proceedings of the 24th ACM International Conference on Multimedia*, New York, NY, USA, 2016 (MM '16), p. 1183-1186, DOI : 10.1145/2964284.2973797.
- SAM 2 : Segment Anything Model 2*, Ultralytics Docs, URL : <https://docs.ultralytics.com/fr/models/sam-2> (visité le 11/05/2026).
- SCHROFF (Florian), KALENICHENKO (Dmitry) et PHILBIN (James), *FaceNet : A Unified Embedding for Face Recognition and Clustering*, arXiv.org, 12 mars 2015, DOI : 10.1109/CVPR.2015.7298682.
- SERGEEV (Alexander), GOLOVIZNINA (Valeriya), MELNICHENKO (Mikhail) et KOTELNIKOV (Evgeny), « Talking to Data : Designing Smart Assistants for Humanities Databases » (). *Spectrum*, Collections Trust, URL : <https://collectionstrust.org.uk/spectrum/> (visité le 18/07/2026).
- SPRIGATH (Gabriele), « Sur le vandalisme révolutionnaire (1792-1794) », *Annales historiques de la Révolution française*, 242–1 (1980), p. 510-535, DOI : 10.3406/ahrf.1980.4227.
- State of Open Models : Summer 2026 Observations*, 12 août 2026, URL : <https://huggingface.co/blog/state-of-open-models-summer-2026> (visité le 25/08/2026).

- STUTZMANN (Dominique), MOUFFLET (Jean-François) et HAMEL (Sébastien), « La recherche en plein texte dans les sources manuscrites médiévales : enjeux et perspectives du projet HIMANIS pour l'édition électronique », *Médiévales. Langues, Textes, Histoire*, 73–73 (73[2017/déc./15]), p. 67-96, DOI : 10.4000/medievales.8198.
- Techniques et formats de conversion en mode texte*, BnF - Site institutionnel, URL : <https://www.bnf.fr/fr/techniques-et-formats-de-conversion-en-mode-texte> (visité le 23/08/2026).
- Text-to-SQL : interroger vos bases en langage naturel*, Flowt, 27 févr. 2026, URL : <https://flowt.fr/blog/text-to-sql-ia-generative-interroger-bases-donnees-langage-naturel/> (visité le 06/05/2026).
- TUZA (Bénédicte), *Interroger la mémoire d'entreprise par l'IA : le RAG face aux archives orales. Enjeux et limites pour l'histoire appliquée*, other, Perles d'Histoire, 40 rue de Paris, 92100 Boulogne-Billancourt, 2025, p. xxxii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05390427> (visité le 26/02/2026).
- ULTRALYTICS, *Qu'est-ce qu'un reranker ? Optimiser la recherche et l'IA*, Ultralytics, 29 janv. 2026, URL : <https://www.ultralytics.com/fr/glossary/reranker> (visité le 29/07/2026).
- Universal bibliographic control and international MARC programme et Fédération internationale des associations de bibliothécaires et des bibliothèques (éd.), *Functional Requirements for Bibliographic Records : Final Report*, München, 1998 (UBCIM Publications, 19).
- VARRY (Dominique), « Les confiscations révolutionnaires », dans *Histoire des bibliothèques françaises*, 2009, p. 7-36, DOI : 10.3917/elec.verne.2009.01.0007.
- Hélène Verdier et France (éd.), *Système descriptif des objets mobiliers*, Paris, 1999 (Documents & méthodes, no 6).
- WANG (Liang), YANG (Nan), HUANG (Xiaolong), YANG (Linjun), MAJUMDER (Rangan) et WEI (Furu), *Multilingual E5 Text Embeddings : A Technical Report*, 8 févr. 2024, DOI : 10.48550/arXiv.2402.05672, arXiv : 2402.05672 [cs.CL].
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, 2026, DOI : 10.48550/arXiv.2603.10285.
- WARWICK (Claire), TERRAS (Melissa), HUNTINGTON (P.) et PAPPAS (N.), « If You Build It Will They Come? The LAIRAH Study : Quantifying the Use of Online Resources in the Arts and Humanities through Statistical Analysis of User Log Data », *Literary and Linguistic Computing*, 23 (14 déc. 2007), p. 85-102, DOI : 10.1093/llc/fqm045.
- WHITELAW (Mitchell), « Generous Interfaces for Digital Cultural Collections », *Digital Humanities Quarterly*, 009–1 (21 mai 2015).

- WILLFRIED BAATZ, *Photography*, 1997, URL : <http://archive.org/details/photography00baat> (visité le 09/07/2026).
- XUE (Dongge), PU (Zhili), XIA (Zhentao), SUN (Hongli), HOU (Ruihui), YU (Guangya), LIN (Yupian), FAN (Yongqi), LIU (Jingping) et RUAN (Tong), « Text-to-ES Bench : A Comprehensive Benchmark for Converting Natural Language to Elasticsearch Query » ().
- YUAN (Cheng), JIANG (Jian), YANG (Kunyi), WU (Lv), WANG (Rui), MENG (Zi), PING (Haonan), XU (Ziyu), ZHOU (Yifan), SONG (Wanli), *et al.*, « Systematic Evaluation and Guidelines for Segment Anything Model in Surgical Video Analysis », *npj Digital Surgery*, 1–1 (1^{er} avr. 2026), p. 2, DOI : 10.1038/s44484-025-00002-2.

Introduction

La conservation du patrimoine et la gestion des collections patrimoniales soulèvent des enjeux politiques, sociaux, culturels et identitaires. Avec l'arrivée du numérique, ces notions n'ont cessé d'évoluer comme le souligne Marcello La Guardia et Mila Koeva :

*« Recent years have been characterised by a profound transformation in the field of Cultural Heritage, shaped by interdisciplinary methodologies, digital innovation, and the demand for more inclusive, sustainable management approaches. »*¹

Dès lors nous devons définir ce que nous entendons par patrimoine et gestion des collections. Quels sont les objets, lieux et pratiques encadrés par ces notions ? Quels en sont les problématiques et limites particulières ? Et enfin, comment patrimoine, gestion des collections et numériques s'imbriquent ?

Patrimoine et gestion des collections sont des notions variant en fonction des contextes institutionnels et culturels. En France, elles prennent racines au XVIII^{ème} siècle lors de la Révolution française au travers des confiscations révolutionnaires.

Entre 1790 et 1793, les biens monarchiques et ecclésiastiques sont placés sous patronage de la Nation. Certains sont revendus pour pallier la crise financière en vigueur, d'autres sont précieusement conservés.² Mais la position révolutionnaire n'est pas unanime : si certains cherchent à conserver pour la Nation, d'autres souhaitent détruire ces symboles de l'Ancien Régime ce qui entraîne des destructions, dégradations et vols.³

Le patrimoine s'affirme en réaction à ces actes au travers du rapport du 31 août 1794 sur les exactions révolutionnaires de l'Abbé Henri Grégoire (*04 décembre 1750 - 28 mai 1831*).

¹Marcello La Guardia, Mila Koeva et Mauro Lo Brutto, « Digital Innovation for the Documentation, Management, and Fruition of Cultural Heritage », *Heritage*, 8-8 (août 2025), p. 292.

²Dominique Varry, « Les confiscations révolutionnaires », dans *Histoire des bibliothèques françaises*, 2009, p. 7-36, p.21.

³Jean-Dominique Mellot, « Confiscations Révolutionnaires et Histoire Des Bibliothèques Françaises : Un "Moment Fondateur à Revisiter" », *French History and Civilization*, 08 (2019), p.134.

Il y dénonce le vandalisme⁴ des « [...] mobiliers appartenants à la Nation [...] »⁵. L'historien Dominique Poulot approfondit : en réalité on souhaite préserver ce qui est justifié par « l'appel à l'avenir » pour un idéal associant « légitimité nouvelle, utilité savante, et conservation raisonnée ».⁶

Le projet de *Bibliographie Universelle de la France*⁷ de 1790, première grande entreprise de catalogage national, ainsi que la recherche constante de lieu de conservation pour ces biens, témoignent de cette naissance de la notion de Patrimoine et de ses particularités françaises.

L'archiviste paléographe Olivia Brissaud soulève dans son article de 2013⁸ les particularités patrimoniales françaises suivantes : d'abord le patrimoine est « inaliénable » et « inviolable ». Ensuite, il relève d'une responsabilité commune. De plus, il devient le fondement identitaire et culturel de la Nation. Enfin, l'État s'octroie la souveraineté juridique sur le patrimoine à l'aide d'un appareil bureaucratique dédié, placé sous sa juridiction directe, devenu depuis le Service des Musées de France.

Ainsi, le patrimoine est une notion culturelle, aux racines profondément politiques et juridiques, constituant le socle identitaire national. Il se matérialise dans des collections d'objets, dont la constitution a permis l'émergence de la notion de patrimoine.⁹ Leur gestion relève directement de la juridiction de l'État français chargé de répondre aux enjeux politiques, juridiques et culturels associés.

Cependant, le patrimoine est un objet vivant qui ne cesse de se diversifier notamment avec l'inclusion de l'image animée¹⁰ en 1936¹¹ puis celle de la photographie¹² en 1964¹³. D'autres typologies d'objets entrent au patrimoine comme les espaces naturels et le patrimoine immatériel en 2003, avec la *Convention pour la sauvegarde du patrimoine culturel* promulguée par l'Organisation des Nations unies pour l'éducation, la science et la culture

⁴Gabriele Sprigath, « Sur le vandalisme révolutionnaire (1792-1794) », *Annales historiques de la Révolution française*, 242-1 (1980), p. 510-535.

⁵L'abbé Grégoire (31 Aout 1794) - *Assemblée Nationale*.

⁶*Ibid.*, p.183-184.

⁷J.D. Mellot, « Confiscations Révolutionnaires et Histoire Des Bibliothèques Françaises : Un "Moment Fondateur à Revisiter" »...

⁸Olivia Brissaud, « L'élaboration du principe d'inaliénabilité pour les collections muséales et les biens du domaine public mobilier sous la Révolution française », *Livraisons de l'histoire de l'architecture*-26 (2013/déc./10), p. 141-156.

⁹Ministère de la Culture, *Guide de Gestion Des Documents Patrimoniaux*, Paris, Ministère de la Culture, 2021, p.17.

¹⁰L'invention de « l'image animée » en tant que tel est difficile à dater. Le brevetage en 1895 du cinématographe des frères Auguste et Louis Lumière consacre cette nouvelle typologie documentaire.

¹¹Création de la Cinémathèque française

¹²Bien que Louis Daguerre grâce à son Daguerrréotype, le premier « appareil photo », a été considéré comme l'inventeur de la photographie, son invention remonterait aux travaux de Nicéphore Niépce et de son héliographe. Voir Willfried Baatz, *Photography*, 1997

¹³Création du Musée Français de la photographie

appelé l'UNESCO

Pour la gestion des collections, depuis la tentative de normalisation en 1890¹⁴, les pratiques de catalogage n'évoluent pas beaucoup malgré la diversification des collections. C'est l'informatique qui apporte un nouveau souffle à ce domaine.

En 1970, la première base de données informatique patrimoniale est créée afin de constituer un premier catalogue des collections mutualisées : c'est JOCONDE qui est destinée aux Musées de France¹⁵. En parallèle, des systèmes de gestion des collections, ou système de gestion des collections pour Système de Gestion des Collections, sont développés : c'est le cas du projet GRIPHOS *Museum Computer Network* à New York en 1967 qui permet de créer un inventaire et suivi informatique des collections physiques dans des musées.

La réduction de la taille des ordinateurs permet d'équiper informatiquement les institutions en masse. Ainsi en 1985 est installé le système de gestion des collections appelé Micromusées à l'échelle nationale sous l'impulsion du Service des Musées de France.¹⁶ L'invention d'internet en 1983 et du *World Wide Web* en 1989 permettent de faire de JOCONDE et Micromusée des outils nationaux pour une mutualisation complète des collections et pratiques.

Des organisations comme l'IFLA ou le CIDOC, profitent de l'essor de l'informatique pour normaliser mondialement les pratiques de gestion des collections. Ainsi, des normes de description, leurs traductions informatiques appelées standards d'encodage et des modèles conceptuels de gestion des collections sont créés.

Le patrimoine devient un bien commun à normaliser dans sa description afin d'en faciliter l'échange et la diffusion nationale et mondiale. Pour ces deux raisons, l'État français incite à informatiser les musées dans un premier temps, puis toute institution possédant des collections patrimoniales.

La dématérialisation des catalogues amène à penser une solution de conservation numérique des collections pensée pour concilier conservation et communication. Alors apparaît la numérisation, processus qui aboutit à la création d'un « jumeau numérique »¹⁷ afin de protéger

¹⁴Charlotte Denoël, « L'apport de Léopold Delisle à la catalographie : de l'élaboration des Instructions pour la rédaction d'un catalogue de manuscrits (1884) à l'interopérabilité des métadonnées numériques », *Bulletin du bibliophile*-2 (2019), p. 342-353.

¹⁵Hélène Verdier et France (éd.), *Système descriptif des objets mobiliers*, Paris, 1999 (Documents & méthodes, no 6), p. 2.

¹⁶Villeneuve De Janti, « Muséologie et Informatique : L'œuvre d'art à l'époque de Sa Reproduction Numérique », dans 2018, p.2.

¹⁷Patrick Bergeot et Morgane Estavoyer, *Le jumeau numérique dans le patrimoine : fantasme ou réalité ?*, Livre Blanc, Paris, Centre des monuments Nationaux, 2025, 193p.

l'objet physique tout en offrant la possibilité de le consulter¹⁸. Pour certaines typologies telles que l'image animée, le numérique devient le moyen de création et de conservation privilégié. Cela s'explique par les avancées technologiques dans ce domaine ainsi que la popularisation de la vidéo numérique.

La numérisation du patrimoine amène en 1997 la BNF à ouvrir le premier site de consultation de documents numérisés : Gallica. Puis en 2009, l'UNESCO reconnaît aux objets numériques, natifs ou numérisés, une valeur patrimoniale¹⁹. Dès lors, le patrimoine numérique connaît une croissance sans précédent : par exemple la BNF possédait environ trois-cent cinquante mille documents numériques en 2007 contre plus de dix millions en 2026.

Les diverses évolutions du patrimoine et de la gestion des collections que nous avons retracées imposent de nouvelles limites et difficultés. Les collections patrimoniales sont aujourd'hui doublement hétérogènes : plusieurs typologies documentaires y coexistent et les objets physiques côtoient leurs équivalents numériques²⁰. Une seule collection appelle une gestion plurielle à travers l'application de différentes normes, standards et modèles conceptuels. À cela s'ajoute l'intensification de l'expansion des collections patrimoniales notamment due au numérique.

La production intensive de données numériques participe à l'explosion quantitative des données que l'on appelle la *Big Data*. À titre d'exemple, en 2023 l'INA stocke plus de 60 pétaoctets de données, soit 60 000 000 de gigaoctets de données.²¹ Avec de telles quantités de données, deux enjeux se renouvèlent : celui du stockage, qui engage des questions d'infrastructures, et celui de l'accès, qui amène à repenser les moyens d'accès aux collections.

Si l'informatique a apporté des solutions de gestion des collections, la diversité des modalités et pratiques ainsi que l'importance desdites collections appellent d'autres solutions. Depuis 2020, le domaine de l'intelligence artificielle, ou IA, semble proposer des solutions face aux défis posés par les collections patrimoniales aujourd'hui.

On entend par « IA » la technologie capable d'effectuer des tâches assimilées à l'intelligence comme l'apprentissage et le raisonnement. Cela se concrétise notamment avec le *machine learning* et le *Deep Learning* permettant une autonomisation de ces outils demandant moins de supervision humaine. L'IA est de plus en plus intégrée au monde culturel et patrimonial : d'abord avec la *computer vision* pour l'analyse d'image et de vidéo et le *Natural Language Processing* pour le traitement des textes. Puis ensuite avec l'arrivée des *Vision*

¹⁸Pour plus d'informations : <https://www.culture.gouv.fr/thematiques/innovation-numerique/soutenir-la-creation-numerique-et-l-innovation/numerisation-des-contenus-culturels>

¹⁹Charte Sur La Conservation Du Patrimoine Numérique - UNESCO Digital Library.

²⁰Voir la notion de jumeau numérique dans Id., *Le jumeau numérique dans le patrimoine : fantasme ou réalité ?*...

²¹Joanna, *Stocker les données : la piste prometteuse de l'ADN*, Interstices, 13 janv. 2023.

Language Model permettant de faire aussi bien de la *computer vision* que du NLP à l'aide d'un seul outil.

Toutes ces nouvelles technologies se mettent peu à peu au profit du patrimoine à l'instar du projet HIMANIS a permis l'indexation massive des 75 000 pages manuscrites du corpus médiéval du Trésor des Chartes grâce au *Handwritten Text Recognition*, ou reconnaissance d'écriture manuscrite.²² La conduite ponctuelle de projet d'IA apporte plus de profondeur dans notre connaissance du patrimoine possédé. Mais aujourd'hui l'attention se concentre sur l'intégration pérenne d'outils d'IA. Des institutions nationales intègrent progressivement de tels outils constituant de véritables processus automatiques : on peut penser à LECTAUREP pour les archives notariales aux Archives Nationales et Gallica Images à la BNF pour l'indexation automatique de documents numérisés. Ces outils sont cependant marginaux puisque les institutions plus petites, mais plus nombreuses, se dirigent vers des solutions de système de gestion des collections sur étagère. Ces dernières intègrent rarement ces outils et seulement de manière partielle avec une prise en main limitée.

Mon stage porte précisément sur ce sujet avec pour angle particulier de penser les outils et la manière de les intégrer dans un tel logiciel développé par l'entreprise SkinSoft à destination de professionnels du monde patrimonial.

Établie à Besançon, SkinSoft est définie comme une PME française, composée d'environ 50 personnes, ainsi qu'un laboratoire de recherche qui fournit une solution de système de gestion des collections. Cette entreprise est une actrice de premier plan sur ce marché international, fournissant aussi bien des institutions publiques (*Château de Fontainebleau, The Royal BC Museum, ...*) que privées (*Fondation Jérôme Seydoux-Pathé, Lacoste, ...*). Elle opère en France principalement, mais aussi en Amérique, en Europe centrale et de l'Est allant même jusqu'en Asie. Au titre de laboratoire de recherche, elle cherche à développer de nouveaux outils pour la gestion des collections notamment basés sur l'IA.

Plusieurs missions ont été définies, chacune portant sur un point d'attention particulier quand on parle d'intégration d'outils IA dans un système de gestion des collections. La première a été de réfléchir à ce que l'IA peut apporter dans l'application à un utilisateur²³, sur des aspects d'usages et d'accessibilités des collections. La seconde mission a consisté en l'identification des besoins utilisateurs et la conception d'outils y répondant. La troisième et dernière mission a été de conceptualiser une chaîne de traitement basée sur l'IA²⁴ afin

²²Pour plus d'informations voir : Dominique Stutzmann, Jean-François Moufflet et Sébastien Hamel, « La recherche en plein texte dans les sources manuscrites médiévales : enjeux et perspectives du projet HIMANIS pour l'édition électronique », *Médiévales. Langues, Textes, Histoire*, 73–73 (73[2017/déc./15]), p. 67-96

²³Ici le mot « utilisateur » désigne tout professionnel membre d'une institution, privée ou patrimoniale, possédant la solution SkinSoft et qui utilise cette dernière pour gérer la collection de ladite institution

²⁴Ici, le terme intelligence artificielle est utilisé au sens global. Nous ne parlons pas encore de domaine, sous-domaine et d'outils précis.

d'automatiser le traitement de l'image animée directement dans l'application.

La réalisation de ces missions a pour objectif de produire différents outils basés sur l'IA afin de permettre une meilleure gestion des grandes quantités de données patrimoniales. D'offrir de meilleurs outils de gestion et d'exploitation des collections et données. Et enfin de faciliter certains processus, comme l'indexation, notamment dans le champ du traitement de l'image animée.²⁵

Finalement, cet objectif pose la question suivante : dans quelle mesure l'implémentation d'outils basés sur l'intelligence artificielle dans un système de gestion des collections permet de répondre aux défis des collections composites sans dénaturer les pratiques de gestion ?

La réponse se fait en 3 temps. Le premier est consacré à l'analyse de ces logiciels, notamment le système SkinSoft, et des difficultés actuelles qu'ils rencontrent. C'est également l'occasion de quelques considérations générales sur l'IA, dans le domaine de la gestion des collections. L'objectif est de solidifier nos connaissances sur le monde dans lequel cette étude s'inscrit et de comprendre en profondeur chaque élément d'attention ciblés quand nous parlons de gestion de collections d'IA appliquée à ce domaine particulier.

Le second temps est dédié à l'exploration de deux technologies d'IA : en particulier le NLP, ou NLP, et l'indexation semi-automatisée²⁶. L'analyse de l'indexation automatisée notamment via une réflexion à son application au domaine de l'image animée. Nous ferons un état de l'art afin de comprendre l'envergure de ces technologies, les problématiques qu'elles résolvent et comment la recherche actuelle conçoit leurs utilisations sur des données patrimoniales. La solution SkinSoft sert ici de cadre d'étude permettant de mieux saisir le périmètre et les limites de chaque technologie.

Le troisième et dernier temps de ce mémoire est dédié à un retour d'expérience sur les deux projets d'IA. En présentant les solutions conceptualisées et comment leurs implémentations ont été pensées. L'objectif est de présenter les apports et limites de ces solutions ainsi que les difficultés rencontrées et les choix effectués. Avant de conclure notre travail, ce temps se termine sur une analyse d'écart entre l'apport envisagé par l'implémentation de ces technologies au début des projets, et l'apport réellement envisageable une fois les projets aboutis.

²⁵Il est important de noter que ce travail ne porte pas uniquement sur l'image animée. Le travail effectué explore d'autres typologies que la seule image animée, bien que cette dernière possède une place particulière ici.

²⁶Ce n'est pas vraiment une technologie à part entière, mais plutôt un ensemble de technologies mobilisées pour une tâche particulière. Par facilité de langage, nous parlerons souvent de l'indexation semi-automatisée comme d'une technologie à part entière.

Première partie

La gestion numérique de collections
composites dans le monde patrimonial
et le secteur privé.

Chapitre 1

Système de gestion de collection et suite SkinSoft

I. Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes

Les systèmes de gestion des collections sont aujourd'hui au cœur des pratiques de gestion des collections et de l'activité des institutions conservatrices. Pour mesurer leur impact, il faut constater à quel point ils ont redéfini le concept de gestion des collections. De fait, ce terme désigne une toute autre réalité que celle d'origine.

À l'origine, ces logiciels transposent toutes les pratiques de gestion des collections en vigueur au moment de leur invention dans un logiciel. Ainsi, ils assurent la pérennité des objets patrimoniaux et de leur histoire afin de léguer les connaissances. Les premiers logiciels comme GRIPHOS puis Micromusées ont pour but principal de répertorier chaque objet possédé, de consigner sa description et son évolution matérielle dans le temps. Finalement, ces premiers systèmes de gestion des collections ne déterminent pas de nouvelles pratiques.

L'explosion des moyens informatiques et leur implémentation à large échelle a conduit à la multiplication des bases de données institutionnelles. Chaque institution possède sa propre base dans laquelle elle décrit simplement ses collections avec ses propres méthodes et vocabulaires. Cela crée un paradoxe : conçu comme un atout à la normalisation des descriptions, ils ont paradoxalement renforcé le cloisonnement des inventaires. Cela devient évident avec l'invention du *World Wide Web* qui rend envisageable la communication de ces inventaires numériques entre institutions et au public mais qui a besoin d'homogénéité. De plus, de nouvelles exigences juridiques sont développées afin de répondre à la rigueur

scientifique requise par la recherche.

Les systèmes de gestion des collections permettent ainsi d'améliorer des pratiques pré-existantes tout en amenant de nouveaux enjeux scientifiques et communicationnels. Plus qu'un outil de transition informatique, ils deviennent les vecteurs d'un éveil des consciences sur le besoin de changement des pratiques de gestion des collections.

À partir de la décennie 1980, la gestion des collections commence à être repensée de même que les principes fondamentaux des système de gestion des collections. L'article de 1987 de David Bearman, spécialiste en stratégie d'information documentaire,²⁷ est fondamental dans la définition de ce que doit être un système de gestion des collections.

Il y marque une rupture conceptuelle en définissant de nouveaux principes clés, afin de dépasser le simple rôle d'inventaire descriptif pour un rôle de gestionnaire de l'activité globale autour des collections.²⁸

Dans sa thèse, il distingue deux systèmes répondant à deux besoins différents : les *Information Retrieval System* et les systèmes de gestion des collections. Le premier se rapproche des systèmes contemporains de David Bearman. Il est concentré autour des « [...] facilities that support curatorial description and information retrieval for collections management purposes [...] »²⁹, à savoir : la collecte et la recherche d'informations de description d'objets. Le second est une notion plus large centrée sur une gestion du cycle de vie des objets culturels. 5 notions sont fondamentale : le temps, l'espace, les fonds financiers, le personnel et les fonds de collections³⁰. C'est le fondement de nos systèmes actuels.

David Bearman soulève un paradoxe : les système de gestion des collections de première génération n'incluent pas de dimensions managériales concrètes mais uniquement du stockage et de la recherche d'informations statiques. Il y a donc un écart entre les besoins croissants des institutions souhaitant établir des stratégies d'utilisation de ces objets et ce que ces outils permettent. En somme, un véritable système de gestion des collections ne doit pas seulement consigner des connaissances descriptive, mais piloter les activités et répondre aux enjeux stratégiques des collections.

Ainsi, un système de gestion des collections doit gérer des données sur le cycle de vie des objets patrimoniaux³¹ et des données centrées sur la gestion de ces derniers³².

²⁷David Bearman, *Archives & Museum Informatics : Publishing :Archives : Functional Requirements for Collections Management Systems : Table of Contents*.

²⁸*Ibid.*, p.1.

²⁹*Ibid.*, p.2.

³⁰*Ibid.*, p.3.

³¹*Ibid.*, p.4-11.

³²*Ibid.*, p.12-22.

Pour le premier point, il s'agit de consigner des données descriptives et historiques de l'objet. Mais également tout ce qui va relever de son intégration dans les collections. Ainsi, on y consigne tout ce qui concerne la vie d'un objet. À savoir ses conditions d'entrées dans les collections, les mouvements successifs, et toute activité concernant l'objet.

Pour le second point, il comprend la création, la catégorisation et la réutilisation de toutes les données produites au sujet de l'activité d'un objet patrimonial au sein des collections. C'est-à-dire qu'on veut consigner et décrire avec la même précision tout ce qui gravite autour de la gestion des collections : les événements, les agents de l'institution, les autorités, c'est-à-dire les personnes, les ressources et actions liées aux objets. Chacun de ces éléments doit être décrit, catégorisé, défini dans ses fonctions et limites et reliés à des objets de la collection afin d'en nourrir le cycle de vie.

il existe ainsi un lien de dépendance important et à double sens. Le fonctionnement d'une institution façonne sa gestion des collections, et ce constat est valable à l'inverse.

Sans aller plus loin dans l'article de David Bearman, on comprend alors que l'objectif d'un système de gestion des collections est d'être un outil stratégique et de pilotage des activités et politiques institutionnelles. La gestion des collections étant le cœur de ces institutions, elle en influence nécessairement les activités institutionnelles et sa capacité d'action.

C'est pour cela que ces systèmes sont très réglementés par des cahiers des charges précis observant des conventions internationales. C'est le cas de la norme SPECTRUM³³ du *Collections Trust* définissant des procédures fondamentales sur : l'entrée, l'acquisition, la localisation, l'inventaire périodique, le catalogage, la sortie, les prêts entrants, les prêts sortants et les mouvements, la conservation, la gestion des risques, l'utilisation des collections et le déclasserment des objets patrimoniaux. Tout système de gestion des collections doit pouvoir les documenter, les renseigner et les tracer dans le respect de l'interopérabilité des données.

Cette norme concerne aussi bien la gestion des objets numériques, que celle des objets physiques. C'est un point important qui fait du système de gestion des collections l'outil de gestion des collections aussi bien physiques que numériques. Cela amène donc à créer un outil multi-facettes afin de correspondre à différentes réalités : celle du numérique et celle du physique. Ainsi, cet outil doit répondre aux enjeux stratégiques institutionnels mais aussi de gestion de fonds doublement hétérogènes.

Ajoutons à cela que les institutions publiques ne sont pas les seules concernées : le secteur privé, notamment le luxe, s'empare désormais de ces logiciels. Pour ces entreprises, la

³³*Spectrum*, Collections Trust.

valorisation du patrimoine est devenue un levier stratégique au service de l'image de marque. Les collections y sont envisagées comme des outils commerciaux à part entière. La quête de productivité et de rendement justifie l'adoption de systèmes de gestion des collections capables d'optimiser le pilotage de leurs activités.

Finalement, aujourd'hui un système de gestion des collections est un outil informatique d'une grande complexité. Devenus le cœur de la gestion des collections dès les années 1970, ils sont devenus les points centraux des institutions conservatrices. Ils assurent la gestion des collections, des stratégies patrimoniales et institutionnelles ainsi que toutes les activités et événements liés à ces deux points.

Pour cette raison, les système de gestion des collections doivent assurer la documentation de l'objet, de sa vie au sein des collections, de son histoire mais aussi de la vie institutionnelle. Au-delà de ces aspects, les système de gestion des collections sont au cœur de politiques internationales d'harmonisation des pratiques de gestion des collections et des données produites au sein des activités concernées. Pour cette raison, ce sont des logiciels très contrôlés avec des cahiers des charges précis et complets qu'il convient de respecter.³⁴

Cela en fait des logiciels complexes et complets qui doivent s'adapter à différentes collections, différents volumes de données et différents buts notamment avec l'arrivée du secteur privé dans le domaine de la gestion des collections.

Ainsi, un système de gestion des collections doit affronter un grand nombre de difficultés. C'est ce que nous allons aborder ensuite.

³⁴en témoigne la liste dressée par l'organisme *Collection trusts* des logiciels approuvés : <https://collectiontrust.org.uk/software/>

II. Défis et difficultés que doit relever un système de gestion des collections aujourd'hui : Bigdata et harmonisation des données

Aujourd'hui, les système de gestion des collections se basent sur une architecture logicielle appliquant les principes décrits précédemment. Ils sont donc assez complexes, disposant de multiples entrées de données, fonctionnalités et manières d'accomplir des tâches précises.

Au cœur de ces logiciels se situe la notice, c'est-à-dire l'unité contenant toutes les informations en rapport avec un objet ou une ressource disponible dans l'application. Elle se base sur les métadonnées, ces données générées par les professionnels afin de décrire et contextualiser des objets patrimoniaux.

Le monde patrimonial a développé une manière bien particulière de créer et gérer cette métadonnée. Il s'agit de tout un univers gravitant autour de principes, standards et modèles conceptuels de gestion. Des notions que nous avons en partie définies, mais qu'il convient d'examiner plus en détail.

1. La métadonnée dans le monde patrimonial

Le patrimoine s'est toujours caractérisé par la diversité des objets conservés et des pratiques professionnelles autour de leur conservation. Au cours de leur existences, chaque institutions à développés ses propres méthodes et vocabulaires de descriptions rendant les données hétérogènes et inégale d'un établissement à l'autre.

L'informatique donne les moyens de créer un réseau d'informations patrimoniales. Cependant les différences de gestion et de descriptions constituaient des freins trop importants.

Pour cette raison, il y a eu des efforts internationaux d'homogénéisation des pratiques de descriptions et de gestion. Cela afin de mettre en place et respecter un but unique : interopérabilité des données.³⁵ Il s'agit de permettre à des systèmes informatiques de s'échanger des données, et de les interpréter de la même manière. Cela sous-entend que les données doivent pouvoir être identiques et stockées dans un schéma fixe lisible par tout systèmes.

Selon ce principe, plusieurs outils ont été mis en place afin d'homogénéiser un maximum les métadonnées. D'abord, des référentiels de métadonnées afin d'utiliser les mêmes éléments pour parler de la même entité. Aussi bien à l'échelle du vocabulaire, grâce aux thésaurus, c'est-à-dire des classements de mots en listes hiérarchique, que de référentiels plus larges comme les autorités.

³⁵Alice Gomstyn Jonker Alexandra, *Qu'est-ce que l'interopérabilité des données ?* / IBM, 24 mars 2026.

Ensuite, des normes descriptives telles que l'ISAD(G) pour les archives ou la norme MPEG-7 pour les documents multimédias, comme les images animées. Ces normes ont pour objectif d'établir : ce qu'il faut décrire, où trouver l'information et où la restituer dans un schéma descriptif. Si les référentiels permettent de normaliser la terminologie des métadonnées, les normes descriptives visent à normaliser leur structure. Elles ont été rapidement traduites dans des standards d'encodage imposant le respect de la hiérarchie informationnelle de la norme. C'est le cas du standard EAD pour les archives, selon la norme ISAD(G), via l'utilisation du langage XML dont on peut contraindre la structuration.

Ces éléments sont valables pour toutes les typologies patrimoniales conservées. Ainsi, elles possèdent parfois leurs propres référentiels, normes et standards d'encodage. Cela a donc homogénéisé les pratiques descriptives, mais a aussi amené à plus de distinction entre les typologies patrimoniales.

L'apparition de séparations plus nette entre les typologies et des standards descriptifs n'a constitué qu'une première étape. Dans le même temps, un constat de changement des attentes du public et des besoins de gestion des collections patrimoniales conduit à une nouvelle évolution.

C'est l'apparition de modèles conceptuels de gestion des collections. Ils ont pour objectif d'apporter de nouvelles conceptions de gestion afin de mieux répondre aux enjeux de conservation et aux attentes du public. Nous avons déjà cité le modèle CIDOC-CRM du CIDOC et le FRBR de l'IFLA. Nous explorerons d'ailleurs ce dernier plus en profondeur par la suite³⁶

Il est important de retenir qu'aujourd'hui ces modèles permettent de créer une stabilité de gestion des collections. Cela crée plus de liens entre les institutions ainsi qu'une stabilité des éléments nécessaires pour retrouver les bonnes informations.

Les efforts de normalisation à différentes échelles sont aujourd'hui plus que nécessaires. L'explosion des moyens informatiques et des créations du patrimoine numérique ont amplifié la masse de métadonnées produites. C'est le phénomène de *Big Data*.

Aujourd'hui, les institutions conservatrices gèrent des quantités impressionnantes de métadonnées descriptives. Les enjeux volumétriques rendent plus difficile l'application de ces standards et normes.

Ensuite par la diversification des formats. Cette massification des métadonnées a demandé de nouveaux moyens de gestion et de transmissions. Les fichiers XML étant assez lourds et verbeux, d'autres formats de fichier sont apparus : c'est le cas du JSON. Sans redéfinir les normes, son apparition impacte les formats d'échange de données entre insti-

³⁶ Chapitre 2. « Le FRBR et le WEMI » page 57

tutions. Par exemple, les sites internet institutionnels se dotent de systèmes d'échange de données, souvent basés sur le format JSON : ce sont les APIs. Cela implique donc de pouvoir transformer, par exemple, un encodage EAD en un fichier JSON , et inversement.

2. La place des systèmes de gestion des collections

L'organisme du *Collection Trust* impose le respect de ces principes concernant aux système de gestion des collections. Leur mission est finalement de constituer un terrain d'entente entre les besoins institutionnels et les efforts de normalisation. À ce titre, le logiciel SkinSoft respecte chaque norme, standard et modèle conceptuel attribués à chaque typologie. Tout en étant directement connectés avec des référentiels externes.

Cependant, ce n'est pas chose aisée. En effet, ces efforts de normalisation sont aujourd'hui en pleine application. Au moment de l'essor de l'informatisation, les institutions ont souvent constitué leurs propres bases de données selon leurs propres conceptions de gestion de la métadonnée. Ces bases dites « maisons » sont relativement fidèles aux normes. La structuration de la donnée leurs est propre : les métadonnées sont saisies selon des standards internes et l'architecture de la base de données est souvent unique.

C'est alors un premier rôle attribué aux système de gestion des collections que de permettre cette transition d'une base de données « maison » vers un système normalisé. Il faut pouvoir assurer la bonne transition de la donnée et des pratiques de saisie. Cela implique une notion de migration de données et d'accompagnement au changement.

De plus, les systèmes de gestion des collections sont en première ligne face aux défis de la *Big Data*. Tout en respectant ces normes, standards et modèles conceptuels, il faut pouvoir gérer de manière homogène cette masse de données. Traiter ce volume croissant et évolutif constitue un défi d'infrastructure, mais aussi un enjeu face à cette homogénéisation.

Cette massification des données et cette mise en danger de l'homogénéisation des métadonnées impose à ces logiciels de mettre en place des moyens suffisants pour conserver et perpétuer ce principe. Ainsi, ce logiciel ne se limite plus seulement à un outil de gestion avec une dimension stratégique mais devient un moyen d'application de l'interopérabilité des données et de l'homogénéité des métadonnées.

En conclusion, les systèmes de gestion des collections ne plus de simples logiciels d'applications de normes. Ils sont de véritables moteurs et appuis de l'évolution du patrimoine dans sa dimension numérique.

Aujourd'hui, ils ont pour enjeu de concilier les volontés d'homogénéisation à la réalité d'hétérogénéité massive. Cela les amène à côtoyer leurs limites et donc à se diriger vers des solutions d'IA pour faciliter cette mission par des processus automatisés ou semi-automatisés.

III. Présentation de la solution SkinSoft

De nos jours, les systèmes de gestion des collections sont essentiels aux institutions patrimoniales. Ils constituent le moyen le plus simple de gérer sa collection patrimoniale en accord avec les modèles conceptuels et standards de gestion. Tout en permettant le pilotage stratégique de l'activité institutionnelle.³⁷

C'est un véritable marché concurrentiel international en expansion. Bien que pour être catégorisé comme système de gestion des collections, il doit être approuvé par le *Collection trusts*³⁸, il n'existe pas vraiment de structure logicielle. Ainsi, il existe une myriade de logiciels aux fonctionnements et principes divergents sur certains points.

Cette dimension internationale est importante. L'effort d'homogénéisation des pratiques de description et de gestion n'est pas parfait. Par exemple, la norme *SPECTRUM* est particulièrement suivie au Royaume-Uni, tandis qu'en France c'est le *Code du Patrimoine* qui domine.³⁹ Cela entraîne des différences de gestion, en plus des différents standards et modèles conceptuels⁴⁰, auxquels ces logiciels doivent s'adapter.

Aujourd'hui l'enjeu est donc le respect de multiples cadres juridiques, normes, standards et modèles conceptuels, sans cadre technique global.

Dans cette partie, nous souhaitons présenter la solution logicielle SkinSoft afin d'amener une compréhension globale de cette dernière avant d'aller plus loin dans notre travail.

Nous allons aborder les aspects fonctionnels et techniques de l'application.⁴¹ L'objectif étant d'avoir une compréhension globale du cadre dans lequel cette étude s'inscrit, et du fonctionnement concret d'un système de gestion des collections.

1. Principe de la solution SkinSoft

Traditionnellement, les différentes typologies patrimoniales sont gérées dans des logiciels dédiés. Par exemple, l'entreprise Axiell propose Micromusée pour les musées, SNBase pour les musées d'histoire naturelle et V-Smart pour les bibliothèques.⁴²

SkinSoft propose un logiciel permettant de gérer toutes les particularités de chaque typologie en un seul logiciel.

³⁷Voir l'examen mené au *Chapitre I. « Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes »* page 3

³⁸Pour rappel, la liste est trouvable ici : <https://collectionstrust.org.uk/software/>

³⁹*Code Du Patrimoine - Légifrance.*

⁴⁰Voir la présentation faite au *Chapitre II. « Défis et difficultés que doit relever un système de gestion des collections aujourd'hui : Bigdata et harmonisation des données »* page 7

⁴¹Pour des raisons de confidentialité, nous resterons en surface sur certains éléments

⁴²Voir <https://www.axiell.com/fr/solutions/>

La suite logicielle *SkinSoft* est une solution *full-web* reposant sur un système de modules. Il existe un socle logiciel qui permet de gérer plusieurs aspects communs. D’abord, les outils de description tels que les thésaurus, les autorités et les localisations. Ensuite, la vie des collections avec les médias, entrées, dépôts, acquisitions, prêts, expositions ou encore les opérations de récollements. Et finalement, les paramètres de l’application : configuration, permissions, gestion des tables.⁴³

Chaque module est dédié à la gestion d’une typologie patrimoniale et vient compléter le socle logiciel. Chaque module apporte la gestion d’une typologie de collections, avec ses propres tables, standards et modèles conceptuels, et des fonctionnalités supplémentaires dédiées. Les modules principaux sont :

- S-Museum pour la gestion des objets de musées
- S-Movies pour la gestion de l’image animée⁴⁴
- S-Archéo pour la gestion du mobilier et opérations archéologiques
- Skin-Archives pour la gestion des archives
- Skin-Libris pour la gestion des collections des bibliothèques
- S-Specimen pour la gestion des collections d’histoire naturelle.

Par exemple, avec *Skin-Archives* il est possible de gérer des fonds et archives selon la structure de l’ISAD(G) et du standard EAD. Avec *S-Movies*, la norme appliquée est le FRBR et nous propose de gérer plus finement nos images animées.

Notons que les modules reposent sur la même architecture logicielle et sont ainsi cumulables permettant à une institution d’en disposer de plusieurs. Par l’accumulation de modules, une institution devient capable de gérer chaque typologie selon sa propre norme et son propre standard au sein d’un logiciel unique.

Rajoutons que ces modules communiquent entre eux. Un objet conservé dans *S-Museum* peut être relié à une archive stockée dans *Skin-Archives*. Il existe également une recherche fédérée permettant de rechercher à travers tous les modules.

Une autre particularité de ce logiciel est la personnalisation offerte. Les standards sont une première contrainte de description et de gestion auxquelles s’ajoutent les politiques institutionnelles.

La description d’un objet de collections dépend toujours d’un contexte et d’une politique institutionnelle.⁴⁵ Deux institutions différentes conservant la même typologie d’objet n’ont

⁴³Unité de stockage thématique d’informations.

⁴⁴Pour une description de *S-Movies*, voir *Chapitre 3. « La gestion de l’image animée dans l’application SkinSoft » page 61*

⁴⁵Andrew Flinn, Mary Stevens et Elizabeth Shepherd, « Whose Memories, Whose Archives ? Independent

pas les mêmes besoins de description et de communication. Dans l'application, cela signifie que certains champs de données ne seront jamais remplis ou alors de manière particulière. Et cela, pour chaque application.

Ainsi, il existe une infinité de champs mobilisables dans ce que l'on appelle des masques de saisie, c'est-à-dire des formulaires permettant d'inscrire de la donnée dans chaque champ. L'institution à la main sur cette partie afin de remplir les données qu'elle souhaite.

2. Composition techniques

L'architecture du socle logiciel est intéressante car représentative de la nécessaire évolutions de ces logiciels. Jusqu'à présent, le langage SQL domine le domaine de la structuration des données grâce à l'utilisation de schémas fixes. L'unité fondamentale est la tables : elles représentent une thématique et contiennent tous les objets y appartenant. Les lignes représentent les objets, et les colonnes déterminent les caractéristiques de chaque objet. Il peut exister un nombre presque illimité de colonnes, cependant elles ne peuvent être laissées vides.

Cela ne correspond pas à la réalité patrimoniale. En fonction des possibilités et besoins descriptifs, certaines colonnes devraient être laissées vides.

Afin de permettre une certaine souplesse, l'application stocke les données dans une base NoSQL. Le NoSQL est un langage permettant de structurer et interroger des bases de données sans la rigidité des tables SQL.

En effet, il n'y a pas de schéma rigide et commun à tous les objets conservés. Ils ont tous leur propre schéma, avec leurs propres champs et données, même au sein d'une même table. Ainsi deux objets d'une même typologie peuvent être décrits de deux manières différentes.

De cette manière, SkinSoft exploite cela pour sa logique modulaire. Chaque besoin descriptif peut coexister au sein d'une même base sans conflit. Cela permet de répondre à la diversité des besoins descriptifs institutionnels.⁴⁶

L'application n'interagit pas directement avec la base NoSQL institutionnelle. En effet, elles sont assez complexes à requêter ce qui entraînerait une trop grande complexité informatique. Pour cela, l'application utilise un intermédiaire : Elasticsearch. Il facilite la manipulation et la recherche des données stockées grâce à son système de recherche.⁴⁷

Community Archives, Autonomy and the Mainstream », *Archival Science*, 9-1-2 (juin 2009), p. 71-86 ; Tom Cook, « Evidence, Memory, Identity, and Community : Four Shifting Archival Paradigms », *Archival Science*, 13 (28 juin 2012), p. 95-120.

⁴⁶Pour plus d'informations sur les bases NoSQL, voir *Chapitre b. « Les processus Text-to-SQL et Text-to-NoSQL » page 46*

⁴⁷Pour plus d'informations sur Elasticsearch, voir *Chapitre I. « La recherche et l'utilisation de la solution*

ElasticSearch est ce que l'on appelle un SRI, c'est-à-dire un système spécialisé pour la recherche des données dans de grandes volumétries. Il est spécialisé sur l'interrogation des bases NoSQL et s'adapte à la modularité de l'application.

Il parcourt la base de données NoSQL et construit ce que l'on appelle des « index » pour chaque table applicative : ils contiennent les objets et leurs données dans des champs dédiés. L'utilisateur interagit directement avec ces index.

3. Limites et défis

Les particularités de cette solution lui permettent de se démarquer et de proposer une modalité de gestion des collections originale.

On peut voir en cette architecture une réponse aux besoins de respect des différentes modalités de gestions et de descriptions pour chaque typologie patrimoniale. Avec l'attention portée à la personnalisation de l'outil, cela ouvre une nouvelle dimension : l'adaptation des standards et modèles aux besoins institutionnels.

Cependant, cette architecture ne répond toujours pas aux problèmes de gestion des collections massives et la difficulté d'usage des systèmes de gestion des collections.

Pour le premier point, l'aspect modulaire et personnalisable n'offre pas de solutions. Quelques fonctionnalités permettent les traitements de masse comme le traitement par lots. C'est utile pour traiter les masses déjà stockées dans la base, mais pas pour accélérer le traitement des objets à intégrer. Ainsi, il y a une certaine difficulté à faciliter le traitement des collections non traitées. C'est en réalité une difficulté assez générale dans le domaine des systèmes de gestion des collections.

Pour le second point, nous avons vu précédemment la complexité de ces logiciels.⁴⁸ Elle se répercute sur des questions d'usages et de gestion des informations. Les flux de données sont nombreux et la structure logicielle labyrinthique. Et l'aspect modulaire peut rajouter une difficulté, notamment lors de la recherche fédérée dans laquelle il est compliqué d'identifier le module de provenance de chaque objet.

L'IA est aujourd'hui pensée comme la solution à ces deux problématiques. L'implémentation de tels outils représente aujourd'hui un défi autant sur l'aspect techniques qu'éthique et d'usage. C'est ce que nous allons aborder par la suite.

dans le logiciel SkinSoft » page 31

⁴⁸Voir *Chapitre I. « Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes » page 3*

Chapitre 2

L'intelligence artificielle dans la gestion des collections

I. Réalités de l'IA dans le domaine patrimonial

De nos jours, dans le domaine de la gestion des objets patrimoniaux et de leurs données revient régulièrement le terme d'« IA ». Nous l'entendons aujourd'hui dans toutes sortes de contextes et de sphères professionnelles avec des définitions souvent très différentes.

Ce terme générique désigne toutes sortes de technologies, processus et outils. Cependant, cela amène une confusion technique et technologique importante. Avant d'approfondir notre travail, nous devons consacrer un temps à la définition de l'IA. Mais aussi aux réalités techniques désignées dans le cadre de son application aux données patrimoniales.

Le Parlement européen définit l'IA comme : « la possibilité pour une machine de reproduire des comportements liés aux humains, tels que le raisonnement, la planification et la créativité ».⁴⁹ La CNIL⁵⁰ élargit cette notion à toute technologie aux « comportements dépassant les capacités humaines, puisque les ordinateurs actuels parviennent aujourd'hui à les surpasser dans certaines tâches ».⁵¹ L'autonomie et la capacité de traitement de masse sont des caractéristiques de ces technologies.

Dès lors, on désigne un ensemble de technologies et d'outils capables d'effectuer des tâches relevant de comportements humains sur de grandes quantités de données en autonomie. Ces outils sont créés et appliqués à une très grande variété d'univers métiers. Cela, à des fins d'accélération de production et d'automatisation de tâches répétitives.

⁴⁹ *Intelligence artificielle : définition et utilisation*, Thèmes | Parlement européen, 9 juill. 2020.

⁵⁰ Commission nationale informatique et des libertés

⁵¹ *Intelligence artificielle, de quoi parle-t-on ?*

L'IA s'articule autour de notions et domaines clés qu'il convient de présenter.

D'abord les « réseaux de neurones artificiels ». Cette technologie est aujourd'hui au cœur de tout système d'IA. Il s'agit d'un système informatique, inspiré du cerveau humain, organisé en réseaux d'unités de calcul appelées « neurones ». Cela permet l'apprentissage, d'analyse et d'autonomie dans diverses tâches. Il en existe plusieurs types, comme les réseaux de neurones convolutifs et les transformers, sur lesquels nous nous attarderons par la suite.

À cela s'ajoute la notion de *machine learning* et *Deep Learning*. La première notion désigne l'ensemble des moyens permettant aux intelligences artificielles d'apprendre et de s'entraîner à accomplir des tâches. La seconde notion est un sous domaine du *machine learning* centré sur l'apprentissage de l'autonomie. Cela passe par la complexification des réseaux de neurones artificiels et des méthodes d'entraînement spécifiques. Actuellement, l'évolution technologique amène à privilégier cette méthode.

En fin, l'intelligence artificielle générative. Outil basé sur des transformers et du *Deep Learning* afin de générer automatiquement du texte, des images ou encore du son. Ils constituent des modèles à part entière, différent des modèles d'IA ne pouvant qu'analyser des données mais pas d'en générer.

Le terme « IA » renvoie à une pluralité d'outils et de réalités techniques. Notons également que le développement constant de ce domaine amène la naissance de tout un langage propre à cet univers. L'utilisation de ce langage n'accorde pas au terme « IA » de définition fixe : il dépend avant tout du contexte dans lequel nous nous trouvons.

Ainsi, deux professionnels de métiers différents peuvent désigner des réalités technologiques différentes par ce même terme. Dans notre domaine, on désigne notamment trois domaines : le NLP, la *computer vision* et le *Retrieval Augmented Generation*.

1. Le *Natural Language Processing* : définition

Ce domaine consiste à « permettre aux machines de comprendre, interpréter, et répondre au langage naturel ».⁵² Cela réunit trois disciplines : la linguistique, la science computationnelle et l'IA.

Son but est de permettre le dialogue entre l'homme et la machine sans le biais du langage informatique. Couplé au *Deep Learning* et aux réseaux de neurones à transformers⁵³, il a donné naissance aux intelligences artificielles génératives et *Large Language Model*.⁵⁴

⁵²NLP : Qu'est ce que le NLP au juste ?

⁵³Jacob Devlin, Ming-Wei Chang, Kenton Lee et Kristina Toutanova, *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, 24 mai 2019, arXiv : 1810.04805 [cs].

⁵⁴Cole Stryker Holdsworth Jim, *Qu'est-ce que le NLP (traitement automatique du langage naturel) ?* / IBM, 11 août 2024.

Par sa compréhension du langage naturel, il permet de saisir le sujet, la grammaire et le sens profond d'un texte à partir des données contenues.⁵⁵ Cela permet l'analyse des vastes corpus documentaires conservés par les institutions patrimoniales.⁵⁶

Dès lors, on peut créer des correspondances sémantiques entre des documents. Cela grâce à la capacité de saisir le sens d'un texte et de le mémoriser via une vectorisation ⁵⁷. Ce domaine recouvre un grand nombre d'outils qu'il convient de présenter :

1. Le *Name Entity Recognition*. Outil qui consiste à repérer tous les noms propres et les associer à une entité. Il saura alors reconnaître que « Paris », et ses occurrences, correspond à un lieu.⁵⁸
2. La coréférence. Outil consistant en l'association d'une entité à des références implicites dans le texte. Par exemple dans « Paris, cette ville est magnifique », il sera compris que « cette ville » renvoie à « Paris ».⁵⁹
3. Le *Part of Speech*. Il s'agit de pouvoir accorder à chaque mot la bonne valeur grammaticale au sein d'une phrase, ou alors au sein d'échelles plus larges. Ainsi, on met en exergue sa construction grammaticale et on en comprend le sens. Particulièrement utilisé dans les analyses de discours.⁶⁰ Ce dernier se décline dans une version plus poussée appelée le « parsing syntaxique ». Il permet de décoder les liens logiques entre les mots et pas uniquement grammaticales.
4. Lemmatiser. Principe linguistique qui consiste à réduire les mots à leurs formes d'origine appelé le lemme. Par exemple, un verbe conjugué sera renvoyé à son infinitif. Cela permet d'analyser la phrase dans un état simple, retirant un maximum d'ambiguïté permettant de mieux comprendre le sens des mots. Combiné à un POS, on peut alors distinguer des homonymes et rapprocher des synonymes.⁶¹
5. L'*opinion mining*. Cet outil consiste à extraire un sentiment exprimé au sein d'une phrase par l'analyse de différents éléments linguistiques. Ainsi, le modèle peut comprendre si on exprime un sentiment négatif ou positif et donc mieux saisir le sujet.⁶²

⁵⁵ *Ibid.*

⁵⁶ Thierry Poibeau, « Le traitement automatique des langues pour les sciences sociales : Quelques éléments de réflexion à partir d'expériences récentes », *Réseaux*, 188–6 (2014), p. 25-51.

⁵⁷ (principe que nous explorons plus tard)

⁵⁸ *Qu'est-Ce Que La Named Entity Recognition ?* / IBM.

⁵⁹ Frédéric Landragin, « Anaphores et coréférences : analyse assistée par ordinateur » ().

⁶⁰ Jacob Murel Ph D. Kavlakoglu Eda, *Qu'est-ce que la racinisation et la lemmatisation ?* / IBM, 18 févr. 2025.

⁶¹ *Ibid.*

⁶² Dominique Boullier et Audrey Lohard, *Opinion mining et Sentiment analysis : Méthodes et outils*, Marseille, 2012 (Sciences Po médialab).

L'ensemble de ces outils consignés dans un modèle entraîné par *Deep Learning*, permet des analyses sémantiques de document textuels et sonores.

On parle bien de déterminer ou estimer le sens car ces outils reposent sur des calculs de probabilités. Cela les amène à prédire le mot suivant plutôt que de « comprendre » le mot et le suivant. Cela peut amener à des erreurs, allant jusqu'à inventer de la donnée : c'est ce que l'on appelle l'hallucination.

2. Définition de la *computer vision*

La *computer vision* vise à donner à des systèmes la capacité de percevoir, analyser et « comprendre » des images, aussi bien fixes que des images animées. L'objectif est de passer d'un amas de pixel à une information structurée compréhensible par un modèle, comme une image l'est pour un humain. Cela repose notamment sur la construction et l'entraînement de modèles pour des tâches, des types de documents et d'objets précis.⁶³

Ce domaine est en pleine expansion depuis l'apparition du *Deep Learning* et des réseaux de neurones de type CNN. Grâce à cela, les modèles spécialisés sur la *computer vision* apprennent de manière autonome à extraire des caractéristiques des images sans intervention humaine.

Pour le monde patrimonial, la *computer vision* représente un avantage important. En plus de posséder des tableaux, ou des images animées, la numérisation massive des collections a produit bon nombre d'images de textes. La *computer vision* permet dès lors de procéder à des analyses de collections entières et de toutes typologies. Une fois associée au NLP, on rend possible l'interprétation de ces documents.

Ce domaine repose sur plusieurs tâches fondamentales :

1. La classification. Procédé technique qui consiste à reconnaître un certain nombre de caractéristiques afin de déterminer sa typologie. Ainsi, le modèle différencie un tableau, d'une gravure, d'un texte, d'une image animée.⁶⁴
2. La détection d'objet. Méthode permettant de repérer une entité définie au sein d'une même image et d'en délimiter les contours. Cela permet de repérer un objet ou une entité cible au sein d'un corpus.⁶⁵
3. La segmentation. Procédé technique afin de déterminer et détourer précisément les objets et entités présentes sur une image. Cela peut être de reconnaître tous les éléments

⁶³ *Qu'est-Ce Que La Vision Par Ordinateur ?* / IBM.

⁶⁴ *Ibid.*

⁶⁵ *Ibid.*

d'un tableau, de repérer les lignes d'un texte ou de suivre des entités au sein d'images animées. Ce processus permet de distinguer tous les objets au sein d'une image, sans les identifier.⁶⁶

4. L'*Optical Character Recognition* et l'HTR. Outils de détection et d'extraction de texte, manuscrit ou typographié, au sein d'une image. Grâce au NLP, cet outil peut aussi le rendre interrogeable. Ces outils sont largement plébiscités au sein des institutions conservant de vastes corpus d'archives.⁶⁷

Dans le domaine patrimonial, la *computer vision* permet l'analyse des collections numériques des institutions conservatrices. Couplée à des technologies NLP, cela peut permettre de rendre ces images interrogeables.

Cependant, la *computer vision* présente deux limites dans sa conception actuelle à commencer par sa grande dépendance aux données d'entraînement. Les processus d'entraînement en *computer vision* sont lourds et mobilisent beaucoup de ressources. Ainsi, on produit souvent des modèles entraînés sur des données, tâches et typologies précises d'objets patrimoniaux. Lors de l'analyse, le modèle associe le document qu'il traite à ses données d'entraînement, soit ce qu'il « connaît ». Si le document traité sort de son champ de « connaissance » il est alors en proie à l'hallucination.

De plus, ces outils restent des outils basés sur des calculs statistiques et de probabilités. Ainsi, il n'y a pas de « compréhension » de ce qu'il analyse mais simplement des associations avec ses « connaissances ». C'est une limite importante pour des analyses très fines basées sur des connaissances précises.

3. le RAG : définition

Le RAG désigne une manière d'employer certaines technologies d'IA dans un but précis : un processus. On aborde donc un champ différent, puisqu'on parle d'un processus au cœur d'outils à destination du monde patrimonial.

L'objectif principal de ce processus est de limiter la capacité à halluciner d'un LLM. Pour cela, on met à disposition une base de connaissance large, diversifiée et spécialisée sur un monde professionnel afin de consolider le modèle sur ce contexte. Ainsi, le RAG associe les capacités d'analyses et de générations de certains outils à une fiabilisation de son système de recherches. De cette manière, on produit un outil capable de distribuer de la connaissance et non de l'inventer.⁶⁸

⁶⁶ *Ibid.*

⁶⁷ *Techniques et formats de conversion en mode texte*, BnF - Site institutionnel ; *Intelligence artificielle et collections de la BnF : l'exemple de l'HTR (Handwritten Text Recognition)*, BnF - Site institutionnel.

⁶⁸ Ivan Belcic, *Qu'est-ce que la génération augmentée par récupération (RAG) ?* / IBM, 3 oct. 2025.

Pour ce faire, on connecte un LLM à une ou plusieurs bases de données externes. Il va dès lors y puiser des données et s'y appuyer afin de justifier ses réponses. Cela se base sur 3 principes : ⁶⁹

1. *Retrieval* : désigne la capacité à aller chercher de la donnée dans des sources externes désignées. Il récupère de la données exacte et pertinentes, c'est à dire qui correspond à la requête utilisateur.
2. *Augmented* : désigne la capacité d'enrichir la requête utilisateur et/ou la réponse générée à l'aide des données stockées. Pour la requête utilisateurs, il s'agit de lui associer les bonnes données stockées afin de mieux cerner son périmètre. Pour la réponse générée, il s'agit de pouvoir indiquer une source, ou un extrait, vers laquelle se référer.
3. *Generation* : désigne finalement la capacité inhérente aux LLM de générer des réponses, le plus souvent en langage naturel.

Par le respect de ces principes, on assure la pertinence des réponses, leur adéquation à un contexte professionnel ou scientifique et la validité des données retournées. Les institutions patrimoniales voient en cette architecture la possibilité simplifier et consolider la recherche dans leurs collections ou corpus. Cela grâce à une interrogation de ces éléments facilitées et à des réponses générées plus exhaustives et fiables.

Nous abordons plus en détails son fonctionnement et ses apports dans des processus déterminés ici à la page 40 de ce travail.

Cette architecture prometteuse connaît quelques fragilités. Son efficacité dépend de sa capacité à bien « comprendre » les sources qui lui sont connectés, autrement tout résultat sera faussé. En fonction des sources, de leurs nombres et de leurs complexités, le résultat de cette première étape est hautement variable. De plus, le RAG peut parfois ne pas suffire à contraindre les LLM à l'utilisation de certaines sources. En effet, l'autonomie des modèles peut les conduire à outrepasser certaines instructions, sans jamais sortir de l'infrastructure.⁷⁰

4. Apports des outils et état des lieux de leur application dans la gestion des collections

Ces outils d'IA sont perçus comme des solutions potentielles face aux difficultés actuelles par les professionnels de la gestion patrimoniale. En effet, devant la massification

⁶⁹Pour plus d'informations voir Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang et Haofen Wang, *Retrieval-Augmented Generation for Large Language Models : A Survey*, 27 mars 2024, arXiv : 2312.10997 [cs.CL]

⁷⁰*Ibid.*

des données, la diversité des standards de descriptions et modèles conceptuels, et l'ambition d'interopérabilité des données à des échelles internationales et mondiales, les institutions manquent de moyens.

Ces outils représentent des solutions car ils permettent les traitements de masses en relative autonomie. Cela peut réduire drastiquement la charge de travail reposant aujourd'hui sur le personnel souvent en sous-nombre. Grâce à leurs capacités d'analyses, de « compréhension » de contextes et d'utilisation du langage naturel pour expliquer des concepts et des analyses, ces outils sont particulièrement intéressants.

Ces logiques ont conduit alors à la mise en place de premières expériences ponctuelles, comme HIMANIS⁷¹, puis aux premiers outils instaurés au sein d'institution comme LECTAUREP ou INASpeechSegmenter.⁷² Ils permettent de réduire le temps de traitement de certaines typologies d'objets patrimoniaux, d'accélérer des tâches de traitement et d'offrir de nouvelles dimensions de recherches.

Ces outils émergent principalement dans les grandes institutions, comme les Archives Nationales ou l'INA, et viennent compléter des méthodes de gestions préexistantes. Cependant, ce n'est pas la réalité pour toutes les institutions conservatrices.

En effet, la plupart des structures utilisent des systèmes de gestion des collections fournis par des entreprises externes, comme SkinSoft, situés au cœur de leurs pratiques. Ces structures plus petites, ont alors du mal à intégrer de nouvelles solutions. D'abord car il peut être difficile de les faire s'interfacer avec des systèmes de gestion des collections tierces. Ensuite par un manque de compétences techniques et de moyens financiers. Il y a donc un décalage entre l'avancée des pratiques de gestions patrimoniales et la possibilité de les inclure à toutes les échelles.

Pour ces raisons, nous constatons un effort global des fournisseurs de solutions externes de tendre vers l'inclusion de tels outils. D'abord afin de correspondre aux nouveaux besoins professionnels. Ensuite, afin de permettre aux institutions utilisatrices de disposer de tels moyens à des coûts techniques et financiers relativement accessibles.

⁷¹D. Stutzmann, J.F. Moufflet et S. Hamel, « La recherche en plein texte dans les sources manuscrites médiévales... ».

⁷²Arthur Lezer, *inaSpeechSegmenter : décompte du temps de parole des femmes et des hommes*, INA le lab.

II. Les enjeux techniques :

Ainsi, l'IA représente une solution pour le traitement des données et collections patrimoniales. Elle offre l'opportunité de pallier deux grandes difficultés : la masse et le temps de traitement. Par leur autonomie et capacité, relative fiabilité et rapidité de traitement sur des masses importantes de données, ces dernières pourraient ne plus être des freins à la gestion des collections. Cependant, ces considérations, si elles prennent en compte les limites précédemment vues, semblent déconnectées des réalités techniques, technologiques et financières des institutions ciblées.

Les technologies d'IA connaissent des évolutions rapides et importantes. Elles sont d'ordre technologique et de la popularité de ces outils. Prenons l'exemple des LLM :

Leur popularité est croissante. En témoigne le rythme de création et de publication en ligne des LLMs passant de un modèle public en novembre 2022 à plus de 500 mille modèles en libre accès sur *Hugging Face*⁷³. Cette croissance impressionnante démontre l'intérêt que l'on a envers ces derniers, également constatable par le nombre d'utilisateurs. Par exemple, ChatGPT est passé de 400 millions d'utilisateurs début 2025 à plus de un milliard en août 2026.⁷⁴

Pour ces technologies, notamment les LLM il y a un nouvel enjeu. Il est amené par l'*open-source* : phénomène de publication en ligne des codes de ces outils pour permettre des déploiements dans des environnements locaux, sous conditions de licence ou d'achat. Cela pousse leur adoption personnelle et professionnelle.

Pour l'aspect technologique, l'évolution entre 2022 et aujourd'hui est vertigineuse. Les corpus de données d'entraînement ne font que grossir, amenant l'ajout de ressource informatiques pour créer des modèles plus puissants. De plus, les LLM « classiques » sont peu à peu remplacés par des modèles multimodaux, capables de traiter du texte mais aussi des images, sons et vidéos. Ce qui démontre l'aspect éphémère de ces technologies.

C'est une première limite : les technologies et processus employés sont rapidement dépassés par des éléments plus récents. Si cela signifie que ce qui n'est pas possible actuellement le sera peut-être demain, cela pose aussi de nombreuses questions techniques. Quel outil utiliser ? Quand arrêter de s'adapter à l'actualité ? Comment maintenir son processus si dans 2 ans le modèle n'est plus maintenu ?

Une seconde limite concernant l'utilisation de ces outils est celle des coûts financiers et de leur impact. Cela dissocie la question de l'usage de celle de l'implémentation, car il s'agit

⁷³State of Open Models : Summer 2026 Observations, 12 août 2026.

⁷⁴AI & ChatGPT Statistics for 2026 (Usage & Adoption Data), Instant Press.

de déterminer les conditions dans lesquelles on dispose de cette technologie et les impacts provoqués. Ces choix sont d'ordre financier, politiques, infrastructurels, éthiques et de l'ordre de la sécurité des données. C'est pour cela que l'on parle de "modèle" : ce sont deux modes de fonctionnement distincts, posant leurs propres enjeux sur chacun des points. Les deux modèles distincts sont les suivants :

Le modèle reposant sur un système d'abonnement à une solution proposée par une entreprise externe. Cette dernière n'est pas possédée par l'institution mais par un acteur externe qui en assume l'hébergement, les coûts et la maintenance. C'est sur ce principe que reposent les agent conversationnel conversationnels publics. C'est un service appartenant à une entreprise externe mais qu'on applique sur nos données. Ce modèle économique repose sur trois principes :

1. Celui de l'abonnement. L'institution ayant souscrit à ce dernier paye régulièrement une somme définie au fournisseur de la solution afin de l'utiliser. Cela permet de prévoir les coûts, permettant à une institution de choisir une solution selon un budget défini et connu.
2. Celui de la dépendance de l'utilisateur envers le fournisseur. En effet l'utilisation de l'outil et l'hébergement des données traitées relèvent dès lors de l'entreprise externe, provoquant une perte de contrôle. Si le fournisseur arrête de maintenir son modèle, l'institution se retrouve sans outil. Si le fournisseur connaît une faille de sécurité, ce sont les données patrimoniales qui sont en danger.
3. Celui de la souveraineté des données. Cette notion désigne la possibilité de gérer et contrôler ses propres données dans leur préservation, diffusion, usage et traitement. Utiliser une solution externe demande aux institutions d'y renoncer partiellement ou du moins de faire des concessions. Les données sont stockées, préservées et traitées par le fournisseur qui devient dès lors responsable de leur sécurité. C'est un véritable enjeu car confier ses données à une entreprise tierce est un véritable risque de sécurité informatique. En effet, il y a moins de visibilité sur l'utilisation de ces données et sur leur sécurité, les rendants sensible aux risques croissant de failles informatiques.

Dans le monde patrimonial, ce modèle est incarné dans des solutions comme Archipassion⁷⁵ ou encore des systèmes de gestion des collections comme Axiell⁷⁶ et SkinSoft.

⁷⁵Archipassion pour le Ciné-Journal suisse.

⁷⁶Pour plus d'informations voir <https://www.axiell.com/fr/solutions/product/ai-for-museums-and-archives/>

Le second modèle est celui de l'intégration technologique en local. L'enjeu est alors la capacité institutionnelle à développer et héberger ses propres processus et technologies d'IA par ses propres moyens. Cela permet de renoncer à un appui sur une entreprise externe et des risques et contraintes liées. Ce modèle est celui employé par les grandes institutions, comme les Archives nationales ou l'INA. Il repose sur 3 principes clés :

1. La dimension locale. L'outil ou processus est développé ou adapté, dans le cas de l'utilisation d'un modèle *open-source*, en interne facilitant l'adaptation à des besoins, contextes et pratiques précises. Cela permet un hébergement local, c'est-à-dire interne à l'institution amenant les données à ne pas sortir de l'institution. On limite ainsi les risques de faille de sécurité par plus de contrôle sur l'ensemble du processus.
2. Le coût des infrastructures et des compétences. Si on développe et applique localement, il faut alors avoir les compétences et infrastructures adaptées. Cela demande de disposer de professionnels spécialisés dans différents domaines (*IA, sécurité informatique, développement, etc*). Ces derniers évoluent très rapidement et les compétences deviennent de plus en plus pointues, rares et coûteuses. Les technologies sont de plus en plus lourdes et demandeuses en puissance de calcul. Il faut alors disposer de mémoire vive, mémoire vidéo, processeurs et processeur graphiques qui, avec les récents progrès technologiques, coûtent de plus en plus cher. Ajoutons que l'utilisation de ces composants informatiques implique un coût électrique : plus la puissance disponible est importante, plus son coût potentiel augmente.
3. Le coût des technologies et de leurs maintient. L'installation locale des technologies demande de les développer ou alors d'en utiliser des préexistantes. L'*open-source* permet de récupérer différents modèles ou processus et de les installer dans son propre environnement informatique. Cependant, ces technologies ne sont pas nécessairement gratuite : il peut être nécessaire de payer une licence et de la renouveler afin de pouvoir utiliser la technologie dans le temps.

Ce modèle est bien plus flexible et intéressant dans un aspect de sécurité et de contrôle des processus, outils et données. Pouvoir disposer de ces technologies en local permet de mieux répondre aux besoins de traitement institutionnels. C'est une solution idéale. Cependant, les coûts financiers et humains très élevés réservent cette possibilité à une sélection d'institutions qui ne représentent pas la réalité du monde patrimonial. Les institutions et entreprises de plus petite envergure sont majoritaires : elles ont des besoins parfois aussi importants, mais des moyens bien plus limités.

On comprend dès lors qu’intégrer de l’IA, peu importe la réalité technique désignée, c’est avant tout faire des choix politiques, économiques, structurels et infrastructurels. Cela amène à se placer dans un modèle ou un autre : donc face à certains enjeux qu’il faut choisir.

Cela amène les institutions à se retrouver dans des dilemmes. Pour le modèle sur abonnement, le dilemme a lieu entre le besoin de disposer de ces outils et le besoin de souveraineté sur ces données et outils. De nos jours, il est au cœur des ambitions de ces institutions de préserver leur souveraineté sur leurs données et outils. Pour le modèle local, c’est un dilemme de rationalisation entre les coût engendrés, à court et long terme, et les performances nécessaires. Plus les performances recherchées sont élevées, plus le coût l’est également. Ce qui peut dès lors décourager la mise en place de ces solutions et rediriger vers le premier modèle, parfois inadapté aux besoins de traitement.

Cette réalité conduit les acteurs du monde patrimonial à introduire progressivement ces technologies sur des segments précis des collections. Autrement dit, en fonction des besoins de traitement et de communications auprès d’un public cible, certains aspects de la collection seront plus rapidement traités par de l’IA que d’autres. Cette introduction progressive entraîne une division du traitement des collections et données patrimoniales, ce qui peut créer des dissonances et des disproportions de traitement au sein des collections patrimoniales. Cela pourrait remettre en question les tentatives actuelles d’homogénéisation des descriptions, devant ainsi prendre en compte une double réalité : les processus automatisés et ceux encore manuels. Chacun entraînant une qualité de données et des possibilités de gestions différentes.

Finalement, l’IA appliqué à la gestion des collections connaît des évolutions lentes et ciblées. Cela amène tout de suite à réévaluer la valeur à accorder à l’implémentation de l’IA dans la gestion des collections. Ce n’est pas une révolution, soudaine et absolue, mais une évolution progressive et nuancée qu’il faut accompagner.

Les enjeux financiers, humains et politiques sont aujourd’hui encore trop grands pour que chaque institution et entreprise puisse se doter de tels outils. Et encore moins d’outils sur mesure. La tendance institutionnelle à reposer sur un modèle à abonnement peut aussi être une explication quant à l’intégration de ces outils dans des systèmes de gestion des collections externes. Cela place ainsi ces logiciels au cœur de l’évolution technologique en matière d’IA.

III. Le cadre juridique :

Les enjeux techniques de l'IA ne représentent qu'une fraction des considérations à prendre en compte. Leurs capacités d'entraînement et de traitement sur des milliers de données variées, ont entraînés une très vive popularité de ces outils.

Cette dimension, mêlée à leur opacité amène à définir un cadre législatif international, en plein essor. Ce dernier fusionne avec le cadre juridique patrimonial afin de normer et contraindre les outils que nous envisageons dans leur conception et leur traitement.

1. Cadre juridique du patrimoine et des données patrimoniales

Le patrimoine est basé sur des documents et objets comprenant des informations au sens large, issues d'institutions publiques ou du cadre privé. L'enjeu réside dans le sens de ces informations, pouvant être de nature sensible. Ce caractère particulier « s'oppose » à l'obligation de communication du patrimoine.

Ainsi, les textes juridiques cherchent à équilibrer cette diffusion du patrimoine avec la protection des informations sensibles. En France, le *Code du Patrimoine*⁷⁷ est la pierre angulaire du cadre juridique. Il impose un délai de communication des documents en fonctions de leur typologie et contenu.⁷⁸ Et régit également les conditions de dépôt et de communication des archives et patrimoines privés, presque sur mesure en fonction des cas.⁷⁹

Ce code est complété par le *Code de la propriété intellectuelle* avec notamment le droit d'auteur.⁸⁰ Le créateur d'une œuvre possède dès lors des droits moraux⁸¹, protégeant le lien entre l'œuvre et son créateur, et des droits patrimoniaux, disons d'exploitation de l'œuvre⁸².

L'informatisation des collections patrimoniales a amené à compléter l'appareil juridique patrimonial avec un volet spécialisé sur les données informatiques. On peut penser au *Code des relations entre le public et l'administration*. Il encadre la réutilisation des documents informatisés à des fins de diffusion, de traitement algorithmique et d'entraînement de modèles d'IA.⁸³

Mais surtout au texte européen : *Règlement général sur la protection des données*⁸⁴, ou

⁷⁷ *Code Du Patrimoine - Légifrance...*

⁷⁸ *Ibid.*, Article 213.1 à 213.3.

⁷⁹ *Ibid.*, Article 213-6.

⁸⁰ *Le droit d'auteur / INPI.*

⁸¹ *Ibid.*, Article 121-1 à 121-9.

⁸² *Ibid.*, Article 122-1 à 122-12.

⁸³ *Livre III : L'ACCÈS AUX DOCUMENTS ADMINISTRATIFS ET LA RÉUTILISATION DES INFORMATIONS PUBLIQUES (Articles L300-1 à L351-1) - Légifrance.*

⁸⁴ *Le règlement général sur la protection des données - RGPD.*

RGPD. Il est particulièrement intéressant dans notre position. Il définit les obligations qui incombent aux entreprises comme SkinSoft qui stockent des données dont elles ne sont pas propriétaires. Les données sont classées par catégories de sensibilités auxquelles sont associés des traitements à effectuer avant diffusions ou conservation. Cette dernière est également contrôlée dans sa forme et sa durée.

Ainsi, les fournisseurs de système de gestion des collections ont la position de « sous-traitant ».⁸⁵ L'entreprise n'a pas de droits sur les données conservées et le propriétaire dispose d'un accès permanents à ces dernières. Tout traitement à effectuer doit être approuvé par l'institution ou la personne propriétaire des données.

2. Contraintes juridiques de l'IA

Le cadre juridique se dessine avec le texte fondateur promulgué par l'Union européenne en 2024 : *l'AI Act*⁸⁶. Il impose des principes généraux sur ces outils. À savoir : la transparence des jeux d'entraînement, des traitements et du stockage des données ou encore le droit d'opposition accordé aux propriétaires des données. L'objectif est de sécuriser l'utilisation d'outils d'IA sur les données. En fonction de la sensibilité des données et du traitement appliqué, un niveau de risque de l'outil est déterminé. Ce dernier impose des principes et conditions de sécurité.

La « recherche augmentée », le chatbot et l'indexation semi-automatisée relèvent du risque limité. Cela impose une transparence de l'entreprise dans l'utilisation, le traitement et le stockage des données des institutions tout en respectant le droit d'opposition.

Cela s'ajoute au respect du *Code du patrimoine* et du *RGPD* précédemment cités. Ainsi, les outils envisagés doivent : respecter les délais de communications, traiter les données sensibles dans l'anonymat, ne pas diffuser les données sans l'accord des propriétaires et être transparent sur les traitements ainsi que la conservation des données. Tout cela doit être encadré par une infrastructure sécurisée.

Ce cadre juridique est hautement évolutif. Aujourd'hui, nous ne sommes qu'à un stade précoce de construction de ce cadre. L'*AI Act* instaure les principes de fond à mettre en relation avec l'appareil juridique patrimonial. Sur ces principes fondamentaux s'élèveront certainement de nouvelles législations. Ainsi, la conformité juridique en matière d'IA est une question évolutive. Et il incombe à des structures comme SkinSoft, si le projet de création d'outils d'IA aboutit, d'évoluer avec ce cadre.

⁸⁵ *Ibid.*, Article 28.

⁸⁶ *Loi européenne sur l'intelligence artificielle*, Explorateur de la loi européenne sur l'IA.

Deuxième partie

Implémenter l'intelligence artificielle
dans un système de gestion des
collections : étude de cas SkinSoft.

Chapitre 3

Le traitement du langage naturel : faciliter l’usage et fiabiliser la recherche

I. La recherche et l’utilisation de la solution dans le logiciel SkinSoft

La première technologie d’IA envisagée est le NLP, au sens large. L’objectif est d’améliorer l’accessibilité aux données stockées et l’usage de l’application par la possibilité d’interagir avec le logiciel par le langage naturel. Deux axes de développement sont identifiés. L’amélioration du système de recherche, et celle de l’utilisation de l’application.

Avant de développer chacun des axes, il est fondamental de comprendre le fonctionnement d’origine de l’application. Cette partie est donc consacrée à l’exploration de la manière dont le logiciel SkinSoft fonctionne sur les deux axes dépeints. Ainsi, nous pourrions mettre en évidence les limites actuelles auxquelles l’intégration du NLP doit répondre.

Le stockage et la recherche des données sont fondamentaux pour un système de gestion des collections. David Bearman sépare deux éléments, le système de gestion des collections, tel qu’il le définit, et l’SRI spécialisé sur la recherche d’informations. Ces outils sont complémentaires, le second devant être un module intégré aux premiers.⁸⁷ Le logiciel SkinSoft fonctionne sur cette logique. Le SRI utilisé est le logiciel *open-source* ElasticSearch, spécialisé sur les bases de données NoSQL orientée document comme celle utilisée par SkinSoft.

⁸⁷D. Bearman, *Archives & Museum Informatics : Publishing : Archives : Functional Requirements for Collections Management Systems : Table of Contents...*, p.43.

ElasticSearch présente l'avantage d'être *open-source*. Son code est accessible au public ce qui permet une grande transparence et adaptabilité applicative. Ce logiciel est également doté d'une grande scalabilité. C'est-à-dire qu'en cas d'augmentation de la masse de données à traiter, ses performances et les coûts engendrés restent stables.

Le fonctionnement d'ElasticSearch est assez simple.⁸⁸ Le logiciel récolte les données de la base de données par API dans un premier temps. Elles sont analysées et restructurée en index par thématique : une structure de stockage des données. Ils sont morcelés en *shards*, ou fragments, afin de ne traiter que ceux déterminés comme pertinents et de manière parallèles. Ces derniers sont répartis sur des nœuds : des serveurs dédiés à une fonction de structuration de la données. Il y en a 3 : celui de configuration, de prétraitement et des données. Les *shards* sont réparti sur les nœuds. Enfin, le logiciel construit des *clusters* qui sont des ensembles de 3 nœuds, un de chaque nature. Voilà un schéma de cette structure finale :




FIG. 1 : Schéma du fonctionnement d'ElasticSearch

⁸⁸Juvéna JVC, *Interrogez efficacement vos bases de données avec Elasticsearch*, Data Transition Numérique, 21 juin 2022.

ElasticSearch propose ses propres modalités de recherche : recherche simple, recherche full-text⁸⁹, recherche par mots-clés, recherche avancée ou bien par facettes⁹⁰. Pour faciliter l'usage, dans l'application à été créé une barre de recherche permettant à l'utilisateur de créer ses requêtes. C'est une interface *no-code* qui permet d'envoyer les requêtes depuis l'application vers l'API ElasticSearch.

Cependant, ces SRI rencontrent des limites dans l'exploitation des données patrimoniales. Les données se sont complexifiées dans leur structure avec l'arrivée de nouvelles normes et leurs multiplication à complexifier les bases de données. Ces éléments n'ont fait que de mettre en évidence des limites déjà présentes, mais qui n'étaient pas forcément bloquantes.

Le première limite est l'absence de la notion de contexte. La recherche s'effectue sur un critère de pertinence attribué par correspondance de mots-clés. Ils décontextualisent les mots : il n'y a pas de prises en compte du sens du mot, pouvant varier, en fonction de la phrase dans laquelle il s'inscrit. Mais ils décontextualisent aussi les documents par l'absence de la notion d'ensemble de documents. Ainsi, une recherche renvoie vers archive d'un fonds mais pas vers les autres composants du fonds.

Ajoutons que ce système est fragile face aux variations d'indexation. Malgré les efforts de normalisation menées, cette opération est par nature variable. Deux personnes vont décrire un même objet en utilisant des mots différents ce qui changent les mots-clés et donc les critères de recherches.⁹¹ La pertinence est déterminée par la fréquence d'un mot dans un document ou son indexation et non sur le sens. Un document présentant une fréquence de termes "pertinents" moins haute qu'un autre ne signifie pas qu'il est moins intéressant au regard de la requête utilisateur. Cette limite peut être élargie aux contenus même des documents historiques, de plus en plus renseignés dans les bases de données. Le vocabulaire employé provoque une double difficulté : la correspondance sémantique et terminologique avec le langage actuel, et la variation de l'écriture d'un même mot à travers le temps. Les SRI n'associent pas les termes historiques à des équivalents actuels ou à leurs évolutions orthographiques. Certaines recherches peuvent alors manquer d'outil précis.⁹²

Une autre difficulté est celle du cloisonnement terminologique des typologies patrimoniales. L'hétérogénéité des collections est prise en charge par la plupart des applications dans

⁸⁹Méthode de recherche qui explore des documents entiers à la recherche de chaîne de caractères demandées.

⁹⁰Méthodes de trie permettant de sélectionner des catégories dans lesquelles sélectionner les données que l'on souhaite voir.

⁹¹Marijn Koolen, Jaap Kamps et Vincent Keijzer, « Information Retrieval in Cultural Heritage », *Interdisciplinary Science Reviews*, 34 (18 juill. 2013), p. 268-284, p.273.

⁹²Babak Ranjgar, Abolghasem Sadeghi, Maryam Shakeri, Fatema Rahimi et Soo-Mi Choi, « Cultural Heritage Information Retrieval : Past, Present, and Future Trends », *IEEE Access*, 12 (1^{er} janv. 2024), p. 42992-43026.

des silos, c'est-à-dire des traitements séparés et cloisonnés. Cependant, les SRI ont du mal à établir une porosité entre les silos, ce qui ne reflète pas la réalité scientifique.⁹³ Dans ce logiciel, la "recherche fédérée" permet de créer des correspondances entre les silos. Il est possible de rechercher à travers toutes les typologies documentaires via des correspondances de champs. Cependant, cette recherche est limitée à quelques champs et typologies car ces correspondances ne sont pas évidentes à traduire dans un SRI

De plus, il y a un décalage croissant entre les pratiques des utilisateurs et les outils proposés par ces systèmes. Ce n'est que très récemment que des études ont été menées sur ce sujet⁹⁴ et elles révèlent 3 problèmes fondamentaux.

En premier lieu, l'amélioration des navigateurs en lignes, tels Google, ont habitués l'utilisateur à fonctionner par échantillonnage. C'est-à-dire que la pertinence des résultats est analysée à partir de quelques pages seulement. Ainsi, quand les SRI génèrent du bruit, il y a un désintérêt utilisateur pour les résultats retournés.⁹⁵

Ensuite, la complexité des interfaces de recherches. Les utilisateurs n'ont pas l'habitude d'utiliser les différents outils proposés par les SRI mais essentiels pour leurs bonnes utilisations. Il est habitué à une interface simple renvoyant des résultats pertinents, ce qui est donc bien plus attractif. Ainsi, les SRI perdent en intérêt..⁹⁶

Enfin ces logiciels ont leur propre manière de structurer et indexer les données. Ce fonctionnement est opaque, ce qui freine les chercheurs à accorder une confiance complète aux résultats retournés.

D'une manière plus générale, un utilisateur en face d'un outil opaque, proposant une interface complexe et des résultats bruités risque d'accorder moins de crédits au logiciel et s'en « désintéresser ».

Il est aussi un constat que de dire qu'il existe des porosités entre nos usages utilisateurs et professionnels. Les moteurs de recherches grand public aujourd'hui permettent l'interrogation en langage naturel, ce qui modifie nos attentes. Cela rejaillit nécessairement sur nos attentes et pratiques professionnelles.

Finalement, dans des collections toujours plus vastes et complexes, les SRI ont de plus en plus de difficultés à satisfaire les exigences utilisateurs et scientifiques. La démocratisation

⁹³M. Koolen, J. Kamps et V. Keijzer, « Information Retrieval in Cultural Heritage »..., p.274.

⁹⁴Claire Warwick, Melissa Terras, P. Huntington et N. Pappa, « If You Build It Will They Come? The LAIRAH Study : Quantifying the Use of Online Resources in the Arts and Humanities through Statistical Analysis of User Log Data », *Literary and Linguistic Computing*, 23 (14 déc. 2007), p. 85-102.

⁹⁵*Ibid.*, p.9.

⁹⁶*Ibid.*, p.23-24.

des outils d'IA dans nos moteurs de recherches changent drastiquement notre rapport à la recherche de données. Nos attentes et pratiques en mutation ont forcément un impact sur notre perception de ces outils, notre utilisations de ces derniers et donc leurs évolutions.

C'est particulièrement visible dans le logiciel SkinSoft reposant sur une base de donnée NoSQL de plusieurs dizaines de collections et aux données très variées. L'utilisation d'une indexation par mots-clés traditionnelle offre des performances limitées : on obtient facilement beaucoup du bruit à moins de savoir comment retrouver ce que l'on cherche. De plus, SkinSoft propose son logiciel afin de gérer toutes les tailles et compositions de collections et on remarque que plus la collection est vaste et hétérogène, plus le SRI offre des performances amoindries. On le voit particulièrement lors de la recherche augmentée.

Ainsi, le logiciel SkinSoft cherche à améliorer son système de recherche par le NLP afin de faciliter l'utilisation de sa recherche tout en offrant de meilleures performances. Pour ces dernières, il s'agit également de la rendre plus performante sur les bases de données particulièrement vaste et hétérogènes.

Pour l'axe de l'amélioration de l'usage applicatif, nous nous retrouvons dans un domaine moins exploré. Deux éléments sont centraux : le premier est l'amélioration de l'usage utilisateur de l'application et de la compréhension qu'il en a. On envisage le NLP à travers un agent conversationnel afin de guider l'utilisateur au sein de l'application. Le second est de proposer un appui à la production ou au contrôle des données patrimoniales. Il pourrait vérifier la saisie des métadonnées, les contradictions potentielles d'ordre sémantique ou avec des normes descriptives. Commençons par le premier point :

L'agent conversationnel, comme ChatGPT, connaît une dynamique de croissance technologique et de diffusion très importantes ces dernières années. L'outil se fait remarquer par sa capacité d'interaction avec un utilisateur par l'usage du NLP. Cette caractéristique représente l'opportunité de faire parler les collections et de faciliter les parcours utilisateurs sur les portails institutionnels. Plusieurs initiatives ont visé à concrétiser cette opportunité, comme celle des musées d'histoire naturelle australiens.⁹⁷

Ces études ont amené à réfléchir sur les interfaces des « logiciels métiers »⁹⁸ des système de gestion des collections, notamment sur l'impact des interfaces sur la gestion des collections.

Ces études abordent notamment la « surcharge cognitive », c'est à dire quand une interface propose trop d'informations et d'interactions variées ce qui perd l'utilisateur.⁹⁹ Dans

⁹⁷Yiyuan Wang, Andrew Johnston, Zoë Sadokierski, Rhiannon Stephens et Shane Ahyong, *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, 2026.

⁹⁸Logiciel conçu pour répondre à des besoins professionnels.

⁹⁹Fred Paas, Alexander Renkl et John Sweller, « Cognitive Load Theory and Instructional Design : Recent Developments », *Educational Psychologist*, 38 (8 juin 2010), p. 1-4, p.1-4.

un système de gestion des collections, la principale source de surcharge cognitive est l'interactivité des éléments. Un objet est relié à énormément d'éléments individuel, parfois de manière complexe, ce qui peut surcharger l'utilisateur et conduire à faire des erreurs. Cela peut également créer une charge mentale pour l'utilisateur, réduisant sa concentration.¹⁰⁰

Le second point est celui de l'interface en elle même. Elle reflète bien souvent la complexité logicielle. Dans notre cas, l'interface représente la diversité des points d'entrées ce qui dénuie l'application de repères visuels évident et exige une expérience de l'application.¹⁰¹ Plus important encore, l'interface est importante pour la gestion de l'information. Quand trop d'options ou d'actions sont proposées, l'information essentielle à extraire ou à intégrer échappe à l'utilisateur. Cela peut pousser un utilisateur à éviter ces endroits surchargés et donc ne pas utiliser certaines fonctionnalités¹⁰².

Le logiciel SkinSoft se heurte à certaines de ses complexités. Prenons les points d'accès : bien que groupés à un même endroit dans l'application, ils sont nombreux. La simplification de l'interface ne peut effacer cette première complexité, car l'accès à chacun de ces points d'entrées est nécessaire. De plus, les interactions entre ces éléments sont nombreuses et demandent différentes fonctionnalités situées à différents endroits. L'objet par exemple, point central de l'application, concentre les liens vers toutes les autres entités. On peut y lier une entrée, un prêt, une exposition, des fiches de récolement et autres éléments complexifiant de fait l'interface et l'expérience ici.

Un autre problème, rarement soulevé, est la duplication de documentation externe. Les fournisseurs logiciels produisent de la documentation destinées à guider l'utilisateur, souvent stockée dans un dépôt externe. Ainsi, quand un utilisateur rencontre une difficulté, il doit sortir de l'application afin de consulter un manuel voire plusieurs. Ainsi, une réponse complexe à trouver entraîne la perte d'intérêt.

Si des chercheurs proposent de décharger les interfaces afin de les rendre intuitives¹⁰³, l'ampleur de la tâche dans les système de gestion des collections est telle qu'on envisage de nouvelles solutions. Le logiciel SkinSoft le démontre bien : l'interface épurée, les efforts de regroupement d'éléments et de leurs répartitions ne suffisent pas à pallier la complexité des systèmes de gestion des collections. L'émergence des agents conversationnels amène la possibilité d'avoir un appui à l'utilisation dans l'application. Ce serait un guide interactif avec

¹⁰⁰ *Ibid.*, p.2.

¹⁰¹ Jakob Nielsen, « Enhancing the Explanatory Power of Usability Heuristics », dans *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, New York, NY, USA, 1994 (CHI '94), p. 152-158, p.153.

¹⁰² *Ibid.*, p.153-154.

¹⁰³ Mitchell Whitelaw, « Generous Interfaces for Digital Cultural Collections », *Digital Humanities Quarterly*, 009-1 (21 mai 2015).

la capacité de s'appuyer sur la documentation externe. Il peut d'ailleurs être le socle d'une technologie plus importante qu'est celle de l'agent IA, qui est capable, lui, d'interagir avec l'application.

Pour le second point, très peu d'articles ont été produit sur le sujet. Beaucoup énoncent l'idée de faire de l'agent conversationnel un assistant de production, mais très peu formulent des propositions d'implémentation. C'est donc une partie bien plus théorique et expérimentale qui est abordée dans ce point.

Des interfaces trop riches favorisent la saisie d'erreurs dans les métadonnées, ce qui finit par constituer une base de données instable. Ajoutons que la redondance des tâches ainsi que la difficulté à renseigner certains objets constituent des explications plus importantes.

Ainsi, sur de large jeux de données toujours en expansion, les moyens de contrôle actuels sont de plus en plus limités.¹⁰⁴ Plus la quantité de données à traiter est importante, plus la fiabilité humaine laisse place à des oublis, des erreurs de saisies et des incohérences de données. Si les erreurs sont très nombreuses et variées, les résultats lors du requêtage perdent en qualité¹⁰⁵.

De plus, certaines collections spécifiques demandent des traitements particuliers. Prenons l'exemple des collections d'histoire naturelle, les spécimens en constituent le cœur et sont très nombreux. Ils se rattachent à des classifications taxonomiques, souvent hypothétiques et donc régulièrement remaniées ou invalidées. Les changements concernent assez rapidement un grand nombre de spécimens et donc de notice dans un système de gestion des collections. Il est donc souvent impossible d'assurer la mise à jour totale des espèces dans les grandes bases de données.¹⁰⁶ Ainsi, un agent conversationnel capable de signaler à l'utilisateur la nécessité de mettre à jour certaines notices est pertinent.

Le logiciel SkinSoft est un bon exemple des difficultés actuelles rencontrées par les systèmes de gestion des collections et les limites des solutions déjà existantes. En effet, la simplification de l'interface et de l'expérience utilisateurs par l'application des principes d'*User Interface Design* et d'*User Experience Design* est limitée. La complexité native de ces systèmes ne peut être résolue entièrement de cette manière. La massification des données et l'hétérogénéité typologiques des collections constituent des défis demandant de nouveaux

¹⁰⁴Michael Lewis, Eljas Oksanen, Frida Ehrnsten, Heikki Rantala, Jouni Tuominen et Eero Hyvönen, « The Impact of Human Decision-Making on the Research Value of Archaeological Data », *ACM Journal on Computing and Cultural Heritage*, 18–3 (9 sept. 2025), 47 :1-47 :22, p.2.

¹⁰⁵*Ibid.*, p.4.

¹⁰⁶Brandon P Hedrick, J Mason Heberling, Emily K Meineke, Kathryn G Turner, Christopher J Grassa, Daniel S Park, Jonathan Kennedy, Julia A Clarke, Joseph A Cook, David C Blackburn, *et al.*, « Digitization and the Future of Natural History Collections », *BioScience*, 70–3 (1^{er} mars 2020), p. 243-251.

moyens de réponses. Ce manque de solutions est dû à un changement de problématique : la question n'est plus de faciliter, mais de créer de nouveaux outils pour combler l'écart entre la capacité de traitement humaine insuffisante face aux besoins du traitement des données massives et hétérogènes.

Ainsi, on comprends que l'intégration d'un agent conversationnel dans l'application a deux enjeux. Le premier enjeu est de simplifier la circulation et l'utilisation de l'application dans sa globalité. Cela est envisagé par la possibilité de converser avec un assistant spécialisé capable de guider en s'appuyant sur de la documentation métier contrôlée. Le second enjeu, est donc de disposer d'un assistant capable de tracer l'activité faite, celle à faire et ainsi que la qualité de ce qui est déjà présent. De cette manière, il va pouvoir apporter une solution au problème principal que tout changement d'interface ne peut régler : la faillibilité humaine.

Le NLP semble aujourd'hui apporter des éléments de réponses afin de combler cet écart. La capacité de cette technologie à interagir avec l'utilisateur et à comprendre les données à une échelle massive ouvre de nouvelles possibilités d'usages et d'interfaces qui permettraient de résoudre les problématiques relatives aux système de gestion des collections. Cependant, cette technologie recouvre un ensemble vaste d'outils et de réalités techniques¹⁰⁷, ce qui demande de les séparer en deux outils différents : la recherche augmentée, répondant aux problématiques soulevées dans le premier point, et un « chatbot », répondant aux problématiques soulevées dans le second point.

¹⁰⁷Voir page 15

II. Recherche augmentée et chatbot/agent IA : état de l’art.

Les deux axes d’améliorations que nous venons de distinguer sont pensés en deux outils distincts. La « recherche augmentée » : une recherche assistée par IA pour interroger le SRI en langage naturel. Et un « chatbot » pour disposer d’un guide et d’un appui au contrôle des données. Ces outils puisent dans la même source technologique mais sont des processus divergents à portées différentes. Ainsi, ils font l’objet d’interfaces différenciées.

Il existe aujourd’hui quelques projets et travaux académiques sur ces deux sujets. Ils ne sont pas nombreux et recouvrent des réalités techniques et professionnelles différentes aux nôtres. Il convient donc de présenter des états de l’art de chaque outil, à l’aide de ses connaissances, afin d’analyser les réalités techniques se cachant derrière ces fonctionnalités. Cela amène à des discussions sémantiques afin de lever des confusions terminologiques et techniques importantes, notamment autour du chatbot. Nous en profiterons pour discerner les apports, limites et enjeux des technologies et processus cités.

1. La « recherche augmentée » :

a. La recherche intelligente

L’origine de ce processus est la recherche intelligente, mis en place par les grands moteurs de recherche afin d’offrir des résultats pertinents sous forme de résumé.¹⁰⁸ Il vise à augmenter l’accessibilité utilisateur grâce au langage naturel et à offrir des résultats plus pertinents par l’interprétation de la phrase.¹⁰⁹ Fondement du reste de notre travail, il convient de l’explorer. Trois outils d’IA le compose : le LLM, le RAG et les modèles de NLP.

Le LLM constitue l’intermédiaire entre les données et l’utilisateur. Basé sur du *Deep Learning*, il mobilise les technologies du NLP et les combine à une faculté de raisonnement. De cette manière, il est capable d’analyser et d’extraire la sémantique d’une phrase mais aussi de formuler ses propres phrases. Dans ce processus, il intervient au moment de la réponse afin de converser avec l’utilisateur. Pour cela il extrait des *tokens*, c’est à dire des mots, de nos phrases qui sont analysés par différents processus de NLP. Ils sont ensuite transformés en vecteur, une suite de chiffre unique, qui lui permettent de faire des liens sémantique et de « comprendre ».

¹⁰⁸ Alexandre Flament, *Google SGE (AI Overviews) : définition, fonctionnement et impact SEO en France*, deux.io, 2 juill. 2025.

¹⁰⁹ *Ibid.*

Le RAG est le procédé au cœur du processus car il permet de fiabiliser et contextualiser les résultats, réduisant les hallucinations des LLMs. En effet, ce dernier peut parfois répondre à l'aide de ses propres « connaissances » ce qui créer des éléments de réponses faussés. En connectant un LLM à une ou plusieurs bases de données, on crée une source de connaissances vérifiée et validée par un opérateur humain sur laquelle il est contraint de s'appuyer. Pour répondre, le LLM doit les analyser et les reformuler.¹¹⁰

Les modèles de NLP sont spécialisés sur des tâches précises telles que le POS et le NER. Ils sont appliqués successivement afin de mieux saisir le besoin profond exprimé dans une requête. Mais aussi de mieux comprendre les données stockées. Cela augmente la qualité de la vectorisation et donc la pertinence des réponses.

La combinaison de ces trois éléments permet de créer la recherche intelligente. On peut distinguer deux temps dans son fonctionnement. Le premier temps est une phase d'analyse, invisible par l'utilisateur. En voici un schéma :




FIG. 2 : Phase d'analyse de la recherche intelligente.

¹¹⁰Pour plus d'informations sur le RAG voir 19

Ce que l'on voit ici est principalement le mécanisme du RAG. Une fois connectés à une source de données, il l'analyse grâce aux modèles de NLP. Ainsi, on donne du sens sémantique à ces données dès lors considérées comme « enrichies ». Elles sont ensuite réunies dans un index : comme un SRI¹¹¹ le RAG dispose de sa propre architecture de données. C'est sur cet index que la vectorisation s'applique, créant des vecteur qui sont légers, plus faciles à interroger et plus fiables que l'index des données. Cela crée un double avantage par rapport à une recherche par mots-clés traditionnels. D'abord, une compréhension sémantique des données et ensuite une rapidité dans leur interrogation. En théorie, nos résultats gagnent en précision et rapidité.

L'envoi d'une requête utilisateur formulée en langage naturel déclenche une nouvelle phase de traitement qui suit les étapes suivantes :




FIG. 3 : Phase dite « active » de la recherche intelligente.

La phase « active » de ce processus débute à l'envoi par l'utilisateur d'une requête en langage naturel. Ensuite on applique le même principe que précédemment : on comprend d'abord sémantiquement la requête à l'aide de modèles de NLP avant d'opérer une vectorisation des données composant la requête.

¹¹¹Voir *Chapitre I. « La recherche et l'utilisation de la solution dans le logiciel SkinSoft »* page 33

Ce sont les vecteurs qui sont ensuite comparés : des vecteurs proches signifient des correspondances sémantiques. Alors on vient chercher le sens profond de la donnée : l'idée qu'elle exprime. De cette manière on crée la capacité à saisir les idées représentées par les mots à une volonté. On ne s'arrête plus à la simple correspondance typographique.

Voici un schéma représentant le fonctionnement final d'un processus de recherche intelligente :




FIG. 4 : Fonctionnement global de la recherche intelligente.

Ce que nous avons décrit ici est un processus générique généralement modifié. Le *Chunking* par exemple, permettant de fractionner des documents en plusieurs morceaux. Cela permet d'accélérer le traitement par la parallélisation de tâches¹¹² et de limiter la perte de précision par des analyses restreintes. Ce n'est qu'après qu'on peut extraire des *tokens*.¹¹³

Ou encore le *Re-Ranking*. À l'issue du processus générique, les résultats les plus pertinents sont sélectionnés et classés selon un ordre d'importance. Le LLM l'utilise afin d'organiser sa réponse. Cet outil consiste à évaluer la pertinence des résultats et les reclasser. Il effectue sa propre recherche dans les données stockées et les compare à la requête utilisateur,

¹¹²Désigne en informatique la capacité à traiter simultanément plusieurs tâches et données parfois dans des processus différents.

¹¹³Qu'est-Ce Que Le Chunking Agentique ? / IBM.

en fonction des divergences il refait un classement si besoin.¹¹⁴

Les limites restent importantes et mettent en doute la qualité scientifique des résultats. L'utilisation d'IA générative entraîne le risque d'hallucination et le RAG limite mais n'annule pas ce risque. Notamment sur des requêtes basées sur des expressions imagées ou des termes spécifiques à des « jargons » professionnels. Si le sens n'est pas saisi, il sera halluciné afin de créer une réponse tout de même.¹¹⁵

De plus, ce processus ne peut procéder à des calculs d'agrégation de données. Ainsi, on en peut avoir recours à des calculs comme des moyennes, ce qui est essentiel dans certains domaines de recherches.¹¹⁶

Ajoutons que la segmentation des documents par *Chunking*, souvent utilisé, apporte des limites aux recherches complexes. Morceler les documents revient à multiplier les points d'informations et donc les calculs. Lorsqu'une requête amène à analyser un grand nombre de segments, le RAG peut entrer dans un état de confusion et générer du bruit.¹¹⁷

De plus, la recherche intelligente n'est pas transparente quant aux modalités de recherche. Le RAG et le LLM ne sont pas transparents dans leurs opérations et processus de réflexion. Ainsi, des doutes peuvent exister : a-t-il confondu des termes ? A-t-il halluciné ? A-t-il mal compris ? Toutes ces questions restent sans réponse et créent le même problème rencontré avec les SRI¹¹⁸.

Il y a aussi un enjeu de sécurité et de confidentialité des données. Il peut arriver que l'on souhaite ne distribuer que certaines informations à certaines personnes, ce qui est faisable grâce aux droits d'accès. Ces derniers sont difficiles à gérer sur des vecteur. Des systèmes le permettent, mais ils connaissent encore un certain nombre de faille trop importante posant le problème de la sécurité de l'information et de sa confidentialité. Deux principes clés dans nos institutions patrimoniales.

b. Les processus *Text-to-SQL* et *Text-to-NoSQL*

L'objectif global est d'adapter le processus précédent aux technologies SQL et NoSQL dans des processus hybrides appelés : *Text-to-SQL* ou *Text-to-NoSQL*. Ils présentent certains avantages :

Il n'y a pas d'hallucination : si la requête n'est pas comprise il n'y a simplement pas de réponse. Ils permettent des calculs mathématiques sur des données stockées en tant que

¹¹⁴Ultralytics, *Qu'est-ce qu'un reranker ? Optimiser la recherche et l'IA*, Ultralytics, 29 janv. 2026.

¹¹⁵Mirco Cazzaro et Gianmaria Silvello, « Querying LLMs as If They Were Digital Libraries » ().

¹¹⁶*Ibid.*

¹¹⁷*Ibid.*

¹¹⁸Voir page 34

chiffres. Et les requêtes complexes, multipliant les sources, ne sont pas sujettes à confusion grâce aux jointures pour le SQL et aux pipeline d'agrégation pour le NoSQL. Les requêtes sont compréhensibles par l'humain et re-jouable ce qui apporte une transparence au processus. Et pour finir, ils intègrent nativement des outils de contrôle des droits d'accès assurant la confidentialité des données. Le NLP devient un outil de traduction vers le SQL ou NoSQL évitant la vectorisation et l'interprétation de l'IA.

Cependant, il y a un manque considérable d'informations sur les projets menés à ce sujet dans notre domaine hors mis quelques approches spécifiques.¹¹⁹ Ainsi, nous allons expliquer de manière générale comment fonctionne un *pipeline Text-to-SQL* et *Text-to-NoSQL*. Commençons par mettre en exergue les trois difficultés majeures de cette adaptation :

D'abord, la compréhension des schémas SQL et du contexte métier. Les bases SQL ont une structure rigide créée sur les besoins de descriptions des institutions. Ces structures embarque des biais de recherches et d'exploitation définis selon une stratégie institutionnelle et les « besoins métiers »¹²⁰. On attend de l'IA qu'elle puisse comprendre un univers métier et institutionnel. On déplace ainsi le curseur de la compréhension des données stockées à celle de l'univers professionnel.¹²¹

Ensuite, la compréhension du besoin utilisateur. Si la recherche intelligente permet de rectifier les processus de réflexions de l'IA, le *Text-to-SQL* est moins souple sur le sujet. Pour changer cette réflexion cela demande de connaître la structuration de la base de données afin de guider le modèle. Cette compétence technique est cependant rare dans les institutions conservatrices ce qui amène le besoin de limiter les incompréhensions des requêtes et les interactions entre l'utilisateur et la base SQL.¹²²

Enfin, la notion de « [...] dialecte SQL [...] »¹²³. Tout les systèmes de gestion des bases de données n'emploient pas exactement le même langage, et les LLMs ont souvent du mal à s'adapter aux différences. Sur certains systèmes, la génération de requêtes complexes s'en trouve complexifiée et réactive le risque d'hallucination.¹²⁴

Deux approches permettent de combler cet écart : les *frameworks* spécialisés comme

¹¹⁹Nous ne développons pas ces approches plus poussées, mais les mentionnons par souci d'exhaustivité. Pour plus d'informations sur ces approches divergentes, consulter Alexander Sergeev, Valeriya Goloviznina, Mikhail Melnichenko et Evgeny Kotelnikov, « Talking to Data : Designing Smart Assistants for Humanities Databases » (); M. Cazzaro et G. Silvello, « Querying LLMs as If They Were Digital Libraries »...

¹²⁰On parle de « besoin métier » pour exprimer les besoins inhérent à un domaine professionnel et propre à ce domaine. Il correspond souvent à la réalité des pratiques employées par les professionnels.

¹²¹*Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL* / Blog Google Cloud, Blog Google Cloud.

¹²²*Ibid.*

¹²³*Ibid.*

¹²⁴*Ibid.*

VANNA AI et les agents SQL comme LangChain¹²⁵. La première approche consiste à créer un processus de RAG avec le schéma SQL, des exemples de requêtes et de la documentation professionnelle. Ainsi, n'importe quel LLM peut comprendre son environnement. Il atteint vite ses limites car chaque changement d'architecture de la base amène un changement de documentation et donc de résultats. La seconde approche est basée sur des LLM spécialisés dans la compréhension et la génération de requête SQL y compris sur des bases complexes. Cet outil est plus complexe à mettre en place et à maintenir. Qu'il soit basé sur un agent SQL ou un *framework*, un processus *Text-to-SQL* ressemble à ceci :




FIG. 5 : Schéma d'un pipeline *Text-to-SQL*. Source : *Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL* / Blog Google Cloud, Blog Google Cloud

Nous en distinguons deux temps : le premier est consacré à la compréhension des besoins utilisateurs exprimés dans la requête initiale. Pour cela, on accorde la capacité au LLM de relancer l'utilisateur à l'aide de question afin de clarifier le besoin. Il est essentiel pour cela que l'outil comprenne l'environnement métier dans lequel il s'inscrit.

Le second temps est consacré à la génération de la requête SQL grâce au LLM. D'abord il reformule la requête afin de la rendre plus compréhensible, augmentant la précision de la requête SQL générée. Cela donne naissance à un nouveau prompt généré par LLM dans le seul but de générer du SQL. Ce prompt entre dans une boucle de traitement : il est examiné, puis soit refusé et reformulé soit validé ce qui entraîne la génération d'une requête SQL et son envoi à un « parseur SQL », un logiciel de vérification syntaxique des requêtes SQL. Cette requête est ensuite directement adressée à la base SQL en question. Dans le cas où l'institution possède plusieurs bases de données, le *Text-to-SQL* peut s'y adapter. Soit par l'intégration d'un moteur de recherche fédéré, déclinant la requête selon l'architecture propre à chaque base, soit en laissant l'IA déterminer quelle base de données est la plus pertinente

¹²⁵ *Text-to-SQL : interroger vos bases en langage naturel*, Flowt, 27 févr. 2026.

afin de répondre à la requête.

Le *Text-to-SQL* se fait remarquer par sa capacité à s'adapter à toutes les bases de données existantes. De plus, ce processus assure des résultats fiables dès sa mise en place car il ne repose pas sur des « connaissances » du LLM, mais bien sur des métadonnées saisies par l'institution conservatrice assurant une plus grande véracité.

Il y a cependant quelques limites : d'abord, la dépendance à la *data definition language*, définissant le schéma de la base de données, et à la documentation métier. Si le schéma de la base, les pratiques et ou besoins métiers évoluent, une absence de mise à jour des documents amène l'échec du processus. Ensuite, son manque de scalabilité. Plus la base se complexifie, plus les requêtes se complexifient. En fonction du LLM et des technologies choisies, la génération de requêtes complexes, comme des requêtes imbriquées, représente une difficulté plus ou moins importante. Cela peut alors conduire à des hallucinations de requête pouvant renvoyer les mauvaises données ou être invalide. Ce second cas finit par créer une boucle dans le processus : le *parseur SQL* refuse de valider la requête et le LLM continue cependant d'halluciner.

Un processus *Text-to-NoSQL* n'est pas très différent. Il repose sur l'exact même architecture ¹²⁶ et ne diverge que dans les implications techniques et les limites.

Il y a trois variations techniques importantes. La première concerne la documentation à fournir. Une base NoSQL ne connaît pas de schéma fixe : chaque objet contenu, notamment dans les bases orientées documents, est défini selon son propre schéma. Sans structure globale fixée par une *data definition language*, le processus passe par une étape d'échantillonnage. Le LLM parcourt un nombre déterminé d'objets afin de cerner la variété des schémas. Sans la constance du schéma SQL on perd en fiabilité et en taux de réussite. À partir d'un échantillon, un LLM ne peut pas se parer à toute éventualité augmentant le risque de se retrouver en situation d'échec ou d'hallucination.

La seconde variation intervient dans le rôle du LLM. En NoSQL, on génère un pipeline d'agrégation. Cet outil fait passer chaque objet à travers des étapes de traitement successives, chaque résultat d'un traitement devient l'entrée du suivant. Ainsi on ne récupère pas les bonnes données brutes, mais les bons objets afin d'en extraire les bonnes données via les bons traitements. En somme, la sélection du document pertinent à partir d'une « connaissance » par échantillonnage peut sembler « hasardeuse ».

La dernière variation intervient sur la validation de la requête et son exécution. Dans un processus *Text-to-NoSQL*, il n'y a pas d'analyse syntaxique car le pipeline d'agrégation est plus souple, plus dense et donc plus complexe à examiner. La solution est l'exécution

¹²⁶voir schéma du pipeline *Text-to-SQL* page 45

du pipeline d'agrégation dans un environnement de test. S'il semble fonctionner, alors il est exécuté sur les données. Cependant, ils sont complexes à générer car très verbeux et comprenant des syntaxes complexes auxquelles les LLM sont encore peu habitués.

Ajoutons que les bases NoSQL sont de typologies variées : orientées documents, graphes ou bien colonne. Chaque typologie a sa propre manière de stocker les données et de les interroger. Ainsi, un processus *Text-to-NoSQL* créé pour une base de données NoSQL ne pourra pas s'appliquer à une base d'une autre typologie. Il y a donc une problématique d'interopérabilité des données du processus le limitant à l'interrogation d'une seule base spécifique.

Avant de conclure cette exploration des différents processus aujourd'hui existant pour améliorer la recherche sur des données, voici un tableau récapitulatif.

Processus	Principe de fonctionnement	Apport	Limites
Recherche intelligente	Indexation par vecteurs du langage naturel d'une base de données	Recherche sémantique et contextualisée via des vecteurs	Hallucinations, opacité, absence de calculs et risques de sécurité
Text-to-SQL	Traduction d'une requête en langage naturel en code SQL	Fiabilité des résultats, prises en compte des données structurées et gestion des droits	Dépendance à la <i>data definition language</i> , requêtes vites complexes et scalabilité difficile
Text-to-NoSQL	Traduction de requête en langage naturel en pipeline d'agrégation	Souplesse face aux structures des données, haute scalabilité	Fonctionne sur échantillonnage, absence de schéma fixe et manque d'interopérabilité

TAB. 3.1 : Comparaison des architectures des systèmes de recherche.

Cette exploration de la recherche intelligente, du *Text-to-SQL* et *Text-to-NoSQL* nous a amené à voir comment répondre aux enjeux actuels d'interrogation des données patrimoniales. Les processus *Text-to-SQL* et *Text-to-NoSQL* permettent de faciliter l'interrogation des bases de données et d'optimiser les réponses obtenues. Résolvant ainsi les problèmes posés par les SRI traditionnels ainsi que les enjeux d'accessibilité aux données.

Cependant, placer ces processus au sein de systèmes de gestion des collections pose des difficultés. Ces technologies sont dépendantes d'un socle de connaissance métier propre à l'institution. Le logiciel SkinSoft s'adressant à une pluralité d'institutions et de collections y rencontre une limite. Chaque institution a ses propres besoins, pratiques et enjeux métier auxquels la « recherche augmentée » doit pouvoir y répondre.

De plus, les processus décrits ne prennent pas en compte l'usage d'un SRI car ils visent à le remplacer. Cependant, la plupart de ces logiciels reposent sur cet outil. Ainsi, commence à être développée une approche hybride associant les SRI aux approches méthodiques des processus *Text-to-SQL* et *Text-to-NoSQL* que nous explorerons par la suite.¹²⁷

Finalement, les expériences sont nombreuses mais les résultats concluants le sont moins. Ce principe de recherche intelligente appliquée au patrimoine ne cesse d'évoluer et de se diversifier, sans jamais vraiment réussir à satisfaire toutes les exigences. C'est donc un état de l'art très contrasté et l'expérience menée par SkinSoft est fondatrice pour les systèmes de gestion des collections

2. Le « chatbot »

La majorité des recherches sur le NLP dans le monde patrimonial ont porté sur les processus *Text-to-SQL* et *Text-to-NoSQL*. Cependant, rendre la recherche de données plus facile et naturelle ne pas résout toutes les problématiques professionnelles.

En effet, une autre source de tensions provient des interfaces complexes et des nombreux parcours utilisateurs proposés. Notons que la production d'un professionnel dépend surtout de sa capacité à utiliser le logiciel et donc de sa clarté d'usage. Ainsi, la « recherche augmentée » n'aborde pas cette problématique de front et n'y apporte pas de solutions.¹²⁸ Il faut chercher la solution dans un autre outil d'IA : le « chatbot ». Notons qu'aujourd'hui, le terme chatbot porte un sens confus que nous devons clarifier.

Malgré les première expérience concluantes en 1966 avec le programme ELIZA¹²⁹, l'ap-

¹²⁷Voir Chapitre a. « Conception de l'outil » page 96

¹²⁸Voir Chapitre I. « La recherche et l'utilisation de la solution dans le logiciel SkinSoft » page 35

¹²⁹Eleni Adamopoulou et Lefteris Moussiades, « Chatbots : History, Technology, and Applications », *Machine Learning with Applications*, 2 (15 déc. 2020), p. 100006.

est assez peu discutée. Cela peut s'expliquer par les risques d'hallucination dus à l'utilisation d'un LLM. Notre attention doit se tourner alors vers les projets professionnels.

Lorsque l'on regarde d'autres systèmes de gestion des collections comme Axiell¹³¹, ou Terentia¹³² on remarque les éléments suivants. D'abord, les termes de chatbot, de agent conversationnel ou de agent IA ne sont pas employés. Il est fait mention « d'outils d'IA », sans plus de précision. Les outils cités semblent peu orientés vers l'accessibilité applicative et les questions d'usages. Que ce soit chez Axiell ou Terentia, les « outils d'IA » ont pour buts principaux de produire de la métadonnée et de faciliter des liens avec des thésaurus externes. En somme ce sont de nouveaux outils pensés pour compléter les fonctionnalités déjà présentes.

En combinant le RAG sur de la documentation métiers et les capacités d'un chatbot, nous pouvons obtenir un véritable assistant à l'utilisation de l'application. Ce système a déjà été appliqué à l'exploration de corpus documentaires afin d'accompagner les chercheurs dans leurs explorations.¹³³ Cela permet des approches approfondies de corpus importants plus rapidement grâce aux capacités de conversation et de réflexion des chatbots limités par un RAG aux seuls corpus.

La problématique réside dans le choix de la documentation. Le RAG demande de la documentation limitée et uniforme ce qui n'est pas le cas dans notre univers métiers. Les normes, standards, modèles conceptuels et politiques institutionnelles prennent des formes très différentes. Il se peut d'ailleurs que fournir une telle diversité de documentations technique au RAG l'incite à commettre des erreurs. Il peut appliquer des concepts d'autres typologies patrimoniale et une typologie tierce.

Il est difficile de faire un état de l'art de cette emploi, encore peu répandue, de cette technologie. Cependant, notre rapide examen permet de conclure que cette perspective est encore expérimentale et semble rencontrer bien des soucis de définitions.

Cependant, les capacités conversationnelles du chatbot et d'intégration dans des processus plus larges permettent d'envisager cette technologie pour faciliter l'utilisation des systèmes de gestion des collections.

¹³¹Pour consulter leurs innovations, voir : <https://www.axiell.com/fr/solutions/product/ai-for-museums-and-archives/>

¹³²Pour consulter leurs innovations, voir : <https://terentia.io/collections-management>

¹³³Bénédicte Tuza, *Interroger la mémoire d'entreprise par l'IA : le RAG face aux archives orales. Enjeux et limites pour l'histoire appliquée*, other, Perles d'Histoire, 40 rue de Paris, 92100 Boulogne-Billancourt, 2025, p. xxxii.

III. Enjeux utilisateurs : comment implémenter ces fonctionnalités en respectant l’utilisateur dans son usage de l’application et son rapport avec l’intelligence artificielle ?

Il s’agit ici d’une partie réflexive dont l’ambition est de présenter un état des lieux et des pistes de réflexion quant à des logiques d’implémentations et d’usage de ces outils.

Lors de notre exploration du chatbot, nous avons discuté de la place centrale des utilisateurs dans un logiciel métier. Les domaines de l’*User Experience Design* et de l’*User Interface Design* vont dans ce sens en proposant des principes et méthodes afin de créer une utilisation optimale, fluide et intuitive d’un logiciel. On y distingue l’expérience, gérée par l’*User Experience Design*, et l’interface, gérée par l’*User Interface Design*, permettant de garantir ces aspects et donc l’adoption du logiciel au près du public cible.

L’*User Experience Design* se concentre sur l’expérience utilisateur, c’est à dire l’ensemble des ressentis, sensations et « émotions » qu’une utilisation de l’application doit produire. L’objet est de garantir une expérience globale positive et qualitative au sein d’ l’application.¹³⁴ Un certain nombre de principes et de règles¹³⁵ constituant ce domaine sont déterminées dans cet objectif.¹³⁶

L’interface est l’intermédiaire « diffusant » l’expérience. Pour l’utilisateur l’interface fait partie intégrante de l’expérience globale, mais du côté des développeurs l’interface se différencie de l’expérience car ce n’est qu’un outil de diffusion et d’interactivité. L’*User Interface Design* prend en charge cette partie afin de garantir des interfaces simples et intuitives. Dès 1990, le psychologue Don Norman démontre la responsabilité des *design* dans les erreurs humaines dans un contexte industriel : « *Most industrial accidents are caused by human error : estimates range between 75 and 95 percent. How is it that so many people are so incompetent ? Answer : They aren’t. It’s a design problem.* »¹³⁷ C’est le fondement de ce domaine : une interface mal conçue entraîne nécessairement une erreur. L’*User Interface Design* a pour objectif de traduire l’*User Experience Design* par des repères visuels et des parcours graphiques permettant d’activer des fonctionnalités.

¹³⁴WEBQAM Groupe, *L’UX Design : Définition, enjeux et mise en pratique* - Webqam, Site Webqam Groupe, 21 févr. 2022.

¹³⁵Notamment *ISO 9241-112 :2025*, ISO

¹³⁶Carine Lallemand, *Méthodes de Design UX. 30 Méthodes Fondamentales Pour Concevoir Des Expériences Optimales. (2e Edition)*, 2018.

¹³⁷Don Norman, « The Design of Everyday Things » (, 2013), p. 325.

Ces domaines ne sont pas rigides ne disposant d'aucune contrainte ou obligation. Ils ne font que proposer des méthodologies et outils obéissant à des principes clés dans l'objectif défini. Chaque développement logiciel peut adapter ces éléments, ou bien créer ses propres principes, règles et méthodologies.

Prenons l'exemple de la norme ISO 9241-112 abordant la question de l'expérience et interface des systèmes informatiques. Elle « [...] énonce des principes de conception ergonomique pour des systèmes interactifs dont la présentation d'information de l'interface utilisateur est contrôlée par logiciel »¹³⁸. Son objectif est de proposer une conception de la structure logicielle optimisée pour la compréhension des informations par l'utilisateur. La marge de liberté et de réappropriation, ou non, des concepts est vaste.

1. *User Experience Design* et *User Interface Design* dans les systèmes de gestion des collections

Dans le cas des système de gestion des collections, ces deux éléments sont particulièrement complexe. Les interfaces sont multiples car elles correspondent à des expériences nombreuses adaptées à des modalités de gestion spécifiques. Cela entraîne des complexités structurelles dans l'organisation de l'application et des données contenues et diffusées.

Dans ce contexte, l'*User Experience Design* et l'*User Interface Design* sont fondamentales pour simplifier l'application destinée à manipuler de très grands volumes de données. Cependant, les besoins patrimoniaux au cœur de la raison d'être de ces logiciel est l'exhaustivité des données, ou plutôt la possibilité d'interagir avec elles dans toutes leurs complexités. C'est cette logique qui amène à dupliquer les expériences utilisateurs et à charger les interfaces avec deux informations en fonctionnalités et données.

Des discussions académiques et professionnelles amènent à repenser ces notions appliquées aux systèmes de gestion des collections autour de deux idées principales. L'application du concept de simplicité sans tendre vers l'épuration, limitant l'exhaustivité naturelle de ces collections, et la recherche de nouvelles solutions d'interactions et graphiques. Cela en fonction de la typologie de collections traitées, les besoins étant divergents.

Aujourd'hui, des tentatives de compromis entre simplicité, exhaustivité et particularité de chaque collections tendant à apparaître dans une logique de communication vers un large public.¹³⁹ On peut tout à fait s'attendre à voir des porosités apparaître entre les systèmes de gestion des collections et les logiciels publiques pour de la cohérence de traitement.

Deux élément dominant les conception d'*User Experience Design* et d'*User Interface*

¹³⁸ ISO 9241-112...

¹³⁹ M. Whitelaw, « Generous Interfaces for Digital Cultural Collections »...

Design appliquées à des système de gestion des collections. D’abord, la théorie de la surcharge cognitive¹⁴⁰ que nous avons déjà abordé.¹⁴¹ Transposé à un environnement logiciel, un surplus d’outils et de données risque d’entraîner une saturation conduisant a un rejet du système. La prévention de ce phénomène est au cœur du *Technology Acceptance Model*¹⁴², rappelant que l’utilité perçue et la facilité d’utilisation d’un outil conditionnent son adoption.

2. Les outils d’IA

L’inclusion de l’IA dans les logiciels bouscule la réalité de l’*User Experience Design* et de l’*User Interface Design* car elle implique ses propres problématiques.

Ces outils sont souvent développés par des entreprises externes, sans lien avec le système souhaitant l’inclure. Ils ont donc leurs propres interfaces et expériences. L’inclusion dans un système hôte peut causer un important décalage entre ces éléments poussant à adapter son *User Experience Design* et *User Interface Design* afin de combler ce dernier. De plus, ils entendent parfois « révolutionner » certaines pratiques communes. Ceci pose la question des habitudes utilisateurs car trop changer en profondeur une fonctionnalité habituelle peut déstabiliser un utilisateur. C’est par exemple le cas avec le chatbot qui change la conception même de l’interaction avec son logiciel

Il se pose également la question de la transparence. Leurs actions sur des données sensibles est contraintes à une certaine transparence par le cadre juridique. Cela dans le but que l’utilisateur puisse savoir les données utilisées et dans quels buts. Cela demande donc de créer une expérience rassurante et transparente, amenant à modifier les interfaces pour permettre la diffusion de ces nouvelles informations.

Ces quelques points nous permettent de comprendre que l’intégration d’IA dans des logiciels demande plus que la création d’une fonctionnalité technique. Il faut aussi, et surtout, intégrer de nouvelles expériences et interfaces rassurantes dans des cadres préexistants sans perturber l’utilisateur.

3. IA et système de gestion des collections : des attentes *User Experience Design* et *User Interface Design* particulières

Nos utilisateurs sont des professionnels sensibles sur l’utilisation de leurs données, et celles dont ils ont la charge, par les outils d’IA. Ainsi, trois aspects semblent être au cœur de

¹⁴⁰F. Paas, A. Renkl et J. Sweller, « Cognitive Load Theory and Instructional Design... ».

¹⁴¹Voir *Chapitre I. « La recherche et l’utilisation de la solution dans le logiciel SkinSoft »* page 35

¹⁴²Atmane Badda, « Technology Acceptance Model (TAM) : Literature Review », *International Journal of Accounting, Finance, Auditing, Management and Economics*, 6–11 (oct. 2025), p. 459-492.

tensions :

D'abord la confiance envers l'outil. Malgré des efforts de contrôles, l'hallucination reste fréquente et gênante car contraire à un besoin d'exactitude scientifique. L'hallucination peut compromettre cette rigueur et entraîner une méfiance, un désintérêt voire un rejet de l'outil. L'*User Experience Design* doit pouvoir prendre en compte ses éléments en proposant des solutions comme des processus dits *humain in the loop* et de gestion des erreurs. L'idée étant de placer l'utilisateur comme contrôleur de la qualité des données et donc au centre.

Le second élément est celui de l'interaction des outils avec l'environnement préexistant. Il faut s'assurer que ces outils amènent une plus-value, qu'ils permettent une simplification des parcours d'usages sans créer des incohérences de parcours. C'est un point essentiel, notamment pour la *recherche augmentée* et le chatbot qui peuvent amener à diffuser beaucoup de données.

Le dernier élément est celui de la perception. Notre examen de la recherche intelligente démontre que le public auquel on s'adresse aujourd'hui est méfiant envers les intelligences artificielles. Ceci peut expliquer partiellement le manque de travaux sur l'utilisation de chatbot dans la production et la gestion de données patrimoniales. Faire de ces outils de véritables assistants à la productivité plutôt que des contraintes visuelles et techniques constitue un enjeu majeur.

4. Conclusion

L'intégration du NLP en deux outils différents, la recherche augmentée et le chatbot, soulève des problématiques d'*User Experience Design* et d'*User Interface Design* inédites. Il ne s'agit pas d'ajouter des fonctionnalités supplémentaires ou de modifier légèrement une expérience utilisateur et l'interface. Il s'agit de changer drastiquement des éléments préexistants par un changement de rapport et de dialogue entre l'utilisateur et son système professionnel dans un domaine exigeant et attentif aux questions de sécurité et de qualité.

Ces nouveaux outils doivent donc amener la conception de nouvelles expériences et interfaces respectant les exigences professionnelles fortes et réduisant la surcharge visuelle et cognitive. Ou du moins, ne pas l'alourdir.

Il faut penser à l'adoption de ces technologies plus qu'aux simples performances technologiques. Cette adoption passe par la nécessité d'un dialogue transparent entre l'outil et l'utilisateur, placé au cœur du processus. Ce qui déplace les enjeux de l'*User Experience Design* et l'*User Interface Design* des questions visuelles et de confort vers celles de confiance et d'accessibilité.

Chapitre 4

Faciliter l'indexation par sa semi-automatisation : le cas de l'image animée

I. La gestion de l'image animée dans le logiciel SkinSoft

Dans cette partie, l'indexation semi-automatisée est pensée dans son application à un objet patrimonial particulier : l'image animée. Les spécificités de cet objet et sa complexité d'indexation, même humaine, le placent au cœur des volontés d'automatisation de son indexation et en démontrent les limites.

1. Définition de l'indexation et de l'image animée

L'indexation est une opération d'analyse et d'extraction d'informations contenues par les objets patrimoniaux afin de produire des métadonnées descriptives attribuant des caractéristiques uniques à chaque objet. Pour cela, l'indexation s'appuie sur différents outils comme des thésaurus afin d'en faciliter l'exécution et de créer une homogénéité.¹⁴³ Sa « semi-automatisation » est l'idée de pouvoir se reposer partiellement sur des outils IA capable de proposer des métadonnées dans les bons champs, respectant les normes et standards. L'opérateur humain n'ayant plus qu'à valider ou modifier ce dernières.

Pour penser de tels processus appliqués à l'image animée, il convient d'en comprendre la nature et complexité. La Fédération Internationale des Archives du Film la définit comme

¹⁴³Direction des Archives de France, *Note d'information DITN/RES/2007/008*, Notes d'informations DITN/RES/2007/008, Paris, Ministère de la Culture et de la Communication — Direction des Archives de France (DITN), 2007, p.2.

un objet regroupant des images enregistrées successivement dont la diffusion donne une impression de mouvement.¹⁴⁴ Cela peut être un *rush*, c'est-à-dire l'enregistrement brute, ou bien une version retravaillée en « post-production ». Elle peut intégrer des bandes sonores enregistrés au moment de la capture des images ou rajoutées en « post-production ». Ainsi, un film, une vidéo, un extrait, une bande-annonce, une publicité sont des images animées.

Elle se caractérise également par sa diversité matérielle. L'image animée a d'abord été enregistré sur des bandes au nitrate d'argent photosensible. Puis sur des bandes vidéos magnétiques permettant l'enregistrement sonore en simultané. Puis sur des supports optiques gravés, comme les DVD. Et enfin les supports numériques, tels des clés USB ou des *clouds*, les stockant dans des formats digitaux comme le MP4 le MKV. Ils servent à l'enregistrement original et/ou à la diffusion. Pour le format numérique, on distingue les formats numériques de production des formats numériques de diffusion. Les formats varient en fonction du matériel utilisé pour enregistré et celui utilisé par diffusé. Pour des raisons de conservation on rencontre un principe similaire sur l'image animée physique, ce qui fait qu'une même œuvre existe dans différentes matérialités simultanément ou successivement.

Il y a également une notion d'état amené par la « post-production ». Prenons un film récent comme *Avatar* (2009) du réalisateur James Cameron. Le film diffusé au public est uniquement fait d'images de synthèse et d'effets spéciaux numériques. Cependant, tout cela a été produit à partir de *rushs* sur lesquels figurent des acteurs, d'autres décors et matériels. Il existe donc deux états du film : la version « brute », composé de *rushs*, et la version diffusée. Ces transformations extrêmes restent rares, cependant la « post-production » a tendance à prendre une place grandissante.

L'image animée nécessite un matériel de diffusion. En effet, sa projection est un aspect fondamental car c'est ce qui fait apparaître la notion de mouvement. Cela implique la conservation des équipements de diffusion propres à chaque matérialité de l'image animée.¹⁴⁵ Cela demande donc d'entretenir ce matériel précieux, certains équipements n'étant plus fabriqués. Il y a donc une double obsolescence : celle des supports de diffusion et celle de l'objet patrimonial. Ainsi, une image animée produite au début du XX^{ème} siècle sur une bande en nitrate d'argent et doublement en danger. D'abord par sa conversation, son composé chimique étant instable et pouvant prendre feu si mal conservé. Ensuite pour sa diffusion, le projecteur n'étant plus fabriqué et les compétences pour l'entretenir se raréfie.¹⁴⁶

¹⁴⁴Natasha Fairbairn, Maria Assunta Pimpinelli, Thelma Ross et Viviane Thill, « Le Manuel de catalogage des images animées de la FIAF » (), p.5.

¹⁴⁵Ray Edmondson, « PHILOSOPHY AND PRINCIPLES » ().

¹⁴⁶*Ibid.*, p.39 et 54.

Il y a également une grande diversité conceptuelle. Nous ne parlons pas de film, de vidéos ou encore de documentaire car ils représentent des réalités différentes leur réalisation, utilisation, objectif, diffusion et conservation. L'image animée concerne aussi bien un film amateur que professionnel, et toutes la typologie que cela recouvre, mais aussi les séries, publicités, etc.¹⁴⁷. Chaque typologie possède ses caractéristiques uniques et donc sa propre indexation.¹⁴⁸

C'est un objet patrimonial unique, faisant face à ses propres défis non partagés avec les autres objets patrimoniaux. Dès lors, au sein de collections hétérogènes l'indexation de l'image animée se doit d'être particulière afin de prendre en compte toutes les complexités brièvement explorées.

2. Le FRBR et le WEMI

Les prémices de cette gestion particulière apparaissent en 1998. Jusqu'alors, la norme internationale qu'est l'ISBD structurait les données bibliographiques autour du seul objet physique. Cela ne permettait pas de créer du lien au sein des collections internes et externes et l'apparition de déclinaisons, comme l'ISBD(A) pour les livres anciens, a finalement fragilisé l'homogénéité des données. Devant l'évolution des besoins utilisateurs, visant à simplifier les requêtes, l'ISBD s'est révélé peu adapté. Une œuvre ne pouvant être présentée avec ses déclinaisons successives, ni ses liens avec d'autres œuvres, la démarche exploratoire de l'utilisateur s'est retrouvé trop limité et frustrante.

Ainsi, l'IFLA souhaite réorganiser la gestion de cet objet patrimonial en déplaçant le point d'intérêt de l'exemplaire vers un ensemble conceptuel plus vaste et structuré. C'est le cœur du modèle FRBR qu'elle publie afin de repenser tout ce système de description et de gestion des données bibliographiques.¹⁴⁹

Il répartit les données bibliographiques en 3 groupes d'informations.¹⁵⁰ D'abord le groupe des informations sur le contenu intellectuel et artistique de l'œuvre indexée. Elles sont réparties sur 4 entités hiérarchisées, représentant chacune un niveau d'indexation de l'œuvre. Ce sont les niveaux WEMI pour : œuvre, ou œuvre, expression, manifestation et item.

¹⁴⁷N. Fairbairn, M. A. Pimpinelli, T. Ross, *et al.*, « Le Manuel de catalogage des images animées de la FIAF »..., p.5.

¹⁴⁸R. Edmondson, « PHILOSOPHY AND PRINCIPLES »..., p.18 et 34.

¹⁴⁹Universal bibliographic control and international MARC programme et Fédération internationale des associations de bibliothécaires et des bibliothèques (éd.), *Functional Requirements for Bibliographic Records : Final Report*, München, 1998 (UBCIM Publications, 19).

¹⁵⁰*Ibid.*, P.12 à 16.

L'œuvre est le niveau hiérarchique le plus haut, représentant l'idée intellectuelle ou artistique sans matérialité définie. C'est l'élément central auquel les niveaux expression, manifestation et item se rattachent et duquel elles héritent les informations principales comme l'auteur et le synopsis. Par exemple, *les Misérables* de Victor Hugo serait décrite dans un niveau œuvre.¹⁵¹

L'expression est une réalisation donnant une forme à l'œuvre à un moment précis et de laquelle peuvent découler des objets physiques. Par exemple, *Les Misérables* connaît plusieurs expressions : le texte original de 1862, sa traduction anglaise en 1863 par Charles Wilbour et son adaptation en film en 2012 par Tom Hooper. Chacune de ces expressions donnent corps à l'idée artistique de l'œuvre.¹⁵²

La manifestation est une forme concrète découlant d'une expression. Elles ont un contexte de production, de nouveaux acteurs qui ont fabriqué une version de l'expression, des dates propres, des lieux de diffusions, etc. Par exemple, le manuscrit original de Victor Hugo a été édité une première fois en 1862 par l'éditeur Albert Lacroix, puis en 1972 aux éditions Gallimard puis en édition numérique ebook en 2010. Ce sont des matérialités différentes d'une même expression.¹⁵³

L'item représente ce que l'on possède, c'est-à-dire un exemplaire issu de la production d'une manifestation. Il est doté de caractéristiques uniques relatives à sa vie dans les collections des institutions conservatrices.¹⁵⁴

Chaque niveau porte ses propres informations tout en héritant de celles renseignées au niveau précédent. Ce qui crée donc 4 niveaux d'indexations, et de liens normalisés pouvant donc s'effectuer d'une institution à une autre. En voici un schéma :

¹⁵¹ *Ibid.*, p.16 à 18.

¹⁵² *Ibid.*, p.18 à 20.

¹⁵³ *Ibid.*, p.20 à 22.

¹⁵⁴ *Ibid.*, p.22 à 23.




FIG. 6 : Schéma d'un WEMI fictif d'une œuvre.

Le second groupe est celui des personnes physiques et morales en lien avec chacun des niveaux WEMI et parfois plusieurs WEMI.

Liée au niveau œuvre elle en est la créatrice, celle qui a pensé l'idée intellectuelle. Liée au niveau expression elle en est la réalisatrice, celle qui lui donne corps. Au niveau manifestation, elle en est la productrice responsable d'une forme générique qu'elle adopte. Et enfin, liée à l'item elle en est la propriétaire. Notons que la créatrice peut aussi être réalisatrice, productrice et possesseuse au sein d'un même WEMI. Ou alors créatrice dans un WEMI et productrice dans un autre. Simplement, le lien avec un niveau WEMI est toujours de même nature.

Enfin, le troisième groupe est celui des éléments complémentaire au niveau œuvre d'un WEMI. on y retrouve les événements, les objets, les lieux ou les sujets qui servent donc à enrichir le niveau œuvre afin de mieux l'indexer. Ce niveau peut être lié à plusieurs éléments de ce groupe et permet de créer des relations entre les œuvre d'une même collection ou entre plusieurs collections. De cette manière, un utilisateur intéressé par un sujet précis peut obtenir plus de résultat à ses requêtes.

De manière schématique, voilà ce que représente un WEMI complet :




FIG. 7 : Schéma de fonctionnement des liens dans un WEMI. Source : https://mediadix.parisnanterre.fr/medias/fichier/catalogage-isbd-unimarc-apports-theorique-maj-2025_1736242651118-pdf

Dans le cadre de l'image animée, la FIAF adapte ce modèle aux particularités de cette typologies. Notamment en modifiant la notion d'œuvre et rajoutant celle de la variante.

Pour l'image animée, l'œuvre et l'expression sont une seule et même entité.¹⁵⁵ Ainsi, elle intègre également les circonstances de création originale de l'image animée, des notions de temporalité, de localisation et de matérialité définies. Elle a également des relations différentes avec les personnes puisqu'elle est dotée d'une personne créatrice, mais aussi réalisatrice et productrice. Ajoutons à cela la diversité typologique importante de l'image animée qui est incluse dans la notion d'œuvre amenant à une fluctuation dans le niveau d'informations attendu.

L'image animée se caractérise également par son caractère évolutif. Outre les restaurations, elle peut être modifiée de multiples manières avant même son entrée dans une collection. Prenons l'exemple de la censure qui peut altérer la bande son, le montage ou encore l'intégrité visuelle de l'œuvre impactant parfois le concept artistique exprimé. Sans constituer une œuvre à part entière, elle n'est plus l'œuvre originale exprimée dès la création artistique. Ainsi, la FIAF crée une entité WEMI unique : la variante.

¹⁵⁵N. Fairbairn, M. A. Pimpinelli, T. Ross, *et al.*, « Le Manuel de catalogage des images animées de la FIAF »..., p.21.

On l'utilise dès lors qu'une modification impacte la description de l'image animée. Que ce soit des ajouts ou des retraites de séquences, scènes ou plans ou bien des modifications dans sa production, dans les comédiens ou dans sa bande son comme par exemple un doublage.¹⁵⁶

Ces particularités changent l'organisation du WEMI de deux manières. D'abord sur le découpage structurel, puisque le niveau expression disparaît laissant place à celui facultatif de la variante. Ensuite, sur la répartition des informations à indexer, puisque ces remaniements demandent de nouveaux points d'analyses à indexer.

Le modèle WEMI proposé par la FIAF est surtout plus souple et ce décline en 4 modèles. Chacun présente une répartition différentes des informations.¹⁵⁷ Nous n'allons pas tous les présenter ici afin de pouvoir nous attarder sur les choix effectués par SkinSoft.

3. La gestion de l'image animée dans l'application SkinSoft

Dans le logiciel SkinSoft, la gestion des image animée est réservée au module S-Movies. Nous ne reviendrons pas sur cette notion de module, déjà vue précédemment¹⁵⁸.

Ce qui distingue S-Movies des autres modules de la suite logicielle est sa gestion totalement transparente des niveaux WEMI. Chaque entité WEMI possède sa propre table, donc ses propres données et points d'accès ce qui permet de bien cloisonner les niveaux WEMI et de diriger l'utilisateur plus facilement entre ces derniers. La structure WEMI adoptée est la suivante :

¹⁵⁶ *Ibid.*, p.23.

¹⁵⁷ Pour plus d'informations voir *Ibid.*, p.9 à 13

¹⁵⁸ Voir page 11




FIG. 8 : Schéma du modèle WEMI implanté dans la solution S-Movies. Source : FAIRBAIRN (Natasha), PIMPINELLI (Maria Assunta), ROSS (Thelma) et THILL (Viviane), « Le Manuel de catalogage des images animées de la FIAF » ()

La variante est considérée comme une manifestation.¹⁵⁹ Ce choix vise à simplifier le parcours utilisateur en rendant son inclusion similaire à celle d'une manifestation, ne s'en distinguant que par un champ permettant de renseigner le type de variante dont il s'agit.

Les différents niveaux WEMI sont connectés via des champs de lien créant une hiérarchie. Ils sont souples, modifiables à tout moment et multi-relationnels. Ainsi, la gestion des images animées reste fidèle aux principes de gestion proposés par la FIAF¹⁶⁰.

Cette souplesse fait de S-Movies un logiciel permissif permettant à l'utilisateur d'adopter différents parcours afin d'effectuer les mêmes actions. Nous allons donc essayer de retracer un parcours utilisateur typique et privilégié, tout en énonçant les diverses possibilités s'ouvrant à lui.

L'utilisateur commence toujours par la création d'une notice œuvre dans la table dédiée, qui est également la page d'accueil de l'application. En fonction de sa configuration¹⁶¹, l'utilisateur peut rentrer manuellement une certaine quantité de données ce qui demande donc, en amont, une étape d'analyse afin de correctement distinguer où stocker l'information. Cette notice peut être liée à des archives, objets de musées ou des notices bibliographiques provenant des autres modules. Cela permet de créer des relations afin de circonscrire des univers cinématographiques entiers tout en gardant les spécificités de gestion de chaque objet.

Ensuite, il peut créer une manifestation depuis la table dédiée ou une notice œuvre. Si la création se fait depuis la table, elle peut être reliée à n'importe quelle œuvre, et si elle est créée depuis une notice d'œuvre elle y est automatiquement reliée. Peu importe la modalité, cette étape demande une analyse humaine afin de préciser la nature de la manifestation, notamment si c'est une variante. Cela demande donc une analyse effectuée au moment de la création du WEMI et basée sur des connaissances cinématographiques. Notons qu'une manifestation peut être liée à plusieurs œuvres, comme les coffrets qui réunissent des œuvres différentes dans une même manifestation.

Enfin, il peut créer un item. Cette notice peut être créée en même temps qu'une notice d'entrée par exemple ou sous bien d'autre modalité, ce qui s'explique par le fait que c'est à ce niveau qu'on gère le « cycle de vie » pensé par David Bearman.¹⁶² Notons que plusieurs items peuvent être liés à une seule manifestation.

¹⁵⁹*Ibid.*, p.23.

¹⁶⁰Voir *Ibid.*

¹⁶¹Pour plus d'informations voir page 11

¹⁶²D. Bearman, *Archives & Museum Informatics : Publishing : Archives : Functional Requirements for Collections Management Systems : Table of Contents...*

4. Complexité et limite de l'indexation des images animées

Les images animées sont très riches en informations visuelles, parfois textuelle avec les crédits. Il faut donc pouvoir récupérer ces données, ce qui demandent des traitements différents puis les répartir sur les niveaux WEMI appropriés. Dans les productions amatrices, les informations à indexer sont souvent uniquement visuelles ce qui demande d'analyser chaque œuvre afin d'en extraire des mots-clés, des caractéristiques uniques, etc, ainsi que d'en déterminer le niveau WEMI d'appartenance.

Rajoutons également que l'indexation se complexifie avec la question de l'héritage des champs notamment pour la variante. En effet, une donnée portée par l'œuvre, comme les comédiens, peut se retrouver invalide dans la variante en découlant. Cela peut créer une incohérence d'indexation et des difficultés de modifications de la donnée.

Pour illustrer ces limites, prenons le cas d'une institution aux besoins de gestion spécifiques et utilisant S-Movies.¹⁶³

Certaines images animées ont été réunies sur un même support de conservations sans séparation entre les œuvres. Deux problématiques en émergent : d'abord un WEMI complexe, puisque plusieurs œuvres sont réunies en une seule manifestation d'où découle plusieurs items. De plus, le besoin de séparer matériellement dans l'application chaque bande vidéos et sonore de chaque item afin de pouvoir les reconstituer dans des notices.

Son schéma WEMI est réalisable, mais toute l'étape de traitement est problématique. Il repose sur l'analyse de bobines entières, l'identification de chaque entités présentes et de leur association au segment de bobine concerné. Cependant, cela ne peut être fait que par l'humain à l'aide de logiciels de traitement externes spécialisé. De plus, il n'y a aucun crédit permettant des identifications de caractéristiques clés facilement. Après avoir segmenté les bobines en plusieurs images animées, il faut les analyser individuellement pour en extraire des informations clés. Ce qui peut être long, fastidieux et prompt aux erreurs humaines.

Cet exemple met en valeur les problématiques principales de l'indexation de cette typologie documentaire. SkinSoft cherche aujourd'hui à faire évoluer S-Movies pour proposer des modalités de gestions plus adaptées par le déploiement d'un outil d'indexation semi-automatisée notamment afin d'automatiser et homogénéiser les indexations. Ce serait un *pipeline* basé sur l'IA allant de l'intégration dans l'application d'une vidéo à son indexation, en passant par sa segmentation en différentes images animées indexées individuellement.

¹⁶³Pour des raisons de sécurité et de confidentialité, le nom de l'institution est anonymisé.

II. Les différentes réalités de l'indexation semi-automatisée : focus sur l'image animées, un objet documentaire particulier.

Ce processus est né de plusieurs constats sur l'indexation des textes, notamment, dans les bases de données patrimoniales. D'abord, l'indexation des textes et objets patrimoniaux par mots-clés, comme pratiquée encore aujourd'hui, permet d'optimiser l'interrogation des bases de données. Cependant, sur de grandes quantités de données procéder à une indexation manuelle, souvent effectuée par plusieurs personnes, amène à créer de la variation là où les bases ont besoins de constances. Ajoutons que plus la cohérence et la stabilité sont basses, plus les résultats sont imprécis.¹⁶⁴

Le second constat vient de la masse documentaire à traiter et de sa typologie. Les textes concernées concerne de vaste périodes chronologiques demandant la compréhension d'un vocabulaire vaste et évolutif et donc l'adaptation des mots clés. De plus, ces collections sont en expansion constante et toujours plus rapide, ce qui demande une augmentation du rythme d'indexation.¹⁶⁵

Ces deux éléments mènent à penser que l'indexation par seul moyens humains devient une limite importante des bases de données patrimoniales qui, finalement, complexifie la tâches des SRI

Mais alors pourquoi une indexation « semi-automatisée » et pas une totalement automatisée ? Si l'automatisation totale permet d'accélérer le traitement, on remarque des défaillances importantes. Ces processus ont tendances à produire les mêmes erreurs d'indexation que les humains tout en étant moins précis dans le choix des mots utilisés.¹⁶⁶

Une indexation semi-automatisée permet de faire de l'IA un outil d'appui, capable de suggérer des indexations et de proposer une base de travail propre très rapidement¹⁶⁷. L'humain n'a plus à analyser chaque document lui même : il n'est plus que le vérificateur qui peut valider la proposition issus du processus ou alors créer une alternative. En associant la vérification humaine à la rapidité de traitement de l'IA, on vise à augmenter la pertinence et la rapidité du processus. C'est ce que l'on l'appelle l'approche *Humain in the loop* : l'IA

¹⁶⁴Laurent Kevers, « Indexation Semi-Automatique de Textes : Thésaurus et Transducteurs », dans *Sixième Conférence Francophone En Recherche d'Information et Applications (CORIA)*, Presqu'Île de Giens, France, 2009, p.1.

¹⁶⁵*Ibid.*

¹⁶⁶*Ibid.*

¹⁶⁷Pierre Husson, *Indexation Iconographique et Intelligence Artificielle : Expérimentations Autour Du Répertoire Des Tableaux Italiens Dans Les Collections Publiques Françaises (RETIF)*, mém. de mast., 2025, p.69 à 71.

analyse et suggère, puis l'opérateur valide, invalide ou modifie.

Avant d'examiner ce qui se fait ou non dans le cadre de l'image animée, commençons par l'analyse du principe appliqué à des collections de musées plus statiques. Pour cela, je m'appuierai principalement sur le projet mené par Pierre Husson¹⁶⁸, promotion TNAH 2025, au sein du projet *IconographIA* consistant en l'application de tels processus sur des tableaux italiens du RETIF¹⁶⁹.

Pierre Husson met tout d'abord en avant la complexité de notion de vocabulaire¹⁷⁰ qui est pluriel. D'abord car adapté à chaque typologie patrimoniale et ensuite car au sein même de ces typologies existent des subdivisions avec leurs propres besoins terminologiques. Ces vocabulaires sont standardisés et contrôlés dans des thésaurus auxquels se rattacher comme ceux du Getty Research Institute.

Bien qu'on puisse s'appuyer sur ces outils pour contrôler la génération d'un outil d'indexation automatique¹⁷¹, il existe un fossé entre la compréhension de ce que l'IA voit et la sémantique des thésaurus. Pierre Husson met en avant que les modèles n'ont pas eu de difficultés des formes génériques (*humains, animaux, épées, etc*). Mais reconnaître que ces formes sont des concepts artistiques, comme des représentations codifiées consignées dans les thésaurus, est encore hors de portée.¹⁷² Ils sont de plus imprécis face aux spécificités de l'art, notamment sur la question du genre iconographiques encore complexe à déterminer malgré de récents progrès.¹⁷³

À la lumière de ces éléments, Pierre Husson conclut que l'indexation iconographique est loin d'être un processus automatisable. Cependant, les récentes avancées notamment avec les modèles multimodaux capables de traiter texte, images, vidéos et/ou sons en même temps, permettent d'envisager de s'appuyer dessus dans des processus semi-automatisés.

Mais alors, pourquoi faire de l'indexation semi-automatisée sur l'image animée ? La raison principale est l'explosion quantitative des collections. La Cinémathèque française conserve à titre d'exemple plus de 40 000 œuvres cinématographiques.¹⁷⁴ Cela s'explique par l'intensification de la production de film professionnel : plus de 9511 films sont réalisés à l'échelle mondiale en 2023 contre 7620 en 2016 selon le WIPO¹⁷⁵. Cela ne prend pas en compte la

¹⁶⁸ *Ibid.*

¹⁶⁹ Répertoire des tableaux italiens dans les collections publiques françaises

¹⁷⁰ *Ibid.*, p.9 à 17.

¹⁷¹ *Ibid.*, p.38 à 40.

¹⁷² *Ibid.*

¹⁷³ *Ibid.*, p.41 à 43.

¹⁷⁴ Pour plus d'information, consulter : <https://www.cinematheque.fr/les-collections-de-films.htm>

1

¹⁷⁵ Pour plus d'informations, consulter : <https://www.wipo.int/fr/web/global-innovation-index/w/b>

production de films amateurs, et toutes images animées produites en dehors du cinéma. De même, cela ne prend pas en compte ce qui est déjà produit et qui continu d'être conservé ce qui crée donc un véritable phénomène de masse demandant à accélérer le processus d'indexation.

Ajoutons à cela que, tout comme les tableaux, l'image animée pose ses propres difficultés à commencer par la notion de mouvement. Pour créer cette impression de mouvement, une œuvre d'image animée est composée de plusieurs centaines, ou milliers, d'images capturées à la chaîne pendant un instant déterminé. Ces images sont donc porteuses de sens, surtout au sein d'ensembles que sont les séquences et les scènes. L'indexation de vidéos ou de films entier repose donc principalement sur l'analyse de ces images au sein de ces deux ensembles qui déterminent un sens précis.

De plus, bien que, comme pour les tableaux, on cherche à reconnaître les entités, les personnes, les objets, et tout autre éléments, mais dans cette notion d'ensemble, l'image animée possède ses propres besoins d'indexation. En voici les trois principaux :

D'abord, celui d'une extraction automatique des séquences ou des scènes au sein d'une œuvre, ou bien d'œuvres au sein d'un même support, afin de proposer une indexation optimale pour des résultats de recherches précis. Disposer d'un outil capable de découper automatiquement les œuvres d'image animée en des unités documentaires plus petites et indexées à cette échelle est essentiel.

Un second besoin est de pouvoir faire des liens entre différentes scènes et/ou séquences d'une même œuvre, ou idéalement entre différentes œuvres. Cela peut permettre de reconstituer des arcs narratifs multiples ou encore de suivre l'évolution d'un sujet d'un bout à l'autre de l'œuvre. L'idée étant de pouvoir saisir la richesse des liens caractérisant les œuvres d'image animée. Ils peuvent être faits entre les œuvres, au sein de suites thématiques comme les duologies la notion de saisons au sein d'une série. Saisir ces liens et porosités est aujourd'hui un objectif pour certaines institutions.

Enfin l'association entre le visuel et le son, une caractéristique principale des images animées aujourd'hui. L'idée est d'exploiter l'œuvre et les thèmes contenus à la fois visuellement et auditivement. Par exemple une séquence triste peut être identifiée par les changements colorimétriques et émotions des acteurs, mais aussi par l'environnement sonore et les dialogues. Cela sous-entend que le processus gagnerait à pouvoir « comprendre » le son au sein de scènes et séquences afin de mieux exploiter les thèmes présents.

L'ensemble de ces éléments distingue clairement le traitement d'images animées de celui de tableaux. Bien que les éléments à extraire peuvent être les mêmes, les spécificités de l'image animée en complexifient fortement la détection et l'analyse. Ce qui demande donc à

penser à de nouveaux outils et processus de traitement.

On peut dès lors distinguer deux phases essentielles de traitement pour l'image animée. Une phase de « pré-traitement » pour décomposer l'œuvre ou la bande vidéo analysée en autant d'entités que nécessaire que cela soit à l'échelle des œuvres, scènes ou séquences. Et une seconde phase de traitement pour reconnaître et identifier les éléments d'indexations par l'usage de termes conforme à au moins un Thésaurus.

Après des recherches sur le sujet, un premier constat s'offre à nous. Il n'existe pas encore de solutions *open-source* permettant d'effectuer cette chaîne de traitement. Des outils existent afin de réaliser certaines tâches comprises dans le processus, comme la détection d'objet, mais ils n'ont encore jamais été rassemblés. Et du côté des solutions privées, certaines solutions à destinations du monde patrimonial existent et sont déjà utilisés. Cependant elles manquent de transparence ce qui fait que nous n'avons pas connaissance de la méthodologie appliquées, des outils utilisés et des compatibilités avec des standards de descriptions.

On peut citer Archipanion que les Archives fédérales Suisses utilisent à des fins de reconnaissance et d'extraction de métadonnées sur des images et vidéos. Cette institutions a indexée plus de 200h de vidéos de l'émission *Ciné-Journal Suisse*.¹⁷⁶ L'article reste succinct et nous n'avons pour information que l'extrait suivant : « Grâce à sa fonction de recherche par contenu visuel, Archipanion permet, en les décrivant, de rechercher des scènes ou des textes figurant dans le fonds du Ciné-Journal suisse et de trouver ainsi des contenus de manière exploratoire [...] Outre la recherche textuelle par description, Archipanion permet aussi de trouver des contenus visuels similaires au sein de la collection. ».

Sur le site d'Archipanion¹⁷⁷ voilà les conclusions que nous pouvons établir. Le processus établit agit sur chaque images à analyser individuellement, y compris au sien d'image animée. En s'appuyant sur de la *computer vision* ou bien des modèles multimodaux, il semble y avoir un processus de vectorisation : chaque image se voit attribuer une vecteur en fonction des entités, des lieux et du style général reconnus. Lorsqu'un utilisateur interroge ces documents, l'utilisateur décrit ce qu'il souhaite trouver, donc une scène ou une image, qui est transmise à l'IA. Cette requête est transformée en vecteur qui sont comparés à ceux des images animées stockées. Plus des vecteur sont proches, plus il est probable qu'il existe une correspondance.

Des questions subsistent. Les personnes sont-elles reconnues ? Qu'en est-il des réalisateurs et équipes techniques ? Qu'elle est la précision des métadonnées générées ? Il y'a-t-il une indexation de toute l'entière de l'œuvre d'image animée ou juste chaque image ?

L'opacité des solutions privées ne nous permet pas d'apporter des réponses à ces ques-

¹⁷⁶ Archipanion pour le Ciné-Journal suisse...

¹⁷⁷ Pour plus d'information, consulter : <https://www.archipanion.com/fr/>

tions. Et les articles d’institutions utilisant cette solution ne sont pas nombreux, en réalité seul celui-ci semble exister ce qui peut s’expliquer par le caractère récent de tels outils. Nous pouvons cependant déterminer deux choses : dans les deux sources, il n’y aucune mention de reconnaissance précises d’entités nommées. Une actrice célèbre, un monument ou encore un objet unique et identifiable ne semble être identifier suffisamment précisément afin de l’indexer de cette manière. Les analyses semblent rester très générales : une voiture, une femme, un homme, etc. Ensuite, il n’y aucune mention de reconnaissance de l’architecture documentaire. Par exemple, une bobine comportant 3 œuvre différentes semble être analysées comme une seule et même œuvre ce qui ne permet de corriger un problème de mélange des supports et des œuvre rencontrées par les institutions sur cette typologie.

Finalement, c’est une solution assez générale appliquant des principes déjà éprouvées sur les images fixes à des objets en mouvements. L’image animée semble être confondu avec une image statique, et est donc analysée de la même manière ce qui amène à perdre la richesse amenée par cette typologie documentaire. De plus, traiter chaque image animée composant une œuvre représente un processus long et coûteux qui, appliqué à des collections comme celles de la Cinémathèque française, peut ne pas présenter un rapport coûts / bénéfices suffisant.

Du côté des solutions dites *open source*, le seul processus de traitement des image animée connu est *vitriivr-engine*¹⁷⁸ développé par l’Université de Bâle, en Suisse, et sur lequel est basé la solution Archipanion.

Cette solution est basée sur la recherche de contenu, c’est à dire qu’on offre la capacité à l’utilisateur de décrire ce qu’il recherche et de l’orienter vers le bon passage d’une vidéo.¹⁷⁹

Son architecture est modulaire, c’est à dire qu’elle se compose, ici, de 3 briques logicielles qui interagissent ensemble mais qui ne composent pas un outil unique. Une interface d’interrogation, *vitriivr-ng*, une base de donnée, *Cottontail DB*, et un logiciel multimodal pour la recherche dans des documents multimédia, *Cineast*. Voici un schéma du fonctionnement global applicatif :

¹⁷⁸Pour plus d’informations, consulter le github du projet : <https://github.com/vitriivr>

¹⁷⁹Luca Rossetto, Ivan Giangreco, Claudiu Tanase et Heiko Schuldt, « Vitriivr : A Flexible Retrieval Stack Supporting Multiple Query Modes for Searching in Multimedia Collections », dans *Proceedings of the 24th ACM International Conference on Multimedia*, New York, NY, USA, 2016 (MM ’16), p. 1183-1186.




FIG. 9 : Schéma de fonctionnement de la solution vitrivr. Source : site officiel vitrivr à l'URL <https://vitrivr.org/vitrivr.html>.

Le logiciel fonctionne sur deux étapes. La première étape est celle de prétraitement des données : à l'intégration des documents multimédias dans la base de données, cela passe par *Cineast* qui analyse l'image animée, en extrait les entités visibles et lui donne un vecteur associé. La base de données stocke à la fois les œuvres multimédias et leurs représentations vectorielles au sein d'une base PostgreSQL adapté au stockage vectoriel¹⁸⁰. La seconde étape est celle de l'interrogation utilisateurs : la requête peut être formulée de différentes manières, par phrase, par recherche de similarité avec une image ou un schéma¹⁸¹, et est d'abord vectorisée par *Cineast* avant d'être envoyée à la base de données par une API. Les vecteurs sont ensuite comparés, et les résultats sont renvoyés à l'utilisateur soit directement dans l'interface *vitrivr-ng* soit en format 3D via *vitrivr-VR*.

Ce qui est intéressant, c'est l'absence des différentes modalités d'interrogations des documents multimédias dans la solution de Archipanion. En effet, seule la recherche par requête textuelle ou par mots-clés semble intégrée. Destinée à la gestion des collections, on peut penser que l'approche par schéma et images similaires ait été jugée non ou peu pertinente notamment dans des questions d'usages et de pratiques.

¹⁸⁰ *Ibid.*

¹⁸¹ *Ibid.*

Finalement, nous nous retrouvons un peu face aux mêmes limites pour une intégration dans le monde patrimonial. Ce logiciel est concentré sur le contenu, le visuel, mais délaisse l’aspect documentaire. Les image animée sont annotées, identifiées, mais elles ne sont pas indexées, mises en relations, décortiquée et encore moins manipuler comme un objet patrimonial. Une institution patrimoniale avec des besoins fort en matière de gestion risque de se trouver limitée : pas d’identification des personnes, pas d’identification technique, pas de rédaction d’une notice, pas de séparation en scènes ou séquences ou même entre œuvres.

Nous pouvons donc conclure que les solutions proposées pour la gestion de l’image animée par IA sont orientées gestion des contenus et non gestion documentaires. C’est insuffisant lorsque l’on souhaite gérer une collection patrimoniale.

Cela nous amène donc à voir plus large que des solutions sur étagères afin de trouver des outils permettant de répondre à l’ensemble des besoins institutionnels. Nous allons donc présenter des outils *open-source* qui, articulé ensemble, peuvent amener à penser et créer une solution d’indexation complète de l’image animée.

1. Manipulation de l’image et des plans

Le premier élément est le besoin de manipulations des documents multimédias en tant que tel. Une institution patrimoniale peut souhaiter séparer différentes œuvres d’image animée présentes sur un même support physique, ou bien une même œuvres en différentes sous-unités que sont la scène et la séquence. Cela demande nécessairement de pouvoir manipuler le document multimédia afin de le découper à des endroits précis et de pouvoir placer des repères temporels sur ces découpages. De cette manière, on pourrait segmenter une bande vidéo en différent segments indépendant avec chacun un « horodatage », c’est à dire un marqueur temporel au début et à la fin du segment afin de le situer à l’échelle de l’œuvre originale.

Pour cela, il existe le logiciel FFmpeg qui permet de manipuler des bandes vidéos et des bandes sons. Logiciel *open-source* pouvant traiter tous les formats vidéos et audios, il est très utilisé par des plateformes multimédia comme Youtube afin de permettre de manipuler les vidéos (*diffusion, manipulation du flux, etc*). Le gros avantage de ce logiciel est sa compatibilité avec des langages de programmation comme python, qui permettent de l’intégrer dans des workflows automatisés de traitement de données assez facilement.¹⁸²

Avec FFmpeg, la segmentation audio et vidéos est rendue possible. Autrement dit, on peut créer un extrait d’une œuvre avec la granularité désirée. Cependant, FFmpeg demande

¹⁸²Pour plus d’informations, consulter : <https://www.ffmpeg.org/documentation.html>

une action humaine : il n'intègre pas de système afin de repérer des variations justifiant un découpage. L'outil PySceneDetect permet d'identifier dans une piste vidéos chaque changement de plans. Il fonctionne selon le principe de *threshold* c'est à dire que l'utilisateur définit un palier indiquant au logiciel que toute comparaison entre image produisant un score inférieur à ce palier signifie que c'est un seul plan. Si le score de comparaison y est supérieur, alors ce sont des plans différents.¹⁸³

Cet outil est très intéressant : d'abord c'est une librairie python ce qui le rend parfaitement intégrable à un script automatique. On peut ainsi lier FFmpeg à PySceneDetect afin de lier la détection à l'extraction. De plus, il s'appuie sur d'autres librairie python reconnues et approuvées pour l'analyse d'image. On peut notamment penser à OpenCV, MoviePY et PyAV pour l'analyse images par images dans une vidéo ou bien d'images fixes. Ce sont des solutions très souples permettant de choisir un détecteur, c'est à dire un algorithme qui permet d'analyser une image et de la comparer avec l'image suivante afin de déterminer si il y a un changement de plan ou non. Chaque détecteur est spécialisé sur l'analyse d'un composant de l'image, par exemple :¹⁸⁴

1. *ContentDetector* : ce détecteur est le plus utilisé car le plus complet et souple. Chaque image est analysée dans son contenu notamment colorimétrique et structurel et obtient un score de détection. En fonction de cette analyse, il calcule un score pour chaque image, disons une forme de vecteur, et compare les scores entre eux. La différence entre les scores est ensuite reportée au *threshold*.
2. *AdaptiveDetector* : ce détecteur reprend le principe précédent. Il analyse les mêmes points, de la même manière. Le changement opère au niveau du système de comparaison. En effet, au lieu de se référer au *threshold* ce détecteur calcule lui même une moyenne glissante entre les images. C'est à dire que le *threshold* change automatiquement en fonction du cas présent. Cela rend le détecteur moins sensible aux mouvements de caméras, qui n'indiquent pas un changement de plan nécessairement.
3. *ThresholdDetector* : si les deux détecteurs précédents sont basés sur des analyses structurelles afin de repérer des coupures, celui-ci s'attarde sur les pixels afin de repérer les changements plus fins comme des transitions.
4. *HistogramDetector* : à l'échelle d'une vidéo, l'histogramme est un graphique permettant de visualiser, et parfois gérer, l'équilibre entre ombres et lumières. Ce détecteur

¹⁸³Pour plus d'informations, consulter : <https://www.scenesdetect.com/>

¹⁸⁴Pour consulter la documentation relative à chaque détecteur, consulter : <https://www.scenesdetect.com/docs/latest/api/detectors.html>

analyse cet histogramme, et compare les histogrammes des images afin de détecter des changements d'équilibre. Efficace afin d'identifier les coupures rapides.

5. *HashDetector* : il est similaire à *ContentDetector* et *AdaptativeDetector* si ce n'est qu'il se base sur la création d'un *hash*, c'est à dire une empreinte de taille fixe et propre à chaque image, pour chaque image. Ensuite, les *hash* sont comparés et leurs écarts calculés puis mis en relation avec le *threshold*

Ces détecteurs peuvent s'accumuler, permettant ainsi des analyses multiples mais alourdissant fortement le processus. Plus il y a de détecteurs, plus le traitement s'alourdit et plus on multiplie la finesse de l'analyse ce qui peut amener à faire de chaque petites variations une raison suffisante pour segmenter.

L'extraction se fait à l'échelle du plan puisque cet outil repère les ruptures de prises de vues ce qui caractérise les différents plans. Les scènes et séquences, beaucoup plus intéressantes pour une institutions patrimoniales, ne sont pas encore saisissables par des solutions informatiques. Il est cependant tout à fait possible d'utiliser cet outil pour découper une œuvre en autant de scènes et séquences qui la compose. Commençons d'abord par définir ce qu'est scène puis une séquence

Une scène représente l'unité de base d'une œuvre d'image animée. Il s'agit d'un ensemble de plans mettant en scènes les mêmes acteurs, dans les même lieux, souvent autour des mêmes objets et toujours autours des mêmes actions, sujets et objectifs. Ainsi, pour recréer une scène il faut pouvoir identifier ces éléments de continuité au sein de plans adjacent et cela jusqu'à l'identification d'une rupture nette. Si nous sommes capables d'identifier ces éléments, on peut tout à fait penser à créer des vecteur pour chaque plan basé sur l'identification de ces éléments. Comme dans un système de « recherche augmentée », c'est la comparaison entre les vecteur qui va déterminer l'action et le résultat à retourner. Si au sein de plan adjacents les vecteur sont extrêmement proche alors ils peuvent regroupé en une scène et cela jusqu'à détecter une rupture avec un autre plan.

Une séquence est un ensemble de scènes regroupées autour d'éléments bien plus abstrait. Ces scènes partagent une thématique commune, un sujet qui bien souvent sert au développement d'une partie de l'intrigue de l'œuvre. En arrivant à saisir un motif, sujet ou thème commun il serait possible d'agir de la même manière que précédemment : vectoriser les scènes sur ces éléments et rassembler les vecteur proches en séquences.

Ainsi on comprends que pour indexer une œuvre d'image animée il faut aller bien plus loin dans le processus de traitement que la simple détection de plan autrement dit de rupture

visuelle. Il faut pouvoir identifier des acteurs, et leurs apparitions dans les plans successifs. Mais aussi reconnaître ou du moins caractériser en partie les lieux, parfois fictif, qui permettent d'ancrer l'action dans un élément « concret ». En allant plus loin, il faut également des outils capable de déterminer la thématique générale des plans : dramatique, comique, action, etc. Ce n'est qu'à l'aide de ces éléments on peut envisager deux choses : indexer des éléments d'une œuvre et utiliser ces éléments pour créer des regroupements de plans.

Nous allons donc présenter des outils intégrable dans un script d'automatisation de l'indexation d'images animées permettant la détection et l'analyse des éléments identifiés. Comme nous l'avons déjà abordé, nous ferons l'impasse sur le module *Cineast* de *Vitrivr*. Gardons simplement à l'esprit que ce module ne propose pas une indexation assez fine et précise et que de plus, l'image animée est traitée comme une image fixe. Débutons par l'outil *SAM 2*¹⁸⁵ et son *framework* dérivé *Seg2Track-SAM2*¹⁸⁶.

2. Segmentation d'une image animée

Développé par l'entreprise Meta, *SAM 2* est un modèle d'IA spécialisé en *computer vision* afin de segmenter une image ou une vidéo : c'est à dire de détecter et isoler tout élément composant une image. Ce modèle est particulièrement intéressant pour trois spécificités :

D'abord sa capacité de *zero-shot*, c'est à dire sans être entraîné à détecter un objet spécifique, il pourra tout de même le segmenter au sein d'une image.¹⁸⁷

Ensuite, sa capacité à recevoir des *prompts* de la part de l'utilisateur, ce qui permet deux choses : de mieux diriger la segmentation et de la réitérer si nécessaire dans un but d'affinage.¹⁸⁸

Enfin, son système de mémorisation des formes détectées. Dans une œuvre d'image animée il n'est pas rare qu'un objet soit totalement visible puis ensuite peu à peu caché par un autre élément. Ce modèle mémorise ce qu'il détecte, de cette manière si l'objet détecté est partiellement couvert à un moment donné, le modèle garde la forme initiale de l'objet. C'est particulièrement utile afin de traquer les objets.¹⁸⁹

Cependant, cet outil possède trois limites importantes. La première est l'absence d'une attribution et d'une gestion d'identité à des objets. Un objet détecté est gardé en mémoire, ainsi si il disparaît partiellement de l'image le modèle garde en mémoire son emplacement

¹⁸⁵*SAM 2 : Segment Anything Model 2*, Ultralytics Docs.

¹⁸⁶Diogo Mendonça, Tiago Barros, Cristiano Premebida et Urbano J. Nunes, *Seg2Track-SAM2 : SAM2-based Multi-object Tracking and Segmentation*, version 2, 2025.

¹⁸⁷Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, *et al.*, « SAM 2 : SEGMENT ANYTHING IN IMAGES AND VIDEOS » (, 2025), p.8 à 10.

¹⁸⁸*Ibid.*, p.3 à 4.

¹⁸⁹*Ibid.*, p.4 à 5 ; *SAM 2*...

et sa forme. Cependant, comme il n'est pas identifié si cet objet disparaît puis réapparaît, *SAM 2* le reconnaît comme un nouvel objet ce qui est faux. Appliquée à des institutions patrimoniales, l'absence de cette identification risque de poser deux problèmes : d'abord car le modèle risque de détecter constamment le même objet, et ensuite car cela complexifie la reconnaissance d'un même objet dans différentes séquences ou scènes. La seconde est la mise en mémoire en elle-même car sur une volumétrie importante, le nombre d'objets à détecter est exponentiel ce qui alourdit la mémoire du modèle et en ralentit le traitement.¹⁹⁰ La dernière limite est l'absence de classification des objets. En effet, *SAM 2* reconnaît des formes mais ne pourra pas déterminer que ceci est une voiture et ceci un vase. C'est ce que l'on appelle un modèle « classe-agnostic »

Seg2Track-SAM2 permet d'apporter quelques solutions. Cet outil est un framework permettant d'associer *SAM 2* à un modèle de reconnaissance d'objet pré-entraîné comme YOLO ou bien Faster R-CNN et au module *Seg2Track* qui s'occupe de gérer l'attribution et la mise en mémoire d'identifiant des objets.¹⁹¹

L'association à un modèle de reconnaissance d'objet externe, choisi par l'institution, permet de spécialiser le *framework* pour la détection de certains objets et en déterminer la nature. Ainsi on brise la nature « classe-agnostic » de *SAM 2* en apportant, par une ressource extérieure, la possibilité d'identifier des classes d'objets comme des voitures, des vases, etc. Au-delà, cela permet d'accélérer le traitement et de le fiabiliser par l'application de deux modèles. *SAM 2* est surtout utilisé afin d'assurer le suivi de l'objet au travers des différents plans se succédant. Le module *Seg2Track* permet de résoudre l'attribution d'identifiant à chaque objet identifié. En effet, ce module permet d'attribuer un identifiant à chaque objet identifié, de le garder en mémoire et de l'associer à la forme de l'objet détecté elle aussi mémorisée, et ainsi de pouvoir reconnaître si le « nouvel objet » détecté est bien un nouvel objet ou un même objet.

Ce *framework* se place aujourd'hui comme une référence dans la segmentation d'images et d'images animées. Sur le jeu de données KITTI MOTS du *benchmarks KITTI*, ce *framework* s'est placé 4ème en 2025 sur l'analyse de ce dernier, essentiellement composé de voitures et de piétons, sans entraînement préalable.¹⁹² Dans un tout autre domaine, celui de la chirurgie, ce *framework* a montré des résultats prometteurs sur la segmentation multi-objets en *zero shot* avec notamment une possibilité de *fine-tuning* en temps réel permettant de réellement fiabiliser les résultats.¹⁹³

¹⁹⁰Id., « SAM 2 : SEGMENT ANYTHING IN IMAGES AND VIDEOS »..., p.22 à 40.

¹⁹¹D. Mendonça, T. Barros, C. Premevida, *et al.*, *Seg2Track-SAM2*...

¹⁹²*Ibid.*, p.5.

¹⁹³Pour plus d'informations sur le sujet, voir : (Cheng Yuan, Jian Jiang, Kunyi Yang, Lv Wu, Rui Wang,

Dans l’indexation d’une image animée, disposer d’un tel outil est pertinent. Parfois chargée en informations visuelle, l’application de *SAM 2* ou du *framework Seg2Track-SAM2* permettrait de faire un tri informationnelle via une segmentation de l’image. Chaque objets et personnes pouvant être détectés et isolés les uns des autres tout en étant suivis au fur et à mesure des images composant l’œuvre analysée.

3. La compréhension des sous-titres

Un autre élément pouvant être analysé pour indexation ce sont les sous-titres. Ils peuvent servir d’appui afin d’extraire du sens au sein d’une scène ou séquence. Des outils comme VideOCR¹⁹⁴ sont spécialisés sur le sujet et permettent d’isoler les sous-titres de l’image, et de les transcrire en chaînes de caractères brutes pouvant ensuite être interprétée soit par l’humain soit par un LLM.

Cependant cet outil a une limite importante. En effet, il ne repère pas automatiquement la zone de sous-titres et demande une intervention humaine : il doit désigner où se situe cette zone à l’aide de son curseur. Il est pertinent de laisser cette possibilité à l’utilisateur : le texte n’est pas uniquement présent dans les sous-titres mais peut aussi l’être dans l’image en elle-même et il faut pouvoir contraindre l’analyse afin d’éviter tout mélange d’informations. De plus, la zone de sous-titres a une position variable : en fonction des dimensions de l’image animée et de sa conception, cette zone peut varier en taille et en localisation. Ainsi, sur un grand jeu de données, cela offre une performance assez limitée puisqu’il faudrait définir à chaque fois la zone à traiter.

4. La reconnaissance de lieux et de personnes

L’indexation demande de reconnaître des éléments tels des acteurs ou des lieux de manière précise. Commençons par l’indexation des lieux :

La reconnaissance des lieux est une thématique assez massivement traitée. En effet, les institutions conservatrices ont assez rapidement exprimé le souhait de pouvoir géolocaliser des prises de vues photographiques à partir d’une analyse. Cette capacité a alors été conférée à des modèles d’IA qui, à partir d’images peuvent estimer une géolocalisation : c’est la

Zi Meng, Haonan Ping, Ziyu Xu, Yifan Zhou, Wanli Song, *et al.*, « Systematic Evaluation and Guidelines for Segment Anything Model in Surgical Video Analysis », *npj Digital Surgery*, 1–1 [1^{er} avr. 2026], p. 2)

¹⁹⁴Pour plus d’informations, consulter : <https://github.com/timminator/VideOCR>

géolocalisation visuelle. Domaine à part entière en IA, elle est composée d’outils et de réalités multiples.

À l’origine, la géolocalisation visuelle a été développée pour les images fixes et donc les algorithmes, modèles et outils répondent aux besoins de ces derniers. On peut penser à l’outil *PIGEON*¹⁹⁵, développé en 2023 et entraîné afin de surpasser l’humain sur le jeu *Geoguesser* dans lequel il s’agit d’estimer une géolocalisation à partir de simples images fixes à 360°. Cet outil extrait des éléments clés de l’image, les analyse et estime à partir de ces derniers une localisation géographique.¹⁹⁶ Pour cela, il est entraîné sur un corpus de plus de 4 millions d’images et possède son propre moteur de découpage géographique permettant d’estimer des positions avec une marge d’erreur d’environ 25 kilomètres.

Cependant, cet outil est également limité. D’abord, les analyses successives ralentissent le processus et le rendent de plus en plus coûteux. De plus, ce modèle n’est pas public : en effet, pouvant estimer des positions très précises il a été souligné que cela comporte un véritable risque de sécurité. Pour cela, il n’est destiné qu’à des usages académiques contrôlés, ce qui échappe à notre domaine d’application.¹⁹⁷

C’est aussi un outil inadapté à l’image animée. En effet, il traite des images fixes sans notions d’ensemble d’images. On sait, par définition, qu’une scène est constituée d’une succession d’images pouvant faire figurer le même lieu, parfois sous des angles différents. Cela implique donc deux limites : d’abord l’analyse de chaque image ou chaque plan ce qui, à l’échelle d’une scène, constitue une tâche répétitive et coûteuse. Et de plus, en fonction du plan la prédiction du modèle peut varier : il n’est pas capable de comprendre qu’il s’agit simplement d’un autre angle et non d’un nouveau lieu.¹⁹⁸

L’application de la géolocalisation visuelle sur l’image animée est relativement récente. L’avancée majeure est de prendre en compte cette notion d’ensemble d’images et donc de repérer différents éléments à plusieurs moments d’une même scène. Cela présente deux avantages : réduire la fréquence d’analyse en n’analysant non pas toutes les images mais uniquement certaines, et éviter les erreurs de prédictions. Deux outils y répondent, chacun avec leurs avantages et inconvénients :

D’abord *SeqNet*, un modèle d’IA basé sur un CNN. Il prend en entrée un extrait vidéo et y récupère des « échantillons » de vidéos répartis sur toute la durée de l’extrait. L’avancée majeure est qu’ils sont analysés individuellement puis réunis afin de donner lieux à une

¹⁹⁵Pour plus d’informations, consulter le github : <https://lukashaas.github.io/PIGEON-CVPR24/>

¹⁹⁶Lukas Haas, Michal Skreta, Silas Alberti et Chelsea Finn, *PIGEON : Predicting Image Geolocations*, arXiv.org, 11 juill. 2023.

¹⁹⁷*Ibid.*, p.11.

¹⁹⁸Sourav Garg et Michael Milford, *SeqNet : Learning Descriptors for Sequence-based Hierarchical Place Recognition*, 24 févr. 2021, arXiv : 2102.11603 [cs.CV], p.1 à 2.

prédiction unique qui s'applique donc à l'ensemble de l'extrait.¹⁹⁹

Ce modèle présente deux limites majeures : sa sensibilité à la taille des extraits fournis, qui doivent avoir une durée et un nombre d'images fixe, et à la continuité visuelle dans ces mêmes extraits. En effet, le modèle attend d'avoir des extraits de taille fixe, avec un nombre d'image fixe et sans variations importantes en terme de plans et de lumière ce qui ne correspond à la réalité des œuvres conservées.

Un second outil est *Video Swin Transformer*²⁰⁰. L'innovation réside ici dans le passage de l'utilisation d'une architecture CNN à une architecture de transformers. Sans rentrer dans les détails techniques, ce modèle reprend les innovations apportées par *SeqNet* et, grâce à un changement d'architecture, y apporte de l'auto-attention appliquée à la 3D ce que *SeqNet* n'intègre pas. De cette manière, le modèle devient moins sensible aux différentes variations visuelles qu'il peut y avoir, tant qu'il ne s'agit pas d'un changement de lieu, et moins sensibles aux variations de durées et de nombre d'images dans un extrait.

Cependant, il existe de nombreuses limites. La première est le coût en ressources : en effet, l'analyse d'éléments en 3D demande d'importantes capacités en processeur graphique ce qui est cher. De plus, on observe une perte de performance croissante en fonction de la taille des extraits : plus l'extrait est long, plus il contient d'images et moins le modèle est efficace. Enfin, le modèle nécessite un pré-entraînement et est très dépendant des données fournies à ce moment là. En effet, il ne possède pas de capacité *zero-shot* ce qui limite très fortement son champ d'application notamment sur des données patrimoniales.

Finalement, le domaine de la géolocalisation visuelle est actuellement en pleine mutation. L'arrivée des VLM et de la diversité des modèles d'architecture d'IA amènent de nouvelles innovations et de nouveaux outils toujours plus légers, rapides et moins coûteux. Cela reste cependant un domaine peu appliqué aux images animées, ce qui amène à questionner la faisabilité d'indexer automatiquement les lieux figurant dans des œuvres.

L'indexation des acteurs et actrices est elle aussi complexe car composée de différentes réalités. Dans un film professionnel par exemple, les acteurs et membres de l'équipe techniques sont répertoriés dans ce que l'on appelle des crédits : ces images avec uniquement du texte présentant la liste des acteurs, actrices et membres des équipes techniques. Cependant, dans un film amateur ce n'est pas la même réalité : les personnes sont souvent inconnues et surtout il n'y a pas de crédit. Imaginons une vidéo amateur sur laquelle figure une personne célèbre, il n'y aura pas de crédit pour l'indiquer.

Il est difficile d'indiquer quel cas est le plus rencontré dans les institutions conserva-

¹⁹⁹ *Ibid.*

²⁰⁰ Ze Liu, Jia Ning, Yue Cao, Yixuan Wei, Zheng Zhang, Stephen Lin et Han Hu, *Video Swin Transformer*, 24 juin 2021, arXiv : 2106.13230 [cs.CV].

trices car tout dépend de la typologie de leurs fonds. Ainsi, nous allons présenter deux outils correspondant aujourd’hui à ce qu’il est possible de réaliser dans ce domaine.

Commençons par les films professionnels. Pour cela, il faut pouvoir repérer les images dites de crédits, en extraire les chaînes de caractère et en analyser le contenu sémantique afin de l’indexer dans les bons champs. Aucun outil ne permet de réaliser les 3 tâches en un seul temps, ce qui constitue un des points de tensions entre le besoin des institutions conservatrices et ce que proposent les solutions d’indexation d’images animées actuelles. Cependant, cela ne signifie pas qu’il n’existe pas de solution. Nous traiterons cela plus en détail par la suite, mais présentons trois outils pouvant être combinés afin de répondre au besoin.

Tout d’abord, il s’agit de pouvoir identifier et extraire les images animées sur lesquelles figurent les crédits ou non. Ils se distinguent de la majorité des autres images composant un film par leur fonds noirs, et le texte blanc réparti en général sur une seule colonne et défilant sur plusieurs minutes. Pour cela, des algorithmes de *computer vision* comme ce qui est faisable avec *OpenCV* peuvent permettre de les reconnaître et de les isoler du reste de l’œuvre. En effet, cette librairie python est très souple : elle permet de segmenter une image, comme de la manipuler ou bien encore de les analyser. Cette analyse se fait sans appui sur du *Deep Learning* et se base sur une analyse structurale comme nous l’avons vu avec la question des détecteurs de *PySceneDetect* ²⁰¹

Ensuite, il s’agit de pouvoir extraire l’information écrite dans l’image. Bien que les crédits tendent aujourd’hui à se diversifier dans la police d’écriture et leur organisation, cela reste plutôt stable. Et on peut penser que pour une institution conservatrice conservant des films relativement « ancien », la stabilité est encore plus grande. Il faut ainsi un modèle d’OCR qui sera capable de reconnaître dans l’image le texte et de l’extraire sous forme de chaîne de caractères brutes. Des outils comme *Tesseract* ou *Kraken* qui sont *open-source* peuvent permettre cette extraction brute.

Cependant, à ce stade nous n’avons pas de compréhension sémantique. D’autant plus que les crédits sont faits de deux manières : pour le casting, nous avons d’un côté le nom de l’actrice et de l’autre côté son rôle, et pour l’équipe technique, des catégories avec des listes de noms sous formes de paragraphes ou bien de liste. Le risque ici est de ne pas réussir à associer l’actrice à son rôle, et de considérer le rôle comme étant une personne réelle à indexer, et de ne pas associer les membres des équipes techniques à leur bon rôle. Pour cela, le LLM constitue un bon outil d’analyse afin de réorganiser l’information. A l’aide de sa capacité de « compréhension » du langage naturel et grâce à sa capacité d’analyse, le LLM peut très bien

²⁰¹Voir page 72

réorganiser l'information.

Pour les films amateurs, ou plutôt dénués de crédits, il faut envisager de nouveaux outils permettant de reconnaître l'identité des personnes souhaitées. C'est le cas de *FaceNet* développé par Google qui permet de reconnaître des personnes grâce à son modèle d'IA basé sur une architecture de CNN. Voilà comment il fonctionne :

D'abord, on l'entraîne sur un jeu de données qui constitue sa base de connaissance. Cela peut être un jeu de données dit « maison », afin de reconnaître des personnes propres aux besoins institutionnels, ou des jeux de données *open-source* plus génériques comme *CelebA*²⁰² ou *Kaggle*²⁰³, plus petit, qui contiennent plusieurs centaines d'images par célébrités. Pour chaque image de visage, il analyse un certain nombre de caractéristiques pré-définies, comme les yeux et la bouche, et vectorise ces derniers.²⁰⁴ Les images avec les vecteur proches sont rassemblées afin de constituer des identités : ce seront nos personnes. Il va ensuite constituer des « triplets », c'est à dire des ensembles de 3 images : une image dite « positive », une image dite « référence » et une image dite « négative ». Ainsi, il maximise ses chances de reconnaissance par la construction de « triplets » permettant de représenter la personne à différents stades de sa vie ou dans différentes situations d'éclairage ou position.

Une fois entraîné, on peut l'appliquer à des image animée. Ce modèle détecte les visages présents sur nos images, vectorise leurs caractéristiques physiques et les compare avec les vecteurs des « triplets » sélectionnés pour représenter chaque personne identifiée en phase d'entraînement. En fonction de la proximité des vecteur des visages à analyser et des visages connus, il établit une correspondance : des vecteur proches indiquant qu'il s'agit de la même personne.²⁰⁵

Notons que cet outil possède une limite importante. En effet, ces outils de reconnaissance faciale sont sensibles aux variations de lumière²⁰⁶ et donc aux variations physiques. Si un acteur se trouve être maquillé avec des prothèses par exemple ou simplement derrière une image de synthèse ,comme dans le cas des films *Avatars*, cet outil risque de ne pas reconnaître la personne en question.

Soulignons alors la pluralité des outils existants. Que ce soit pour reconnaître des lieux ou des personnes figurants à l'écran, il existe plusieurs manières d'y parvenir, avec des degrés

²⁰²Lien vers le *dataset* : <https://www.innovatiana.com/fr/datasets/celeba>

²⁰³Lien vers le *dataset* : <https://www.kaggle.com/datasets/vishesh1412/celebrity-face-image-dataset/data>

²⁰⁴Florian Schroff, Dmitry Kalenichenko et James Philbin, *FaceNet : A Unified Embedding for Face Recognition and Clustering*, arXiv.org, 12 mars 2015.

²⁰⁵*Ibid.*

²⁰⁶*Ibid.*

de précision différents et demandant une mobilisation de ressources toujours plus importantes. Cette pluralité des outils correspond à une pluralité des besoins. Assez généralement, un film amateur demandera, pour être aussi bien indexé qu'un film professionnel, des moyens plus poussés étant donné l'absence de crédits, l'utilisation de lieux plus quotidiens et la figuration de personnes moins connues.

Ces outils peuvent alors très vite alourdir le traitement si l'on souhaite pouvoir tout indexer. Il faut garder à l'esprit que plus il y a d'éléments à analyser, plus le traitement sera long et coûteux. Ce qui pose la question de la limite de l'indexation semi-automatisée : jusqu'où souhaitons nous guider le professionnel dans son indexation ? Nous explorerons tout cela plus tard.

5. Les VLM

L'indexation semi-automatisée est aussi plus large. En effet, elle demande de pouvoir repérer des lieux et surtout des personnes de manière précises et cela afin de faciliter la saisie de données et la recherche sur ses éléments précis. Mais nous avons aussi vus qu'il était essentiel de pouvoir capturer le sens des scènes afin de pouvoir les rassembler en séquences.

Cela demande donc de pouvoir prendre en charge une compréhension sémantique d'images animées présentant des actions sur des thématiques précises. Cela fait intervenir une autre technologie, capable de tirer du sens depuis une vidéo : les VLM.

En combinant la puissance de raisonnement des LLM au domaine de la *computer vision* notamment dans l'analyse vidéo, cet outil est capable de générer des résumés de plans, scènes ou séquences. C'est à dire que plus qu'une simple détection d'objets, ou d'identification de lieux et de personnes, ces modèles peuvent comprendre et exprimer ce qu'il se passe. Ainsi, ils peuvent cerner un sujet ou une thématique et générer un texte qui permettra de l'expliquer et de le développer.

Pour cela, le VLM va d'abord analyser l'image à l'aide de différents outils de *computer vision* intégrés en son sein, ce qui conduit à sa représentation en vecteur. Ces derniers sont créés à partir des formes, couleurs, répartitions de pixels et objets détectés au sein d'une image. Ces vecteurs sont incompréhensibles pour la partie LLM, chargée de l'analyse complète et de la génération du résumé. Ainsi, ces vecteurs sont en quelque sorte « traduits » par un composant dédié qui permet de passer des vecteurs vers des *tokens* avec lesquels le LLM peut interagir. Enfin, tous ces *token* sont ensuite donnés directement au LLM qui les analyse un par un avant de générer un résumé général.

Pour cela, les VLM s'appuient assez largement sur un outil qui peut être utilisé seul que l'on appelle CLIP. Ce modèle d'IA est créé afin d'associer le texte, le NLP, à l'image, la *computer vision*, afin de reconnaître non pas des formes mais des objets clairement identifiés.

Mettons en contraste avec *SAM2* : ce dernier reconnaît les formes mais ne les catégorise pas. Il peut reconnaître plusieurs formes, les délimiter même quand elles sont confondues et les suivre mais en aucun cas il ne pourra dire que ceci est une voiture ou bien un vase. CLIP permet cette reconnaissance multi-objet, c’est à dire qu’il est capable de dire que dans cette image nous avons tel objet qui effectue tel action.

Cela est possible par l’association du NLP à la *computer vision*. Ce modèle est entraîné sur des paires associant un concept exprimé en langage naturel par une chaîne de caractères à une image.²⁰⁷ De cette manière, plus que de reconnaître une image, il reconnaît un concept et est capable de l’identifier en *zero-shot*.²⁰⁸

Rajoutons que les VLM sont en plein développement et les modèles sont donc nombreux. Pour les modèles propriétaires nous pouvons citer *GPT-4* et *Gemini 2.5 Pro* qui sont excellent pour l’analyse visuelle globale et la compréhension de l’image. Du côté de l’*open-source* nous pouvons citer les modèles *QWEN-VL* et *Llama3.2 Vision* qui sont parmi les plus performants. Notons cependant que ces modèles sont volumineux et demandent des ressources processeur graphique et processeur très importantes.

Cependant, les VLMs possèdent des limites d’utilisation importantes. La première est son coût. En effet, le VLM mobilise une grande quantité de ressources afin d’analyser et résumer chaque image qui lui est fournie et plus l’œuvre est longue plus le coût sera important.²⁰⁹ De plus, l’analyse quantitative amène la mémoire de ces modèles à sa limite. Cristóbal Eyzaguirre écrit : « *a car that has driven for an hour is, in principle, harder to query than one that just started* »²¹⁰. Autrement dit, plus l’œuvre est longue plus il est difficile de retenir tous les éléments et donc de créer une compréhension globale.

6. Le traitement des pistes audios

Comme vu précédemment, l’image animée se compose d’une bande vidéo, qui contient les images, et d’une bande sonore contenant les dialogues, la musique, et les bruits ambiants. C’est en tout cas vrai pour la majeure partie des images animées : le son étant enfin capturé en même temps que les images à partir des années 1930, celles étant antérieure à cette date

²⁰⁷Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, *et al.*, *Learning Transferable Visual Models From Natural Language Supervision*, 26 févr. 2021, arXiv : 2103.00020 [cs.CV], p.3 à 4.

²⁰⁸*Ibid.*, p.6 à 11.

²⁰⁹Cristobal Eyzaguirre, Jiajun Wu et Juan Carlos Niebles, *Linear Scaling Video VLMs for Long Video Understanding*, 29 mai 2026, arXiv : 2605.31598 [cs.CV], p.2.

²¹⁰*Ibid.*

ne sont généralement pas dotées de son.

C’est un composant essentiel lorsqu’il s’agit de comprendre le contexte, l’action ou bien la thématique et le genre d’une scène. Une scène triste se caractérise par une ambiance sonore particulière par exemple. De plus, si une scène se détermine à l’aide de repères visuels cela peut aussi être à l’aide du son. Par exemple, une scène peut être composée d’images très différentes mais unie autour d’une thématique exprimée par une voix dite hors-champs.²¹¹

Un des points centraux est de pouvoir comprendre les dialogues et d’en associer la prononciation à la bonne personne. Deux outils ce sont vite distingués sur ces deux champs : *Whisper* afin de faire de l’audio-transcription et *Pyannote.audio* afin de faire une diarisation de l’image animée. Ces outils sont complémentaires et souvent utilisés au sein d’un pipeline.

Whisper est développé par OpenAI, publié en *open-source*, et basé sur une IA à architecture de transformers permettant la transcription d’un audio comme un discours par écrit.²¹² Ce modèle est capable de transcrire la parole en texte et de traduire vers l’anglais une langue étrangère. Cependant, ce modèle reste relativement limité dans son application d’abord car il s’agit d’une plateforme en ligne à laquelle on transfère ses données. Ensuite, car elle est majoritairement concentrée sur l’Anglais, bien que des modules supplémentaires prennent en charge d’autres langues. Enfin c’est un modèle qui demande beaucoup de ressources informatiques mais qui, malgré ça, reste sensible aux hallucinations notamment si il y a beaucoup de bruit ambiant ou de la musique. Rajoutons que ce modèle ne prend pas en charge la diarisation.

C’est pour cette raison qu’on combine souvent *Whisper* avec *Pyannote.audio* afin de transcrire la parole tout en l’attribuant à un locuteur identifié et cela sur toute la durée de l’image animée. Cette bibliothèque python fonctionne sur plusieurs IA fournis par *PyTorch*, bibliothèque *open-source* pour le *Deep Learning* largement utilisée aujourd’hui. Son fonctionnement est le suivant : elle commence par segmenter les différentes prises de paroles, leur attribue des vecteurs et ensuite agrège les segments audios aux vecteurs les plus proches. De cette manière, le modèle est capable d’associer les bons temps de paroles aux bons locuteurs permettant ainsi de retracer le discours de chaque personne. Cependant, cet outil est assez limité notamment dans notre domaine d’application. Tout d’abord, au-delà de deux voix distinctes les confusions deviennent de plus en plus fréquentes et plus il y a de locuteurs plus cette confusion s’intensifie. Ensuite, les chevauchements de paroles ou les coupures dues à

²¹¹La voix hors-champs, ou *voix-off*, est un procédé où l’on rajoute sur un ensemble d’images la voix d’une personne sans voir son visage. Cela permet souvent, par un monologue, de guider le spectateur au travers de différentes images dès lors liées par une explication orale ou pour exprimer les pensées intérieures d’un personnage.

²¹²A. Radford, J. W. Kim, Tao Xu, Greg Brockman, Christine McLeavey et Ilya Sutskever, « Robust Speech Recognition via Large-Scale Weak Supervision » ().

deux locuteurs parlant en même temps ne sont pas traités par le modèle : il n’arrive pas à identifier les interlocuteurs et leurs paroles.²¹³

C’est une première réalité très morcelée et finalement partielle du traitement audio. La recherche ayant été très concentrée sur le discours, sa transcription et son attribution aux bons locuteurs notamment afin de résumer des réunions professionnelles. Or, notre besoin est plus large et ne demande pas nécessairement de transcrire un discours mais au moins d’en comprendre la tournure, le genre et surtout d’analyser l’ambiance sonore de la scène donc la musique et les bruits ambiants.

De plus, notons qu’aucun de ces outils ne permet de tendre vers une logique d’indexation. Il n’y a pas d’analyse et de compréhension des discours, de la répartition de la parole et des tons employés. Finalement, ils n’abordent aucun point qui serait intéressant pour une indexation complète d’une image animée patrimoniale.

Cela conduit naturellement à nous diriger de nouveau vers les modèles multimodaux orientés texte et analyse sonore : les *Audio Large Language Model*. Ces modèles sont plus puissants que les outils précédemment cités : plus robuste et polyvalent, ils permettent de réellement saisir le « sens sonore » d’une image animée, de l’analyser et de l’exprimer.

L’outil le plus utilisé est alors *Qwen-Audio* ou *Qwen2-Audio*, sa version plus avancée et actuelle. Ce modèle permet notamment de traduire une entrée sonore en une analyse textuelle en sortie. Il combine deux architectures neuronales, le CNN et les transformers avec notamment deux outils clés : un LLM et un encodeur audio. La première architecture pré-traite la bande son et la rend plus facilement analysable, la seconde architecture constitue le cœur de ce modèle en permettant l’analyse.

Il permet d’effectuer une diarisation de la bande son, comme *Pyannote.audio*, mais en pousse l’analyse jusqu’à pouvoir comprendre le ton du discours employé par chaque locuteur. Comme *Whisper*, il permet de transcrire des paroles en texte mais de manière plus poussée puisqu’il prend nativement en charge plus de langues. *Qwen2-Audio* apporte aussi des nouveautés dans le domaine de l’analyse audio : il reconnaît et identifie la nature des bruits ambiants et traite la musique afin d’en caractériser l’ambiance sonore.²¹⁴

Tout comme les VLM précédemment cités, les ALM sont gourmands en processeur

²¹³Hervé Bredin, « Pyannote.Audio 2.1 Speaker Diarization Pipeline : Principle, Benchmark, and Recipe », dans 2023, p. 1983.

²¹⁴Yunfei Chu, Jin Xu, Xiaohuan Zhou, Qian Yang, Shiliang Zhang, Zhijie Yan, Chang Zhou et Jingren Zhou, *Qwen-Audio : Advancing Universal Audio Understanding via Unified Large-Scale Audio-Language Models*, 21 déc. 2023, arXiv : 2311.07919 [eess.AS].

graphique. On remarque aussi que ces modèles ont généralement tendance à être en grande difficulté face à des enregistrements sonores de faible qualité que ce soit à cause de conditions d’enregistrement ou de conservation difficiles. Cela renforce la possibilité d’hallucination, déjà présente dès lors que l’on parle d’IA. De plus, ces modèles sont très sensibles à leurs entraînement. La plupart de ces modèles sont entraînés sur des langues internationales comme l’anglais et le français, car on dispose de très grandes quantités de données sur ces langues ce qui provoque des difficultés face à des langues plus régionales.

7. Vers une révolution des modèles multimodaux : les *native multimodal modeling* ?

Nous avons parlé jusque-là de VLM et d’ALM de manière séparée. Car fondamentalement, ils constituent deux outils séparés obéissant ainsi à la logique première de la multimodalité des modèles qui est de mêler deux domaines d’analyses. Cependant, avec les progrès technologiques récents la multimodalité voit ses limites repoussées et certains modèles sont maintenant capables d’agir sur le son, l’image et le texte. C’est ce que l’on appelle : la multimodalité native

Jusqu’à présent, un modèles multimodaux combine soit un encodeur visuel soit un encodeur sonore avec un LLM. C’est ce qui conférerait cette capacité de transiter de l’un vers l’autre et donc de comprendre et d’analyser du son ou de l’image. Ainsi, pour indexer une image animée il fallait créer ce que l’on appelle une « architecture en cascade » c’est-à-dire que l’on traitait le son et la vidéos dans des *pipelines* différenciés avant de fusionner les résultats.

Cependant, cette architecture n’est pas sans problème. Traiter le son et l’image de manière séparée ne permet pas une analyse profonde de l’image animée à l’état brut ce qui finalement retire une profondeur d’analyse.²¹⁵ Les traitements différencier, dans des moments différents et avec des moyens diverses entraînent un manque de cohérence et de profondeur dans les résultats. On peine à faire des liens entre l’audio et la vidéo ce qui, dans une logique d’indexation patrimoniale, constitue une limite importante d’application de tels modèles.

En réponse à cela, est en train de se développer les *native multimodal modeling* qui sont des modèles plus larges et puissants embarquant nativement des encodeurs vidéos et sonores en plus d’un LLM afin de traiter simultanément son et images.²¹⁶ L’objectif étant de créer

²¹⁵Siyu An, Junru Lu, Junnan Dong, Qiufeng Wang, Yinghui Li, Weizhi Fei, Zichao Yu, Zheng Yuan, Biao Liu, Haopeng Wang, *et al.*, *Toward Native Multimodal Modeling : A Roadmap*, 25 mai 2026, arXiv : 2605.25343 [cs.CV], p.1.

²¹⁶*Ibid.*

des modèles basés sur une architecture dite « *unimodal* »²¹⁷

Nous ne rentrerons pas dans les détails et nous contentons de rester succints afin de ne pas aborder trop de détails techniques. Cette « unimodalités » pourrait prendre diverses formes : d'abord il y aurait les modèles dits de *Mid-fusion* qui traite chaque élément de manière distincte, en gardant des frontières entre les éléments, mais au sein d'un même réseau permettant de conserver et exploiter les liens. Ensuite, les modèles dits de *Early-fusion*, qui traitent chaque modalité de la même manière via une seule modalité de traitement adaptée à toutes les typologies²¹⁸

Les différences de résultats entre les modalités ne sont pas très claires car il s'agit avant tout de théoriser deux manières d'opérer ce traitement multimodal. Car la problématique est que les *native multimodal modeling* sont aujourd'hui en expansion croissante sans pour autant se construire autour de démarche définie, ce qui risque, à long terme, de poser problème.

On a de plus 3 typologies de modèles : les modèles *Multi-to-Text*²¹⁹ qui peuvent prendre en charge de la vidéos, du son et du texte et de générer des résultats d'analyses sous forme de texte. Les *Multi-to-Target*²²⁰ qui, en somme, conviennent à des usages spécifiques et désignés ne gérant qu'une entrée spécifique et désignée. Et enfin les *Multi-to-Multi*²²¹ capables de prendre en charge toutes les entrées simultanément, de les traiter de la même manière et de générer n'importe quel type de sortie : autant une analyse textuelle, qu'une image ou qu'une vidéo.

Des modèles comme *GPT-4o*, propriétaire, ou *Qwen2.5-Omni*, *open-source* mettent déjà en application les préconisations effectuées par le chercheur An Siyu sur lequel nous nous basons.

Ces modèles, peu importe leurs modalités de traitement et typologies, permettent d'envisager des traitements unifiés et des analyses plus importantes des images animées. En analysant dans un même temps, de la même manière et avec la conservation des liens entre chaque composant de l'image animée alors on peut penser atteindre une nouvelle dimension de l'indexation automatique.

Cependant, l'article reste assez flou quant aux limites de ces *native multimodal modeling* mais certaines paraissent être évidentes. D'abord, la consommation de ressources de

²¹⁷ *Ibid.*

²¹⁸ *Ibid.*, p.1 à 5.

²¹⁹ *Ibid.*, p.3 à 9.

²²⁰ *Ibid.*, p.10 à 12.

²²¹ *Ibid.*, p.12 à 14.

ces modèles. Nous avons déjà vu précédemment que les VLM et ALM demandent des ressources importantes en processeur graphique et processeur. Alors que devons-nous penser du coût potentiel d’un *native multimodal modeling* sur des image animée de plusieurs heures ? Appliquer à des institutions publiques, cette réalité technique risque d’être peu atteignable.

De plus, quel est la quantité de données nécessaire afin d’entraîner ces modèles ? La stratégie d’entraînement annoncée avance un entraînement sur 4 axes distincts, abordant plusieurs jeux de données certainement spécialisés sur chacune des typologies à traiter.²²² Bien que non estimé, cela demande des compétences techniques précises et nombreuses représentant un coût humain important. La mise en place de ces modèles peut donc être complexe.

8. Conclusion

Ce bref état d’art n’est pas exhaustif. En effet, il existe encore bon nombre d’outils et de technologies pouvant être employés à des fins d’indexation de l’image animée. Cependant, l’objectif ici était de se concentrer sur quelques outils différents permettant de traiter les différents besoins sur ce sujet.

Cela nous a permis de mettre en lumière la complexité de l’indexation de cet objet patrimonial et documentaire. Si dans les technologies développées il y a eu une légère tendance à penser que l’image animée n’était que peu différente de l’image fixe, la réalité est toute autre. La notion de mouvements, l’association entre l’image et le son et la complexité des structures des différentes œuvres demandent des technologies et moyens de traitement propres.

De fait, les moyens sont assez divers et on constate un éclatement des traitements. En effet, peu de solutions permettent d’indexer une image animée ou alors pas avec le niveau de précision et de fiabilité scientifique attendus. Cela s’explique tout d’abord par le manque de dialogue entre les différentes technologies et domaines d’IA sollicités aujourd’hui. Chaque domaine a développé ces propres technologies qui ne sont pas élaborés afin de satisfaire les besoins plus globaux de l’indexation automatique de l’image animée. Ces moyens divers amènent également des résultats divers ce qui pose deux contraintes : articuler entre elles les données différentes issues de *pipeline* différenciées et s’assurer de leur conformité aux principes d’interopérabilité des données. Nous aborderons ces points plus en détails, mais il est intéressant de garder cela en tête comme des premières limites.

Ces différents outils sont largement intégrables au sein de *pipeline* de traitement dans du code, notamment en Python. Bien que cela reste accessible, ces outils demandent donc des compétences spécifiques afin de les articuler correctement mais aussi de pouvoir les mettre en place. Les VLM et ALM notamment demandent généralement à être entraînés sur des

²²² *Ibid.*, p.14 à 25.

données spécifiques, ou alors à passer par un processus de *fine-tuning* pour obtenir de meilleurs résultats.

De plus, l'articulation de ces outils en un *pipeline* demande des ressources computationnelles importantes afin de le faire fonctionner. Outre la puissance demandée par ces outils, le nombre de données générées semble être considérable à l'échelle d'institutions patrimoniales ce qui entraîne un coût de stockage important. De fait, posséder une telle puissance peut sembler hors d'atteinte pour la plupart des institutions conservatrices.

Les *native multimodal modeling* semblent présenter une piste prometteuse. En réunissant en un seul outil les VLM et ALM afin de traiter son et images en un seul temps et de la manière adaptée, cela résout la question de la cohérence des données. Cependant, ces technologies n'en sont qu'aux prémices et ne sont pas encore assez éprouvées afin de constituer une base de traitement stable. De plus, il n'y a pas encore d'évaluations précises quant à leurs applications à des documents patrimoniaux, leurs coûts et limites. Mais on ne peut que, à l'instar des connaissances et technologies actuelles, penser qu'ils seront plus gourmands que les VLM et ALM actuels.

Finalement, l'indexation automatique d'image animée n'en semble qu'à ses prémices. Le traitement automatisé de la vidéo et du son, séparément et simultanément, par IA sont en pleine effervescence et de nouvelles technologies et procédés apparaissent chaque année. Dans cette perspective, établir un processus adapté aux besoins institutionnels et patrimoniaux revient à se concentrer sur les besoins d'indexation plus que sur les possibilités actuelles. Car il est hautement probable que de nouvelles technologies permettent d'aller dans le sens du processus pensé et décrit ici dans la suite de ce mémoire, à commencer par le développement des *native multimodal modeling*

III. Enjeux utilisateurs : comment implémenter cette fonctionnalité en respectant l'utilisateur dans son usage de l'application et son rapport avec l'intelligence artificielle ?

Nous ne reviendrons pas dans cette partie sur les notions d'*User Experience Design* et d'*User Interface Design*²²³. Il s'agit ici de reprendre les considérations précédentes et de se questionner sur l'inclusion de l'indexation semi-automatisée dans un système de gestion des collections.

Nous avons donc mis en exergue la complexité que représente l'intégration du NLP, sous deux outils différents, dans l'application. Cela revient à changer presque totalement le rapport de l'utilisateur avec son système de production par l'introduction de technologies envers lesquelles une certaines méfiances existent. Ce changement important ne doit pas provoquer de bouleversement graphique et d'expérience utilisateur : si à l'échelle technique les changements sont importants, l'impact utilisateur se doit d'être contrôlé.

Finalement, le cœur de l'enjeu réside dans l'adoption de ses outils, ou du moins leur non-rejet, ce qui passe par deux besoins. D'abord la transparence des processus et résultats. Ensuite, le besoin de placer l'humain au cœur des processus notamment par la possibilité de valider ou invalider des résultats.

Mais qu'en est-il de l'indexation semi-automatisée ? Les enjeux d'*User Experience Design* et d'*User Interface Design* sont-ils similaires ? Ont-ils les mêmes réponses ? La réponse est en réalité assez nuancée.

Avec l'intégration d'un chatbot et d'une recherche augmentée, on amène des changements dans le rapport et l'interaction entre l'utilisateur et le système. Cependant, il n'y a pas de changement drastique dans l'usage de l'application : on offre une nouvelle manière d'explorer et d'interagir sans pour autant effacer ce qui préexiste. Au contraire, ces outils agissent comme des compléments et améliorations afin d'approfondir des parcours préexistants.

L'approche ici est très différente puisqu'il s'agit de créer quelque chose d'inexistant dans l'expérience et l'interface utilisateur et de manquant. Cette création ne vient pas compléter un parcours, mais en remplacer un préexistant autant à l'échelle de l'application qu'à celle des institutions. Ainsi, on bouleverse nécessairement l'expérience utilisateur d'indexation de l'image animée et l'interface par la création de nouveaux parcours avec des interfaces dé-

²²³ Chapitre III. « Enjeux utilisateurs » page 51

diées. En somme, on ne parle pas de changer quelques points plus ou moins généraux dans un système mais bien de changer des pratiques et logiques dans un univers métier.

En effet, les chaînes de traitement d'indexation de l'image animée sont bien définies, comme nous l'avons vu, et n'intègrent le système de gestion des collections que partiellement. C'est l'endroit où on stocke les données et extraits obtenus par différentes chaînes de traitement basées sur des processus et outils externes.

Si l'indexation semi-automatisée intégrée dans un système de gestion des collections change certains aspects logiciels, devant maintenant pouvoir afficher des propositions et proposer un parcours simple menant à cela, elle vise surtout à mettre fin à ces traitements externes. Ce qui change la réalité métier et les logiques de productions de métas-données. Ainsi, il incombe au logiciel et à la nouvelle fonctionnalité de pouvoir accompagner les utilisateurs dans un changement à si grande échelle.²²⁴ Ceci nous amène à faire face à différentes problématiques, et à présenter différentes logiques en réponse :

1. On peut par exemple penser à rendre ce processus optionnel. L'utilisateur ne doit pas changer drastiquement sa manière de faire et produire de la méta-données, il peut choisir une option ou l'autre. Cela signifie qu'il faut inclure la notion de choix dans l'expérience et l'interface.
2. Dans l'univers métiers dépeint, on comprend qu'un tel outil peut donner une sensation de perte de contrôle. En effet, la production de méta-données revient à une IA qui va également créer les extraits selon sa propre logique. L'aspect semi-automatisé et optionnel risque de ne pas être suffisant pour rassurer l'utilisateur, notamment dans la capacité de l'outil à respecter les WEMI et à produire des données scientifiques et certaines. Il faut donc intégrer un système « *human in the loop* », plaçant l'utilisateur au centre de tout et en position de contrôle.²²⁵
3. Intégrer une distinction visuelle claire entre les données suggérées par IA et celles validées ou saisies par un utilisateur. L'interface doit traduire cette différence afin de donner à l'utilisateur des moyens visuels à des fins de distinctions et de contrôle. De plus, cela peut permettre de réduire la surcharge cognitive²²⁶ en offrant à l'utilisateur un moyen de distinction rapide, sans avoir besoin de réflexion. C'est ce que l'on appelle,

²²⁴A. Badda, « Technology Acceptance Model (TAM)... ».

²²⁵Saleema Amershi, Kori Inkpen, Jaime Teevan, Ruth Kikin-Gil, Eric Horvitz, Dan Weld, Mihaela Vorvoreanu, Adam Fourney, Besmira Nushi, Penny Collisson, *et al.*, *Guidelines for Human-AI Interaction*, 2019, p. 13.

²²⁶F. Paas, A. Renkl et J. Sweller, « Cognitive Load Theory and Instructional Design... ».

entre autres, le principe de *explainable artificial intelligence* c'est-à-dire le fait de pouvoir expliquer et constater les choix et productions effectués par IA.²²⁷

Mais différents éléments relevant des logiques d'implémentations et des questions d'usages semblent devoir trouver des inspirations nouvelles. À l'échelle de l'expérience il faut distinguer deux éléments : le souhait d'implémentation et le confort d'usage. Il existe une tension entre la direction que l'on souhaite prendre, son objectif final et l'envergure du changement que cela amène, et le besoin d'un certain confort de l'utilisateur passant surtout par la confiance accordable à l'outil.

Par exemple, comment gérer les erreurs d'indexation semi-automatisée ? Par définition, ce processus n'est pas infaillible et c'est pour cela qu'il ne fait que proposer des éléments d'indexation. Il peut très bien mal segmenter une image, créer des extraits mal identifiés, ou ne pas reconnaître une entité sur l'image et ne pas pouvoir l'indexer. Tout cela peut créer des omissions et des fausses détections qui risquent de mettre à mal le confort utilisateur, n'ayant finalement pas de gain de temps. Si l'utilisateur doit corriger sans cesse, le gain de temps est finalement minime et l'outil peut désintéresser.

Ou encore comment gérer la surcharge informationnelle ? En effet, indexer une image animée c'est prendre le risque de produire d'énormes quantités de données et dès lors de submerger l'utilisateur. De plus, cette quantité de données doit être répartie sur l'ensemble des WEMI ce qui pose des problématiques techniques, mais aussi d'usage puisque chaque institution peut utiliser le WEMI de différentes manières. Adopter une position « *human in the loop* » risque de surcharger l'utilisateur avec un nombre de décisions à prendre trop important.²²⁸

En somme, comme avec le chatbot et la recherche augmentée, le succès de l'implémentation de l'indexation semi-automatisée des images animées réside moins dans la précision technologique de l'outil que dans ses caractéristiques graphiques et d'expérience utilisateur. L'objectif est de réussir à instaurer un climat de confiance suffisant avec l'utilisateur afin de l'amener à changer ses habitudes métiers. L'outil se doit donc d'être inventif en termes d'*User Experience Design* et d'*User Interface Design*.

²²⁷Q. Vera Liao et Kush R. Varshney, *Human-Centered Explainable AI (XAI) : From Algorithms to User Experiences*, 19 avr. 2022, arXiv : 2110.10790 [cs.AI].

²²⁸Martin Eppler et Jeanne Mengis, « The Concept of Information Overload : A Review of Literature from Organization Science, Accounting, Marketing, MIS, and Related Disciplines », *The Information Society*, 20 (1^{er} nov. 2004), p. 325-344.

Troisième partie

**Solutions élaborées et résultats
obtenus**

Chapitre 5

Recherche Augmentée et chatbot : conception technique, conception utilisateur et résultat.

La gestion des collections est aujourd'hui pleine de complexité et de frein. Que cela soit à cause des collections massives et doublement hétérogène ou à cause de la complexité des système de gestion des collections. Par nos différentes état de l'art, nous constatons que la création d'outils d'IA répondants aux besoins professionnels est aujourd'hui secondaire.

Ajoutons que les système de gestion des collections sont aujourd'hui devenu trop complexe pour être pleinement exploité et ne permettant plus de faciliter suffisamment la gestion des collections. De plus, l'hétérogénéité et massivités croissantes des collections amènent aujourd'hui ces logiciels à leurs limites. Prenons l'exemple des SRI dit « classique » qui sont de plus en plus limité afin de répondre aux besoins professionnels.

L'implémentation d'outil d'IA pour les professionnels pourrait aujourd'hui constituer une solutions à cette double limite. D'abord en simplifiant le traitement des collections par l'automatisation de processus ou l'apport d'une puissance de calcul pour en faciliter l'exploration. Ensuite en permettant de simplifier l'usage d'un système de gestion des collections en appuyant l'utilisateur dans son utilisation de l'application et sa productivité de différentes manières. Cependant, la réalité des outils d'IA pour le patrimoine est diversifiés en fonction des outils :

Soit il existe des projets et travaux mais orientés usage grand public. Leurs objectifs sont d'améliorer la relation du grand public avec les collections en augmentant leurs découvrabilités et les possibilité d'interactions. C'est dans ce cadre qu'est créer le *pipeline Text-to-SQL* par exemple.

Ou alors, on a une absence presque totale de projets et de travaux peu importe l'usage

envisagé. C’est le cas des domaines en pleine émergence au sein du patrimoine comme chatbot.

Il y a finalement un manque d’outils à destination des professionnels de la gestion des collections. Afin de créer cette littérature à destination d’usage professionnel de tels outils, il convient de questionner et examiner leurs implémentations dans des logiciels métiers comme des système de gestion des collections. Cela permettra de déterminer les conceptions techniques à retenir, les parcours utilisateurs à penser, et les apports et limites de ces outils dans ces univers professionnels. C’est ce que nous allons explorer ici au sein du logiciel SkinSoft en commençant par la recherche augmentée, avant d’aborder le cas du chatbot.

1. La recherche augmentée :

Une des limites principales des système de gestion des collections sont les SRI sur lesquels reposent les systèmes de recherche. Rappelons les deux limites exploré :

1. D’abord la complexité de l’outil. Sans aborder son fonctionnement,²²⁹, rappelons qu’ils proposent différentes modalités de recherches²³⁰. C’est à l’utilisateurs de juger quelles modalités utiliser et accumuler. Aujourd’hui, cette conception de la recherche par accumulation manuelle des modalités constitue un frein important ralentissant l’usage.
2. Ensuite, les limites techniques ²³¹ de ces logiciels. Ils s’appuient sur une correspondance par mots clés offrant des résultats d’une pertinence relative appliqué aux masses de données gérée s’expliquant par l’absence de compréhension sémantique. Cela peut conduire à attribuer de mauvaises clés ou à fausser la valeur d’un objet aux yeux de l’application.

L’axe de conception est double. D’abord offrir à l’utilisateur un outil plus simple, demandant moins de manipulations entre différentes modalités de recherches. Ensuite, permettre une meilleure *recherchabilité*²³² des objets grâce à une compréhension sémantique et contextuelle des données.

a. Conception de l’outil

Nous avons précédemment décrit trois processus : la recherche intelligente, le *Text-to-SQL* et le *Text-to-NoSQL*. Nous avons également énoncé une quatrième possibilité²³³ mêlant

²²⁹Voir Chapitre ?? « ?? » page ??

²³⁰Voir Chapitre I. « La recherche et l’utilisation de la solution dans le logiciel SkinSoft » page 34

²³¹Voir Chapitre I. « La recherche et l’utilisation de la solution dans le logiciel SkinSoft » page 33 page

²³²Anglicisme couramment utilisé dans le milieu de l’informatique et provenant de *searchability*. Désigne la capacité d’un contenu, d’un objet à être recherché correctement et facilement.

²³³Voir Chapitre b. « Les processus *Text-to-SQL* et *Text-to-NoSQL* » page 48

les SRI aux *pipelines* de RAG. C'est ce que l'on appelle l'approche *Text-to-ElasticSearch*²³⁴ sur laquelle repose entièrement la structure de la « recherche augmentée ». Voici un schéma :




FIG. 10 : Schéma d'un *pipeline Text-to-ElasticSearch*.

Cette approche hybride associe les forces d'un SRI à celles d'un *pipeline* de RAG. Associer ces deux éléments permet de :

1. Disposer d'une recherche flexible exploitant la diversité du langage naturel. Le système de mots-clés de ElasticSearch écarte toute notions sémantique pour la seule exactitude orthographique impactant la pertinence résultats. L'intégration à ElasticSearch de NLP, les mots-clés deviennent des marqueurs porteur de sens. Ils sont moins rigide et ouvert à des liens conceptuels ou lemmatique.
2. S'affranchir de la rigidité du schéma de données. Le SQL repose sur un schéma de base de données fixe et des requêtes exactes. Or, la nature des collections patrimoniales produit une variété de « schémas » incompatible avec ce principe. Le NoSQL épouse cette diversité, mais la base de données est trop difficilement interrogeable par le *Text-to-NoSQL*. L'index ElasticSearch offre un entre-deux. Généré pour chaque table de l'application, il repose sur un schéma d'indexation précis et connu à l'avance. Cependant, chaque objet indexé ne possède qu'une sélection de champs s'y rattachant. Ainsi, un LLM connaissant le schéma d'indexation de base peut s'adapter à la diversité de chaque objet.
3. Disposer de fonctions d'agrégations. ElasticSearch dispose nativement de fonctions d'agrégations permettant de répondre à cette attente scientifique. Ce sont des fonctions propres à ElasticSearch qui, dès lors, sont utilisable facilement par le logiciel. En

²³⁴Dongge Xue, Zhili Pu, Zhentao Xia, Hongli Sun, Ruihui Hou, Guangya Yu, Yupian Lin, Yongqi Fan, Jingping Liu et Tong Ruan, « Text-to-ES Bench : A Comprehensive Benchmark for Converting Natural Language to Elasticsearch Query » ().

associant cela à une compréhension des requêtes par LLM, on décuple les possibilités de recherches.

Voici un tableau de différence entre l’approche *Text-to-SQL*, *Text-to-NoSQL* et *Text-to-ElasticSearch* :

Critère	<i>Text-to-SQL</i>	<i>Text-to-NoSQL</i>	<i>Text-to-ElasticSearch</i>
Recherche & tolérance au langage naturel	Correspondance exacte, requêtes qui échouent à la moindre imprécision	Non traité comme un avantage propre dans le paragraphe	Mots-clés enrichis par le NLP : tolérance aux variations typographiques, liens sémantiques et lemmatisation
Structure & schéma des données	Schéma de base de données fixe et rigide, incompatible avec la diversité des collections patrimoniales	Schéma inexistant ou totalement hétérogène : impossible de connaître exhaustivement tous les champs à l’avance	Schéma d’indexation fixe et connu à l’avance, mais champs variables selon les objets indexés (entre-deux)
Fonctions d’agrégation	Disponibles nativement, mais nécessitent des requêtes exactes	Non disponibles nativement	Disponibles nativement et combinables avec une recherche floue

TAB. 5.1 : Comparaison des trois approches

de plus, le *Text-to-ElasticSearch* permet de ne pas trop changer la structure du système de gestion des collections. Prenons l’exemple d’un *pipeline Text-to-NoSQL*, ce processus nécessite une connexion directe avec la base de donnée NoSQL. Or le SRI est un intermédiaire entre l’application et la base de données NoSQL. Cela pourrait conduire à retirer le SRI demandant de repenser entièrement la structure du logiciel. Cela représente un danger pour l’*User Experience Design* et des coûts financiers trop élevés.

Ajoutons que cela permet de respecter l’expérience utilisateur déjà par la conservation du SRI qui maintient un usage préexistant. Les modalités de recherches restent les mêmes de même que l’*User Interface Design*. La « Recherche augmentée » devient ainsi une alternative possible, offrant plus de précision et de puissance à la recherche.

Ainsi, la « recherche augmentée » est pensée comme un assistant de requêtage. D’une requête en langage naturel, le processus détermine les moyens de recherches à utiliser, génère les requêtes correspondantes et les propose à l’utilisateur. En comprenant les besoins utilisateurs, cette fonctionnalité dispense l’utilisateur d’analyser son propre besoin et elle détermine les moyens de recherches pertinents. Elle aboutit à une génération de requête en utilisant toutes les modalités de recherches nécessaire. L’utilisateur est en position de contrôle sur sa requête : il peut la modifier ou l’invalider à tout instant.

Cette fonctionnalité est limitée à chaque table de l’application. Les index Elasticsearch sont générés par table présente dans l’application en fonction des « documents » y étant rattaché et des champs utilisés. De cette manière, récupère le bon index, servant de contexte pour la « compréhension » de la structure des données.

Pour la compréhensions des besoins institutionnels, ce la se fait par la possibilité dans l’application d’inscrire des informations complémentaire pour chaque champs. Elle permettant d’indiquer aux utilisateurs l’utilisation souhaitée d’un champs selon l’institution. Cela permet de modifier la valeur sémantique d’un champs pour chaque table et index. Le processus de RAG se base autant sur l’index Elasticsearch ²³⁵ de la table interrogées, que sur ces informations institutionnelles complémentaires. De cette manière, l’institution peut modifier la « compréhension » d’un champs en lui attribuant une nouvelle valeur sémantique.

Voici un schéma du processus :

²³⁵Voir le livrable technique *index.pdf* disponible sur le dépôt github : <https://github.com/floflo-boop/Livrable-technique>




FIG. 11 : Schéma du processus de « recherche augmentée ».

b. Choix des composants techniques

Avant toute chose, notons que la « recherche augmentée » mise en place au cours du stage n'est qu'expérimentale. Le processus n'en est qu'à un *Proof of concept*²³⁶ représentant un stade basique de développement suffisant pour estimer que la fonctionnalité peut fonctionner. Des changements techniques, dans le processus où les technologies utilisées, sont à

²³⁶Test informatique sans vocation à être diffusé servant à vérifier si un projet est réalisable.

prévoir.

Ici nous explorons le choix des technologies utilisées. La capacité de traitement, leurs puissances et qualité déterminent la fiabilité d'un outil. Le choix dépend de trois éléments : le besoin à satisfaire, les performances attendues et les capacités infrastructurelles et financières. Dans notre contexte, les technologies employées doivent être *open-source* et compatible avec la dimension commercial du produit.

En ce qui concerne le LLM, nous avons choisi le modèle *open-source* et *zero-shot* Gemma-4-31B développé par Google.²³⁷ Il peut être installé localement pour stocker et traiter les données en toute sécurité. Ce modèle peut ingérer jusqu'à 256 000 *tokens* en même temps, permettant la compréhension de contextes longs et détaillés. Il repose sur 31 milliards de paramètres ajustable : c'est un bon compromis entre légèreté du modèle et capacité de réflexion.²³⁸ Il nécessite plus de 65 go de mémoire vidéo et rencontre des difficultés de génération lorsque le contexte à ingérer avoisine sa limite de *tokens*.

Pour l'architecture RAG, l'attention se porte sur deux outils : le modèle de vectorisation et le mode de calcul de similarité. Pour le premier, aujourd'hui nous en utilisons deux :

1. *intfloat/multilingual-e5-small* à 384 dimensions²³⁹. Ce modèle de vectorisation prend en charge le multilinguisme : il peut s'appliquer avec fiabilité à des données dans les langues les plus parlées. L'application étant exportée à l'internationale et permettant l'usage de plusieurs langues, ce modèles est tout à fait pertinent. Les 384 dimensions déterminent la complexité des vecteur qu'il génère. Plus un modèle comporte de dimensions, plus les vecteur générés sont complexes et unique. 384 dimensions représente une moyenne basse, offrant en contre partie plus de rapidité de calcul.²⁴⁰
2. *intfloat/multilingual-e5-base*, la version supérieure au modèle précédent avec 768 dimensions, ce qui constitue une moyenne.²⁴¹ Par exemple, le modèle d'IA BERT qui révolutionné le NLP²⁴², base ses calculs de vecteur sur 784 dimensions. C'est un standard.

Ce second modèle est utilisé de manière conditionnelle. Sur les tables volumineuse et complexe, l'utilisation d'un modèle de vectorisation à 384 dimensions est assez risqués. Les

²³⁷Présentation du modèle Gemma 4, Google AI for Developers.

²³⁸Google/Gemma-4-31B-it · Hugging Face, 20 août 2026.

²³⁹Intfloat/Multilingual-E5-Small · Hugging Face.

²⁴⁰Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder et Furu Wei, *Multilingual E5 Text Embeddings : A Technical Report*, 8 févr. 2024, arXiv : 2402.05672 [cs.CL].

²⁴¹Y. Wang, A. Johnston, Z. Sadokierski, et al., *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums...*

²⁴²J. Devlin, M.W. Chang, K. Lee, et al., *BERT...*

vecteur risquent d'être trop proches. Des vecteur plus précis se distinguent plus facilement ce qui permet de se recentrer sur les liens sémantiques très proches.

En ce qui concerne le calcul de similarité, basé sur les vecteurs, il existe différentes méthodes calculs. Nous utilisons la plus répandue : la similarité de cosinus basée sur une méthode dite KNN.

Très courante dans les modèles de NLP, cette méthode consiste à représenter les vecteur dans leurs espaces multidimensionnel et de calculer l'angle les séparants. Si cet angle est inférieur à 90° , les vecteur sont alors très proches et les similarités importantes. Si il est supérieur à 90° , alors il est fort à parié que ces vecteur n'ont aucune, ou très peu, de connexion.²⁴³ De cette manière, il tri et classe la pertinence des vecteurs par rapport à une requête ou des documents vectorisés.

Ainsi, la présence de deux modèles de vectorisation relativement léger permet de fiabiliser le processus. Cela répond également à un enjeu financier et infrastructurel. Rien que le LLM peut consommer à lui seul jusqu'à 65 go de mémoire vidéo, représentant plusieurs centaines d'euros. on équilibre ainsi les coûts.

Il faut penser que, dans le cadre de SkinSoft, cette technologie va être utilisée par différentes institutions et utilisateurs en simultané. Impliquant des analyses fréquentes de différentes requêtes, sur différents jeux de données. Pour le moment le processus n'est qu'expérimental et n'est donc déployé que sur un serveur dédié avec peu de données.

Mais il est réaliste de penser que ce processus va connaître des déclinaisons technologiques en fonctions des cas d'usages. Des processus plus léger, et moins gourmands pour les bases de données les plus petites. Et des processus plus importants pour le traitement des volumétries et complexité de données bien plus importantes. Cela permet de disposer de deux types d'infrastructures et d'adapter la solution au cas d'usage, et donc d'adapter les coûts potentiels.

c. Conception du parcours utilisateur final

Le parcours utilisateur n'est pas nettement défini. Une spécification à été rédigée afin d'établir les lignes directrices du parcours utilisateurs.²⁴⁴ Il n'y a donc pas de visuel à l'appuis et il s'agira ici de balayer une possibilité d'implémentation avec sa raison d'être.

Il s'agit de la modification d'une fonctionnalité préexistante de recherche et non de

²⁴³ *Qu'est-Ce Que l'algorithme Des k plus Proches Voisins ? / IBM.*

²⁴⁴ Voir le livrable technique *spécification.pdf* disponible sur le dépôt github : <https://github.com/floflo-o-boop/Livrable-technique>

la création d'une nouvelle fonctionnalité. Pour ne pas perturber l'utilisateur, il faut trouver l'équilibre permettant de différencier la recherche simple de la « recherche augmentée » sans les opposer. Elles composent la même grande fonctionnalités : la recherche.

Trois principes clés ont été défini :

1. Transparence afin de permettre à l'utilisateur de comprendre quand il utilise la recherche simple, et quand il utilise la « recherche augmentée ».
2. Stabilité afin que son parcours ne change que très légèrement. C'est à dire ici : permettre l'interrogation de la base de données par des phrases et de ne pas avoir à manipuler les différentes modalités de recherches.
3. Simplicité, c'est à dire de ne pas surcharger l'utilisateur en informations visuelles ou peu utiles.

Ainsi, seul un bouton doit être, à terme, ajouté à côté de la barre de recherche afin de passer de la recherche simple à la « recherche augmentée ».

À son activation, la barre de recherche devient interrogeable en langage naturel. Pour le signaler et être transparent : le bouton d'activation se colorie dans la couleur de l'institution. Le message de la barre de recherche passe de « Rechercher » à « Interrogez-moi ». Et un symbole rouge apparaît dans l'extrémité droite de cette barre de recherche. À son survol, un message se déploie : « Recherche augmentée activée. Vous utilisez l'IA pour interroger vos données. ».

Lors de l'envoi d'une requête, ce processus génère un résumé visible juste à côté de la barre de recherche. il indique : les modalités de recherches utilisées et les requêtes générées pour chacune. Au clique sur l'une de ces modalités, il accède à l'interface dédiée pour la modifier. C'est une fonctionnalité nouvelle qui met en avant les principes de transparences et de simplicité : c'est un moyen de communiquer avec l'utilisateur et de lui offrir un centre de contrôle.

On offre également à l'utilisateur la possibilité de reporter une erreur. En remplissant un formulaire, l'utilisateur peut faire part d'un problème rencontré. Si ce problème concerne l'analyse du LLM ou le modèle de vectorisation, il est utilisé pour leur amélioration. Les modalités sont encore mal défini, mais nous souhaitons utiliser la capacité de *fine-tuning* des LLM sur les rapports pour évoluer en autonomie.

Ce parcours hypothétique montrent qu'il faut repenser non pas l'usage de l'application mais le dialogue entre cette dernière et l'utilisateur. Cela permettant de ne pas repousser ce dernier

d. Analyse réflexive

Ici, nous allons articuler deux éléments. D’abord les résultats obtenus lors du *Proof of concept*. Ce sera l’opportunité d’apprécier l’apport et les limites de cet outil appliqué au logiciel SkinSoft. Ensuite, les différentes difficultés encore non résolues et différentes réflexions sur les évolutions à mener.

Le *Proof of concept* a été mené sur la seule table des archives au sein de l’application ainsi que sur un jeu de données fictif de tests. On ignore ainsi encore son comportement sur plusieurs indexs et des données réelles.

La première limite qui en ressort, c’est la compréhension des dates. Il existe de multiples dates : date de création de l’instrument de recherche, date de création de l’archive ou encore de son entrée dans les collections. Quand on demande à la « recherche augmentée » de rechercher une archive avec une date d’entrée de collections et de création précises, il peut inverser les valeurs. Sur des requêtes plus simples, il arrive à ce qu’il ne reconnaisse pas le bon champs de dates à interroger. Aux yeux du LLM les champs de dates ne sont pas différenciés.

Nous n’avons pas encore détecté l’origine de la confusion. Est ce l’index qui est trop flou à ce sujet ? Ou alors simplement un manque de compréhension pouvant provenir des vecteurs générés ? Ou encore un manque de compréhension du LLM ? Des examens futurs devraient permettre de le déterminer.

La seconde limite est l’utilisation de formulation trop longue et alambiquée. Les vecteurs générés sont bien trop éloignés de ceux des champs présents dans l’index. Plus la requête est simple, plus le vecteur se rapproche de ceux des champs et cela fiabilise le résultat.

La troisième limite, est la prise en charge du multilinguisme. L’application gère les langues d’une manière particulière : chaque application peut disposer d’un certain nombre de langues souhaitées. Ainsi, elle peut remplir ces données dans chaque langue disposées de manière manuelle. Le passage d’une langue à une autre se fait par un bouton de sélection, changeant la langue d’affichage ou des données en fonction. Par défaut, si une donnée n’a pas été traduite dans une langue le logiciel affiche la donnée dans la langue dite principale.

Grâce à ses composants techniques, notre processus peut interroger différentes langues. Une requête rédigée en Anglais interrogera les données disponibles dans cette langue. Cependant, il ne gère les correspondances linguistiques : je ne peux pas requêter en français pour chercher des données en Anglais.

Cette problématique peut se résoudre avec la mise en place d’un autre processus permet-

tant de créer ces correspondances. Il faudrait un LLM capable d'effectuer une telle opération et un outil capable d'accéder aux données dans la langue précisée dans la requête. Ils risquent d'allourdir le processus et être plus gourmand en mémoire vive.

Au delà de ces limites techniques, cet outil pose un certains nombre de questionnement venant redéfinir le parcours utilisateurs ou certaines fonctionnalités.

D'abord, à propos des modalités de recherches. L'application en propose plusieurs²⁴⁵ mais elles peuvent être assez poreuses. Par exemple, la recherche plein-texte ciblée et la recherche avancée permettent d'interroger en texte des livres des champs de données. La première modalité est spécialisée sur cette tâche. Bien que la recherche plein-texte ciblée ne soit pas encore incluse, on se demande si cette dernière sera utilisée par l'outil. Ce qui pose la question de l'usage de cette fonctionnalité à plus large échelle : est-elle vraiment pertinente et utilisée ?

Les réponses pourrons amener soit à dissocier plus clairement la recherche avancée de la recherche plein-texte ciblée. Soit à supprimer la recherche plein-texte ciblée en la confondant avec la recherche avancée, afin de correspondre à une réalité d'usage majoritaire.

Cela montre également que la mise en place d'outil d'IA vient ébranler les acquis applicatifs. Penser la mobilisation de ces fonctionnalités par une IA permet de mettre en évidence leurs fragilités et pousse alors à améliorer l'application sur d'autres aspects.

Finalement, la place et l'usage de cette application est encore assez flous. Le modèle de parcours utilisateurs proposé correspond à un idéal, mais n'a pas encore été éprouvé. Ainsi, des questionnements subsistent encore quant à l'utilisation d'une même barre de recherche pour deux modalités de recherches. Ne faudrait-il pas les dissocier afin de mieux les distinguer ? Ou bien encore, est-il pertinent de maintenir une fonctionnalité de recherche simple si la « recherche augmentée » prend place au même endroit ? À cette question nous pensons que oui, car l'utilisateur doit avant tout avoir le choix d'utiliser l'IA sur ces données ou non.

Un autre exemple de problématique liée à cette fonctionnalité, est celle de sa capacité à générer des résumé. C'est sur ce principe que repose la recherche intelligente, et pendant un moment cela a été envisagée. Nous avons pris la décisions de la rendre muette pour deux raisons. D'abord, pour ne pas créer de confusion avec le chatbot capable de générer des résumés nativement. Ensuite, pour assurer que le processus ne génère pas de données mais utilise celles de l'institutions. Cependant, cela est-il le reflet d'une réalité d'usage souhaitée ?

Ainsi, c'est encore un outil à développer notamment dans des questions d'*User Expe-*

²⁴⁵Voir Chapitre I. « La recherche et l'utilisation de la solution dans le logiciel SkinSoft » page 34

rience Design et d'User Interface Design difficile à cerner. La nouveauté de cette typologie d'outil dans les système de gestion des collections nous invitent à expérimenter et tatôner afin de trouver différentes équilibres. Cela implique d'avoir recours à de multiple étapes de développement dans l'objectif de définir précisément toutes ces notions.

2. Le chatbot :

Ce processus n'a pas fait l'objet d'une *Proof of concept* ou de spécification très définie. Ce n'est encore qu'une idée, un concept assez flous.

Cela tient à plusieurs raisons. D'abord, la « recherche augmentée » a été définie comme plus importante et urgente attirant l'essentiel des efforts. Ensuite, les changements techniques et applicatif à mener pour le chatbot sont plus importants et coûteux que pour la « recherche augmentée ».

Nous allons tout de même aborder cet outil d'abord en présentant les conceptions fonctionnements y étant relié. Cela permet d'ouvrir la discussions sur l'implémentation de cette technologie dans des système de gestion des collections. Nous présenterons également une proposition technique et de parcours utilisateurs. Et enfin une analyse réflexive, qui cette fois ne retracera pas les défis rencontrés mais les défis potentiels.

a. Conception de l'outil

La conception du chatbot n'est en réalité pas très différente de la « Recherche augmentée ». Dans les deux cas, il s'agit de recevoir une requête en langage naturel, de l'analyser et d'y répondre avec les bonnes informations. Ce qui change, c'est la définition que l'on donne à différents concepts et le rôle que ces outils ont.

Pour la « recherche augmentée », il s'agissait de pouvoir améliorer la recherche d'objets patrimoniaux dans la base de données institutionnelles. Ainsi, par « répondre avec les bonnes informations » nous entendons la diffusion dans l'interface des bons objets patrimoniaux.

Pour le chatbot, son rôle premier est de guider l'utilisateur dans l'utilisation de l'application en répondant à ses questions. Ainsi, il doit pouvoir disposer de documentation sur toutes les fonctionnalités de l'application pour alimenter ses réponses. Ainsi par « répondre avec les bonnes informations » nous entendons la génération d'un écrit permettant d'expliquer une fonctionnalité et de présenter des étapes d'utilisations. À terme, il est pensé comme un assistant de production. Pour cela, il devra pouvoir vérifier les métadonnées, leurs homogénéité et leurs propreté au sein même de l'application. Il doit avoir accès à des fonctionnalités et des documents institutionnels.

Voici une représentation de ce processus :




FIG. 12 : Schéma du processus de chatbot.

b. Proposition technique

Ici, nous allons présenter un ensemble d'outils pour chaque besoins du processus imaginé. Ils sont sélectionné au regard des outils utilisés précédemment afin de conserver une cohérence de coûts.

D'abord, il faut pouvoir reconnaître le bon cas d'usage exprimé dans la requête. Il faut ainsi vectoriser requête utilisateur ce qui conduit à réutiliser *intfloat/multilingual-e5-small*. À partir de ces vecteur, des outils peuvent en retirer du sens et faire de la *function-calling* : c'est à dire utiliser le bon codes pour appliquer le bon traitement. Nous proposons d'utiliser *Semantic Router*, un outil d'IA capable d'extraire du sens à partir des vecteur généré et d'effectuer un *function-calling*. Il est léger, local et fiable et peu s'appuyer sur les vecteurs

générer par l’outil en notre possession. Il est également capable de sélectionner le bon index à interroger.

Si le cas définis est celui de l’usage applicatif :

1. En amont à lieu une étape de RAG sur la documentation fournie par SkinSoft sur l’application. On réutilise la même architecture que précédemment : *intfloat/multilingual-e5-small*, le calcul de similarité KNN puis leurs injections dans un index Elasticsearch dédié. De cette manière, la documentation est pré-traitée est accessibles directement dans l’application. Cela permet au chatbot de gagner en rapidité lors de l’interrogation des données et de ne pas rendre cette documentation visible par l’utilisateur. Cette dernière n’est pas encore déterminée, mais cela peut inclure des documents sensible tels que des spécifications ou du code auxquels on ne souhaite pas donner accès.
2. Lors du requête, on se sert des vecteurs afin de les comparer à ceux de l’index dédié. Une fois la bonne documentation trouvée, le modèle *Gemma-4-31B* se charge de récupérer les passages, les analyser et de formuler une réponse.

Si le cas définis est celui de l’assistance à la production alors le procédé change quelques peu. Le problème principal étant les données à traiter. En effet, il existe plusieurs centaines de thésaurus, plus ou moins volumineux, et un nombre exponentiel de notices. La volumétrie des données brutes à analyser est telle qu’une simple analyse par LLM amène le risque d’une saturation totale du processus. Cela peut ralentir le processus, le rendre imprécis voire inefficace. Il faut donc penser à un tout autre processus, par exemple un script python en 3 temps :

1. La librairie python *Polars*. Elle permet de stocker les données dans un format colonnaire²⁴⁶ en mémoire vive. Cela accélère le traitement des données par la suite. Elle permet aussi d’analyser les données et de détecter les doublons, les manques, et erreurs typographiques. Ainsi, on peut repérer l’existence d’un terme en double, orthographié de deux manière différentes, et déterminer lequel garder. *Polars* peut se connecter à l’API d’ElasticSearch et interragir avec ces différents index.
2. La librairie python *Pydantic*. Elle reçoit les données générées par *Polars* et les transforme en format JSON . Ce dernier étant un schéma fixe, cela pousse à reformuler les erreurs trouvées dans une forme standardisée où chaque champs à une signification.

²⁴⁶Les données sont disposées sur une seule colonne et non plusieurs lignes, facilitant le traitement des données

3. Notre LLM *Gemma-4-31B* peu lire le JSON généré, « comprendre » le problème et le reformuler dans un résumé. De cette manière, il communique l’erreur à l’utilisateur et lui permet de se corriger. Par sa capacité de mémorisation et de contextualisation, il garde en mémoire les conversations avec chaque utilisateur sans les mélanger.

Ces processus sont assez léger et souple, ce qui permet de proposer une rapidité de réponse assez satisfaisante. De plus, on réutilise les outils utilisé par la « recherche augmentée » ce qui simplifie l’implémentation technique.

c. Proposition de parcours utilisateurs

Contrairement à la « recherche augmentée » il s’agit ici d’inventer un tout nouveau parcours utilisateur. À savoir une nouvelle interface et une nouvelle expérience devant s’intégrer dans ce qui préexiste.

La réponse à la construction de ces deux élément peut se trouver dans ce qui préexiste au sein de l’application. Afin de ne pas créer de confusion chez l’utilisateur, il faut créer une continuité, une logique graphique et d’expérience. Ainsi, il faut se baser au maximum sur ce qui préexiste dans l’application.

L’expérience est assez simpliste. Le chatbot doit être un outil disponible n’importe où et à n’importe quel moment, pouvant prendre en entrée une requête et afficher un texte en sortie. Pour cela, nous réutilisons la conception du chatbot classique.

En fonction de la requête utilisateurs, le processus s’adapte et utilise certaines technologies dans un certains buts. Ainsi, l’utilisateur n’a pas à modifier des paramètres car le processus se charge d’interpréter et d’appliquer le traitement adapté. C’est une expérience assez intéressante, car elle permet de faciliter au maximum l’utilisation de l’outil.

Ajoutons que le chatbot à une limite définie il ne modifie, ne supprime ou ne créé pas de la donnée directement dans la base institutionnelle. Les IA générative, sont sources de méfiances de la part des professionnels de la gestion des collections. Leurs capacités à générer de la données faussée et de l’inscrire durablement dans les bases institutionnelles et vu comme un danger à la rigueur scientifique de cet univers métiers. En limitant le chatbot à redistribuer de l’information et de l’analyse de cette dernière, on place l’utilisateur au centre de la validation de la rigueur scientifique. L’outil se contente de recommander et expliquer, l’utilisateur modifie selon sa propre volonté. Cet aspect vise à mettre l’utilisateur dans une position de confiance vis à vis de l’outil.

Pour l’affichage, nous disposons d’une zone de requêtage avec un bouton d’envoi, et

d’une zone d’affichage des résultats. Cela constitue l’interface principale avec laquelle l’utilisateur va interagir.

L’affichage et l’activation de cette interface sont des questions aux réponses beaucoup moins définies.

On peut s’inspirer de la saisie tabulaire proposée par l’application permettant la modification des données en grille de recherche. On l’active par un clique sur le bouton dédié puis sur une case. À ce moment, une interface se déploie sur la droite de l’écran provoquant un redimensionnement du reste. On peut s’en inspirer : on crée un bouton dédié au chatbot. À son activation, la même interface se déploie et on peut interagir avec son chatbot. Cependant, cela risque de créer une confusion entre la saisie tabulaire et le chatbot.

Une autre piste est celle de la fenêtre flottante comme cela est d’usage aujourd’hui. Cela permet de placer SkinSoft dans un réseau plus large d’usage de cet outil. Malheureusement, plusieurs problématiques émergent : une fois dépliée, la fenêtre recouvre-t-elle des éléments ? Redimensionne-t-on ce qui existe ? Doit-on laisser un espace vide pour ce déploiement ? Ce sont des questions complexes mettant en jeu l’*User Experience Design* et l’*User Interface Design* de l’application en général ce qui peut sembler risqué.

Une dernière piste est celle des agents conversationnels grand public comme ChatGPT. Ils sont sur une page entière, sans chevauchement d’éléments et sans surcharge de données. Intégré à l’application, on pourrait considérer le chatbot comme une « notice » à ouvrir. Nous aurions ainsi une interface unique dans l’application qui n’entrerait pas en conflit avec ce qui préexiste. Cependant, cela peut briser l’aspect assistant disponible dans l’application à tout moment. Il n’est pas constamment avec nous, il faut aller dans un endroit précis de l’application pour l’interroger.

d. Perspective d’avenir

Ainsi, l’implémentation du chatbot est assez mal définie. Car son intégration dans une solution préexistante impacte de front les rapports existants entre l’utilisateur et son application métier. Ajoutons également que de l’acceptation de la « recherche augmentée » par les utilisateurs dépend le choix d’implémentation du chatbot.

Si l’accueil de la « recherche augmentée » est favorable, cela amène à valider : le choix du LLM et du modèle de vectorisation choisis. Mais aussi le choix d’une architecture technique locale et la disposition des utilisateurs à faire confiance à l’IA au sein d’un environnement de travail. Au contraire, le rejet de cette dernière amène à reconsidérer l’implémentation du chatbot dans un tel environnement.

Comme nous ne disposons pas d’une expérience d’un *Proof of concept* pour le chat-

bot, nous ne pouvons pointer des difficultés techniques réelles. Nous ne pouvons qu’attirer l’attention sur des choix à effectuer et des défis techniques potentiels :

1. D’abord les défis d’infrastructure. En effet, il mobilise finalement bien plus de ressources que la « recherche augmentée » et peut amener à les surexploiter. Il est crucial d’adapter son processus et son *pipeline* technologique à ses contraintes d’infrastructures. C’est pour cela que ce processus est pensé pour éviter d’exploiter le LLM sur d’énorme quantités brutes de données.
2. Ensuite le défis de l’implémentation vis-à-vis d’un équilibre entre la visibilité de l’outil et la surcharge cognitive dûes à l’encombrement de l’espace de travail. La densité d’informations présente et présentée par un système de gestion des collections complexifie l’implémentation de cette technologique. Tout choix d’implémentation devient très complexe. Le chatbot doit respecter l’*User Experience Design* et l’*User Interface Design* applicatif.
3. Enfin, le chatbot souligne le défis de la recherche d’un équilibre entre l’apports de ces technologies IA et les besoins scientifique et métiers. Cela doit amener à placer l’humain au centre de la rigueur scientifique. Il doit donc garder la charge de la décision afin que ce soit lui qui définisse la rigueur scientifique des collections. Ces outils ne doivent être que de simples assistants. Car tendre vers trop d’automatisation, c’est amener à retirer le facteur humain de son propre patrimoine et à corrompre certains éléments. Au delà, cet équilibre passe par une question de sensation et de ressenti à l’usage. Ces outils doivent observer et conserver cet approche profondément humaine.

Chapitre 6

Indexation semi-automatique : conception technique, conception utilisateur et résultat.

La facilité d'usage d'un système de gestion des collections n'est pas le seul frein rencontré. Face à la complexification de gestion de certaine typologie, ces logiciels atteignent leurs limites. C'est le cas de l'image animée dont la description et la gestion sont éminemment complexe.²⁴⁷

Les systèmes de gestion des collections rencontrent aujourd'hui des limites particulières à la gestion de cet objet. À l'image de S-Movies, l'indexation et le stockage de segments vidéos liés à des notices WEMI ne rencontrent pas de frein particulier. Mais l'absence de moyen de traitement et d'indexation automatisée directement intégré à l'application constitue un frein.

Les besoins descriptifs et la réalité de conservation de cet objet font de l'absence d'un module de traitement dédié une limite d'usage.²⁴⁸

Alors disposer d'un outil d'indexation semi-automatisée devient un objectif. Cependant, les tentatives d'indexation semi-automatisée ou automatisée de l'image animée sont aujourd'hui en demi-teinte. Il existe certaines solutions propriétaires, assez peu convaincante dans un usage patrimonial. Et pour l'*open-source*, il n'existe qu'une myriade d'outils traitant de points spécifiques.²⁴⁹

Notons que cet outil fait face à ces propres enjeux bien différents de ceux soulevés par les précédents outils.

²⁴⁷Voir *Chapitre I. « Dans le logiciel Skinsoft »* page 55

²⁴⁸*Chapitre 4. « Complexité et limite de l'indexation des images animées »* page 64

²⁴⁹*Chapitre II. « Outils et réalité technique »* page 65

Pour l’indexation semi-automatisée des images animées, il s’agit bien de produire de la donnée scientifique afin d’indexer les collections. On touche au cœur des missions des institutions conservatrices pour en changer les modalités.²⁵⁰ Cela implique deux contraintes : une haute fiabilité du processus et un parcours utilisateur solide dans un but de transition.

Ajoutons qu’il subsiste également un véritable enjeu de compréhension et d’utilisation de la solution existante. Cet outil doit intégrer la notion de WEMI, rattacher les bonnes données aux bons niveaux et donc réussir à créer et gérer les bonnes notices.

Enfin, l’enjeu le plus délicat est sans doute celui de la flexibilité. La gestion de l’image animée est surtout une question de choix institutionnel : il n’existe pas une unique modalité de gestion comme dans les archives. Les préconisations sont assez permissives et chaque institution peu les adaptées selon ses propres besoins. Notre outil doit faire de même.

En plus de devoir faire preuve de souplesse face aux modalités de gestions, cela doit être fait également pour les besoins utilisateurs. L’exemple de besoin institutionnel que nous avons soulevés n’est pas un cas répandus et d’autres institutions ont des besoins plus simples. Par exemple l’indexation d’extrait déjà créé avec une faible granularité d’information.

La création d’un tel outil est donc particulièrement complexe

1. Conception de l’outil

Nous proposons un processus au plus exhaustif, calqué sur le besoin institutionnel servant de cas d’étude. C’est un besoin complexe permettant la mise en avant des possibilités et limites actuelles dans ce traitement.

Nous avons donc réfléchi à une solution prenant en charge chacun de ces besoins. Elle doit prendre en entrée une bande vidéo et son, la diviser en plusieurs extraits, à savoir scènes et séquences, identifier les personnes et entités présentes et inscrire les bonnes données dans les bons champs.

Nous divisons ce processus en deux parties. Une première partie de traitement de la bande vidéo et sonore afin d’extraire des scènes, des séquences, des œuvres et des métadonnées. Puis une seconde partie centrée sur l’intégration des métadonnées dans les notices WEMI dédiées.

Pour la première partie du processus, voici ce qui a été conceptualisé :

²⁵⁰ Chapitre III. « Enjeux utilisateurs » page 90




FIG. 13 : Schéma du processus d'indexation semi-automatisée.

Ce processus technique à deux objectifs :

Le premier est de reconstituer les scènes et séquences à partir des plans. Les scènes sont des regroupements de plans proches, et les séquences des regroupements de scènes proches chronologiquement. Il y a également une stabilité importante des éléments : mêmes acteurs, même musique, même entités, etc. Par la vectorisation de ces éléments dans un plan, on peut ensuite comparer les vecteur générés et les regrouper par correspondance afin de reconstituer une scène. Le principe est similaire pour la séquence avec l'ajout d'une analyse sonore car la musique et les voix hors champs peuvent donner corps à la séquence.

Le second est la génération de métadonnées sur chaque élément analysé afin de pouvoir procéder à une indexation exhaustive.

1. Notre première étape traite directement les bandes vidéos et sonores. Nous la découpons en plan, donc à chaque rupture visuelle, et isolons les plan de crédits. De cette manière, ont produit des unités de traitement plus petites et légères et on facilite l'extraction des données contenues dans le texte des crédits. Chaque plan est horodaté, c'est à dire qu'on indique à quel moment du film il se place.
2. Dans la seconde étape, l'objectif est d'accélérer le traitement en déterminant une image et un extrait sonore clés par plan. De cette manière, on « résume » un plan en une image présentant le plus d'informations ce qui facilite le traitement. Au besoin, les images adajacentes reste traitable notamment pour mieux saisir les mouvements.
3. Dans la troisième étape, l'objectif est d'identifier tout ce qui compose l'image clés. On génère ici les métadonnées en détectant les objets, les personnes, les personnages et les actions. Toutes ces méta-données sont consignées dans un fichier JSON à la structure fixe de manière à toujours trouver les mêmes métadonnées au même endroit.
4. Notre quatrième étape est la plus importante. On récupère l'image clés, l'extrait audio et le fichier JSON et nous les analysons. Cela produit une description qui viens enrichir notre corpus. Nous nous appuyons sur l'ensemble de ces 4 fichiers pour générer un vecteur par plan représentés par son image clés. Ces métadonnées peuvent être générée avec un appuis sur les thésaurus et autorités stockées dans l'application. Étant donné qu'ElasticSearch stocke ces informations, notre algorithme compare la données générées avec les index en question. Si des vecteur sont proches, alors il s'agit de la même notion et ce qui est stockées dans le thésaurus, par exemple, fait fois. Il utilisera donc ce terme.
5. Pour notre cinquième étape, les vecteurs et horodatages de chaque plans sont utilisé pour recréer les scènes. Deux critères sont observés : la continuité temporelle et visuelle. Des vecteurs de plan très proches indiquent une continuité des éléments visuels et sonore. On peut donc les rassembler en une scène. La seule continuité visuelle ne suffit pas : on analyse la proximité temporelle grâce à l'horodatage. Ainsi, plus deux plans sont éloigné l'un de l'autre moins ils peuvent constituer une scène malgré la proximité vectorielle. À l'issus de cette étape, nous avons nos scènes reconstituée avec un horodatage indiquant son début et sa fin. Enfin, nous recalculons un vecteur pour chaque scène.

Cette cinquième étape possède un second temps de synthétisation des JSON des plans regroupés en scènes pour garantir une stabilité des descriptions. On parcourt

chacun des JSON de chaque plans, on en extrait le sens et on les agrèges en un JSON pour la scène.

6. Notre sixième étape réitère l'étape cinq mais à l'échelles des séquences. Nous ne reviendrons pas sur cette étape qui connaît également un même second temps de traitement.
7. Notre septième et dernière étape reconstitue les œuvres dans le cas où plusieurs co-existent dans la même bande vidéo. On procède de la même manière qu'à l'étape cinq. Si une œuvre ne comporte pas de séquence, on applique le même traitement sur les scènes en lieu et place de notre sixième étape actuelle.

En plus de se conclure sur la reconstitution des scènes, séquences et œuvres, ce processus offre un certains nombre d'éléments essentiels pour la suite. Nous avons des fichiers JSON structurant la méta-données de manière fixe et des vecteur pour chaque plan, scène et séquence. Ces éléments constituent notre bases de connaissances à indexer dans chaque WEMI de notre application.

Cependant, ce premier processus est assez lourd. Sans aborder la question technique, les multiples vectorisation et analyse de ressources de nature différentes alourdissent ce dernier. Ajoutons que les failles sont nombreuses :

1. La reconstitution des scènes et séquences est loin d'être infaillible leurs limites pouvant être flous. C'est notamment le cas de la séquence où l'analyse des thèmes et sujets est centrale. Il pourrait être pertinent d'ajouter une nouvelle étape d'analyse par LLM dans ce but. Cependant cela peut alourdir le processus sans garanti d'une meilleure détection.
2. La détection d'images clés limite fortement le champs d'analyse. Il est possible d'exclure des éléments qui ne seront donc pas analysé ce qui fausse les résultats obtenus.
3. La reconstitution des œuvres reste expérimentale. Aucun travaux n'a été mené sur ce sujet, ainsi rien n'en garantit le fonctionnement.
4. La génération de fichier JSON est également problématique. En cas d'erreur d'analyse par nos outils, la correction manuelle demande à entrer et corriger le fichier JSON . Il faut donc en connaître la structure afin de pouvoir se repérer et comprendre ce que l'on modifie. Cela peut demander des compétences techniques.
5. Enfin, la génération des métadonnées en elle même pose certaines problématiques. Comme vus précédemment, ces métadonnées s'appuient sur des référentiels tels des thésaurus. Ici, il n'y a aucune garanti du respect de ces derniers car cela dépend des rapprochements que l'IA sera capable de faire.

Notre deuxième partie de processus consistent à redistribuer les métadonnées dans les bonnes notices WEMI et de les stocker. Voici une représentation de cette deuxième partie de processus :




FIG. 14 : Schéma du processus d'intégration des données générées par le traitement des images animées.

Grâce à la première partie du processus, nous disposons des méta-données à mettre dans les bons champs et niveaux WEMI ainsi que des vecteurs des plans, scènes et séquences à associé aux notices correspondantes.

Le cœur de ce processus se situe à notre étape 2. Il s’agit d’assurer l’intégration de ces différentes ressources aux bons endroits applicatifs. Pour les méta-données, il s’agit d’établir des règles de correspondances entre les champs de nos JSON et ceux champs de notre index Elasticsearch rattachés aux bons WEMI. Grâce à la stabilité du JSON et des champs Elasticsearch, on s’assure de la répétabilité de la procédure.

Pour cela, on établi la structure du JSON et la correspondes des champs en amont. Ainsi, on donnera à nos différents outils les *templates* à remplir en fonction de ce qui est attendu. Chaque *template* sera dors et déjà compatible avec les champs Elasticsearch ciblés.

Les vecteurs étant associé aux JSON , ils seront automatiquement rattachés aux bonnes notices items. L’avantage de les stocker dans Elasticsearch est de permettre, par la suite, l’utilisation de la « recherche augmentée ». On peut imaginer une utilisation alternative de cette dernière centrée sur la table des médias. Une requête basée sur une description d’une action ou d’un thème créer un vecteur comparable avec ceux des plans, scènes et séquences. Ce qui permet donc de rechercher des extraits par des requêtes imprécises.

2. Proposition de conception technique

Ici, nous allons proposer des outils à utiliser pour ce processus. Notons cependant qu’un tel processus demande des technologie variées. Un effort de réutilisations des mêmes technologies à été menée. Ajoutons que, bien que non estimée, la mobilisation de toutes ces technologies demande des ressources informatiques importantes.

Nous allons prendre chacun de nos deux traitements et présenter les outils à utiliser pour chaque étape en nous concentrant sur leur utilisation dans notre processus.

Commençons par notre processus de traitement²⁵¹ qui articule au sein d’un script python :

1. Pour la première étape, nous utilisons PySceneDetect²⁵², FFmpeg²⁵³ et le VLM *SmolVLM2-2.2B-Instruct*²⁵⁴. En combinant la détection des ruptures visuelles de PySceneDetect

²⁵¹Voir figure 13 page 115

²⁵²Voir Chapitre 1. « Manipulation de l’image et des plans » page 72

²⁵³Voir Chapitre 1. « Manipulation de l’image et des plans » page 71

²⁵⁴*HuggingFaceTB/SmolVLM2-2.2B-Instruct* · *Hugging Face*, 6 mai 2024.

et la manipulation vidéo de FFmpeg, on extrait tous les plans. Avec *SmolVLM2-2.2B-Instruct*, on pourra dès lors lire les crédits et les stocker dans le fichier JSON dédié. Nous proposons ce modèle car il est très léger, pesant 2,2 giga octets seulement, tout en étant précis et fiable.

2. Pour notre seconde étape, l'extraction d'une image clé d'un plan et de son extrait audio, FFmpeg l'intègre nativement. C'est une fonction dédiée basée sur la détections des points clés des images et sur la sélection de celles en contenant le plus.
3. Pour notre troisième étape, afin d'identifier et reconnaître les entités, les personnes et l'ambiance sonore nous utilisons 3 outils. SAM2 pour la segmentation et leu suivis des objets²⁵⁵. FaceNet pour la reconnaissance de visages²⁵⁶. Puis QWEN2-Audio pour l'analyse de la bande son.²⁵⁷. L'application successive de ces outils, dans un ordre à définir, permet d'identifier les célébrités et d'analyser l'ambiance sonore ainsi que les entités présentes.
4. Pour notre quatrième étape, celle de vectorisation des éléments identifiés, il y a deux approches possibles :

L'utilisations de *SmolVLM2-2.2B-Instruct* et QWEN2-Audio pour générer des analyses sémantiques textuelles. Sur ces analyses, nous appliquons notre modèle de vectorisation déjà éprouvé *intfloat/multilingual-e5-small*, ou *intfloat/multilingual-e5-base*, pour générer des vecteur. La problématique se situe dans le fait qu'on génère des vecteur sur du texte et non à partir de l'image ou du son. Cela implique un intermédiaire pouvant créer un décalage.

Ou l'utilisation de modèles multimodaux comme CLIP²⁵⁸ capable d'analyser aussi bien le son que la vidéo. Contrairement aux processus précédent, les vecteur générés par CLIP à partir des vidéos et sons et non d'analyse textuelles précédemment générées.

5. Pour notre cinquième étape, nous avons recours à une matrice de proximité. C'est une méthode de calcul tabulaire permettant d'établir le degré de similarité entre deux objets à partir de différents éléments. En somme, cela permet d'établir des proximités entre les plans selon leurs vecteur et leurs horodatages. Ainsi, deux plans à l'horodatage proche seront plus facilement rapproché que deux plans à l'horodatage très éloignés. Cela permet d'éviter de consituer des scènes avec des plans éparpillés dans la bande vidéos.

²⁵⁵Voir Chapitre 2. « Segmentation d'une image animée » page 74

²⁵⁶Voir Chapitre 4. « La reconnaissance de lieux et de personnes » page 80

²⁵⁷Voir Chapitre 6. « Le traitement des pistes audios » page 84

²⁵⁸Chapitre 5. « Les VLM » page 81

6. Pour la deuxième partie de cette cinquième étape, nous utilisons notre LLM *Gemma-4-31B*²⁵⁹ afin d’analyser tous les JSON des plans rassemblés et de constituer un JSON pour la scène.
7. Pour les séquences et œuvre, aux étapes 6, 6 « bis » et 7, nous réitérons ce traitement. En effet, le traitement n’est guère différent si ce n’est qu’on ne l’applique plus aux plans mais aux scènes. Cela ne nécessite pas de changement.

Pour le processus d’intégration des données dans l’application, les technologies sont déjà présentes. En effet, pour notre étape numéro 3 sur le stockage et la mise à disposition des données dans ElasticSearch, c’est le logiciel qui s’en charge. Nous n’avons donc pas d’ajout à effectuer.

Cependant, l’étape précédente d’injection des données demande une technologie précise afin de créer les correspondances de champs entre les JSON et ElasticSearch. La librairie *Pydantic*, déjà utilisée pour la *recherche augmentée*, permet d’établir et de vérifier ces règles en amont. L’intégration est alors exécutée après validation des fichiers JSON. Les vecteurs sont quant à eux déjà pris en charge par un module spécifique d’ElasticSearch.

Ce processus mobilise un grand nombre de technologies différentes, certains sont assez volumineux même lorsqu’on prend les options « légères ». Nous pensons notamment aux VLM et ALM qui mobilisent énormément de ressources.

Le poids du processus est donc conséquent. Il s’agit de procéder à énormément de calculs complexes dans une chaîne de traitement itérative. En effet, elle s’applique sur chaque image clé de chaque plan sachant qu’une œuvre cinématographique peut se composer aisément de plus de 1000 images clés. C’est donc un processus long, répétitif et très demandeur en ressources. Modifier le processus pour traiter toutes les images clés en lots, et non successivement, ne représente pas une solution. Cela risque de saturer la mémoire vive et les capacités des outils conduisant à des hallucinations.

3. Proposition de conception du parcours utilisateurs

Nous allons ici procéder à une analyse afin d’identifier les points d’attentions en terme d’*User Experience Design* et d’*User Interface Design*.

D’abord, le processus présenté est pensé comme étant interne à l’application. Ce qui demande donc de le connecter à des éléments déjà présents afin de ne pas perturber l’utilisateur. C’est ce que nous avons fait avec la « recherche augmentée ». Dans SkinSoft l’utilisateur

²⁵⁹Voir Chapitre b. « Choix des composants techniques » page 101

à la possibilité d'intégrer des fichiers dans le logiciel par simple « glisser / déposer ». On peut alors penser qu'au moment de déposer une vidéo, l'application génère une fenêtre d'interaction demandant à l'utilisateur de choisir soit une intégration simple, soit l'indexation semi-automatisée.

Il faut établir un choix et message clair, permettant de faire comprendre qu'il ne s'agit de produire automatiquement une indexation mais d'en suggérer une. À ce titre, l'humain garde son rôle de décisionnaire et peut valider, modifier ou invalider la production. Si l'utilisateur choisit l'indexation semi-automatisée alors le processus décrit s'applique. Cependant, ce processus doit s'appliquer sous contrôle de l'utilisateur. Ce qui demande donc une interface et une expérience d'utilisations.

Cela nous amène à la notion de choix. Notre processus est complexe et prend en charge divers aspects de traitement. La division d'une vidéo à différentes échelles, l'extraction de différentes données et la création de notices WEMI pré-remplies. Chacun de ces aspects demande des choix utilisateurs.

En premier lieu, il se peut qu'un utilisateur ne souhaite pas diviser sa vidéo en unités plus petites notamment car il s'agit déjà d'un extrait. Il faut donc offrir cette possibilité.

Ensuite, il se peut que l'utilisateur souhaite créer l'item d'un WEMI préexistant. Auquel cas, l'analyse des crédits et l'analyse d'éléments appartenants aux niveaux œuvre et expression ou manifestation ne sont pas nécessaires.

Enfin, il se peut également qu'un utilisateur souhaite seule compléter des notices préexistantes. Cet usage implique un changement de la fonctionnalité afin qu'elle s'applique sur des éléments préexistants, et des champs déjà remplis.

Chacun de ces cas d'usages place la notion de choix au cœur de l'*User Experience Design* et de l'*User Interface Design*. Cela implique que la fonctionnalité doit être hautement modulable afin de répondre à différentes attentes simples comme complexes. Ainsi l'*User Experience Design* doit être basée sur la notion de choix et l'*User Interface Design* doit présenter une interface permettant à l'utilisateur de moduler la fonction. Cela peut se faire via la sélection ou désélection de certaines options de traitements.

De plus, il faut offrir la possibilité de modifier, valider ou invalider le travail effectué à chaque étape de traitement. Par exemple, le découpage en plans, scènes ou séquences peut ne pas être satisfaisant, ainsi une interface doit permettre de modifier cela simplement. Cela doit aussi être valable pour les données générées dans les JSON. Il faut penser à une façon de présenter les informations en retirant l'aspect technique du JSON. Cela peut être par une

pré-visualisation de la notice créée avec les champs pré-remplis avec les données correspondantes. Les modifications effectuées ici se répliquent ensuite sur le fichier JSON .

En somme, l'intégration des questions du parcours utilisateurs, centré sur une approche *human in the loop*, complexifie techniquement le processus. Notamment en imposant divers stade de gestion d'erreur et une modularité du code.

De plus, le nombre d'éléments à prévoir en terme de validation et d'étape de contrôle demande une interface dédiée. Ce qui amène à complexifier encore le système de gestion des collections par l'ajout d'une fonctionnalité supplémentaire avec sa propre expérience et interface.

4. Apports et limites

Le processus que nous avons dépeint met en lumière plusieurs éléments quant à la possibilité de s'appuyer sur des processus semi-automatisé pour traiter de telle typologie. Mais il est important de mettre en lumière l'apport de ces outils, mais aussi leurs limites. L'indexation semi-automatisée est une solution très contrastée, renouvelant des problématique et en créant de nouvelles.

Ce processus, qui n'a pas encore fait l'objet d'un *proof of concept*, semble ouvrir la voix au traitement automatisée de cette typologie documentaire. Différents outils sont aujourd'hui articulable afin de répondre aux besoins les plus précis de traitement de cette typologie documentaire. Mais ce processus tout à fait conceptuel présente des difficultés majeures.

Ce processus présente deux avantages majeurs. Le premier est la possibilité de traiter des œuvre d'image animée de plusieurs heures à la chaîne, et sans interventions humaine. Cela permet de décharger l'utilisateur de l'analyse manuelle de plusieurs heures de bande vidéos, et lui permet de s'occuper d'autres tâches. Le second avantage c'est ça répétabilité. Par la production de JSON dans un format fixe et interfacée avec les index Elasticsearch concernés, ce processus est très stable. On s'assure d'extraire les mêmes métadonnées et de les intégrer toujours au même endroit.

Il faut ajouter à cela qu'il reste simple d'usage. Il suffit d'entrer une œuvre, de laisser le traitement s'accomplir, puis de contrôler à chaque étape afin de rectifier. Le seul défaut, est que la plus part des outils ne peuvent pas faire l'objet d'un *fine-tuning*. Prenons l'exemple de PySceneDetect, il s'appuie sur la *computer vision* algorithmique c'est à dire sans IA. Si les détections de changements de plans sont erronés, la correction manuel par l'utilisateur n'entraîne pas d'améliorations à long terme.

Nous pouvons également dire qu'il reste largement flexible. Par exemple, le modèle

SAM2 est parfaitement compatible avec un modèle YOLO²⁶⁰ pour la détection et l'identification d'objets précis. Ou bien encore le modèle FaceNet peut s'entraîner sur une base de données constituée par l'institution pour détecter des personnalités précises. De cette manière, le processus est très souple et offre diverse possibilité d'adaptation intéressante.

Les limites sont également nombreuses. D'abord l'absence de reconnaissance de la typologie de l'image animée. En effet, dans ce processus nous n'avons pas incorporer ce principe de détection typologie car nous ignorons l'efficacité de ces technologies à accomplir cette tâche.

En effet, les VLM et modèles multimodaux sont entraînés pour déterminer et décrire ce qu'il se passe au sein d'une image ou d'une scène. Ils peuvent aller plus loin par des analyses colorimétriques, et sonore avec des ALM, afin de déterminer le ton du film, le sentiment qui s'en dégage. Cependant, nous n'avons rien trouver au sujet de leurs capacité à distinguer un film muet, d'un film en couleur et sonore, d'un film d'animation.

Sans que cela semble impossible, aujourd'hui les outils que nous possédons sont trop peu entraînés et spécialisé sur ce domaine. D'autant que la typologie d'un objet patrimonial peut ne pas correspondre à une typologie publique. Ajoutons également que certaines typologie se distingue par des nuances très fines. Par exemple comment distinguer une image animée professionnelle d'une image animée amateur ? Elle se distingue par les moyens de productions, la possibilité de reconnaître les personnes qui s'y trouvent et la présence d'une construction sémantique de l'œuvre. Mais toutes ces dimensions semblent difficile à être prise en compte.

Ajoutons à cela la fiabilité des métadonnées générées. Concernant la fiabilité, nous en revenons à notre problématique d'hallucination des modèle d'intelligences artificielles sur lequel nous n'avons que peu de contrôle. Étant au cœur des données patrimoniales, puisqu'il s'agit de la produire, le contrôle de ce phénomène est important.

²⁶⁰Voir <https://www.ultralytics.com/fr/yolo> pour plus d'informations

Chapitre 7

Impact potentiel des outils sur les données et collections patrimoniales

Ces innovations technologiques promettent des évolutions importantes pour les systèmes de gestion des collections et le monde professionnel concerné. Elles ont pour but d'accompagner les professionnels face aux nouveaux défis et enjeux de la gestion des collections. Pour cela, on a identifié trois axes d'améliorations :

L'axe de l'accessibilité aux données stockées, par une recherche plus intuitive et puissante qu'est la « recherche augmentée ». Celui de l'accessibilité applicative et d'appui à la production, pour une meilleure maîtrise de son environnement de travail, ce qu'aborde notre chatbot. Et enfin celui de la production massive des données patrimoniales par un processus d'indexation semi-automatisée des images animées.

Ces outils sont pensés pour « révolutionner » ces trois axes par l'apport de solutions simples, immédiates et fiables. Nous avons démontré que cela n'est pas réellement possible, ces outils étant faillibles et hautement évolutifs.

Mais il faut surtout comprendre que de tels outils ne « révolutionnent » pas la gestion des collections patrimoniales mais impactent profondément diverses couches de cet univers métier. L'impact de ces outils n'est pas seulement technique, il est aussi juridique et éthique venant jusqu'à questionner et redéfinir des acquis.

Ainsi, pour chaque outil nous allons aborder de front les questions soulevées par leurs implémentations dans les systèmes de gestion des collections, au cœur des pratiques et données des collections patrimoniales.

1. La recherche augmentée

Cet outil à une position intéressante car il s’agit, finalement, de transposer les pratiques de recherche grand public sur internet dans le logiciel. Ce qui dès lors créer des porosités entre notre position d’utilisateur d’internet, et celle d’utilisateur de logiciel métier. Nos pratiques publiques influent sur notre conception de concept que l’on retrouve dans le domaine professionnel, ce qui amène à un effort de création de lien entre les deux mondes afin d’unifier les pratiques.

Finalement cet outil amène à mélanger aux pratiques professionnelles, des pratiques et attentes « grand public ». Aujourd’hui, lorsque l’on utilise un moteur de recherche, on formule instinctivement une phrase. Avec les agent conversationnel, c’est une dimension encore plus forte, qui entre de plus en plus dans nos habitudes. Ainsi, un mode de recherche traditionnels par mots-clés, provoque un sentiment de frustration même au sein d’un logiciel métier.

Cela pose donc un questionnement éthique important sur cette porosité entre l’usage public et l’usage professionnel. À quel moment l’infusion d’attentes et de pratiques « grand public » dans des logiciels métier doit-elle s’arrêter ? On peut peut penser au moment où de telles pratiques mettent en danger les valeurs fondamentales de l’univers professionnels.

Juridiquement, cela pose les entreprises fournisseuses de système de gestion des collections, comme SkinSoft, dans une position délicate. Elle propose un outil d’IA traitant, sur son propre serveur, des données patrimoniales d’une institution tierce. Juridiquement, cela pose l’entreprise comme responsable de la conservation des données et de leurs sécurités. Cela demande un contrôle total du traitement exécuté sur les données par le processus.

Cette double responsabilité est encadrée par le RGPD.²⁶¹ Mais le développement de tels outils et leur popularité croissante dans ce contexte, peut amener à questionner sa pertinence. Ou plutôt son application à de tels processus demandant des redéfinitions juridiques pour un meilleur encadrement dans ce domaine.

2. Le chatbot

Pour le chatbot, nous pouvons retrouver les mêmes considérations juridiques dès lors que nous le pensons comme assistant de contrôle de la qualité des données. Son accès aux données patrimoniales et sa capacité à les traiter pose les mêmes questions juridiques.

Mais ce n’est pas l’aspect le plus important de cet outil. Les implications et enjeux sont bien plus d’ordre éthique et des pratiques métiers, que de l’ordre juridique.

²⁶¹Voir *Chapitre III. « Le cadre juridique : »* page 26

Le premier élément est la redéfinition du rapport de l'utilisateur avec ses propres données. En effet, disposer d'un moyen de contrôle rapide, accessible et efficace peut-il impacter la productivité ? La possession d'un moyen de contrôle alimenté par de l'IA peut pousser à croire à une infaillibilité de ce dernier et donc à baisser sa vigilance. Sans être une conséquence inévitables, c'est une considération éthique qu'il convient d'observer.

Cela questionne directement le type d'outils que l'on doit et peut offrir dans un système de gestion des collections. Comment les concevoir afin de constituer un outil d'appui sans remplacer l'utilisateur humain ou créer un relâchement de sa vigilance ? Où se situe la frontière entre l'outil d'appuis, et l'outil de remplacement ?

Le chatbot entre directement dans ces questions. Automatiser des tâches de contrôle et d'assistance par IA ne risque-t-il pas de modifier trop profondément le rapport de l'utilisateur à son logiciel métier ? Trop de simplicité apporté par des outils provenant du quotidien, peut-elle représenter un danger pour la productivité et la posture professionnelle des utilisateurs ?

Nous ne saurons apporter de réponses. Cependant, il est certains que des réflexions éthiques et méthodologiques seront à mener vis à vis de ces outils. Il faut peut être envisager d'encadrer les pratiques utilisateurs, en commençant par limiter l'impact de ces outils sur un équilibre professionnel préexistant.

3. L'indexation semi-automatisée des images animées

Mise à part des enjeux techniques et des questions d'*User Experience Design* et d'*User Interface Design*, cet outil remet en question des principes fondamentaux.

D'abord le principe de rigueur scientifique. Contrairement à la « recherche augmentée » ou au chatbot, ici on génère de la donnée à valeur scientifique. Ce processus s'appuie sur des formes d'IA générative : les LLM, VLM et ALM. La génération des données par ces outils peut être compromise par des hallucinations impactant la qualité des données et donc la rigueur scientifique.

Nous en revenons à la même problématique rencontrées avec la « recherche augmentée ». La particularité ici est qu'une architecture RAG n'est pas applicable. Cela contraint à adopter des architectures *human in the loop* assez lourde, pouvant compromettre le gain de temps que l'on cherche à obtenir. Il faut donc penser et établir de nouveaux procédés de contrôles des hallucinations afin de certifier une rigueur scientifique suffisante.

Ensuite, le principe de confiance. Fragiliser la véracité des informations des bases de données institutionnels amène à provoquer des doutes dans l'usage de ces applications et dans la données produites. Ce qui, à plus large échelle, peut conduire à une méfiance du public auquel on diffuse ces informations.

On entre ici dans un domaine flous, à la croisée entre le procédé technique et les questions d'*User Experience Design* et d'*User Interface Design*. Habituellement, ces deux domaines permettent de rassurer l'utilisateur dans son usage d'une fonctionnalité. Mais devant la complexité de ces processus et les risques d'hallucinations, cela ne semble plus être suffisant. Il y a donc une demande de nouveaux moyens.

Il se pose également la question de la provenance des données indexées. Les institutions conservatrices ont l'obligation de retracer la provenance des données conservées. On entre dans une limite juridique et éthique au sujet de l'IA. Doit-on préciser que cela à été extrait par IA ? Ou doit-on pousser l'IA à citer les sources ? Le cadre juridique impose de préciser quand un contenu est généré par IA²⁶². Mais lorsqu'il s'agit d'une donnée produites dans de tel processus, où l'IA ne sert que d'extracteur, devons-nous le préciser ?

Ainsi, il y a une redéfinition profonde des pratiques métiers dans la conservation du patrimoine. L'utilisateur du système de gestion des collections n'est plus créateur de la données, mais vérificateurs et validateurs ce qui change le paradigme.

4. Conclusion

Finalement, l'implémentation de tels outils possède trois niveaux de complexités. Technologiques d'abord, car les problématiques, défis et attentes sont hétérogènes et complexes. De l'ordre éthique ensuite car leurs implémentations et usage bouleverse des pratiques et valeurs portées par le monde de la gestion des collections. L'adaptations à ces éléments et nécessaire, mais il existe un fossé important pouvant demander une adaptation inversée. Et enfin juridique car ces outils peuvent être assez opaque et représenter des menaces face au principe de gouvernant des données.

Nous sommes aujourd'hui au début de ces transformations profondes. Les outils ne sont pas encore mûr, et leurs utilisations professionnelles dans la gestion des collections pas encore effective. Cependant, elles annoncent dors et déjà des transformations importantes de cet univers professionnelles qu'il nous faut maîtriser et diriger.

²⁶²Voir *Chapitre III. « Le cadre juridique : »* page 26

Conclusion

Patrimoine et gestion des collections sont des domaines étroitement liés, actuellement en proie à des difficultés exarcebées et, pense-t-on, à l’aube d’une révolution technologique.

La double hétérogénéité des collections, des données informatiques générées ainsi que leurs masses sont aujourd’hui des problématiques fondamentales. Chaque typologie patrimoniale connaît ses propres normes et standards de descriptions, ainsi que ces propres modèles conceptuels de gestions. Leur numérisation duplique les obligations et besoins de gestion, comme nous l’avons vu avec l’image animée où cette double nature amène de doubles enjeux de conservations. Et enfin, leurs masses, dûs au phénomène de *Big Data*, complexifie les efforts d’harmonisation et de gestions.

Les systèmes de gestion des collections sont au cœur de nos pratiques de gestion des collections. Plus que de simple registre numérique, ce sont de véritables outils stratégiques afin de piloter la vie des collections et institutions conservatrices. L’évolution des difficultés et des besoins dans ce domaine ont toujours amenée ces logiciels à s’adapter. L’intégration des normes et standards, l’application de l’interopérabilité des données et des modèles conceptuels sont aujourd’hui prise en compte, comme nous l’avons vu avec la suite SkinSoft.

Mais aujourd’hui, la *Big Data* amène un renouveau des difficultés et ne ces derniers ne semblent plus disposer des moyens de s’y adapter pleinement. Le problème majeur se situe en amont du logiciel : lors de la production et de l’intégration des données. Par exemple, pour l’image animée les systèmes de gestion des collections ne proposent pas de solution concrète de facilitation d’une indexation fastidieuse. Situé au cœur de ces derniers, l’indexation humaine de telles typologies patrimoniales est aujourd’hui limitée. Elle ne permet plus de traiter à un rythme suffisant la masse de données entrante. Ajoutons que les modalités de gestion très spécifiques et maléables de ces typologies rendent leurs intégrations de manière simple et ergonomique assez complexe à établir.

Ces logiciels ont alors deux limites principales face aux évolutions des pratiques aux enjeux du *Big Data* dans notre milieu. D’abord fonctionnelle, car ils n’arrivent plus à faciliter les processus d’indexation et de gestion des données entrantes dans des modèles de gestion complexes. Ensuite ergonomiques, car la nature complexe de ces logiciels n’offre plus de moyen de repères suffisant afin d’aborder sereinement cet outil de travail.

Aujourd’hui, l’IA est en plein essor et se fait remarquer par sa capacité de traitement en autonomie de très grandes volumétries de données. Mais également pour sa capacité d’interaction avec d’autres logiciels.

Dans le domaine patrimonial, nous sollicitons surtout les technologies de NLP, RAG et de *computer vision*. L’utilisation de ces outils est paradoxale : rapidement utilisés de différentes manières pour le patrimoine, la recherche semble aujourd’hui préférer une utilisation pour l’ac-

cessibilité grand public. Leurs applications à la sphère professionnelles pour la production de métadonnées s’oppose à des principes de rigueur scientifique. En effet, leurs capacités à halluciner constitue un risque de corruption du bien fondé des bases de données institutionnelles. Vraisemblablement, cela amène à repousser le moment d’intégration de ces outils.

Cependant, ces technologies propose des pistes prometteuses pour soulager, si ce n’est résoudre, la plus parts des difficultés actuelles des systèmes de gestion des collections. Le RAG et le NLP sont prometteur afin de permettre des recherches plus naturelles, fines et faciles dans sa propre base de données. La capacité de ce dernier à « comprendre » le langage humain semble en faire un parfait intermédiaire entre l’application et l’humain. Pour la *computer vision*, c’est sa capacité à analyser des images, identifier et exploiter des caractéristiques clés dans des résumés sémantiques qui représente une voie d’amélioration de l’indexation de l’image animée.

Ces outils peuvent répondre aux difficultés fonctionnelles, par des processus d’indexation automatisée en interaction avec des thésaurus par exemple. Mais aussi aux difficultés ergonomiques en facilitant l’accessibilité à l’outil et aux données, peut être même jusqu’à appuyer l’homogénéisation des données. De tels outils semblent être prometteurs pour appuyer les professionnels dans leurs diverses tâches de production et d’utilisation des systèmes de gestion des collections.

Ces outils n’ont pas encore été pensés pour une intégration au cœur de système de gestion des collections. Cela pose donc la question de la faisabilité technique et de l’impact potentiel sur les pratiques et fonctionnement de ces logiciels.

Nous avons donc suivi cette piste en se demandant comment intégrer de tels technologies dans le logiciel SkinSoft, dans quel but et surtout quels en sont les enjeux. Cela à aboutit à explorer les deux axes à l’aide d’outils pensé pour appuyer les professionnels. D’abord l’axe ergonomique avec la « recherche augmentée » pour une amélioration de la pertinence des résultats et une facilité d’interrogation des données institutionnelles. Mais également avec le chatbot, pensé pour accompagner l’utilisateur dans son utilisation de l’application et ses missions de contrôle de la qualité des métadonnées indexées. Mais également l’axe fonctionnel avec l’indexation semi-automatisées des images animées, représentant un volume très importants de données à intégrer selon des exigences normatives variables et exigeante.

Nos différentes explorations, encore très conceptuelles, de ces outils nous amène à différents constats. D’abord, l’inégalité des contraintes techniques et des faisabilités technologiques. Des processus comme la « recherche augmentée » sont aujourd’hui basés sur des technologies plus stables et moins gourmandes en ressources qu’un processus d’indexation semi-automatisée de l’image animée. Ce dernier semblant dès lors bien plus inaccessibles que

la « recherche augmentée », à cause de sa complexité et de sa demande en ressources complexe à satisfaire.

Nous démontrons que la réussite de ces outils ne dépendent pas de ces seuls question. Ce sont en effet des conditions préalables à la réalisations de ces outils, mais l'enjeu final de l'adoption de l'outil réside dans d'autre domaine. À savoir l'*User Experience Design* et l'*User Interface Design*, en charge de la facilité d'utilisation de ces outils. De cette facilité d'usage dépend l'adoption de ces outils par les professionnels du patrimoine. C'est finalement ce degré d'adoption de l'outil qui transforme ou non nos pratiques. Ce qui finalement place les questions d'*User Experience Design* et d'*User Interface Design* au cœur des enjeux.

De plus, de tels outils s'inscrivent dans un cadre réglementaire et technique strict. Le patrimoine et la gestion des données sont riches en contraintes et exigence. La souveraineté des informations, la protection du droit d'auteur, et la conformité au cadre juridique de l'*AI Act* sont des enjeux capitaux. Plus que la performance, un bon outil d'appui aux professionnels dans un système de gestion des collections est avant tout un outil respectueux et conforme à cet univers.

Sur le plan éthique, l'intégration de tels outils est aussi problématique. Ils questionnent des valeurs d'honnêteté, de rigueur et d'exhaustivité scientifique dans les bases de données institutionnelles. Combinés aux facteurs juridiques, cela réaffirme que l'automatisation ne peut être totale. L'approche de ces outils doit être évolutive et prudente. Cela passe par des architectures (*human-in-the-loop*), demeurant la condition *sine qua non* d'une exploitation éthique, pérenne et acceptée.

Finalement, l'implémentation d'outils d'IA peu permettre de répondre aux défis actuels de deux manières. D'abord par l'augmentation de l'accessibilité et de la facilité d'usage des système de gestion des collections et des bases de données patrimoniales. Bien qu'assez largement ignorés aujourd'hui, nous avons démontré que la première limite de ces logiciels viens de leurs propres architecture logicielle. Les chatbots et recherche assistées par IA peuvent permettre d'en améliorer l'accessibilité, d'en facilité l'usage et d'offrir des expériences d'utilisations plus confortables créant de meilleur conditions de productions.

Ensuite par l'automatisation relative de chaîne d'indexation sur certaines typologies documentaires. Bien que notre essais sur l'image animée ai montré toute la complexité et les limites d'un tel processus, on peut penser qu'appliqué à des objets plus structuré et traités comme des archives, de tels processus puisse être réalisable. Cependant, la consommation de ressources de ces outils et les danger de l'hallucination demandent à en relativiser l'application.

Cette étude nous permet finalement de répondre à notre problématique initiale. Ces technologies peuvent améliorer nos utilisations des systèmes de gestion des collections et nos capacités d'indexations, sans pour autant les révolutionner étant donné leurs limites. Ainsi, ils ne peuvent remplacer l'expertise humaine. L'arrivée de ces outils dans tels domaines de production amènent des réflexions éthiques et juridique qui convergent vers leurs rationalisation pour en faire des outils d'appui, de facilitation et non de remplacement.

Loin de « dénaturer » nos pratiques, il est naturel que ces dernières évoluent sans pour autant changer drastiquement. Et il est aujourd'hui de notre responsabilité d'ériger ces cadres éthiques, juridiques et technologiques pour une conception et une utilisation raisonnée de tels outils, cruciaux pour répondre aux défis de la gestion des collections.

Annexe A

Github des livrables techniques

Lien : <https://github.com/floflo-boop/Livable-technique>

Ce dépôt *Github* se constitue de deux documents PDF. Ce sont des documents produits dans le cadre du stage à propos de la création de la fonctionnalités de « recherche augmentée ». ²⁶³ L'objectif de ce dépôt est de montrer ce qui a été mis en place pour la fonctionnalité de « recherche avancée » bien que cela ne soit pas exhaustif.

Le premier document *specification.pdf* contient la spécification rédigée afin d'établir la fonctionnalités de la « recherche augmentée ». Elle explicite les attendus de la fonctionnalité et permet d'établir les règles et fonctions à mettre en place pour le parcours utilisateurs.

Loin d'être un document « technique » au sens qu'il ne développe pas de processus, ni de codes, son objectif est de contraindre le développement de la fonctionnalité par un raisonnement centré sur l'utilisation et l'adoption de l'outil par l'utilisateur. C'est donc un document de contrainte afin de réaliser les attentes utilisateurs dans une fonctionnalités, et non l'inverse.

Le second document *index.pdf* est un index ElasticSearch commenté pour être utilisé par la fonctionnalité de « recherche augmentée ». L'objectif est de montrer comment ce structure un index ElasticSearch et comment les exploiter pour cette fonctionnalité. Il faut garder en tête que chaque index doit être commenté de cette manière afin de faire fonctionner la « recherche augmentée ».

²⁶³Ces documents professionnels sont la propriétés de l'entreprise et ne peuvent être diffusé librement

Glossaire

agent conversationnel L’agent conversationnel n’est pas une technologies mais un outils. Ce mot fait référence à la forme que peut prendre un programme avec lequel interagir sur le principe de l’envoi d’une requête et d’une génération de réponse. En somme, on désigne l’interface par lequel on interagit avec le programme, qui peut être un chatbot ou un LLM, que le programme en lui même. Il y a cependant aujourd’hui une confusion claire dans le langage courant entre agent conversationnel et LLM.. 26, 41, 60, 61, 128, 146, 153, 154, 158

agent IA Contrairement à l’agent conversationnel, l’agent IA est un programme basé sur l’IA capable d’interagir avec son environnement informatique. Il est capable de prendre des décisions mais aussi d’utilisé des outils informatiques qui lui sont mis à disposition afin d’exécuter des tâches comme la manipulation de données.. 46–62, 153, 172

agent SQL Désigne un LLM, souvent sous forme d’un agent conversationnel, capable de comprendre, interagir et générer du code SQL et de bases SQL. Dans des processus de *Text-to-SQL*, il permet notamment de générer et vérifier la requête SQL générée avant de l’exécuter.. 54

Audio Large Language Model Sous typologie des modèles multimodaux, elle est spécialisée sur le traitement du texte et des bandes sons. Elle permet d’analyser, transcrire, décrire une bande son.. 102, 103, 105, 106, 140, 143, 147

auto-attention Méthode courante du NLP permettant à une IA d’évaluer l’importance de mots au sein d’une phrase. Cette méthode permet de dépasser le cadre grammatical afin de comprendre les relations conceptuels entre les mots et le contexte d’une phrase, permettant ainsi de déterminé quel mot est plus déterminant qu’un autre.. 96, 165

Big Data Phénomène d’augmentation quantitative importantes de la données dans tous les domaines à l’échelles mondiale à partir de 2010. On utilise se terme pour faire références aux nouvelles techniques de traitement de la données mis en place afin de répondre aux défis poser par ce phénomène. xviii, 9, 10

BNF Successeure de la Bibliothèque Royale, la Bibliothèque Nationale de France, ou BNF, est l'institution en charge de la collecte, l'archivage et la préservation de l'édition en France notamment à travers le dépôt légal dont elle est la seule responsable. Elle a également à charge une des plus grandes collections patrimoniale française. xviii, xix

champs Dans une base de données No-SQL, le champs est l'unité de bases du documents. Un champs c'est une clés, un intitulé, qui contient un ensemble de valeur concernant le document et qui ont toutes le même rôle, la même valeur sémantique. Un champs "dates" contiendra, par exemple, toutes les dates. Chaque documents possède plusieurs champs, en fonction des différentes données qu'il stocke. La particularité du champs dans une base de données No-SQL est qu'il est rattaché au document et non à la collection, ainsi plusieurs documents d'une même collections peuvent ne pas avoir exactement les mêmes champs.. 41, 70

chatbot Désigne tout d'abord une réalité technique : un programme informatique conçu sur un système de règles permettant de répondre à un utilisateur avec des réponses pré-définies. Se base sur les premières expérimentations de NLP, ne correspondant plus à la réalité technique actuelle. Aujourd'hui, ce terme voit un nouvel usage, plus large, puisque désignant tout programme, IA ou non, permettant d'interagir avec l'utilisateur par le texte. ²⁶⁴. i, 30, 46–63, 66–68, 107, 109, 113–130, 145–147, 153, 169, 172, 173

Chunking Procédé informatique fortement utilisé dans les différents domaines de l'IA, qui consiste à diviser une informations en unité plus petites afin de la stocker plus facilement et d'être plus précis notamment dans des processus de RAG.. 50, 51

CIDOC Le Comité international pour la documentation est un comité international représentant les musées à l'échelle mondiale. Ce comité se spécialise dans la rédaction et l'application de normes pour la gestion et description des collections des musées.²⁶⁵. xvii, 9

classification Dans le domaine de la *computer vision*, désigne la capacité d'une IA à analyser une image et de lui attribuer une étiquette agissant comme une identité globale. Elle rattache des images à des groupements déjà prédéfinis selon des caractéristiques prédéfinies également. De cette manière, un modèle peut faire la distinction entre une photo, une peinture et une gravure par exemple.. 21, 163

²⁶⁴Pour plus d'informations sur cette transition, consulter : ??

²⁶⁵Pour plus d'informations voir <https://cidoc.mini.icom.museum/>

CLIP Développé par Open-AI, il s'agit d'un modèles multimodaux capable de comprendre une image dans son sens global et de la décrire avec des mots. Ce modèles est aujourd'hui utilisé dans la plus part des VLM afin de faciliter le traitement des images et image animée.. 100

collections Propre aux bases de données No-SQL orienté documents, comme MongoDB, les collections sont un équivalents des tables SQL. On y stocke des documents, c'est à dire des données, de même nature sans schéma particuliers ce qui permet donc une grande souplesse et élasticité.. 36, 41

computer vision La *computer vision*, ou vision par ordinateur en français, est sous-domaine multidsicplinaire de l'IA, cela désigne la capacité d'analyse et d'interprétation des images donnée à un ordinateur ou système informatique.. xviii, xix, 18, 20–22, 84, 86, 92, 97, 99, 100, 142, 155, 156, 163, 171

coréférence Méthode de traitement propre au NLP permettant d'associer un mot, une entité, à toutes ses références au sein d'une phrase ou d'un texte entier.. 19

data definition language C'est un composant du langage SQL constituant à lui seul un langage à part entière. C'est part ce langage que l'on peut créer une base de données SQL ou en modifier sa structure par différentes opérations appelées CRUD pour *Create*, *Read*, *Update* et *Delete*. 14, 55–57

Deep Learning Branche du *machine learning*, il désigne à la fois un modèle d'architecture de réseaux neuronaux d'IA et une méthode d'entraîner les technologies basée sur cette architecture. Désigne tout outil d'IA reposant sur une architecture en couche successive de réseaux neuronnaux artificiels, conçu pour imiter le cerveau humain. Cette architecture est ensuite entraînée en autonomie, ou presque, sur de grandes quantités de données. De cette manière, ces outils se spécialisent et développent la capacité de traiter de nouvelles données.. xviii, 18–21, 47, 60, 81, 97, 102, 159

diarisation Processus informatique basé sur de l'IA consistant à pouvoir détecter au sein d'une image animée qui parle et quand. De cette manière, on peut associer un dialogue au bon personnage.²⁶⁶. 101, 103

détection d'objet Dans le domaine de la *computer vision*, désigne la capacité d'une IA de repérer et identifier un objet précis, pour lequel elle a été entraîné, au sein d'une image. On confonds souvent segmentation et détection d'objet. Contrairement à la

²⁶⁶Pour plus d'information, consulter : <https://sonix.ai/resources/fr/diarisation-des-locuteurs/>

segmentation, il ne s'agit pas de reconnaître tout les objets et toutes les entités au sein d'une image.. 21, 156, 163

ElasticSearch ElasticSearch est un logiciel appartenant à la famille des SRI. Il permet de stocker, analyser et redistribuer de la donnée textuelle sur de grands volumes de données grâce à son système d'index en document JSON . C'est une solution *open-source* et hautement scalable avec laquelle il est possible d'interagir par des APIs.. 15, 115, 117, 126, 127, 134, 138, 140, 142, 164

expression Niveaux WEMI qui désigne une réalisation concrète d'un concept exprimé au niveau œuvre. Sans avoir encore de forme physique très définies, ici on définit une forme intellectuelle qui incarne l'idée intellectuelle exprimée plus tôt.. 72, 76, 141, 159, 161, 166

fine-tuning Technique en IA qui consiste au réentraînement d'un modèle, comme un LLM, sur un nouveaux jeux de données. Cela afin de le spécialiser sur une tâche précise, pour laquelle il ne l'est pas à l'origine. En l'entraînant sur un nouveau jeu de données, le modèle réajuste ces paramètres afin de se spécialiser sur le jeux de données en question. Un *fine-tuning* trop poussé peut conduire à une sur-spécialisation du modèle, devenant efficace uniquement sur le jeux de données en question.. 94, 106, 122, 142, 157

FRBR Définis par l'IFLA en 1997, c'est un modèle conceptuel conçu pour améliorer la gestion des collections bibliographiques dans les bibliothèques. Cela s'inscrit dans le mouvement de transition numérique de la gestion des collections et insiste sur la création de liens entre les exemplaires. Il repose essentiellement sur une architecture précise : le WEMI. Depuis, ce modèle est adopté par de plus en plus d'institution notamment celles conservant des images animées.. 9, 72, 79, 80, 166, 172

function-calling Désigne la capacité accorder à un processus informatique de réutiliser un même bloc code afin d'effectuer une tâche définies, souvent répétitives. Dans l'IA, le *function-calling* amène aussi des notions de reconnaissance contextuelle et de prise de décisions de la part du modèle : il doit comprendre dans quel cas d'usage il est et appliqué le traitement approprié.. 126, 157

Fédération Internationale des Archives du Film Fondée en 1938, fédération à portée internationale qui a pour objectif de protéger et d'assurer la préservation de la culture cinématographique, et plus largement de l'image animée. Aujourd'hui, elle assume également un rôle de guide dans la standardisation et l'homogénéisation des pratiques dans la gestion des collections d'image animée.. 70, 75, 76, 78, 161, 166

grille de recherche Notion propre à l'application SkinSoft. La grille de recherche constitue un moyen simple d'afficher les données souhaitées des objets recherchés au sein de l'application. Hautement modifiable, l'utilisateur choisit quelle donnée il souhaite visualiser.. 78, 128, 157

Handwritten Text Recognition L'*Handwritten Text Recognition* est basé sur la même idée que l'OCR, la reconnaissance d'écriture manuscrite, ou HTR, applique le même principe à l'analyse des écritures manuscrites. On l'applique surtout aux documents anciens nécessitant des connaissances paléographiques.. xix, 21, 39

histogramme La définition accordée à ce terme ici est celle de l'histogramme d'une bande vidéo. Désigne le graphique destiné à représenter la distribution de la lumière, de l'ombre et des tons au sein d'une image notamment une image animée. Permet d'analyser la composition lumineuse d'une image.. 91

IFLA La Fédération internationale des associations et institutions de bibliothèques est une organisation internationale représentant les bibliothèques mondiale. Cette organisation se charge de défendre les intérêts de ces institutions et de développer la gestion des collections de bibliothèques de manière commune.²⁶⁷. xvii, 9, 72, 157

image animée ce terme désigne tout objet constitué par une suite d'images capturées par différents procédés et dont la diffusion à la chaîne crée du mouvement. Par image animée, on désigne bien souvent les documents audiovisuels comme les films, les séries, les documentaires, vidéos que ce soit amateur ou professionnel. i, xvi, xviii, xx, 9, 13, 20, 21, 69–110, 131, 132, 137, 139, 142, 143, 145, 147, 155–157, 160, 162–164, 166, 169, 172, 173

inaliénable En terme juridique, cela désigne ce qui ne peut être retiré, altéré ni même vendu ou donné. Un droit inaliénable est un droit qui ne peut être modifié. xvi

Information Retrieval System Logiciels spécialisés sur la recherche d'information dans des données non structurées. Le plus souvent, ces logiciels sont connectés à une base de données afin de stocker les données dans un index permettant de faciliter l'interrogation de volumes de données massifs. Ils fonctionnent comme un intermédiaire entre l'utilisateur et la base de données : il se charge de l'analyse des données, de les découper en segments qu'il répartit ensuite dans des nœuds qu'il indexe.. 15, 36, 38–41, 46, 47, 49, 52, 58, 81, 113–116, 156, 164

²⁶⁷Pour plus d'informations voir <https://www.ifla.org/>

intelligence artificielle Ensemble vaste de technologies et procédés informatiques et d'ingénierie qui visent à permettre à l'ordinateur d'effectuer des tâches assimilés à l'intelligence humaines. Ses origines remontent aux travaux de John McCarthy en 1956 et qui voit ses premières expériences concluantes apparaître dans les années 1990. xviii–xx, 11, 16–33, 35, 40, 46, 47, 51–53, 55, 58–61, 66, 67, 69, 80–85, 87, 89, 92, 95, 96, 98, 100–103, 106, 108, 109, 113, 119, 121, 123, 126, 129, 135, 142, 143, 146–148, 153–166, 171, 172

intelligence artificielle générative Typologie de modèle d'IA, généralement des LLM, capable de générer, à partir d'une requête, du texte, des images, des vidéos ou du sons. Ils ne se contentent pas d'analyser des données, mais de générer quelques choses qu'on lui a demandé à partir de ces analyses. Ces modèles sont aujourd'hui extrêmement répandus et utilisé dans plein de domaine. Les agent conversationnel publics comme ChatGPT, Mistral et Claude sont des intelligences artificielles génératives. 18, 19, 127, 147, 158

interopérabilité des données Désigne la capacité à rendre les données d'un systèmes compréhensibles, utilisable et échangeable avec un autre système sans intervention humaine. Cela repose sur des normes et standards permettant de structurer les données de manière uniforme.. 6, 8, 10, 106

inviolable En terme juridique, désigne un caractère protégé qu'on ne peut enfreindre. Un droit inviolable ne peut être enfrein et si il est associé à un objet, cela rend ce dernier également inviolable. . xvi

item Niveaux WEMI le plus petit, il désigne l'exemplaire physique que l'on conserve au sein d'une institution ou que l'on détient. Il a des caractéristiques propres à sa vie en tant qu'objet indépendant du reste de son WEMI.. 72, 73, 80, 138, 141, 161, 166

Large Language Model Souvent abrégé par LLM, les *Large Language Model*, ou grand modèles de langues en français, sont des intelligences artificielles basée sur des transformers. Ils sont spécialisés dans la compréhension de requête, l'analyse de données textuelles, le raisonnement et la génération de réponse. Pour cela, elles sont entraînées sur de très grandes quantités de données par *Deep Learning* afin de leurs conférer ces capacités. Ces IA sont concentrées autour de l'alliance entre les technologies regroupées et développées au sein du NLP afin de pouvoir effectuer de tel traitement.. 19, 22, 23, 25, 47, 48, 51, 53–56, 60, 61, 83, 94, 98–100, 102–104, 115, 116, 119, 120, 122, 123, 126, 127, 129, 135, 140, 147, 153, 154, 156, 158, 160, 162, 164

lemmatiser Procédé appliqué dans le domaine du NLP, il désigne le fait ramener un mot conjugués, accorder ou décliner à son état de base que l'on appelle le lemme. Un verbe conjuguer sera ainsi ramené à son infinitif par exemple. On l'utilise afin d'épurer le texte et d'en faciliter sa « compréhension » sémantique. 20, 47, 48

machine learning Domaine d'étude de l'intelligence artificielle qui vise à permettre à un système informatique basé, généralement, sur des réseaux de neurones artificielles d'apprendre. Ce domaine se consacre à développer de nouvelles manières de conférer à l'intelligence artificielle des moyens d'apprendre de différentes manières.. xviii, 18, 153, 156

manifestation Niveaux WEMI qui désigne toute forme concrète prise par expression. Une manifestation correspond à une matérialité bien définie, que l'on peut dater au moins sur une période de production, obéissant à des critères strictes tels que la durée, le nombre de pages, le lieu de production, la maison d'éditions, le réalisateur, etc.. 72, 73, 78, 80, 141, 161, 166

modèle Désigne tout programme informatique basée sur de l'IA afin d'apprendre et réaliser des tâches, des prédictions ou bien des décisions à partir de données issues d'une requête. Le modèle constitue l'outil de base en ingénierie d'IA.. 25, 30, 119, 143, 155, 157, 159, 161, 166

modèles multimodaux Modèles d'IA permettant d'associer plusieurs domaines de traitement au sein d'un même outil afin de traiter plusieurs types de données. Ils associent généralement un LLM à un encodeur dédié à un autre type de données. Ils permettent notamment d'analyser des vidéos ou des sons et de générer à partir de là, le plus fréquemment, des analyses textuelles.. 25, 83, 86, 102, 103, 139, 143, 154, 155, 160, 173

multimodalité native Dans l'IA, désigne un système conçu pour traiter tout type de données en entrée et créer tout type de donnée en sortie. Plus précisément, ce système doit être capable de traiter des données vidéos, sonores et textuelles en même temps, de la même manière et en conservant les liens les unissant si tel est le cas afin d'améliorer sa capacité d'analyse et de compréhension. Ce principe souhaite révolutionner les modèles multimodaux actuels, ne prenant en charge qu'un seul type de données en entrée et en sortie. Cela pourrait révolutionner la compréhension de documents composites et complexes comme les images animées. 103, 160

mémoire vidéo Liée au processeur graphique, c'est à dire que ces derniers en déterminent la quantité et disponibilité, elle définit la puissance de calcul dédiées aux traitements

des images, vidéos et objets 3D disponibles. Plus il y a de mémoire vidéo, plus le nombre de calcul réalisable dans court délais appliqué à des images, vidéos et objet 3D augmente. Elle peut aussi être utilisée pour traiters d'autres catégories données, bien que ce ne soit pas son utilisation première et privilégiée.. 27, 119, 120

mémoire vive Composant informatique qui définis la puissance de calcul et la rapidité de leurs exécution. Plus elle est importantes, plus il sera possible de réaliser un grand nombre de calcul plus rapidement et donc de traiter plus de données.. 27, 123, 140, 162

Name Entity Recognition Technologie d'IA composant une partie du sous-domaine des technologies d'intelligence artificielle : le NLP. Le *Name Entity Recognition*, ou NER, est la capacité de reconnaître une chaîne de caractère signifiante comme un nom de personne, de lieux, de marque, d'événements ou encore les dates. . 19, 47, 48

native multimodal modeling Désigne les modèles d'IA correspondants aux principes de multimodalité native. Ils couvrent des modalités et typologies de modèles différentes, obéissant aux mêmes grandes logiques de traitement tout en divergeant un peu les uns des autres. ²⁶⁸. 103–106, 173

Natural Language Processing Le *Natural Language Processing*, ou traitement automatique du langage naturel, est un sous-domaine multidisciplinaire de l'intelligence artificielle, faisant notamment appelle à l'ingénierie informatique et la linguistique, baser sur l'utilisation du *machine learning* pour conférer à un système informatique la capacité d'analyser, comprendre et communiquer dans ce que l'on appelle le langage naturel ou langage courant.. xviii–xx, 18, 19, 21, 35, 41, 44, 46–50, 52, 59, 68, 100, 107, 115, 116, 120, 154, 155, 159–161, 165, 171

NoSQL Acronyme de *Not Only SQL*, désigne un ensemble de base de données, de typologies variées, ne fonctionnant pas sur un système de table comme le SQL. Ces bases de données ont leurs propres manière de structurer la données, de manière beaucoup plus souple puis que variable, et ont leurs propres manière d'interroger les données stockées. Les différentes typologies sont : les bases clés-valeurs comme Redis, les bases orientés documents comme MongoDB, les bases orientées colonnes comme Cassandra et les bases orientées graphes comme Neo4j.. 15, 52, 56, 57, 115, 116, 161, 164

œuvre Niveaux WEMI le plus haut, il désigne une idée artistique et intellectuelle que l'on réalise par la suite dans une expression, une manifestation et un item qui est le témoins

²⁶⁸Pour plus d'information, voir : 85 et (S. An, J. Lu, J. Dong, *et al.*, *Toward Native Multimodal Modeling...*)

de sa production. C'est le niveau le plus conceptuel, qui, en dehors du modèle adopté par la FIAF, n'a pas de matérialité physique.. 72, 73, 75, 76, 78–80, 87, 91, 132, 135, 140–143, 156, 166, 169

open-source Désigne un mouvement informatique de mise à disposition du public le code informatique d'un logiciel. Cela permet donc de récupérer ces logiciels ou modèle d'IA, de les modifier et de les utiliser au sein de *pipelines* ou d'autre logiciel. Ce mouvement s'oppose aux logiciels dit propriétaire, gardant le code logiciel secret et ne permettant pas de le modifier. Cependant, *open-source* ne signifie pas gratuité et liberté absolue. Les logiciels appartenants à ce mouvement sont encadrés par des licences, réglementant leurs usages et distributions et peuvent être payants.. 25, 27, 97, 100, 101, 105, 119, 131, 156, 161

opinion mining Méthode de traitement propre au NLP avec pour objectif d'identifier, extraire et analyser les sentiments, émotions et prises de positions exprimées au sein d'un texte. Permet l'analyse de texte dans le contenu intellectuel, notamment sollicité dans l'analyse de discours.. 20

Optical Character Recognition *l'optical character recognition* créé par l'ingénieur Autrichien Gustave Tauschek, ou reconnaissance optique de caractère en français, désigne la capacité conféré à un système informatique de reconnaître des mots typographiés. Le premier système à pouvoir le faire est la machine Gismo inventé en 1951 par David Shepard.. 21, 39, 97

Part of Speech Technologie d'IA composant une partie du sous-domaine des technologies d'intelligence artificielle : le NLP. Le *Part of Speecg*, ou POS, c'est l'anlyse grammaticale d'une phrase qui aboutit à l'étiquetage du rôle de chaque mot dans une phrase. Chaque mot est analysé au sein de la phrase, son contexte, et est catégorisé dans l'une des classes grammaticales. La décomposition grammaticale permet ainsi d'en faire sortie le sens. 20, 47, 48

pipeline d'agrégation Spécifique au langage NoSQL, notamment le système MongoDB, désigne les étapes successives de traitement effectués sur les données afin de retourner à l'utilisateur les bonnes données. Il peut s'agir de calculs, de filtres ou bien de modification afin d'homogéniser le traitement et le résultat.. 52, 56, 164

plan Dans le milieu de l'image animée, désigne une prise de vue simple, qui peut être fixe ou en mouvement, faisant figurer des personnes et/ou des lieux et des actions. Elle se compose de plusieurs images, et peuvent être plus ou moins courts en fonction des choix

de réalisation. C'est l'unité la plus petites d'une image animée. Chaque changement d'angle entraînant une nouvelle prise de vue amène un nouveau plan.. 76, 89–93, 99, 133–135, 138–141, 163, 172

processeur Composant informatique agissant comme le centre de calcul de l'ordinateur. Il est chargé de réaliser tous les calculs nécessaires afin de lancer les applications, exécuter du code ou encore mobiliser des ressources comme la mémoire vive de manière intelligente pour des besoins précis. Il se compose de plusieurs caractéristiques essentielles : les cœurs, qui sont des composants physiques permettant de paralléliser les tâches, les threads, composants virtuels permettant la même chose, et la fréquence qui détermine la vitesse d'exécutions des calculs. . 27, 100, 105

processeur graphique Composant informatique spécialisé sur le traitement des images et dédiés aux calculs à effectuer de les afficher.. 27, 96, 100, 103, 105, 160

Re-Ranking Procédé informatique s'appuyant sur une IA généralement placée à la fin d'un processus de type RAG. Il permet de réévaluer et réorganiser les résultats obtenus à l'issue du traitement avant transmission à l'utilisateur afin de s'assurer de leurs pertinences.. 51

Retrieval Augmented Generation Ici nous parlons d'une manière d'utiliser l'IA parce que l'on appelle un *pipeline* ici appelé RAG. Il consiste à consolider la base de connaissance d'un LLM en le connectant à une source de données contrôlées sur laquelle se baser pour la génération de réponses suite à une requête. Il fonctionne en 3 étapes : l'étape de *retrieval* qui consiste en la recherche des données pertinentes afin de répondre à la question utilisateur. L'étape de l'*augmented* qui consiste à enrichir la réponse générées en faisant référence directement aux sources utilisées et identifiées lors de l'étape précédente. Puis l'étape de *génération* qui consiste en la rédaction d'une réponse prenant pour contexte la requête utilisateur.²⁶⁹. 18, 22, 23, 47–49, 51, 54, 58, 61, 62, 115, 117, 119, 126, 147, 155, 162, 164, 171

RGPD . 146

rush Dans le milieu de l'image animée, désigne les plans qui sont enregistrés au moment de leurs prises de vues. Les *rush* sont par définition bruts, sans modification effectuées en post production.. 70

²⁶⁹Pour plus d'informations sur ce procédé, consulter (B. Tuza, *Interroger la mémoire d'entreprise par l'IA...*)

réseau de neurones convectifs C'est un type de réseaux de neurones créer pour l'analyse d'image et de vidéos. Chaque couche de réseaux de neurones applique un traitement particulier à l'image ou à la bande vidéo traitée. Chaque couche est dédiée à un traitement, qui s'effectuent de manière successive. Nous avons généralement trois couches : la couche dite de « convolution » qui déconstruit l'image en zone et en extrait des motifs simples d'abord et complexes ensuite. La couche de regroupement qui sert à compresser les données afin d'accélérer et simplifier le traitement. La couche de connexion qui détermine le résultat final. Ces modèles permettent de faire de la classification, de la segmentation et de la détection d'objet.. 18, 21, 96, 98, 102, 165

scène Dans le milieu de l'image animée, désigne l'unité la plus importante, notamment, d'un film. Une scène est définis comme un ensemble de plan faisant figurer les mêmes personnages, dans les mêmes lieux, autours des mêmes actions et sujets. Notion surtout utilisée dans le domaine cinématographique, mais également applicable à toute image animée. 76, 84–87, 89, 91–96, 99, 101, 102, 132–135, 138–141, 143, 164

segmentation Dans le domaine de la *computer vision* désigne la capacité d'une IA de diviser l'image en fonctions des objets et entités qu'elle y trouve. Sans les identifier précisément, la segmentation permet d'isoler les objets et entités présentent les unes des autres et donc de resituer la composition d'une image.. 21, 90, 92, 94, 139, 156, 163, 172

système de gestion des collections Logiciels particulièrement utilisé dans le monde patrimonial permettant de gérer des collections d'objets patrimoniaux de manière informatiques. Ces fonctions principales sont : le catalogage, le suivis, la gestion de l'inventaire et la description des collections numériques et physiques. Ce sont des logiciels aujourd'hui très complexes et complets se comportant que de véritable outils de gestion et de prise de décision stratégique sur la gestion des collections patrimoniales. Ils constituent le cœur des processus de traitement des collections patrimoniales et sont au centre des pratiques et enjeux métiers. Pour plus d'informations, voir *Chapitre I. « Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes »* page 3. xvii, xix, xx, 3–8, 10–12, 16, 24, 26, 28, 30, 33, 35, 36, 40, 42–46, 58, 59, 61, 62, 64, 65, 67, 80, 81, 107, 108, 113, 114, 116, 124, 129, 131, 142, 145–148, 165, 171, 172

séquence Dans le milieu de l'image animée, désigne un regroupement de scène dans une unité de temps basée sur le partage d'une thématique commune, de sujet commun et contribuant à l'avancer d'un même point d'une intrigue. Notion surtout utilisée dans le

domaine cinématographique, appartenant à la structure basique d'un film.. 76, 84–87, 89, 91–94, 99, 132, 133, 135, 138, 141

table La table constitue la structure de base d'une base de données SQL. Constituée de colonne et de ligne, elles permet de contenir des ensemble de données structurées. On parle d'enregistrement pour la donnée située sur la ligne, et d'attribus pour les colonnes. Dans l'application SkinSoft, une table correspond à une unité thématiques de stockage de données. On parle par exemple de la « table des archives », car c'est dans cette partie de l'applicaïton que nous stockons les objets de collections que sont les archives. Ces tables sont rattachées à des index ElasticSearch, c'est à dire une struture de données particulières dédiée à l'objet concernés par la table.. 13–15, 76, 78, 115, 117, 120, 122, 138

Text-to-ElasticSearch Processus similaire aux *Text-to-SQL* et *Text-to-NoSQL* qui permet d'associer des outils d'IA à ElasticSearch afin d'améliorer le système de recherche de ce dernier. Approche encore expérimentale, elle hybride les processus innovants *Text-to-SQL* à la sécurité et robustesse de logiciel largement implémenter que sont les SRI. 115, 116, 169

Text-to-NoSQL Adaptation du procédé *Text-to-SQL* aux particularité du langage et des bases de données NoSQL. Encore en développement, l'objectif et de permettre de conférer à un LLM la capacité de comprendre et d'interagir avec une base de données NoSQL et ses particularités comme les pipelines d'agrégation et la semi-structuration du langage. Il se base lui aussi sur un RAG.. 15, 52, 53, 56–58, 114–116, 164, 172

Text-to-SQL Procédé informatique basé sur l'IA, le RAG et la recherche intelligente. Il consiste faciliter l'interrogation d'une base de données SQL par l'utilisateur à travers l'usage d'un LLM. Il fonctionne en deux temps : d'abord la phase de compréhension de la base de données, permettant de construire le RAG puis la phase de requêtage. L'idée générale est d'augmenter l'interrogeabilité de la base de données par la compréhension de la base de données et des requêtes lui étant adressé notamment grâce aux vecteur.²⁷⁰ 15, 52–58, 113, 114, 116, 154, 164, 169, 172

thésaurus Les thésaurus sont des hiérarchies de terme représentant des concepts rattachés à des domaines. De cette manière, ils constituent des listes de vocabulaires contrôlés fixant ainsi la terminologie utilisable pour décrire certains domaine. Particulièrement utilisé dans le monde patrimonial et les système de gestion des collections afin fixer la terminologie utilisée dans l'indexation.. 9, 13, 69, 82, 83

²⁷⁰Pour plus d'informations, voir (*Text-to-SQL...*)

token En informatique, le *token* désigne une unité de stockage destiné à contenir une information de taille variable. En IA, on s'en sert notamment afin de contenir des mots ou des morceaux de mots et de phrases. Ils désignent ainsi aussi bien ce qui est envoyé par l'utilisateur lors d'une requête que ce qui est généré par l'IA.. 47, 51, 100, 119, 165

transformers Désigne une architecture neuronale développée par Google en 2017 et mise très tôt en application dans le domaine du NLP²⁷¹. Ce modèle permet ce que l'on appelle l'auto-attention afin de saisir le sens global d'une phrase, d'un texte, et permet la parallélisation des tâches ce qui accélère le traitement et les tâches d'apprentissage. Il vient remplacer les modèles basés sur CNN dans le domaine du NLP par son net avantage technologique permettant de fiabiliser les résultats.. 18, 19, 47, 96, 101, 102, 159

UNESCO L'Organisation des Nations unies pour l'éducation, la science et la culture est une organisation internationale créée en 1945 qui a pour but de promouvoir la coopération internationale autour des champs de l'éducation, de la culture, de la science et de la communication. Ces missions sont plurielles, mais elle est très largement connue pour ses initiatives sur le patrimoine : reconnaissance du patrimoine immatériel en 2003 et la construction d'un patrimoine mondial commencé en 1972.. xvii

User Experience Design Domaine dans la conception de logiciel informatique visant à rendre l'usage de l'application intuitif, facile et accessible pour tout humain. Ce domaine définit un ensemble de règles et de méthodes à utiliser pour remettre l'humain au centre du logiciel. 42, 44, 58, 59, 62–68, 107, 109, 116, 124, 128, 129, 140, 141, 147, 148, 172

User Interface Design Domaine dans la conception de logiciel informatique visant à rendre l'interface générale de l'application simple et attrayante afin d'en simplifier l'usage applicatif par un humain. Cela s'accompagne d'un ensemble de règles et de méthodes évolutives afin de créer des interfaces utilisables.. 42, 44, 58, 59, 62–68, 107, 109, 116, 124, 128, 129, 140, 141, 147, 148, 172

vandalisme Inventé par l'abbé Grégoire en 1792²⁷² à l'occasion de son étude sur l'impact révolutionnaire sur les biens culturels français, il a assez peu changé depuis. Le vandalisme se définit comme tout acte de destruction ou de dégradation volontaire d'œuvres d'arts, de monuments ou de matériel. xvi

²⁷¹J. Devlin, M.W. Chang, K. Lee, *et al.*, *BERT*...

²⁷²G. Sprigath, « Sur le vandalisme révolutionnaire (1792-1794) »...

variante Notion propre au monde de l'image animée qui désigne une version divergente d'une œuvre originale sans constituer une œuvre à part entière. Introduit par la FIAF dans le WEMI, il permet de conscrire les modifications que peut vivre une œuvre cinématographique durant son cycle de vie qui viennent en modifier la structure ou le contenu sans que cela soit drastique.. 75, 76, 78, 79

vecteur Issus d'une vectorisation, le vecteur est une suite décimale unique calculés à partir des caractéristiques uniques d'une données. Ils peuvent être plus ou moins complexes et donc éviter des confusions. Ces vecteurs calculés sont ensuite stockés dans une base de données vectorielles permettant la comparaison des vecteurs.. 47–50, 52, 57, 59, 87, 88, 90, 91, 100, 102, 119, 120, 122, 126, 133–135, 138–140, 164

vectorisation Méthode informatique de calcul et d'attribution d'un identifiant informatique unique à une données en fonction de certains facteurs clés. C'est à dire qu'en amont du processus nous allons lui donner une données, comme un mot, et en sortie nous allons obtenir un identifiant unique sous forme de suite décimales. De cette manière, nous évitons toutes confusion entre des données similaires mais non identiques.. 19, 47–50, 52, 86, 119, 120, 122, 129, 133, 135, 139

Vision Language Model Modèles d'intelligence artificielle avec des capacité multimodales. C'est à dire que ce modèle n'est plus limité à un champs d'action : il est capable de traiter l'image comme le texte en autonomie.. xviii, 96, 99, 100, 103, 105, 106, 138–140, 143, 147, 155, 173

WEMI Fondement du modèle FRBR, il s'agit d'un découpage en 4 entités d'une œuvre artistique y compris littéraire. On y distingue le œuvre, *Work*, qui désigne le concept. L'expression qui caractérise une réalisation de ce concept sous une forme définie comme une pièce de théâtre, ou un film. La manifestation qui désigne toute production découlant de l'expression. Puis l'item qui désigne l'exemplaire que l'on conserve. Cette desconstruction en 4 entités permet de créer plus de liens au sein des catalogues et donc des recherches transversales.. 9, 72, 74, 76, 78–80, 108, 109, 131, 132, 135, 136, 138, 141, 156, 157, 159, 161, 166, 172

zero-shot En IA désigne la capacité d'un modèle à reconnaître et traiter un objet ou une données sur laquelle il n'a pas été entraîné dès la première tentative. Pour cela, le modèle mobilise toutes ces connaissances afin de déterminer une méthode de traitement adapté, la mettre en place et la sauvegardé pour des traitements futurs.. 96, 119

Table des figures

1	Schéma du fonctionnement d'ElasticSearch	32
2	Phase d'analyse de la recherche intelligente.	40
3	Phase dite « active » de la recherche intelligente.	41
4	Fonctionnement global de la recherche intelligente.	42
5	Schéma d'un pipeline <i>Text-to-SQL</i> . Source : <i>Comment obtenir du code SQL de qualité avec l'IA : décryptage des techniques de Text-to-SQL</i> / Blog Google Cloud, Blog Google Cloud	45
6	Schéma d'un WEMI fictif d'une œuvre.	59
7	Schéma de fonctionnement des liens dans un WEMI. Source : https://mediadix.parisnanterre.fr/medias/fichier/catalogage-isbd-unimarc-approports-theorique-maj-2025_1736242651118-pdf	60
8	Schéma du modèle WEMI implanté dans la solution S-Movies. Source : FAIRBAIRN (Natasha), PIMPINELLI (Maria Assunta), ROSS (Thelma) et THILL (Viviane), « Le Manuel de catalogage des images animées de la FIAF » ()	62
9	Schéma de fonctionnement de la solution vitrivr. Source : site officiel vitrivr à l'URL https://vitrivr.org/vitrivr.html	70
10	Schéma d'un <i>pipeline Text-to-ElasticSearch</i>	97
11	Schéma du processus de « recherche augmentée ».	100
12	Schéma du processus de chatbot.	107
13	Schéma du processus d'indexation semi-automatisée.	115
14	Schéma du processus d'intégration des données générées par le traitement des images animées.	118

Table des matières

Résumé	i
Remerciements	iii
Introduction	xv
I La gestion numérique de collections composites dans le monde patrimonial et le secteur privé.	1
1 Système de gestion de collection et suite SkinSoft	3
I. Qu'est ce qu'un système de gestion de collections à l'heure des collections doublement hétérogènes	3
II. Défis et difficultés que doit relever un système de gestion des collections aujourd'hui : Bigdata et harmonisation des données	7
1. La métadonnée dans le monde patrimonial	7
2. La place des systèmes de gestion des collections	9
III. Présentation de la solution SkinSoft	10
1. Principe de la solution SkinSoft	10
2. Composition techniques	12
3. Limites et défis	13
2 L'intelligence artificielle dans la gestion des collections	15
I. Réalités de l'IA dans le domaine patrimonial	15
1. Le <i>Natural Language Processing</i> : définition	16
2. Définition de la <i>computer vision</i>	18
3. le RAG : définition	19
4. Apports des outils et état des lieux de leur application dans la gestion des collections	20

II.	Les enjeux techniques :	22
III.	Le cadre juridique :	26
1.	Cadre juridique du patrimoine et des données patrimoniales	26
2.	Contraintes juridiques de l'IA	27

II Implémenter l'intelligence artificielle dans un système de gestion des collections : étude de cas SkinSoft. 29

3 Le traitement du langage naturel : faciliter l'usage et fiabiliser la recherche 31

I.	La recherche et l'utilisation de la solution dans le logiciel SkinSoft	31
II.	Recherche augmentée et chatbot/agent IA : état de l'art.	39
1.	La « recherche augmentée » :	39
a.	La recherche intelligente	39
b.	Les processus <i>Text-to-SQL</i> et <i>Text-to-NoSQL</i>	43
2.	Le « chatbot »	48
III.	Enjeux utilisateurs	51
1.	<i>User Experience Design</i> et <i>User Interface Design</i> dans les systèmes de gestion des collections	52
2.	Les outils d'IA	53
3.	IA et système de gestion des collections : des attentes <i>User Experience Design</i> et <i>User Interface Design</i> particulières	53
4.	Conclusion	54

4 Traitement et indexation de l'image animée 55

I.	Dans le logiciel Skinsoft	55
1.	Définition de l'indexation et de l'image animée	55
2.	Le FRBR et le WEMI	57
3.	La gestion de l'image animée dans l'application SkinSoft	61
4.	Complexité et limite de l'indexation des images animées	64
II.	Outils et réalité technique	65
1.	Manipulation de l'image et des plans	71
2.	Segmentation d'une image animée	74
3.	La compréhension des sous-titres	76
4.	La reconnaissance de lieux et de personnes	76
5.	Les VLM	81
6.	Le traitement des pistes audios	82

7.	Vers une révolution des modèles multimodaux : les <i>native multimodal modeling</i> ?	85
8.	Conclusion	87
III.	Enjeux utilisateurs	89
III	Solutions élaborées et résultats obtenus	93
5	Recherche Augmentée et chatbot : conception technique, conception utilisateur et résultat.	95
1.	La recherche augmentée :	96
a.	Conception de l'outil	96
b.	Choix des composants techniques	100
c.	Conception du parcours utilisateur final	102
d.	Analyse réflexive	104
2.	Le chatbot :	106
a.	Conception de l'outil	106
b.	Proposition technique	107
c.	Proposition de parcours utilisateurs	109
d.	Perspective d'avenir	110
6	Indexation semi-automatique : conception technique, conception utilisateur et résultat.	113
1.	Conception de l'outil	114
2.	Proposition de conception technique	119
3.	Proposition de conception du parcours utilisateurs	121
4.	Apports et limites	123
7	Impact potentiel des outils sur les données et collections patrimoniales	125
1.	La recherche augmentée	126
2.	Le chatbot	126
3.	L'indexation semi-automatisée des images animées	127
4.	Conclusion	128
	Conclusion	134
	A Github des livrables techniques	135
	Glossaire	137